

Ingeniería en la cadena de suministro



Notas de clase

Segunda edición

Juan Esteban Salamanca

2026

Notas hechas por estudiante de pregrado

Trabajo en proceso. Puede contener errores, omisiones o imprecisiones.

Índice general

Prefacio	11
1. Modelos de control de inventario	13
1.1. Modelos con demanda determinística y estática	13
1.1.1. Modelo EOQ	14
1.1.2. Modelo EPL	34
1.2. MRP y modelos con demanda determinística y dinámica	46
1.2.1. Heurística Lote a Lote	48
1.2.2. Heurística POQ	52
1.2.3. Heurística EOQ	56
1.2.4. Heurística PPB	60
1.2.5. Heurística Silver Meal	61
1.3. Modelos con demanda estocástica	63
1.3.1. Modelo de vendedor de diarios	63
1.3.2. Modelo Q-R	75
1.3.3. Modelo S-T	83
2. JRP - Reaprovisionamiento Conjunto	89
2.1. Reaprovisionamiento sin coordinar	91
2.2. Reaprovisionamiento conjunto $m_j = 1$	93
2.3. Reaprovisionamiento conjunto $m_j \geq 1$	100
3. Coordinación de inventarios	107
3.1. Caso 1-1	107
3.2. Caso 1-n	122
3.3. Ejemplos de ejercicios anidados	124
3.3.1. Caso 1-1-n con énfasis en 1-1	124

3.3.2.	Caso 1–1–n con énfasis en 1–n	127
3.3.3.	Caso 1-n-1	129
4.	Modo de transporte	131
5.	Ruta más corta	139
5.1.	Algoritmo Dijkstra	139
5.1.1.	Networkx	143
5.1.2.	Implementación con código	144
6.	Ruteo	147
6.1.	Barrido geométrico	147
6.2.	Vecino más cercano	149
6.3.	Heurística de inserción	150
6.4.	Clarke & Wright	151
6.5.	PyVRP	155
6.5.1.	Motivación: ruteo de vehículos en cadena de suministro	155
6.5.2.	Preparación de datos para PyVRP	155
6.5.3.	La arquitectura de PyVRP	162
6.5.4.	Casos de aplicación	170
7.	Localización	179
7.1.	Medidas de distancia en problemas de localización	179
7.1.1.	Distancia rectilínea o Manhattan	180
7.1.2.	Distancia euclidiana	180
7.1.3.	Distancia euclidiana al cuadrado	181
7.1.4.	Comparación de medidas	181
7.2.	Método alternativo: mediana ponderada	182
7.3.	Método de gravedad	184
7.4.	Algoritmo de Weiszfeld	186
8.	Diseño de ruta	189
8.1.	Algoritmo ADD	189
8.2.	Algoritmo DROP	193
8.3.	Formulación básica de diseño de red	196

A. Demostraciones Cap 1	205
A.1. EOQ y EPL	205
A.2. Algoritmo iterativo (Q, R) con backorders	208
A.2.1. Óptimos de modelo cuando no tenemos β	210
A.3. Modelo (Q, R) iterativo dado un valor de β bajo normalidad	212

Índice de algoritmos

1.	Dijkstra con restricciones y atributos acumulables	142
2.	Clarke & Wright con ahorros	153
3.	Heurística ADD con matriz de costos	191
4.	Heurística DROP con matriz de costos	195

Prefacio

Estas notas corresponden a una segunda edición de un documento de apoyo para estudiar temas de Ingeniería en la Cadena de Suministro. Se basan en versiones anteriores del curso, materiales afines y ejercicios contruidos para practicar conceptos tradicionales de logística, inventarios, ruteo, localización y diseño de red. No constituyen material oficial del curso, no están afiliadas formalmente a la coordinación de la materia y no garantizan la cobertura exacta del syllabus vigente. Por tanto, pueden existir temas omitidos, cambios de enfoque o diferencias frente al material oficial usado en clase.

Cambios en esta segunda edición. Esta edición reorganiza y corrige partes de la primera versión, amplía algunas explicaciones de inventarios, JRP y coordinación, e incorpora nuevos desarrollos en ruteo computacional con `PyVRP`, localización de instalaciones, medidas de distancia, métodos de mediana ponderada, gravedad y Weiszfeld. También se añade una introducción a modelos de diseño de red mediante programación lineal entera mixta, incluyendo ejemplos implementados en Python.

Convenciones. A lo largo del texto se procura mantener consistencia de unidades: demandas como tasa (unds/tiempo), costos de mantener inventario como $\$/(\text{und} \cdot \text{tiempo})$ y costos fijos por pedido como $\$/\text{pedido}$. Cuando se presentan algoritmos, tablas de iteración, archivos de Excel o notebooks de Python, se busca explicar no solo el resultado, sino también la lógica de construcción de los datos y de la solución.

Sobre las soluciones. Las soluciones incluidas están pensadas para los ejercicios específicos que se construyen en estas notas. No deben tomarse como plantillas universales para resolver cualquier ejercicio nuevo. En muchos modelos, una fórmula puede cambiar si cambian los supuestos, las unidades, la estructura de costos, la distribución de demanda, la política de inventario o las restricciones operativas. Por eso, antes de reutilizar una fórmula, se recomienda verificar que el nuevo problema cumpla las mismas condiciones del ejercicio tratado.

Errores y mejoras. Aunque esta segunda edición intenta corregir errores de la versión anterior y mejorar la claridad de varias secciones, todavía pueden existir erratas, inconsistencias de notación, errores conceptuales o imprecisiones en algunos ejercicios. Este documento debe leerse como un trabajo en proceso. Si el lector identifica algún error, se

recomienda anotar y reportarlo mediante el siguiente formulario: [Google Form](#). La idea es que estas notas sigan funcionando como un documento vivo que mejore con el tiempo.

Estructura y enfoque. El objetivo de estas notas es ofrecer una guía práctica y razonablemente rigurosa para estudiar y resolver ejercicios. En los temas donde resulte útil, se incluye una justificación matemática mínima para entender de dónde salen las fórmulas, cuándo se puede derivar e igualar a cero, cuándo existe una solución cerrada y cuándo conviene recurrir a heurísticas, aproximaciones o solvers computacionales. Estas explicaciones no reemplazan el material oficial del curso; buscan complementar el estudio y ayudar al lector a interpretar mejor los métodos.

Alcance de los ejemplos. En esta edición se intenta reunir varios de los casos más amplios y representativos que podrían aparecer en el estudio de la materia. Sin embargo, los ejercicios reales pueden formularse de maneras distintas, combinar supuestos no tratados aquí o requerir estrategias de solución diferentes. Por tanto, estas notas deben entenderse como una guía de estudio y práctica, no como una garantía de cobertura de parciales. Lo que finalmente se evalúe dependerá exclusivamente del enfoque definido por el equipo docente del curso.

Estado del documento

Esta es la **segunda edición** de las notas. El documento fue compilado por última vez el **6 de junio de 2026**. Puede existir una versión más reciente con correcciones, nuevos ejemplos o ajustes de notación. Antes de estudiar o compartir este archivo, se recomienda consultar la versión actualizada en: [última versión disponible](#).

Capítulo 1

Modelos de control de inventario

Antes de empezar el capítulo, mostraremos un mapa global de la clasificación de los diferentes modelos que estudiaremos más adelante.




Figura 1.1: Diagrama de decisión para seleccionar un modelo/política de control de inventarios.

1.1. Modelos con demanda determinística y estática

Como lo dice el título, para estos modelos se asume que se conoce con exactitud la demanda que será satisfecha a lo largo del horizonte del tiempo. Decimos que este tipo de modelos tienen demanda estática porque los parámetros son constantes a lo largo de los ciclos y suponemos que las decisiones que tomamos a lo largo de estos (como el tamaño de lote a ordenar) son constantes.

1.1.1. Modelo EOQ

Este primer modelo aplica solamente en empresas distribuidoras: partimos suponiendo que la empresa en cuestión no produce y simplemente despacha pedidos para satisfacer una demanda conocida. Asimismo, asumimos un lead time despreciable, por ende, todo lo que se pide llega al instante. En este orden de ideas, nuestro objetivo será minimizar costos de operación. El indicador principal a encontrar será el Economic Order Quantity (EOQ) o tamaño de lote óptimo.

Resumen supuestos EOQ:

1. Empresa distribuidora.
2. La tasa de demanda o consumo (λ) es constante a lo largo del tiempo.
3. Lead time (τ) despreciable: apenas se ordena, el pedido llega.
4. Orientado a ejercicios: En la mayoría de casos asumimos que tenemos costos de pedido (K), unitario (c) y de almacenamiento (h). Así como las tasas de demanda (λ) y de producción (P).

Notación EOQ

- K : Costo fijo de hacer un pedido [€].
- c : Costo unitario [€/und].
- i : Porcentaje de inventario que se almacena en cada periodo [%/Tiempo].
- h : Costo de almacenar una unidad en un periodo de tiempo [€/Tiempo–und].
- λ : Tasa de consumo o de demanda [unds/tiempo].
- f : Frecuencia de pedido [1/Tiempo].
- T : Tiempo de ciclo [Tiempo].
- $\bar{I}$: Inventario promedio a lo largo de la política [unds].
- Q : Tamaño de lote [unds].
- $\mathcal{K}$: Costo total de ordenar por ciclo [€/Tiempo].
- $\mathcal{H}$: Costo total de almacenamiento por ciclo [€/Tiempo].
- $G(Q)$: Costo total promedio asociado a la política que ordena un tamaño de lote Q [€/Tiempo].

Deducción de función de costos:

Desde este punto es natural preguntarnos “Ok, sabemos que queremos minimizar costos, pero ¿cómo lo hacemos?”

Antes de entrar a ver fórmulas y ejemplos, entendamos exactamente qué es lo que queremos minimizar. Para esto, será necesario definir una función de costos totales cómoda de manejar. Para esto partiremos este costo total en tres partes centrales:

1. Costos totales de pedido: Si sabemos que tenemos un costo fijo de hacer un pedido K , el costo total de pedido por ciclo será este valor multiplicado por la frecuencia de pedido f que manejaremos, reexpresado, tendremos

$$\mathcal{K} = Kf = \frac{K}{T}$$

2. Costos totales de adquirir: Ahora, tendremos que estimar el costo total por adquirir el producto. Para esto, multiplicaremos el costo unitario c por el tamaño de lote óptimo a ordenar Q . Como podemos ordenar varias veces por ciclo, tenemos que multiplicar esto de nuevo por la frecuencia de pedido. Reexpresando, tendremos

$$\text{C. Adquirir} = cQf = \frac{cQ}{T}$$

3. Costo total de almacenamiento: El costo de mantener inventario se incurre de manera continua a lo largo del tiempo y es proporcional al nivel de inventario disponible. Por ello, el costo promedio de almacenamiento por unidad de tiempo se modela como el costo unitario de mantenimiento h multiplicado por el inventario promedio en el tiempo. Como la política de reabastecimiento determina la trayectoria del inventario y, en particular, depende del tamaño de lote Q , escribimos dicho promedio como $\bar{I}(Q)$. En consecuencia,

$$\mathcal{H}(Q) = h\bar{I}(Q).$$

De esta forma, llegamos a nuestra función de costos totales denotada por $G(Q, T)$ o $CT(Q, T)$ tal que

$$\begin{aligned} G(Q, T) &= \mathcal{K} + \frac{cQ}{T} + \mathcal{H} \\ &= \frac{K}{T} + \frac{cQ}{T} + h\bar{I} \end{aligned}$$

A pesar de que esta será la función que usaremos, tiene un problema:

Notemos que esta función está definida sobre $\mathbb{R}^2$. Optimizar dos variables Q y T simultáneamente no tendrá sentido dado que definirá soluciones degeneradas.

Ejemplo 1.1 (Difícil de optimizar). Tomemos los siguientes parámetros $K = \$50$, $c = \$2/\text{und}$, $h = \$0,4/\text{mes-und}$, $\lambda = 300[\text{unds}/\text{mes}]$, $\bar{I} = Q/2$. Tendremos la siguiente función a minimizar

$$G(Q, T) = \frac{K}{T} + \frac{cQ}{T} + h\bar{I}(Q) = \frac{50 + 2Q}{T} + 0,4 \cdot \frac{Q}{2} = \frac{50 + 2Q}{T} + 0,2Q, \quad T > 0, Q \geq 0.$$

Y grafiquemos la superficie en $\mathbb{R}^3$




Figura 1.2: Función de costos totales multivariada

Gráficamente, podemos ver que la superficie no parece tener un mínimo global claro. Intentemos optimizar aplicando el procedimiento que siempre hemos aplicado en cálculo: derivar e igualar a cero.

Como es una función multivariada, saquemos gradiente, igualemoslo a cero y resolvamos el sistema de ecuaciones. Notemos que en este despeje no usamos la tasa de demanda λ en ningún lado.

$$G(Q, T) = \frac{50 + 2Q}{T} + 0,2 Q$$

$$\frac{\partial G}{\partial Q} = \frac{2}{T} + 0,2, \quad \frac{\partial G}{\partial T} = -\frac{50 + 2Q}{T^2}.$$

$$\nabla G(Q, T) = 0 \iff \begin{cases} \frac{2}{T} + 0,2 = 0, \\ -\frac{50 + 2Q}{T^2} = 0, \end{cases}$$

$$\begin{aligned} \frac{2}{T} + 0,2 = 0 &\iff \frac{2}{T} = -0,2 \iff T = -10, \\ -\frac{50 + 2Q}{T^2} = 0 &\iff 50 + 2Q = 0 \iff Q = -25. \end{aligned}$$

Los resultados obtenidos nos dan tiempos y unidades negativas, cosa que no tiene sentido. No es difícil demostrar que sin importar qué parámetros se usen en la función de costos, el óptimo analítico siempre será degenerado.

Conclusión: Necesitaremos modificar la forma en la que tratamos esta función para poder desarrollar un procedimiento robusto que siempre sirva. Para esto, intentaremos relacionar las variables Q y T para que la función de costos solo dependa de una variable. Introducimos la ecuación que nos facilitará estos procesos mediante la siguiente mnemotecnía.

Mantra: Mi tamaño de lote óptimo es lo que me demandan por el tiempo que me lo demandan.

$$Q = \lambda T$$

Volvamos al anterior ejemplo pero ahora usando esta poderosa ecuación.

Ejemplo 1.2 (Ej. 1.1 revisitado). Retomemos los mismos parámetros $K = \$50$, $c = \$2/\text{und}$, $h = \$0,4/\text{mes}$, $\lambda = 300[\text{unds}/\text{mes}]$, $\bar{I} = Q/2$. Haciendo uso de la anterior ecuación podemos simplificar significativamente la función de costos totales tomando $T = Q/\lambda$ tal que

$$\begin{aligned} G(Q) &= \frac{K}{T} + \frac{cQ}{T} + h\bar{I}(Q) \Bigg|_{T=\frac{Q}{\lambda}} = \frac{K\lambda}{Q} + c\lambda + h\bar{I}(Q) = \frac{K\lambda}{Q} + c\lambda + h\frac{Q}{2} \\ &= \frac{15000}{Q} + 600 + 0,2Q \end{aligned}$$

Ahora, grafiquemos la función de costos en dos dimensiones




Figura 1.3: Función de costos totales univariada

A simple vista parece que tampoco tendrá un mínimo analítico. Derivemos e igualemos a cero para confirmar sospechas:

$$G'(Q) = \frac{d}{dQ} \left(\frac{15000}{Q} + 600 + 0,2Q \right) = -\frac{15000}{Q^2} + 0,2.$$

$$\begin{aligned} G'(Q) = 0 &\iff -\frac{15000}{Q^2} + 0,2 = 0 \\ &\iff \frac{15000}{Q^2} = 0,2 \\ &\iff Q^2 = \frac{15000}{0,2} = 75000 \\ &\iff Q^* = \sqrt{75000} \approx 273,86 \quad [\text{unds}] \end{aligned}$$

A pesar de no verse gráficamente, ahora sí tenemos un mínimo que tiene sentido. Ahora, usaremos de nuevo la ecuación más reciente y encontraremos el tiempo de ciclo óptimo.

$$T = Q/\lambda = \frac{\sqrt{75000}}{300} \approx 0,9128 \quad [\text{meses}]$$

Puede que con solo un ejemplo no quede claro, pero acabamos de llegar a un resultado importante: la función de costos univariada es convexa. Esta propiedad será de suma importancia pues asegurará la existencia de un único óptimo global Q^* que podemos encontrar analíticamente derivando la función, igualando a cero y despejando para Q .

Truco geométrico para calcular $\bar{I}(Q)$

En el EOQ, el costo de almacenamiento depende del inventario promedio $\bar{I}(Q)$. En lugar de “adivinarlo”, lo calcularemos a partir de la gráfica $I(t)$ (inventario vs. tiempo). La idea es que el promedio temporal de una función es el área bajo la curva dividida por la longitud del intervalo:

$$\bar{I}(Q) = \frac{1}{T} \int_0^T I(t) dt.$$

Bajo los supuestos del EOQ (demanda determinística y reposición instantánea, sin faltantes), el inventario inicia en Q justo después de ordenar y decrece linealmente hasta 0 al final del ciclo. Por tanto, $I(t)$ es compuesto por triángulos y rectángulos. Veamos un ejemplo clásico.

Ejercicio 1.1. [Inventario promedio de EOQ clásico] Tomemos el ejemplo de una empresa con una demanda anual de $\lambda = 1000$ [unds/año]. Encontremos el inventario promedio.

Solución: Primero, hagamos la gráfica Inventario vs Tiempo. (**Nota:** El saber hacer correctamente esta gráfica será clave para llegar a la solución de futuros ejercicios).




Figura 1.4: Inventario vs Tiempo en EOQ clásico

En este caso, podemos aprovechar la geometría de la función para encontrar el área bajo la curva. Como todo lo que ordenamos se consume, podemos identificar Q , T y λ en la gráfica




Figura 1.5: Inventario vs tiempo de EOQ clásico con parámetros identificados

Ahora, podemos encontrar el inventario promedio encontrando el área bajo la curva y dividiendo entre el tiempo total

$$\bar{I}(Q) = \frac{\text{Área del triángulo}}{\text{Tiempo total de ciclo}} = \frac{QT}{2} \cdot \frac{1}{T} = \frac{Q}{2}$$

Como podemos ver, el inventario promedio nos queda en términos de Q nada más. No obstante, puede que próximos ejemplos no sean así de fáciles de trabajar.



Ya que tenemos más o menos una intuición del método, ahora sí iremos con los ejemplos

Ejemplos

Empezaremos esta sección con las ecuaciones que acabamos de deducir, luego daremos una receta general. Puede que una primera lectura no sea suficiente para entenderla

completamente, por ende se harán varios ejemplos en donde se hará hincapié en cada parte del proceso. Finalmente, se dará una nueva receta que se “salta pasos” pero da un resultado más directo y se revistarán los ejemplos difíciles usando este nuevo algoritmo.

Ecuaciones EOQ

Mantra:

$$Q = T\lambda \iff T = Q/\lambda \quad \text{para } \lambda > 0$$

No lo demostramos, pero es útil saber que

$$h = i \cdot c$$

Función de costos totales:

$$\begin{aligned} G(Q) &= \mathcal{K} + \frac{cQ}{T} + \mathcal{H} \\ &= \frac{K}{T} + \frac{cQ}{T} + h\bar{I} \end{aligned}$$

Relación entre frecuencia de pedido y tiempo de ciclo:

$$f = 1/T$$

Inventario promedio:

$$\begin{aligned} \bar{I} &= \frac{\sum_t I_t}{T} = \frac{\int_t I(t)}{T} = \frac{\text{Inv. Acum}}{\# \text{ Periodos}} \\ &= \frac{\sum \text{Áreas bajo la curva}}{\sum \text{Periodos}} \end{aligned}$$

Desagregar áreas:

$$\begin{aligned} \sum_i Q_i &= Q \\ \sum_j T_j &= T \end{aligned}$$

Receta (completa): Encontrar Q, T y $G(Q)$ teniendo acceso a los demás parámetros con demanda constante a trozos.

★ Setup:

1. Identificar parámetros que asumiremos constantes.
2. Hacer gráfica de Inventario vs. Tiempo.
3. Identificar áreas a encontrar.

★ Inventario promedio:

4. Usar fórmula de “Base $\times$ Altura” para rectángulos o “(Base $\times$ Altura)/2” para triángulos para expresar Área total = $\sum$ Áreas chiquitas.

5. Ajustar fórmula de inventarios totales $\bar{I}(Q_i; T_j) = \text{Área total} / \sum_j T_j$.
6. Usar fórmula $Q = \lambda T$ en cada tramo con demanda positiva para hacer que $\bar{I}$ dependa de los T_j s.
7. Usar relaciones temporales del enunciado para unificar los T_j s y hacer que $\bar{I}$ dependa únicamente del tiempo de ciclo total T .
8. Usar la relación $Q = \sum_i Q_i = \sum_j \lambda_j T_j$ para lograr encontrar una relación entre T y Q de la forma $T = \gamma Q$ donde γ es una constante a lo sumo dependiente de las tasas de demanda λ_i . Con esta, expresaremos $\bar{I}$ en términos de Q únicamente.

★ **Tamaño de lote óptimo:**

9. Ajustamos la función de costos totales

$$G(Q) = \frac{K}{T} + \frac{cQ}{T} + h\bar{I}$$

y reemplazamos anteriores resultados para que esta quede únicamente en función de Q .

10. Derivamos, igualamos a cero y despejamos para Q , el resultado encontrado será nuestro tamaño de lote óptimo Q^* .

★ **Outputs:**

11. Reportamos Q^* .
12. Usamos la relación anteriormente encontrada $T = \gamma Q$ para encontrar el tiempo de ciclo.
13. Reemplazamos Q , T y parámetros que asumíamos constantes en la función de costos inicial para encontrar costo total.

Podemos resumir el proceso para sacar el inventario total en esta siguiente gráfica. La idea será aplicar las siguientes transformaciones para lograr hacer que esta ecuación solo dependa de Q :





Figura 1.6: Transformaciones de inventario promedio en EOQ

Ejercicio 1.2 (EOQ clásico revisitado). Tome una empresa distribuidora con demanda de 3000 unds constante a lo largo del año, precio de adquisición unitario de \$30, porcentaje de retención mensual de inventario de 5 % y costo de ordenar de \$100. Ajuste un modelo de inventario tipo EOQ encontrando el tamaño de lote óptimo, tiempo de ciclo y costos totales anuales.

Solución: Primero, expresemos los parámetros que usaremos más adelante en unidades consistentes.

- $\lambda = 3000[\text{unds/año}]$
- $c = 30[\$/\text{und}]$
- $i = 0,05 \cdot 12 = 0,6[1/\text{año}]$
- $K = 100[\$]$
- $h = i \cdot c = 30 \cdot 0,6 = 18[\$/\text{año-und}]$

Ahora, hagamos el dibujito de la gráfica Inventario vs. Tiempo e identifiquemos parámetros que queremos obtener. Ya sacamos esta anteriormente.



Encontremos el nivel de inventario promedio sumando áreas y dividiendo entre el periodo total

$$\bar{I}(Q) = \frac{\text{Área del triángulo}}{\text{Tiempo total de ciclo}} = \frac{QT}{2} \cdot \frac{1}{T} = \frac{Q}{2}$$

Ajustemos la función de costos totales y pongámosla en función de una única variable Q usando la relación $T = Q/\lambda$

$$\begin{aligned} G(Q) &= \frac{K}{T} + \frac{cQ}{T} + h\bar{I}(Q) \Big|_{T=\frac{Q}{\lambda}} \\ &= \frac{K\lambda}{Q} + c\lambda + h\frac{Q}{2} \end{aligned}$$

Derivamos e igualamos a cero:

$$\begin{aligned} G'(Q) &= -\frac{K\lambda}{Q^2} + \frac{h}{2}, \\ G'(Q) = 0 &\iff -\frac{K\lambda}{Q^2} + \frac{h}{2} = 0 \\ &\iff \frac{K\lambda}{Q^2} = \frac{h}{2} \\ &\iff Q^2 = \frac{2K\lambda}{h} \\ &\iff \boxed{Q^* = \sqrt{\frac{2K\lambda}{h}}} \end{aligned}$$

Paréntesis: Fun fact

Esta última expresión será usada en temas posteriores. Generalmente la literatura se refiere a ella como el EOQ pues es útil asumir este ejemplo que estamos trabajando de política de control de inventarios como base para otras aplicaciones.

Reemplazamos parámetros y encontramos valor de Q^*

$$Q^* = \sqrt{\frac{2(100)(3000)}{18}} = \sqrt{\frac{600000}{18}} = \sqrt{33333,3333} \approx 182,574 \text{ [unds]}$$

Usamos la relación $T = \frac{Q}{\lambda}$ para encontrar tiempo de ciclo óptimo

$$T = \frac{Q^*}{\lambda} \approx \frac{182,574}{3000} \approx 0,060858 \text{ [años]}$$

Reemplazamos parámetros obtenidos en función de costos inicial

$$\begin{aligned} G(Q^*) &= \frac{K}{T} + \frac{cQ^*}{T} + h \frac{Q^*}{2} \\ &= \frac{100}{0,060858} + \frac{(30)(182,574)}{0,060858} + 18 \frac{182,574}{2} \\ &\approx 1643,168 + 90000,000 + 1643,168 \\ &\approx 93286,3353 \text{ [$/año]} \end{aligned}$$


⌋

Ejercicio 1.3 (Demanda constante a tramos). Tome una empresa distribuidora con demanda de 3000 unds constante a lo largo de la primera mitad del año y con demanda de 1500 unds a lo largo de la segunda mitad del año, precio de adquisición unitario de \$30, porcentaje de retención mensual de inventario de 5 % y costo de ordenar de \$100. Ajuste un modelo de inventario tipo EOQ encontrando el tamaño de lote óptimo, tiempo de ciclo y costos totales anuales.

Solución: Expresemos los parámetros que usaremos más adelante en unidades consistentes. Notemos que ahora no solo tenemos una tasa de demanda λ .

- $\lambda_1 = 3000[\text{unds/año}]$
- $\lambda_2 = 1500[\text{unds/año}]$
- $c = 30[\$/\text{und}]$
- $i = 0,05 \cdot 12 = 0,6[1/\text{año}]$
- $K = 100[\$]$
- $h = i \cdot c = 30 \cdot 0,6 = 18[\$/\text{año-und}]$

Hagamos el dibujito de Inventario vs. tiempo con esta nueva situación identificando los nuevos parámetros. Será útil desagregar las áreas que define el problema así como diferentes niveles de inventario denotados por Q_i , $i = 1, 2$ y tiempos en donde la demanda cambia, dados por T_i , $i = 1, 2$ con el fin de calcular cada área de forma más cómoda.



La geometría nos facilita encontrar el área total para encontrar el inventario promedio

$$\text{Área total} = \sum_{i=1}^3 A_i = \frac{Q_1 T_1}{2} + Q_2 T_1 + \frac{Q_2 T_2}{2}$$

$$\bar{I}(Q_1, Q_2, T_1, T_2) = \frac{\frac{Q_1 T_1}{2} + Q_2 T_1 + \frac{Q_2 T_2}{2}}{T_1 + T_2}$$

Hay un problema con esta fórmula de inventario promedio: está en función de varias variables. Para simplificarla, usaremos la relación básica “EOQ = tasa × tiempo” en cada mitad del ciclo:

$$Q_1 = \lambda_1 T_1, \quad Q_2 = \lambda_2 T_2.$$

$$\begin{aligned} \bar{I}(T_1, T_2) &= \frac{\frac{Q_1 T_1}{2} + Q_2 T_1 + \frac{Q_2 T_2}{2}}{T_1 + T_2} = \frac{\frac{(\lambda_1 T_1) T_1}{2} + (\lambda_2 T_2) T_1 + \frac{(\lambda_2 T_2) T_2}{2}}{T_1 + T_2} \\ &= \frac{\frac{\lambda_1 T_1^2}{2} + \lambda_2 T_1 T_2 + \frac{\lambda_2 T_2^2}{2}}{T_1 + T_2} \end{aligned}$$

Ahora usamos las relaciones del enunciado. Como hablamos de primera y segunda mitad del año, los tiempos son simétricos:

$$T_1 = T_2$$

Luego, como $T = T_1 + T_2$, se sigue que

$$T_1 = T_2 = \frac{T}{2}$$

Sustituimos $Q_1 = \lambda_1 T_1$ y $Q_2 = \lambda_2 T_2$ en la expresión de $\bar{I}$, y además usamos $T_1 = T_2$. Con

esto, todo queda en función de un solo tiempo:

$$\begin{aligned}
 \bar{I}(T) &= \frac{\frac{\lambda_1 T_1^2}{2} + \lambda_2 T_1 T_2 + \frac{\lambda_2 T_2^2}{2}}{T_1 + T_2} \\
 &\stackrel{T_1=T_2}{=} \frac{\frac{\lambda_1 T_1^2}{2} + \lambda_2 T_1^2 + \frac{\lambda_2 T_1^2}{2}}{2T_1} \\
 &= \frac{\left(\frac{\lambda_1}{2} + \frac{3\lambda_2}{2}\right) T_1^2}{2T_1} = \left(\frac{\lambda_1 + 3\lambda_2}{4}\right) T_1 \\
 &\stackrel{T_1=\frac{T}{2}}{=} \left(\frac{\lambda_1 + 3\lambda_2}{4}\right) \frac{T}{2} = \frac{\lambda_1 + 3\lambda_2}{8} T
 \end{aligned}$$

Finalmente, para expresar $\bar{I}$ en términos de Q , usamos el total pedido en el ciclo:

$$Q = Q_1 + Q_2 = \lambda_1 T_1 + \lambda_2 T_2 = \lambda_1 \frac{T}{2} + \lambda_2 \frac{T}{2} = \frac{\lambda_1 + \lambda_2}{2} T$$

de donde

$$T = \frac{2Q}{\lambda_1 + \lambda_2}$$

Nota: Si nos fijamos, acabamos de llegar a una expresión de la forma

$$T = \gamma Q, \quad \gamma = \frac{2}{\lambda_1 + \lambda_2} \in \mathbb{R}$$

Como la que expusimos en el diagrama de cajitas al inicio de esta sección.

Reemplazando en $\bar{I}(T)$ obtenemos

$$\bar{I}(Q) = \frac{\lambda_1 + 3\lambda_2}{8} \left(\frac{2Q}{\lambda_1 + \lambda_2} \right) = \frac{\lambda_1 + 3\lambda_2}{4(\lambda_1 + \lambda_2)} Q$$

Con el inventario promedio, ahora ajustaremos la función de costos totales

$$\begin{aligned}
 G(Q) &= \frac{K}{T} + \frac{cQ}{T} + h \bar{I}(Q) \\
 &= \frac{K}{\frac{2Q}{\lambda_1 + \lambda_2}} + \frac{cQ}{\frac{2Q}{\lambda_1 + \lambda_2}} + h \frac{\lambda_1 + 3\lambda_2}{4(\lambda_1 + \lambda_2)} Q \\
 &= \frac{K(\lambda_1 + \lambda_2)}{2Q} + \frac{c(\lambda_1 + \lambda_2)}{2} + \frac{h(\lambda_1 + 3\lambda_2)}{4(\lambda_1 + \lambda_2)} Q
 \end{aligned}$$

Derivamos e igualamos a cero

$$\begin{aligned}
 G'(Q) = 0 &\iff \frac{K(\lambda_1 + \lambda_2)}{2Q^2} = \frac{h(\lambda_1 + 3\lambda_2)}{4(\lambda_1 + \lambda_2)} \\
 &\iff 2K(\lambda_1 + \lambda_2)^2 = h(\lambda_1 + 3\lambda_2) Q^2 \\
 &\iff Q^* = \sqrt{\frac{2K(\lambda_1 + \lambda_2)^2}{h(\lambda_1 + 3\lambda_2)}} = (\lambda_1 + \lambda_2) \sqrt{\frac{2K}{h(\lambda_1 + 3\lambda_2)}}
 \end{aligned}$$

Reemplazamos parámetros y llegamos al tamaño de lote óptimo

$$Q^* = 4500 \sqrt{\frac{200}{18(3000 + 3 \cdot 1500)}} = 4500 \sqrt{\frac{200}{18 \cdot 7500}} \approx 173,2051 \text{ [unds]}$$

Usamos la fórmula de T en función de Q

$$T = \frac{2Q}{\lambda_1 + \lambda_2} = \frac{2(173,2051)}{3000 + 1500} = \frac{346,4102}{4500} \approx 0,07698 \text{ [años]}$$

Finalmente, volvemos a reemplazar parámetros y llegamos al costo total

$$\begin{aligned} G(Q^*) &= \frac{100(3000 + 1500)}{2(173,2051)} + \frac{30(3000 + 1500)}{2} + \frac{18(3000 + 3 \cdot 1500)}{4(3000 + 1500)}(173,2051) \\ &\approx 1299,0381 + 67500 + 1299,0381 \\ &\approx 70098,0762 \text{ [$/año]} \end{aligned}$$

⤴


Ejercicio 1.4 (Demanda constante a tramos con periodos ociosos). Tome una empresa distribuidora con demanda de 3000 unds constante a lo largo de los primeros 3 meses del año. Dada la estacionalidad de la demanda, la empresa pasa los siguientes 6 meses sin recibir pedidos. Al final del año la empresa reactiva sus actividades económicas, teniendo una demanda de 1500 unds a lo largo de los últimos 3 meses de operación. En cuanto a su precio de adquisición unitario, este es de \$30, tiene un porcentaje de retención mensual de inventario de 5% y costo de ordenar de \$100. Ajuste un modelo de inventario tipo EOQ encontrando el tamaño de lote óptimo, tiempo de ciclo y costos totales anuales.

Solución: Primero, expresemos parámetros en unidades consistentes

$$\lambda_1 = 3000 \text{ [unds/año]} \quad \lambda_2 = 0 \text{ [unds/año]} \quad \lambda_3 = 1500 \text{ [unds/año]}$$

$$c = 30 \text{ [$/und]} \quad i = 0,05 \cdot 12 = 0,6 \text{ [1/año]} \quad K = 100 \text{ [\$]} \quad h = i \cdot c = 18 \text{ [$/año-und]}$$

Luego, hagamos un dibujito de la situación identificando los parámetros involucrados.



Usemos la geometría del inventario. Dividamos el ciclo en tres tramos con tiempos T_1, T_2, T_3 y niveles Q_1, Q_2 como en la figura. El área total bajo la curva se descompone como

$$\text{Área total} = \frac{Q_1 T_1}{2} + Q_2 T_1 + Q_2 T_2 + \frac{Q_2 T_3}{2}$$

Luego, el inventario promedio es

$$\bar{I}(Q_1, Q_2, T_1, T_2, T_3) = \frac{\frac{Q_1 T_1}{2} + Q_2 T_1 + Q_2 T_2 + \frac{Q_2 T_3}{2}}{T_1 + T_2 + T_3}$$

Para simplificar, aplicamos $Q = \lambda T$ en cada tramo con demanda positiva

$$Q_1 = \lambda_1 T_1 \quad Q_2 = \lambda_3 T_3$$

Sustituyendo

$$\begin{aligned} \bar{I}(T_1, T_2, T_3) &= \frac{\frac{(\lambda_1 T_1) T_1}{2} + (\lambda_3 T_3) T_1 + (\lambda_3 T_3) T_2 + \frac{(\lambda_3 T_3) T_3}{2}}{T_1 + T_2 + T_3} \\ &= \frac{\frac{\lambda_1 T_1^2}{2} + \lambda_3 T_1 T_3 + \lambda_3 T_2 T_3 + \frac{\lambda_3 T_3^2}{2}}{T_1 + T_2 + T_3} \end{aligned}$$

Ahora usamos las relaciones temporales del enunciado. Como son 3 meses, luego 6 meses, luego 3 meses

$$T_2 = 2T_1 \quad T_3 = T_1$$

De donde

$$T = T_1 + T_2 + T_3 = T_1 + 2T_1 + T_1 = 4T_1 \quad T_1 = \frac{T}{4}$$

Reemplazando $T_2 = 2T_1$ y $T_3 = T_1$ en $\bar{I}(T_1, T_2, T_3)$

$$\begin{aligned} \bar{I}(T) &= \frac{\frac{\lambda_1 T_1^2}{2} + \lambda_3 T_1^2 + \lambda_3 (2T_1) T_1 + \frac{\lambda_3 T_1^2}{2}}{4T_1} \\ &= \frac{\left(\frac{\lambda_1}{2} + \frac{7\lambda_3}{2}\right) T_1^2}{4T_1} \\ &= \frac{\lambda_1 + 7\lambda_3}{8} \cdot \frac{T_1}{4} \\ &= \frac{\lambda_1 + 7\lambda_3}{32} T \end{aligned}$$

Para pasar a $\bar{I}(Q)$, primero expresamos Q en términos de T

$$Q = Q_1 + Q_2 = \lambda_1 T_1 + \lambda_3 T_3 = \lambda_1 \frac{T}{4} + \lambda_3 \frac{T}{4} = \frac{\lambda_1 + \lambda_3}{4} T$$

Luego

$$T = \frac{4Q}{\lambda_1 + \lambda_3}$$

Sustituyendo en $\bar{I}(T)$

$$\bar{I}(Q) = \frac{\lambda_1 + 7\lambda_3}{32} \cdot \frac{4Q}{\lambda_1 + \lambda_3} = \frac{\lambda_1 + 7\lambda_3}{8(\lambda_1 + \lambda_3)} Q$$

Con esto armamos la función de costos totales

$$G(Q) = \frac{K}{T} + \frac{cQ}{T} + h \bar{I}(Q)$$

Usando $T = \frac{4Q}{\lambda_1 + \lambda_3}$ y $\bar{I}(Q) = \frac{\lambda_1 + 7\lambda_3}{8(\lambda_1 + \lambda_3)} Q$

$$\begin{aligned} G(Q) &= \frac{K}{\frac{4Q}{\lambda_1 + \lambda_3}} + \frac{cQ}{\frac{4Q}{\lambda_1 + \lambda_3}} + h \frac{\lambda_1 + 7\lambda_3}{8(\lambda_1 + \lambda_3)} Q \\ &= \frac{K(\lambda_1 + \lambda_3)}{4Q} + \frac{c(\lambda_1 + \lambda_3)}{4} + \frac{h(\lambda_1 + 7\lambda_3)}{8(\lambda_1 + \lambda_3)} Q \end{aligned}$$

Derivamos e igualamos a cero

$$\begin{aligned} G'(Q) &= -\frac{K(\lambda_1 + \lambda_3)}{4Q^2} + \frac{h(\lambda_1 + 7\lambda_3)}{8(\lambda_1 + \lambda_3)} \\ G'(Q) = 0 &\iff \frac{K(\lambda_1 + \lambda_3)}{4Q^2} = \frac{h(\lambda_1 + 7\lambda_3)}{8(\lambda_1 + \lambda_3)} \\ &\iff 2K(\lambda_1 + \lambda_3)^2 = h(\lambda_1 + 7\lambda_3) Q^2 \\ &\iff Q^* = \sqrt{\frac{2K(\lambda_1 + \lambda_3)^2}{h(\lambda_1 + 7\lambda_3)}} = (\lambda_1 + \lambda_3) \sqrt{\frac{2K}{h(\lambda_1 + 7\lambda_3)}} \end{aligned}$$

Reemplazando parámetros iniciales

$$Q^* = 4500 \sqrt{\frac{200}{18(3000 + 7 \cdot 1500)}} = 4500 \sqrt{\frac{200}{18 \cdot 13500}} \approx 129,0994 \text{ [unds]}$$

Tiempo de ciclo óptimo

$$T^* = \frac{4Q^*}{\lambda_1 + \lambda_3} = \frac{4(129,0994)}{4500} \approx 0,1148 \text{ [años]}$$

Costo total anual

$$\begin{aligned} G(Q^*) &= \frac{100(3000 + 1500)}{4(129,0994)} + \frac{30(3000 + 1500)}{4} + \frac{18(3000 + 7 \cdot 1500)}{8(3000 + 1500)} (129,0994) \\ &\approx 871,4213 + 33750 + 871,4213 \approx 35492,8425 \text{ [$/año]} \end{aligned}$$

⌋

Como hemos visto, este proceso muestra muy bien el paso a paso pero en general, toma tiempo. Por ende, introduciremos una forma más directa de resolver este tipo de ejercicios. Los cambios son mínimos, pero ayudan a ahorrar tiempo.

Receta (directa): Encontrar Q , T y $G(Q)$ teniendo acceso a los demás parámetros con demanda constante a trozos.

★ **Setup:**

1. Identificar parámetros que asumiremos constantes.
2. Hacer gráfica de Inventario vs. Tiempo poniendo el eje x directamente como fracción de T .
3. Identificar áreas a encontrar.

★ **Inventario promedio:**

4. Ajustar fórmula de inventarios totales $\bar{I}(Q_i; T_i) = \text{Área total} / \sum_i T_i$ usando de una vez la relación $Q = \lambda T$ en tramos con demanda positiva.
5. Usar la relación $Q = \sum_i Q_i = \sum_i \lambda_i T_i$ para lograr encontrar una relación entre T y Q de la forma $T = \gamma Q$ donde γ es una constante a lo sumo dependiente de las tasas de demanda λ_i . Con esta, expresaremos $\bar{I}$ en términos de Q únicamente.

★ **Tamaño de lote óptimo:**

6. Ajustamos la función de costos totales

$$G(Q) = \frac{K}{T} + \frac{cQ}{T} + h\bar{I}$$

y reemplazamos anteriores resultados para que esta quede únicamente en función de Q .

7. Igualamos el primer y tercer término de la función de costos totales y despejamos para Q , el resultado encontrado será nuestro tamaño de lote óptimo Q^* .

★ **Outputs:**

8. Reportamos Q^* .
9. Usamos la relación anteriormente encontrada $T = \gamma Q$ para encontrar el tiempo de ciclo.
10. Reemplazamos Q , T y parámetros que asumíamos constantes en la función de costos inicial para encontrar costo total.

Veamos como quedan los ejemplos que acabamos de hacer con esta nueva forma de resolverlos.

Ejercicio 1.5 (Ejercicio 1.3 revisitado). Tome una empresa distribuidora con demanda de 3000 unds constante a lo largo de la primera mitad del año y con demanda de 1500 unds a lo largo de la segunda mitad del año, precio de adquisición unitario de \$30, porcentaje de retención mensual de inventario de 5 % y costo de ordenar de \$100. Ajuste un modelo de inventario tipo EOQ encontrando el tamaño de lote óptimo, tiempo de ciclo y costos totales anuales

Solución:


Paso 1: Identificar parámetros constantes y unidades

$$\lambda_1 = 3000 \text{ [unds/año]} \quad \lambda_2 = 1500 \text{ [unds/año]} \quad c = 30 \text{ [$/und]} \quad K = 100 \text{ [\$]}$$

$$i = 0,05 \cdot 12 = 0,6 \text{ [1/año]} \quad h = i \cdot c = 0,6 \cdot 30 = 18 \text{ [$/und} \cdot \text{año]}$$

Paso 2-3: Gráfica $I(t)$ vs tiempo con eje x como fracción de T

$$T_1 = \frac{T}{2} \quad T_2 = \frac{T}{2}$$



Paso 4: Inventario promedio usando $Q = \lambda T$

$$Q_1 = \lambda_1 T_1 = \lambda_1 \frac{T}{2} \quad Q_2 = \lambda_2 T_2 = \lambda_2 \frac{T}{2}$$

$$\begin{aligned} \bar{I}(T) &= \frac{\left(\frac{\lambda_1 \frac{T}{2}}{2}\right)\left(\frac{T}{2}\right) + \left(\lambda_2 \frac{T}{2}\right)\left(\frac{T}{2}\right) + \frac{\left(\lambda_2 \frac{T}{2}\right)\left(\frac{T}{2}\right)}{2}}{T} \\ &= \frac{\lambda_1 + 3\lambda_2}{8} T \end{aligned}$$

Paso 5: Relación $T = \gamma Q$ a partir de $Q = \sum_i Q_i = \sum_i \lambda_i T_i$

$$Q = Q_1 + Q_2 = \lambda_1 \frac{T}{2} + \lambda_2 \frac{T}{2} = \frac{\lambda_1 + \lambda_2}{2} T \quad T = \gamma Q \quad \gamma = \frac{2}{\lambda_1 + \lambda_2}$$

$$\bar{I}(Q) = \frac{\lambda_1 + 3\lambda_2}{8} T = \frac{\lambda_1 + 3\lambda_2}{8} \gamma Q = \frac{\lambda_1 + 3\lambda_2}{4(\lambda_1 + \lambda_2)} Q$$

Paso 6: Ajustar $G(Q)$ reemplazando $T = \gamma Q$ y $\bar{I}(Q)$

$$G(Q) = \frac{K}{T} + \frac{cQ}{T} + h\bar{I}(Q)$$

$$\begin{aligned} G(Q) &= \frac{K}{\gamma Q} + \frac{cQ}{\gamma Q} + h \left(\frac{\lambda_1 + 3\lambda_2}{4(\lambda_1 + \lambda_2)} Q \right) \\ &= \frac{K(\lambda_1 + \lambda_2)}{2Q} + \frac{c(\lambda_1 + \lambda_2)}{2} + \frac{h(\lambda_1 + 3\lambda_2)}{4(\lambda_1 + \lambda_2)} Q \end{aligned}$$

Paso 7: Igualar primer y tercer término para obtener Q^*

$$\frac{K(\lambda_1 + \lambda_2)}{2Q} = \frac{h(\lambda_1 + 3\lambda_2)}{4(\lambda_1 + \lambda_2)} Q$$

$$Q^* = \sqrt{\frac{2K(\lambda_1 + \lambda_2)^2}{h(\lambda_1 + 3\lambda_2)}}$$

Paso 8: Reportar Q^*

$$Q^* = \sqrt{\frac{2(100)(3000 + 1500)^2}{18(3000 + 3 \cdot 1500)}} = \sqrt{\frac{2(100)(4500)^2}{18(7500)}} \approx 173,2051 \text{ [unds]}$$

Paso 9: Hallar tiempo de ciclo usando $T = \gamma Q$

$$T = \gamma Q^* = \frac{2}{\lambda_1 + \lambda_2} Q^* = \frac{2(173,2051)}{4500} \approx 0,0769800 \text{ [años]}$$

Paso 10: Calcular costo total anual

$$\begin{aligned} G(Q^*) &= \frac{K(\lambda_1 + \lambda_2)}{2Q^*} + \frac{c(\lambda_1 + \lambda_2)}{2} + \frac{h(\lambda_1 + 3\lambda_2)}{4(\lambda_1 + \lambda_2)} Q^* \\ &= \frac{100(4500)}{2(173,2051)} + \frac{30(4500)}{2} + \frac{18(7500)}{4(4500)} (173,2051) \\ &\approx 70098,0762 \text{ [$/año]} \end{aligned}$$

⌋

Ejercicio 1.6 (Ejercicio 1.4 revisitado). Tome una empresa distribuidora con demanda de 3000 unds constante a lo largo de los primeros 3 meses del año. Dada la estacionalidad de la demanda, la empresa pasa los siguientes 6 meses sin recibir pedidos. Al final del año la empresa reactiva sus actividades económicas, teniendo una demanda de 1500 unds a lo largo de los últimos 3 meses de operación. En cuanto a su precio de adquisición unitario, este es de \$30, tiene un porcentaje de retención mensual de inventario de 5% y costo de ordenar de \$100. Ajuste un modelo de inventario tipo EOQ encontrando el tamaño de lote óptimo, tiempo de ciclo y costos totales anuales

Solución:


Paso 1: Identificar parámetros constantes y unidades

$$\lambda_1 = 3000 \text{ [unds/año]} \quad \lambda_2 = 0 \text{ [unds/año]} \quad \lambda_3 = 1500 \text{ [unds/año]} \quad c = 30 \text{ [$/und]}$$

$$i = 0,05 \cdot 12 = 0,6 \text{ [1/año]} \quad h = i \cdot c = 0,6 \cdot 30 = 18 \text{ [$/und} \cdot \text{año]} \quad K = 100 \text{ [\$]}$$

Paso 2–3: Gráfica $I(t)$ vs tiempo con eje x como fracción de T e identificación de áreas

$$T_1 = \frac{T}{4} \quad T_2 = \frac{T}{2} \quad T_3 = \frac{T}{4}$$



Paso 4: Ajustar $\bar{I} = \text{Área total} / \sum_i T_i$ usando $Q = \lambda T$ en tramos con demanda positiva

$$Q_1 = \lambda_1 T_1 = \lambda_1 \frac{T}{4} \quad Q_2 = \lambda_3 T_3 = \lambda_3 \frac{T}{4}$$

Luego

$$\begin{aligned} \bar{I}(T) &= \frac{T_1 = \frac{T}{4}, T_2 = \frac{T}{2}, T_3 = \frac{T}{4}}{\frac{\lambda_1}{2} \left(\frac{T}{4}\right)^2 + \lambda_3 \left(\frac{T}{4}\right) \left(\frac{T}{4}\right) + \lambda_3 \left(\frac{T}{2}\right) \left(\frac{T}{4}\right) + \frac{\lambda_3}{2} \left(\frac{T}{4}\right)^2} \\ &= \frac{\lambda_1 + 7\lambda_3}{32} T \end{aligned}$$

Paso 5: Usar $Q = \sum_i Q_i = \sum_i \lambda_i T_i$ para obtener $T = \gamma Q$ y expresar $\bar{I}$ en Q

$$Q = Q_1 + Q_2 = \lambda_1 T_1 + \lambda_3 T_3 = \lambda_1 \frac{T}{4} + \lambda_3 \frac{T}{4} = \frac{\lambda_1 + \lambda_3}{4} T \quad T = \gamma Q \quad \gamma = \frac{4}{\lambda_1 + \lambda_3}$$

$$\begin{aligned} \bar{I}(Q) &= \frac{\lambda_1 + 7\lambda_3}{32} T = \frac{\lambda_1 + 7\lambda_3}{32} \gamma Q = \frac{\lambda_1 + 7\lambda_3}{32} \cdot \frac{4}{\lambda_1 + \lambda_3} Q \\ &= \frac{\lambda_1 + 7\lambda_3}{8(\lambda_1 + \lambda_3)} Q \end{aligned}$$

Paso 6: Ajustar la función de costos totales $G(Q)$ sustituyendo $T = \gamma Q$ y $\bar{I}(Q)$

$$G(Q) = \frac{K}{T} + \frac{cQ}{T} + h\bar{I}(Q)$$

$$\begin{aligned} G(Q) &= \frac{K}{\gamma Q} + \frac{cQ}{\gamma Q} + h \left(\frac{\lambda_1 + 7\lambda_3}{8(\lambda_1 + \lambda_3)} Q \right) \\ &= \frac{K(\lambda_1 + \lambda_3)}{4Q} + \frac{c(\lambda_1 + \lambda_3)}{4} + \frac{h(\lambda_1 + 7\lambda_3)}{8(\lambda_1 + \lambda_3)} Q \end{aligned}$$

Paso 7: Igualar primer y tercer término y despejar Q^*

$$\begin{aligned}\frac{K(\lambda_1 + \lambda_3)}{4Q} &= \frac{h(\lambda_1 + 7\lambda_3)}{8(\lambda_1 + \lambda_3)} Q \\ 2K(\lambda_1 + \lambda_3)^2 &= h(\lambda_1 + 7\lambda_3) Q^2 \\ Q^* &= (\lambda_1 + \lambda_3) \sqrt{\frac{2K}{h(\lambda_1 + 7\lambda_3)}}\end{aligned}$$

Paso 8: Reportar Q^*

$$Q^* = (3000 + 1500) \sqrt{\frac{2(100)}{18(3000 + 7 \cdot 1500)}} = 4500 \sqrt{\frac{200}{18(13500)}} \approx 129,0994 \text{ [unds]}$$

Paso 9: Encontrar el tiempo de ciclo con $T = \gamma Q$

$$T = \gamma Q^* = \frac{4}{\lambda_1 + \lambda_3} Q^* = \frac{4(129,0994)}{4500} \approx 0,1147550 \text{ [años]}$$

Paso 10: Calcular el costo total anual reemplazando en $G(Q)$

$$\begin{aligned}G(Q^*) &= \frac{100(3000 + 1500)}{4(129,0994)} + \frac{30(3000 + 1500)}{4} + \frac{18(3000 + 7 \cdot 1500)}{8(3000 + 1500)}(129,0994) \\ &\approx 871,4213 + 33750 + 871,4213 \\ &\approx 35492,8425 \text{ [$/año]}\end{aligned}$$

⌋

Bonus: Todo este proceso puede hacerse en Excel con buscar objetivo de forma MUCHO más directa. [EOQ con buscar objetivo.xlsx](#)

1.1.2. Modelo EPL

Este se parece mucho al modelo EOQ, pero ahora tenemos en cuenta empresas que producen y distribuyen. De resto, todos los supuestos que manejábamos anteriormente seguirán siendo vigentes y usados en este caso.

Los principales outputs de esta sección serán los mismos que en EOQ: El tamaño de lote óptimo Q^* , el tiempo de ciclo asociado T^* y el costo total $G(Q^*)$ de la política óptima.

Resumen de supuestos EPL:

1. Empresa productora y distribuidora.
2. Tasas de demanda o consumo (λ) y de producción (P) constantes a tramos en el tiempo.
3. Lead time (τ) despreciable: apenas se ordena, el producto llega.

4. Orientado a ejercicios: En la mayoría de casos asumimos que tenemos costos de pedido (K), unitario (c) y de almacenamiento (h). Así como las tasas de demanda (λ) y de producción (P).

Notemos que con este modelo, tendremos la misma lógica que en EOQ, pero en vez de ordenar y que se consuma todo en el ciclo, tendremos que producir y consumir la totalidad del lote en este ciclo. Por ende, tendremos nuevas ecuaciones que relacionarán estas dinámicas para complementar el análisis de este tema.

Notación EPL

- K : Costo fijo de hacer un pedido [\$].
- c : Costo unitario [\$/und].
- i : Porcentaje de inventario que se almacena en cada periodo [%/Tiempo].
- h : Costo de almacenar una unidad en un periodo de tiempo [\$/Tiempo-und].
- λ : Tasa de consumo o de demanda [unds/tiempo].
- P : Tasa de producción [unds/tiempo].
- f : Frecuencia de pedido [1/Tiempo].
- T : Tiempo de ciclo [Tiempo].
- $\bar{I}$: Inventario promedio a lo largo de la política [unds].
- Q : Tamaño de lote [unds].
- H : Nivel máximo de inventario [unds].
- $\mathcal{K}$: Costo total de ordenar por ciclo [\$/Tiempo].
- $\mathcal{H}$: Costo total de almacenamiento por ciclo [\$/Tiempo].
- $G(Q)$: Costo total promedio asociado a la política que ordena un tamaño de lote Q [\$/Tiempo].

En cuanto a ecuaciones, podemos heredar la mayoría de fórmulas que usamos anteriormente en EOQ, pero ahora tendremos que tener en cuenta una nueva relación que conecte P con λ . Lograremos esto extendiendo el “**mantra**” que veíamos antes pero ahora teniendo en cuenta la parte de producción.

Mantra parte 2: Mi lote óptimo es lo que produzco por el tiempo que lo produzco

$$Q = PT$$

Finalmente, para periodos donde se produce y consume al tiempo, será útil tener un nuevo elemento en la gráfica Inventario vs. Tiempo y una relación final

Mantra parte 3: Mi nivel máximo de inventario en un periodo, es la relación entre lo

que se produce y consume por la duración del periodo.

$$H = \begin{cases} (P - \lambda)T, & P > \lambda \\ (\lambda - P)T, & P < \lambda \end{cases}$$

Ejemplos:

Ecuaciones EPL

Ecuaciones fundamentales generalizadas:

1. **Mantra:**

$$Q = \sum_j T_j \lambda_j \quad \text{para } \lambda > 0$$

2. **Mantra pt 2:**

$$Q = \sum_j T_j P_j \quad \text{para } P > 0$$

3. **Mantra pt 3:**

$$H = \begin{cases} (P - \lambda)T, & P > \lambda \\ (\lambda - P)T, & P < \lambda \end{cases}$$

No lo demostramos, pero es útil saber que

$$h = i \cdot c$$

Función de costos totales:

$$\begin{aligned} G(Q) &= \mathcal{K} + \frac{cQ}{T} + \mathcal{H} \\ &= \frac{K}{T} + \frac{cQ}{T} + h\bar{I} \end{aligned}$$

Relación entre frecuencia de pedido y tiempo de ciclo:

$$f = 1/T$$

Inventario promedio:

$$\begin{aligned} \bar{I} &= \frac{\sum_t I_t}{T} = \frac{\int_t I(t)}{T} = \frac{\text{Inv. Acum}}{\# \text{ Periodos}} \\ &= \frac{\sum \text{Áreas bajo la curva}}{\sum \text{Periodos}} \end{aligned}$$

Desagregar áreas:

$$\begin{aligned} \sum_i Q_i &= Q \\ \sum_j T_j &= T \end{aligned}$$

Receta: Encontrar inventario promedio, Q^* , T asociado, $\bar{I}(Q^*)$ y costos totales promedios de política óptima dados datos de costos y estructura de inventario.

★ **Setup**

1. Poner datos de costos y demandas en unidades consistentes.

★ **Inventario promedio**

2. Hacer gráfica de Inventario vs. Tiempo e identificar elementos del enunciado en ella.
3. Usar ecuaciones fundamentales para dejar T en función de Q .
4. Ajustar inventario promedio en términos de Q usando la geometría de la gráfica Inventario vs. Tiempo.

★ **Outputs**

5. Ajustar función de costo total.
6. Igualar primer y tercer término y despejar para Q . Reemplazar y reportar Q^*
7. Encontrar tiempo de ciclo óptimo T asociado al Q^* que acabamos de sacar.
8. Encontrar $G(Q^*)$ con la información que se acaba de sacar.

Ejercicio 1.7. Tome una empresa que pasa una primera parte del año solamente produciendo con una tasa de 3000 unds. Durante la segunda parte del año, la empresa se dedica unicamente a distribuir el inventario acumulado durante la primera etapa. La tasa de demanda es igual a la de producción en esta segunda parte. En cuanto a costos, Se sabe que la empresa cuenta con un lead time (τ) despreciable, un costo fijo por realizar un pedido de \$300, un costo de adquirir una unidad de \$5 y una tasa de retención de inventario de 10 % cada año. Ajuste un modelo de control de inventario tipo EPL con esta información. Reporte el nivel de inventario promedio, tamaño de lote óptimo, tiempo de ciclo asociado a al tamaño de lote óptimo y costos anuales totales promedio (**Nota:** El hecho de que se describa el comportamiento de la industria diciendo cosas como “primera parte” o “segunda parte” del año NO implica $T_1 = T_2 = T/2$).


Solución:

1. Ponemos datos del enunciado en unidades consistentes

$$\lambda = 3000 \text{ [unds/año]} \quad P = 3000 \text{ [unds/año]} \quad K = 300[\$]$$

$$i = 0,1 \text{ [1/año]} \quad c = 5 \text{ [$/und]} \quad h = i \cdot c = 0,5 \text{ [$/año-und]}$$

2. Hacemos dibujito de Inventario vs. Tiempo



3. Consideramos las relaciones $Q = PT_1 \implies T_1 = Q/P$ y $Q = \lambda T_2 \implies T_2 = Q/\lambda$.
Entonces

$$T = T_1 + T_2 = \frac{Q}{P} + \frac{Q}{\lambda}$$

4. Ajustamos inventario promedio en términos de Q .

$$\bar{I}(Q) = \frac{A_1 + A_2}{T_1 + T_2} = \frac{\frac{QT_1}{2} + \frac{QT_2}{2}}{T_1 + T_2} = \frac{\frac{Q}{2}(T_1 + T_2)}{T_1 + T_2} = \frac{Q}{2}$$

5. Ajustamos función de costos totales

$$G(Q) = \frac{K}{T} + \frac{cQ}{T} + h\bar{I} = \frac{K}{\frac{Q}{P} + \frac{Q}{\lambda}} + \frac{cQ}{\frac{Q}{P} + \frac{Q}{\lambda}} + h\frac{Q}{2}$$

6. Igualamos primer y tercer término y despejamos para Q

$$\begin{aligned}
 \frac{K}{\frac{Q}{P} + \frac{Q}{\lambda}} &= h \frac{Q}{2} \\
 \frac{K}{Q \left(\frac{1}{P} + \frac{1}{\lambda} \right)} &= h \frac{Q}{2} \\
 K &= \frac{hQ}{2} Q \left(\frac{1}{P} + \frac{1}{\lambda} \right) \\
 K &= \frac{hQ^2}{2} \left(\frac{1}{P} + \frac{1}{\lambda} \right) \\
 Q^2 &= \frac{2K}{h \left(\frac{1}{P} + \frac{1}{\lambda} \right)} = \frac{2K}{h \left(\frac{\lambda+P}{P\lambda} \right)} = \frac{2KP\lambda}{h(\lambda+P)} \\
 \Rightarrow Q &= \sqrt{\frac{2KP\lambda}{h(\lambda+P)}} \\
 &= \sqrt{\frac{2(300)(3000)(3000)}{(0,5)(3000+3000)}} = \sqrt{\frac{5,400,000,000}{3,000}} = \sqrt{1,800,000} \\
 &\approx 1341,64 \text{ unds}
 \end{aligned}$$

7. Tiempo de ciclo

$$T = \frac{Q}{P} + \frac{Q}{\lambda} = \frac{1341,64}{3000} + \frac{1341,64}{3000} = \frac{2(1341,64)}{3000} \approx 0,8944 \text{ años.}$$

8. Costos totales

$$\begin{aligned}
 G(Q) &= \frac{KP\lambda}{Q(\lambda+P)} + \frac{cP\lambda}{\lambda+P} + \frac{hQ}{2} \\
 &= \frac{300(3000)(3000)}{(1341,64)(6000)} + \frac{5(3000)(3000)}{6000} + \frac{0,5(1341,64)}{2} \\
 &\approx 335,41 + 7500 + 335,41 = 8170,82 \text{ \$/año}
 \end{aligned}$$

⌋

Ejercicio 1.8 (Producción y consumo simultáneo). Tome una empresa que pasa una primera parte del año produciendo con una tasa de 3000 unds y consumiendo a una tasa de 1000 unds. Durante la segunda parte del año, la empresa se dedica unicamente a distribuir con una demanda de 1500 unds. La tasa de demanda es igual a la de producción en esta segunda parte. En cuanto a costos, Se sabe que la empresa cuenta con un lead time (τ) despreciable, un costo fijo por realizar un pedido de \$300, un costo de adquirir una unidad de \$5 y una tasa de retención de inventario de 10 % cada año. Ajuste un modelo de control de inventario tipo EPL con esta información. Reporte el nivel de inventario promedio, tamaño de lote óptimo, tiempo de ciclo asociado a al tamaño de lote óptimo y

costos anuales totales promedio (**Nota:** El hecho de que se describa el comportamiento de la industria diciendo cosas como “primera parte” o “segunda parte” del año NO implica $T_1 = T_2 = T/2$).


Solución:

1. Ponemos datos del enunciado en unidades consistentes

$$\lambda_1 = 1000 \text{ [unds/año]} \quad P_1 = 3000 \text{ [unds/año]} \quad \lambda_2 = 1500 \text{ [unds/año]}$$

$$i = 0,1 \text{ [1/año]} \quad c = 50 \text{ [$/und]} \quad h = i \cdot c = 0,5 \text{ [$/año-und]} \quad K = 300 \text{ [\$]}$$

2. Hacemos gráfica de Inventario vs. Tiempo. Notemos que en este caso no se tiene $Q = (P_1 - \lambda_1)T_1$, por ende denotaremos con H el nivel máximo de inventario en este escenario.



3. Consideramos las siguientes relaciones dadas las ecuaciones fundamentales

a) Ecuación 1:

$$Q = \lambda_1 T_1 + \lambda_2 T_2$$

b) Ecuación 2:

$$Q = P_1 T_1 \implies T_1 = \frac{Q}{P_1}$$

c) Ecuación 3:

$$H = (P_1 - \lambda_1)T_1 = \lambda_2 T_2 \implies T_2 = \frac{(P_1 - \lambda_1)}{\lambda_2} T_1$$

Entonces

$$T = T_1 + T_2 = \frac{Q}{P_1} \left(1 + \frac{(P_1 - \lambda_1)}{\lambda_2} \right)$$

4. Ajustamos función de inventario promedio en términos de Q

$$\begin{aligned}\bar{I}(Q) &= \frac{A_1 + A_2}{T} = \frac{\frac{HT_1}{2} + \frac{HT_2}{2}}{T} = \frac{\frac{H}{2}(T_1 + T_2)}{T} = \frac{H}{2} \\ &= \frac{1}{2}(P_1 - \lambda_1)T_1 = \frac{(P_1 - \lambda_1)Q}{2P_1} = \frac{Q}{2} \left(1 - \frac{\lambda_1}{P_1}\right)\end{aligned}$$

5. Ajustamos función de costos totales

$$G(Q) = \frac{K}{\frac{Q}{P_1} \left(1 + \frac{P_1 - \lambda_1}{\lambda_2}\right)} + \frac{cQ}{\frac{Q}{P_1} \left(1 + \frac{P_1 - \lambda_1}{\lambda_2}\right)} + h \left(\frac{P_1 - \lambda_1}{2P_1}\right) Q$$

6. Igualamos primer y tercer término y despejamos para Q

$$\begin{aligned}\frac{K}{\frac{Q}{P_1} \left(1 + \frac{P_1 - \lambda_1}{\lambda_2}\right)} &= h \left(\frac{P_1 - \lambda_1}{2P_1}\right) Q \\ \frac{K}{\frac{Q}{P_1} \left(\frac{\lambda_2 + P_1 - \lambda_1}{\lambda_2}\right)} &= h \left(\frac{P_1 - \lambda_1}{2P_1}\right) Q \\ \frac{KP_1\lambda_2}{Q(\lambda_2 + P_1 - \lambda_1)} &= h \left(\frac{P_1 - \lambda_1}{2P_1}\right) Q \\ \frac{KP_1\lambda_2}{\lambda_2 + P_1 - \lambda_1} &= h \left(\frac{P_1 - \lambda_1}{2P_1}\right) Q^2 \\ Q^* &= \frac{2KP_1^2\lambda_2}{h(P_1 - \lambda_1)(\lambda_2 + P_1 - \lambda_1)} \\ \Rightarrow Q^* &= \sqrt{\frac{2KP_1^2\lambda_2}{h(P_1 - \lambda_1)(\lambda_2 + P_1 - \lambda_1)}}\end{aligned}$$

Reemplazamos parámetros y reportamos el valor de Q^*

$$\begin{aligned}Q^* &= \sqrt{\frac{2KP_1^2\lambda_2}{h(P_1 - \lambda_1)(\lambda_2 + P_1 - \lambda_1)}} \\ &= \sqrt{\frac{2(300)(3000)^2(1500)}{(0,5)(3000 - 1000)(1500 + 3000 - 1000)}} \\ &= \sqrt{\frac{8,100,000,000,000}{3,500,000}} \\ &= \sqrt{2,314,285,714,285,714} \\ &\approx 1521,28 \text{ unds.}\end{aligned}$$

7. Tiempo de ciclo

$$\begin{aligned}
T^* &= \frac{Q^*}{P_1} \left(1 + \frac{P_1 - \lambda_1}{\lambda_2} \right) \\
&= \frac{1521,28}{3000} \left(1 + \frac{3000 - 1000}{1500} \right) \\
&= 0,50709 (2,33333) \\
&\approx 1,1832 \text{ años.}
\end{aligned}$$

8. Costos totales anuales

$$G(Q^*) = \frac{K}{T^*} + \frac{cQ^*}{T^*} + h \bar{I}(Q^*)$$

$$T^* \approx 1,18321778 \text{ años,} \quad \bar{I}(Q^*) \approx 507,09333 \text{ unds,} \quad Q^* \approx 1521,28 \text{ unds,}$$

$$\begin{aligned}
G(Q^*) &= \frac{300}{1,18321778} + \frac{5(1521,28)}{1,18321778} + 0,5(507,09333) \\
&\approx 253,54589 + 6428,57142 + 253,54667 \\
&\approx 6935,66397 \text{ \$/año.}
\end{aligned}$$

✧

Ejercicio 1.9 (Desperdicios). Tome una empresa que pasa una primera parte del año produciendo con una tasa de 3000 unds. Durante la segunda parte del año, la empresa se dedica únicamente a distribuir con una demanda de 1500 unds. Últimamente, la implementación de nuevos estándares para el control de calidad del producto ha hecho que el $\alpha = 5\%$ del inventario total al finalizar la etapa de producción sea desechado. En cuanto a costos, Se sabe que la empresa cuenta con un lead time (τ) despreciable, un costo fijo por realizar un pedido de \$300, un costo de adquirir una unidad de \$5 y una tasa de retención de inventario de 10 % cada año. Ajuste un modelo de control de inventario tipo EPL con esta información. Reporte el nivel de inventario promedio, tamaño de lote óptimo, tiempo de ciclo asociado a al tamaño de lote óptimo y costos anuales totales promedio (**Nota:** El hecho de que se describa el comportamiento de la industria diciendo cosas como “primera parte” o “segunda parte” del año NO implica $T_1 = T_2 = T/2$).


Solución:

1. Ponemos datos del enunciado en unidades consistentes

$$P = 3000 \text{ [unds/año]} \quad \lambda = 1500 \text{ [unds/año]} \quad \alpha = 5\%$$

$$i = 0,1 \text{ [1/año]} \quad c = 5 \text{ [$/und]} \quad h = i \cdot c = 0,5 \text{ [$/año-und]} \quad K = 300[\$]$$

2. Hacemos dibujito de Inventario vs. Tiempo



3. Consideramos las siguientes relaciones dadas las ecuaciones fundamentales

a) Ecuación 1:

$$Q = PT_1 \implies T_1 = \frac{Q}{P}$$

b) Ecuación 2:

$$Q * (1 - 0,05) = \lambda T_2 \implies Q = \frac{\lambda T_2}{0,95} \implies T_2 = \frac{(0,95)Q}{\lambda}$$

Entonces

$$T = T_1 + T_2 = \frac{Q}{P} + \frac{(0,95)Q}{\lambda} = Q \left(\frac{1}{P} + \frac{(0,95)}{\lambda} \right)$$

4. Ajustamos función de inventario promedio en términos de Q .

$$\begin{aligned} \bar{I}(Q) &= \frac{A_1 + A_2}{T} = \frac{\frac{QT_1}{2} + \frac{0,95QT_2}{2}}{T} = \frac{Q}{2} \frac{T_1 + 0,95T_2}{T} = \frac{Q}{2} \frac{\frac{Q}{P} + (0,95)^2 \frac{Q}{\lambda}}{\frac{Q}{P} + \frac{(0,95)Q}{\lambda}} \\ &= \frac{Q}{2} \frac{\frac{1}{P} + (0,95)^2 \frac{1}{\lambda}}{\frac{1}{P} + \frac{(0,95)}{\lambda}} = \frac{Q}{2} \cdot \frac{\lambda + 0,95^2 P}{\lambda + 0,95 P} \end{aligned}$$

5. Ajustamos función de costos totales

$$G(Q) = \frac{K}{Q \left(\frac{1}{P} + \frac{(0,95)}{\lambda} \right)} + \frac{cQ}{Q \left(\frac{1}{P} + \frac{(0,95)}{\lambda} \right)} + h \frac{Q}{2} \cdot \frac{\lambda + 0,95^2 P}{\lambda + 0,95 P}$$

6. Igualamos primer y tercer término y despejamos para Q

$$\begin{aligned}
 \frac{K}{Q \left(\frac{1}{P} + \frac{0,95}{\lambda} \right)} &= h \frac{Q}{2} \cdot \frac{\lambda + 0,95^2 P}{\lambda + 0,95 P} \\
 K &= h \frac{Q^2}{2} \left(\frac{1}{P} + \frac{0,95}{\lambda} \right) \cdot \frac{\lambda + 0,95^2 P}{\lambda + 0,95 P} \\
 Q^2 &= \frac{2K}{h \left(\frac{1}{P} + \frac{0,95}{\lambda} \right) \cdot \frac{\lambda + 0,95^2 P}{\lambda + 0,95 P}} \\
 &= \frac{2K}{h \left(\frac{\lambda + 0,95 P}{P \lambda} \right) \cdot \frac{\lambda + 0,95^2 P}{\lambda + 0,95 P}} \\
 &= \frac{2K}{h \left(\frac{\lambda + 0,95^2 P}{P \lambda} \right)} = \frac{2K P \lambda}{h(\lambda + 0,95^2 P)} \\
 \Rightarrow Q^* &= \sqrt{\frac{2K P \lambda}{h(\lambda + 0,95^2 P)}}.
 \end{aligned}$$

Reemplazamos parámetros y reportamos tamaño de lote óptimo (corregido)

$$\begin{aligned}
 Q^* &= \sqrt{\frac{2(300)(3000)(1500)}{0,5(1500 + 0,95^2 \cdot 3000)}} \\
 &= \sqrt{\frac{2,700,000,000}{2,103,75}} = \sqrt{1,283,422,459893} \\
 &\approx 1132,88 \text{ unds.}
 \end{aligned}$$

7. Tiempo de ciclo

$$\begin{aligned}
 T^* &= Q^* \left(\frac{1}{P} + \frac{0,95}{\lambda} \right) \\
 &= 1132,88 \left(\frac{1}{3000} + \frac{0,95}{1500} \right) \\
 &= 1132,88 (0,000333333 + 0,000633333) \\
 &= 1132,88 (0,000966667) \\
 &\approx 1,09512 \text{ años.}
 \end{aligned}$$

8. Costos totales anuales


$$\begin{aligned}
 \bar{I}(Q^*) &= \frac{Q^*}{2} \cdot \frac{1500 + 0,95^2 \cdot 3000}{1500 + 0,95 \cdot 3000} = \frac{1132,88}{2} \cdot \frac{4207,5}{4350} \approx 547,89 \text{ unds,} \\
 G(Q^*) &= \frac{K}{T^*} + \frac{cQ^*}{T^*} + h\bar{I}(Q^*) \\
 &= \frac{300}{1,09512} + \frac{5(1132,88)}{1,09512} + 0,5(547,89) \\
 &\approx 273,94 + 5172,41 + 273,94 \\
 &\approx 5720,30 \text{ \$/año.}
 \end{aligned}$$



Ejercicio 1.10 (Arbolito). Arbolito es una compañía de árboles navideños que posee maquinaria capaz de producir a una tasa P . Debido a las recomendaciones del fabricante de la maquinaria es necesario realizar mantenimientos periódicos. Durante el mantenimiento se debe parar la línea de producción. La compañía se ha percatado que, en la primera sexta parte del ciclo, la producción será la mitad de la capacidad de la máquina. A partir de este momento, hasta $T/2$ la máquina tiene los mantenimientos. Después, la producción será a máxima capacidad hasta $2T/3$ y, finalmente, en el último tercio del ciclo, la demanda de árboles navideños tiene una tasa mensual constante λ . Exponga la forma de la gráfica Inventario vs. Tiempo, exprese las relaciones entre Q , T , λ y P , exprese el inventario promedio en función de T y luego de Q .

Solución:

1. Este ejercicio es más conceptual, entonces no manejaremos datos explícitos
2. Hacemos dibujito de Inventario vs. Tiempo



3. Obtenemos relaciones con ecuaciones fundamentales

a) Ecuación 1:

$$Q = \lambda \frac{T}{3}$$

b) Ecuación 2:

$$Q = \frac{P}{2} \frac{T}{6} + P \frac{T}{6} = \frac{T}{6} \left(\frac{P}{2} + P \right) = \frac{T}{6} \frac{3P}{2} = \frac{TP}{4}$$

4. Ajustamos función de inventario promedio en términos de Q

$$\begin{aligned}
 \bar{I}(Q) &= \frac{A_1 + A_2 + A_3 + A_4 + A_5}{T} \\
 &= \frac{\frac{P}{2} \left(\frac{T}{6}\right)^2 \left(\frac{1}{2}\right) + \frac{P}{2} \left(\frac{T}{6}\right) \left(\frac{T}{3}\right) + \frac{P}{2} \left(\frac{T}{6}\right)^2 + P \left(\frac{T}{6}\right)^2 \left(\frac{1}{2}\right) + \lambda \left(\frac{T}{3}\right)^2 \left(\frac{1}{2}\right)}{T} \\
 &= \frac{\frac{P}{2} \left(\frac{T^2}{36}\right) \left(\frac{1}{2}\right) + \frac{P}{2} \left(\frac{T^2}{18}\right) + \frac{P}{2} \left(\frac{T^2}{36}\right) + P \left(\frac{T^2}{36}\right) \left(\frac{1}{2}\right) + \lambda \left(\frac{T^2}{9}\right) \left(\frac{1}{2}\right)}{T} \\
 &= \frac{\frac{PT^2}{144} + \frac{PT^2}{36} + \frac{PT^2}{72} + \frac{PT^2}{72} + \frac{\lambda T^2}{18}}{T} \\
 &= \frac{\left(\frac{1}{144} + \frac{1}{36} + \frac{1}{72} + \frac{1}{72}\right) PT^2 + \frac{\lambda T^2}{18}}{T} \\
 &= \frac{\frac{1}{16} PT^2 + \frac{1}{18} \lambda T^2}{T} = \left(\frac{P}{16} + \frac{\lambda}{18}\right) T
 \end{aligned}$$

Usando $T = \frac{3Q}{\lambda}$ obtenemos:

$$\begin{aligned}
 \bar{I}(Q) &= \frac{P}{16} \left(\frac{3Q}{\lambda}\right) + \frac{\lambda}{18} \left(\frac{3Q}{\lambda}\right) \\
 &= \frac{3P}{16\lambda} Q + \frac{1}{6} Q
 \end{aligned}$$

Podemos dejar a P en función de λ tal que $P = \frac{3\lambda}{4}$ obteniendo

$$= \frac{5Q}{12}$$

Nota importante: En este tipo de ejercicios tenemos que estar atentos a la cantidad de corridas de inventario que se hacen. En este caso, tendremos dos corridas de inventario, por ende, el costo fijo de ordenar K debe entrar multiplicado por 2 en la función de costos si se nos llega a pedir.

⌋

Bonus: Este tipo de ejercicios también se pueden sacar con buscar objetivo. Ver [EPL con buscar objetivo.xlsx](#)

1.2. MRP y modelos con demanda determinística y dinámica

Para este tipo de modelos, seguiremos asumiendo que sabemos exactamente cuál va a ser la demanda en los siguientes periodos. No obstante, no fijamos el esquema de costos y otros parámetros. Entradas como el lead time (τ) pueden variar entre periodos. Asimismo, como empezaremos a trabajar con un lead time no despreciable y no necesariamente constante

en el tiempo, tendremos que introducir nuevos conceptos para hacer un buen Material Requirements Planning (MRP) en ejercicios anidados.

Definición 1.1 (BOM). El Bill of Materials (BOM) es una lista jerárquica de todos los componentes, subcomponentes y materias primas necesarios para fabricar una unidad de un producto terminado, junto con las cantidades requeridas de cada uno y sus respectivos lead times.

Ejemplo 1.3 (Un sándwich). Supongamos que estamos en una empresa de comida rápida y tenemos que ajustar las órdenes de ingredientes para el producto estrella: un sándwich. Veamos qué podemos esperar del BOM este producto.




Figura 1.7: BOM de un sándwich con tiempos de entrega (τ) por ítem.

¿Por qué es importante saber qué es el BOM?

Porque dependiendo de este vamos a tener que cuadrar en qué momento se ordenan los componentes de cada unidad de producto y de qué forma se administran los inventarios de los mismos.

Notemos que a pesar de pertenecer a un mismo producto, el manejo de inventarios de los sub componentes pueden no ser los mismos. El tener bien establecido el BOM facilita la comunicación entre componentes. Para próximas heurísticas seguiremos la siguiente lógica para llevar a cabo esta comunicación entre componentes al establecer modelos de manejo de inventarios.

Intuición: Al bajar por el BOM, basta con seguir el flujo “natural” del producto. Si en cierto momento decidimos producir (o liberar) una cantidad del producto final, automáticamente estamos fijando cuántos componentes necesitaremos después. Por ejemplo, si liberamos una orden para hacer sándwiches, esa decisión define cuántos panes se requieren; y, a su vez, decidir cuántos panes se van a hacer fija cuánta harina y levadura deben estar disponibles. En otras palabras, cada decisión en un nivel del BOM arrastra, de forma directa, los requerimientos del nivel inferior.

Esta intuición caracterizará la forma en la que “navegaremos” el BOM de ahora en adelante:

¿Cómo bajamos por el BOM?

El Requerimiento Bruto (RB) del siguiente subcomponente es la Liberación de Orden Planificada (LOP) del componente actual multiplicado por la cantidad de subcomponentes que se necesitan.

1.2.1. Heurística Lote a Lote

Esta primera heurística se caracteriza por intentar ordenar exactamente lo que se requiere en cada periodo. Con esto, se intentan minimizar costos de inventario, pero pueden generarse costos excesivos por ordenar puesto que se harán muchos pedidos.

Notación heurística Lote a Lote

Parámetros:

- Requerimiento bruto (RB_t): Proyección de cantidad de material que se necesita para cada periodo.
- Recepción programada (RP_t): Cantidad de material que llega en un periodo específico ajeno a la producción de la empresa.
- Stock de seguridad (SS_t): Inventario guardado en el periodo t .
- Requerimiento neto (RN_t): Requerimiento de material sumando stock de seguridad y quitando las recepciones programadas y el inventario disponible .
- Inventario (I_t): Inventario al final del periodo t .
- Recepción de Orden Planificada (ROP_t): Orden que se espera que llegue en cada periodo.
- Liberación de Orden Planificada (LOP_t): Orden que se espera que sea liberada en cada periodo.
- Lead time (τ) : Es el tiempo de demora entre la orden del pedido y su llegada.

Costos:

- K : Costo de hacer un pedido [\$/pedido].
- c : Costo de adquirir una unidad [\$/und].
- i : Porcentaje de inventario que se guarda en un periodo específico [%/Tiempo].
- h : Costo de almacenar una unidad durante un periodo en específico [\$/Tiempo-und].

Ecuaciones heurística Lote a Lote**Propios del modelo:**

$$RB_t = D_t$$

$$RP_t = \text{Nos lo da el enunciado}$$

$$RN_t = RB_t + SS_t - RP_t - I_{t-1}$$

$$I_t^{(\text{proy})} = I_{t-1} + RP_t + RN_t - RB_t$$

$$LOP_t = RN_{t+\tau} \quad (\text{Cuando } \tau \text{ es constante})$$

$$ROP_t = LOP_{t-\tau}$$

$$I_t^{(\text{real})} = I_{t-1} + RP_t + ROP_t - RB_t$$

Costos:

$$\text{CT. Ordenar} = (\# \text{ Periodos con } LOP > 0) \cdot K$$

$$\text{CT. Adquirir} = \left(\sum_t LOP_t \right) \cdot c$$

$$\text{CT. Adquirir} = \left(\sum_t I_t^{(\text{real})} \right) \cdot h$$

¿Por qué hacemos una distinción entre inventario “proyectado” e inventario “real”?

Porque es la única forma en la que a mí no me daba fórmula circular en Excel cuando hay lead times variables en el tiempo.

Receta: Encontrar estructura de costos totales dada una demanda determinada para T periodos en el futuro y un lead time posiblemente variable en el tiempo.

Periodo
RB
RP
SS
RN
$I^{(\text{Proy})}$
LOP
ROP
$I^{(\text{Real})}$

★ **Estructura de despacho de pedidos:**

1. | Periodo | : Poner acorde al enunciado. Generalmente empezamos desde uno antes para poder poner parámetros I_0 e ir actualizando los inventarios de forma más cómoda.
2. | RB_t | : Poner acorde al enunciado.

3. | RP_t | : Poner acorde al enunciado.
4. | SS_t | : Poner acorde al enunciado. Generalmente es una fracción de la demanda.
5. | RN_t | : $RB_t + SS_t - RP_t - I_{t-1}^{(\text{Proy})}$ y arrastrar hasta el final de la derecha.
6. | $I_t^{(\text{proy})}$ | : $I_{t-1}^{(\text{proy})} + RP_t + RN_t - RB_t$ y arrastrar hasta el final de la derecha
(**Nota:** Tendremos que inicializar también valor de I_0 si nos lo dan).
7. | LOP_t | : Vemos cuál es el $RN_{t+\tau}$. Si el τ es constante, podemos usar $LOP_t = RN_{t+\tau}$. En caso de que τ sea variable, tenemos que ver la forma en la que se satisfaga la demanda ordenando periodos antes (ver 1.12).
8. | ROP_t | : Movemos el LOP_t el lead time τ periodos en el futuro usando $ROP_t = LOP_{t-\tau}$.
9. | $I_t^{(\text{real})}$ | : $I_{t-1}^{(\text{real})} + RP_t + ROP_t - RB_t$ y arrastrar hasta el final de la derecha
(**Nota:** Tendremos que inicializar también valor de I_0 si nos lo dan).

★ **Estructura de costos:**

10. Calculamos costos totales de ordenar pedidos.

$$\text{CT. Ordenar} = (\# \text{ Periodos con } LOP > 0) \cdot K$$

Notemos que lo hacemos con el LOP_t y no con el RN_t porque puede que en casos con lead time variable no se pida cada vez que hay demanda, o sea puede que hayan menos pedidos que periodos con demanda positiva (ver 1.12).

11. Calculamos costos totales de adquirir las unidades ordenadas.

$$\text{CT. Adquirir} = \left(\sum_t LOP_t \right) \cdot c$$

12. Calculamos costos totales de mantener las unidades ordenadas.

$$\text{CT. Adquirir} = \left(\sum_t I_t^{(\text{real})} \right) \cdot h$$

★ **Siguientes componentes:**

13. Ver si hay subcomponentes para los que debemos ajustar una heurística. En caso de que lo haya, establecer su RB como el LOP actual multiplicado por la cantidad necesaria (como lo vimos en la cajita al inicio de la sección) y hacer nueva tabla según la heurística que se emplee.

Ejercicio 1.11 (Lead time constante). Tome una empresa con un lead time (τ) despreciable y la siguiente estructura de demanda para los siguientes periodos

Periodo	1	2	3	4	5	6
Demanda (RB)	40	60	70	20	90	160

Cuadro 1.1: Demanda bruta (RB) por periodo

Y la siguiente estructura de costos

- K : 300 [\$].
- h : 2 [\$/periodo-und].
- c : 10 [\$/und].
- I_0 : 0 [unds].

Ajuste un modelo Lote a Lote de control de inventarios y reporte su costo total.

Solución: Veamos el siguiente Excel y notemos que lo llenamos fila por fila siguiendo la receta anterior. [Lote a Lote con lead time Constante.xlsx](#)



Ejercicio 1.12 (Lead time variable). Tome una empresa con un lead time (τ) despreciable y la siguiente estructura de demanda para los siguientes periodos

Semana	0	1	2	3	4	5	6
Lead time (semanas)	1	2	2	2	3	1	
Demanda (unds)		420	450	330	420	390	330

Cuadro 1.2: Demanda y lead time por semana

Y la siguiente estructura de costos

- K : 70000 [\$].
- c : 5000 [\$/und].
- i : 3 % [1/semana].
- I_0 : 120 [unds].
- Porcentaje de retención de demanda como SS_t : 30 %.

Ajuste un modelo Lote a Lote de control de inventarios y reporte su costo total.

Solución: Veamos el siguiente Excel y notemos que lo llenamos fila por fila siguiendo la receta anterior. Observemos que dada la variabilidad del lead time, hay periodos en donde ordenamos para abastecer varias semanas en el futuro. [Lote a Lote con lead time variable.xlsx](#)



1.2.2. Heurística POQ

La heurística de Period Order Quantity (POQ) busca agrupar la demanda de varios períodos en un mismo pedido, con el fin de reducir los costos de ordenar. Para ello, se aproxima un tiempo de ciclo óptimo asumiendo una demanda promedio constante y, a partir de este, se realizan pedidos que cubren exactamente la demanda de un número fijo de períodos consecutivos. De esta forma, POQ intenta balancear los costos de inventario y los costos de preparación, evitando tanto pedidos demasiado frecuentes como excesivos niveles de inventario.

Notación Heurística POQ

Parámetros:

- Requerimiento bruto (RB_t): Proyección de cantidad de material que se necesita para cada periodo.
- Recepción programada (RP_t): Cantidad de material que llega en un periodo específico ajeno a la producción de la empresa.
- Stock de seguridad (SS_t): Inventario guardado en el periodo t .
- Requerimiento neto (RN_t): Requerimiento de material sumando stock de seguridad y quitando las recepciones programadas y el inventario disponible .
- Inventario (I_t): Inventario al final del periodo t .
- Recepción de Orden Planificada (ROP_t): Orden que se espera que llegue en cada periodo.
- Liberación de Orden Planificada (LOP_t): Orden que se espera que sea liberada en cada periodo.
- Lead time (τ) : Es el tiempo de demora entre la orden del pedido y su llegada.

POQ:

- $\bar{D}$: Promedio de las demandas que nos dan.
- D_i : Demanda del i -ésimo periodo.
- EOQ : Cantidad de orden óptima dada por el modelo básico EOQ.
- N : Cantidad de periodos para los cuales tenemos demanda.

Costos:

- K : Costo de hacer un pedido [\$/pedido].
- c : Costo de adquirir una unidad [\$/und].
- i : Porcentaje de inventario que se guarda en un periodo específico [%/Tiempo].
- h : Costo de almacenar una unidad durante un periodo en específico [\$/Tiempo-und].

Ecuaciones heurística POQ**Generales:**

$$RB_t = D_t$$

$$RP_t = \text{Nos lo da el enunciado}$$

$$RN_t = RB_t + SS_t - RP_t - I_{t-1}$$

$$I_t^{(\text{proy})} = I_{t-1} + RP_t + RN_t - RB_t$$

$$LOP_t = RN_{t+\tau} \quad (\text{Cuando } \tau \text{ es constante})$$

$$ROP_t = LOP_{t-\tau}$$

$$I^{(\text{real})} = I_{t-1} + RP_t + ROP_t - RB_t$$

Propios del modelo:

$$EOQ = \sqrt{\frac{2K\lambda}{h}} = \sqrt{\frac{2K\bar{D}}{h}}$$

$$\bar{D} = \frac{\sum_{i=1}^N D_i}{N}$$

$$T_{\text{ciclo}} = EOQ / \bar{D} = \left(\sqrt{\frac{2K\bar{D}}{h}} \right) / \bar{D}$$

Costos:

$$\text{CT. Ordenar} = (\# \text{ Periodos con } LOP > 0) \cdot K$$

$$\text{CT. Adquirir} = \left(\sum_t LOP_t \right) \cdot c$$

$$\text{CT. Adquirir} = \left(\sum_t I_t^{(\text{real})} \right) \cdot h$$

Receta:

Periodo
RB
RP
SS
RN
$I^{(\text{Proy})}$
LOP
ROP
$I^{(\text{Real})}$

★ Inicialización de parámetros

1. Identificamos demandas pronosticadas $\{D_i\}_{i=1}^N$.
2. Sacamos promedio de estas $\bar{D} = \frac{\sum_{i=1}^N D_i}{N}$.

3. Identificamos el EOQ

$$EOQ = \sqrt{\frac{2K\lambda}{h}} = \sqrt{\frac{2K\bar{D}}{h}}$$

4. Sacamos

$$T_{ciclo} = EOQ/\bar{D} = \left(\sqrt{\frac{2K\bar{D}}{h}} \right) / \bar{D}$$

Y redondeamos al entero más cercano (a menos de que se nos indique lo contrario).

★ **Inicialización estándar del método**

5. | Periodo | : Poner acorde al enunciado. Generalmente empezamos desde uno antes para poder poner parámetros I_0 e ir actualizando los inventarios de forma más cómoda.
6. | RB | : Poner acorde al enunciado.
7. | RP | : Poner acorde al enunciado.
8. | RN | : $RB_t + SS_t - RP_t - I_{t-1}$ y arrastrar hasta el final de la derecha.
9. | $I^{(Proy)}$ | : $I_{t-1}^{(Proy)} + RP_t + RN_t - RB_t$ y arrastrar hasta el final de la derecha.

★ **Aplicación de la heurística**

10. | LOP | : Consideramos el T_{ciclo} que sacamos anteriormente, encontramos el primer periodo para el cual necesitamos realizar una orden y hacemos pedidos cada T_{ciclo} periodos desde ahí en adelante.
11. | ROP | : Desplazamos τ periodos el LOP que hemos encontrado. Notemos que generalmente $ROP_t \neq RN_t$ en este método.
12. | $I^{(real)}$ | : Aplicamos $I_t^{(real)} = I_{t-1}^{(real)} + RP_t + ROP_t - RB_t$.

★ **Estructura de costos:**

13. Calculamos costos totales de ordenar pedidos.

$$CT. Ordenar = (\# \text{ Periodos con } LOP > 0) \cdot K$$

Notemos que lo hacemos con el LOP_t y no con el RN_t porque puede que en casos con lead time variable no se pida cada vez que hay demanda, o sea puede que hayan menos pedidos que periodos con demanda positiva (ver 1.12).

14. Calculamos costos totales de adquirir las unidades ordenadas.

$$CT. Adquirir = \left(\sum_t LOP_t \right) \cdot c$$

15. Calculamos costos totales de mantener las unidades ordenadas.

$$CT. Adquirir = \left(\sum_t I_t^{(real)} \right) \cdot h$$

★ **Siguientes componentes:**

16. Ver si hay subcomponentes para los que debamos ajustar una heurística. En caso de que lo haya, establecer su RB como el LOP actual multiplicado por la cantidad necesaria (como lo vimos [en la cajita al inicio de la sección](#)) y hacer nueva tabla según la heurística que se emplee.

Ejercicio 1.13 (Lead time despreciable). Tome una empresa con un lead time (τ) despreciable y la siguiente estructura de demanda para los siguientes periodos

Periodo	1	2	3	4	5	6
Demanda (RB)	40	60	70	20	90	160

Cuadro 1.3: Demanda bruta (RB) por periodo

Y la siguiente estructura de costos

- $K : 300$ [\$].
- $h : 2$ [\$/periodo-und].
- $c : 10$ [\$/und].
- $I_0 : 0$ [unds].

Ajuste un modelo tipo POQ de control de inventarios y reporte su costo total.

Solución: Veamos el siguiente Excel y notemos que lo llenamos fila por fila siguiendo la receta anterior. [POQ con lead time despreciable.xlsx](#)



Ejercicio 1.14 (Lead time constante con BOM). Considere un producto final P que requiere dos subcomponentes A . La estructura (BOM) es lineal. La demanda del producto final P (requerimiento bruto) para los siguientes periodos es:

Periodo	1	2	3	4	5	6
RB de P (unds)	20	0	30	0	20	0

Cuadro 1.4: Requerimiento bruto (RB) del producto final P .

Suponga que no se permiten faltantes y que el inventario inicial es cero en todos los ítems: $I_0^P = I_0^A = 0$. Los lead times (constantes) son:

$$\tau_P = 2, \quad \tau_A = 1$$

La estructura de costos (por periodo) para cada ítem es:

- **Producto final P :** $K_P = 200$ [\$], $h_P = 7$ [\$/periodo-und], $c_P = 20$ [\$/und].

- **Subcomponente A:** $K_A = 120$ [\$], $h_A = 2$ [\$/periodo-und], $c_A = 8$ [\$/und].

Asimismo, se planea ajustar un stock de seguridad del 10 % de la demanda del producto terminado P y se tienen dos recepciones programadas del producto A : una de 5 unidades en el periodo 3 y otra de 10 unidades en el periodo 5. Con esta información:

- Dibuje el BOM señalando el lead time y la cantidad de componente y sus respectivas cantidades para fabricar una unidad de su predecesor.
- Construya el MRP de P y A (RB, RN, ROP, LOP e inventario final) y determine el plan de liberación de órdenes. Luego, aplique la heurística POQ al ítem P y reporte el costo total de la política (ordenar + mantener + compra/producción).

Solución:

- Hacemos dibujo del BOM con la información del enunciado.




Figura 1.8: BOM en cadena: $P \rightarrow A$ con lead times constantes.

- Sigamos la receta llenando el siguiente Excel línea por línea. [POQ con lead time constante y BOM.xlsx](#)

Notemos que en ejemplos como este podemos llegar a tener periodos con $RN_t < 0$. En estos casos, como esto no tiene sentido, fijaremos $RN_t = 0$.

✎

1.2.3. Heurística EOQ

Nos basamos en la teoría de la anterior heurística y ahora en vez de basarnos en un tiempo de ciclo constante, intentaremos ordenar una cantidad constante de producto a lo largo de los periodos, notaremos que las fórmulas serán casi iguales, simplemente que la aplicación de las mismas estará enfocada al pedido por periodo en vez del tiempo de ciclo.

Notación Heurística EOQ**Parámetros:**

- Requerimiento bruto (RB_t): Proyección de cantidad de material que se necesita para cada periodo.
- Recepción programada (RP_t): Cantidad de material que llega en un periodo específico ajeno a la producción de la empresa.
- Stock de seguridad (SS_t): Inventario guardado en el periodo t .
- Requerimiento neto (RN_t): Requerimiento de material sumando stock de seguridad y quitando las recepciones programadas y el inventario disponible .
- Inventario (I_t): Inventario al final del periodo t .
- Recepción de Orden Planificada (ROP_t): Orden que se espera que llegue en cada periodo.
- Liberación de Orden Planificada (LOP_t): Orden que se espera que sea liberada en cada periodo.
- Lead time (τ) : Es el tiempo de demora entre la orden del pedido y su llegada.

POQ:

- $\bar{D}$: Promedio de las demandas que nos dan.
- D_i : Demanda del i -ésimo periodo.
- EOQ : Cantidad de orden óptima dada por el modelo básico EOQ.
- N : Cantidad de periodos para los cuales tenemos demanda.

Costos:

- K : Costo de hacer un pedido [\$/pedido].
- c : Costo de adquirir una unidad [\$/und].
- i : Porcentaje de inventario que se guarda en un periodo específico [%/Tiempo].
- h : Costo de almacenar una unidad durante un periodo en específico [\$/Tiempo–und].

Ecuaciones heurística EOQ**Generales:**

$$RB_t = D_t$$

$$RP_t = \text{Nos lo da el enunciado}$$

$$RN_t = RB_t + SS_t - RP_t - I_{t-1}$$

$$I_t^{(\text{proy})} = I_{t-1} + RP_t + RN_t - RB_t$$

$$LOP_t = RN_{t+\tau} \quad (\text{Cuando } \tau \text{ es constante})$$

$$ROP_t = LOP_{t-\tau}$$

$$I^{(\text{real})} = I_{t-1} + RP_t + ROP_t - RB_t$$

Propios del modelo:

$$EOQ = \sqrt{\frac{2K\lambda}{h}} = \sqrt{\frac{2K\bar{D}}{h}}$$

$$\bar{D} = \frac{\sum_{i=1}^N D_i}{N}$$

Costos:

$$\text{CT. Ordenar} = (\# \text{ Periodos con } LOP > 0) \cdot K$$

$$\text{CT. Adquirir} = \left(\sum_t LOP_t \right) \cdot c$$

$$\text{CT. Adquirir} = \left(\sum_t I_t^{(\text{real})} \right) \cdot h$$

Receta:

Periodo
RB
RP
SS
RN
$I^{(\text{Proy})}$
LOP
ROP
$I^{(\text{Real})}$

★ Inicialización de parámetros

1. Identificamos demandas pronosticadas $\{D_i\}_{i=1}^N$.
2. Sacamos promedio de estas $\bar{D} = \frac{\sum_{i=1}^N D_i}{N}$.

3. Identificamos el EOQ

$$EOQ = \sqrt{\frac{2K\lambda}{h}} = \sqrt{\frac{2K\bar{D}}{h}} = T_{ciclo} * \bar{D}$$

Y redondeamos al entero más cercano en caso de no manejar unidades parciales.

★ **Inicialización estándar del método**

4. | RB | : Poner acorde al enunciado.
5. | RP | : Poner acorde al enunciado.
6. | RN | : $RB_t + SS_t - RP_t - I_{t-1}$ y arrastrar hasta el final de la derecha.
7. | I | : $I_{t-1} + RP_t + RN_t - RB_t$ y arrastrar hasta el final de la derecha.

★ **Aplicación de la heurística**

8. | LOP | :

$$LOP_t = \begin{cases} \max\{EOQ; RN_{t+1}\} & , \text{ si } RN_{t+1} > 0 \\ 0 & , \text{ si } RN_{t+1} \leq 0 \end{cases}$$

9. | ROP | : Transladamos el LOP τ periodos en el futuro.
10. | $I^{(real)}$ | : $I_t^{(real)} = I_{t-1} + RP_t + ROP_t - RB_t$

★ **Estructura de costos:**

11. Calculamos costos totales de ordenar pedidos.

$$CT. \text{ Ordenar} = (\# \text{ Periodos con } LOP > 0) \cdot K$$

Notemos que lo hacemos con el LOP_t y no con el RN_t porque puede que en casos con lead time variable no se pida cada vez que hay demanda, o sea puede que hayan menos pedidos que periodos con demanda positiva (ver 1.12).

12. Calculamos costos totales de adquirir las unidades ordenadas.

$$CT. \text{ Adquirir} = \left(\sum_t LOP_t \right) \cdot c$$

13. Calculamos costos totales de mantener las unidades ordenadas.

$$CT. \text{ Adquirir} = \left(\sum_t I_t^{(real)} \right) \cdot h$$

★ **Siguientes componentes:**

14. Ver si hay subcomponentes para los que debamos ajustar una heurística. En caso de que lo haya, establecer su RB como el LOP actual multiplicado por la cantidad necesaria (como lo vimos en la cajita al inicio de la sección) y hacer nueva tabla según la heurística que se emplee.

1.2.4. Heurística PPB

Para la heurística Part-Period Balancing (PPB) nos basaremos en el hecho que cuando el costo de ordenar y el costo de mantener alcanzan valores iguales, encontramos la política óptima para ordenar (esta conclusión viene del modelo EOQ, específicamente de la Proposición A.3). Así pues, este método tendrá una tabla de iteración asociada que indicará el criterio de paro: que los costos vuelvan a subir. No obstante, al tener demanda dinámica, no podemos asegurar que alcanzaremos un óptimo global.

Receta:

★ Forma general de tabla de inventarios:

Periodo	-1	0	1	...
RB	Enunciado	Enunciado	Enunciado	Enunciado
RP	Enunciado	Enunciado	Enunciado	Enunciado
SS	Enunciado	Enunciado	Enunciado	Enunciado
RN	0	$RB_0 + SS_0 - RP_0$	$RB_1 + SS_1 - RP_1$	...
LOP	Tabla aux	Tabla aux	Tabla aux	Tabla aux
ROP	$LOP_{-1+\tau}$	$LOP_{0+\tau}$	$LOP_{1+\tau}$	...
I	Enunciado	$I_{-1} + RP_0 + ROP_0 - RB_0$	$I_0 + RP_1 + ROP_1 - RB_1$	...

★ Forma general de tabla de iteración:

Pido en	P. satisf.	Q=RN	CT.Ord	Inv	CT.Mant	$\Delta Cost$	T
---------	------------	------	--------	-----	---------	---------------	-----

Nota: La columna de “Inv” no es necesaria pero se incluye para tener constancia del inventario que se va acumulando periodo a periodo.

No se darán más detalles de la forma de la tabla de iteración puesto que esta depende de los lead times y la notación que se maneje en cuanto al nombre de los periodos.

La intuición es que cada vez que se llega a un óptimo en el número de periodos a satisfacer (o sea, el $\Delta Cost$ baja y vuelve a subir), el RN asociado se pone como LOP en la tabla de inventarios.

Veamos ejemplos para entender bien cómo se comporta esta conexión entre tablas de costos e inventarios.

Ejercicio 1.15 (PPB con lead time despreciable). Tome una empresa con un lead time (τ) despreciable y la siguiente estructura de demanda para los siguientes periodos

Periodo	1	2	3	4	5	6
Demanda (RB)	40	60	70	20	90	160

Cuadro 1.5: Demanda bruta (RB) por periodo

Y la siguiente estructura de costos

- $K : 300$ [\$].

- $h : 2$ [\$/período-und].
- $c : 10$ [\$/und].
- $I_0 : 0$ [unds].

Ajuste un modelo tipo PPB de control de inventarios y reporte su costo total.

Solución: Veamos el siguiente Excel notando cómo se comunican ambas tablas en el desarrollo del ejemplo. [PPB con lead time despreciable.xlsx](#)



Ejercicio 1.16 (PPB con lead time y costos variables). Tome una empresa con la siguiente estructura de demanda

Periodo	Marzo	Abril	Mayo	Junio	Julio	Agosto
RB	0	998	708	750	770	756
RP	0	0	140	0	400	780
SS	0	350	0	250	130	200

Y la siguiente estructura de costos

Periodo	Marzo	Abril	Mayo	Junio	Julio	Agosto
Costo de ordenar	1200	700	1000	600	1500	900
Cost. Mant. unitario x mes	5	2	3	1	6	4

Ajuste un modelo tipo PPB de control de inventarios y reporte su costo en cada iteración teniendo en cuenta que se tiene un lead time de un mes y un inventario de 550 unidades den el mes de marzo.

Solución: Veamos el siguiente Excel notando cómo se comunican ambas tablas en el desarrollo del ejemplo. Se tiene que tener en cuenta que en el desarrollo del ejercicio no se mantiene el inventario inicial. [PPB con lead time y costos variables.xlsx](#)



1.2.5. Heurística Silver Meal

La heurística de Silver–Meal es un método de control de inventarios para demanda determinística y dinámica que, al igual que PPB, construye iterativamente bloques de periodos que serán abastecidos con un solo pedido. Para ello, se apoya en una tabla de iteración auxiliar en la que se evalúa, para distintos tamaños de bloque, el costo asociado a cubrir un número creciente de periodos con una única orden. A diferencia de PPB, cuyo criterio de selección busca balancear el costo de ordenar con el costo total de mantener inventario, Silver–Meal se fundamenta en el costo promedio por periodo.

Matemáticamente, ¿qué cambia?

En PPB teníamos como criterio de parada alcanzar una política que tuviera

$$\text{CT. Ordenar} \approx \text{CT. Mantener} \iff K \approx h \sum_{t=1}^T I_t$$

Fundamentado en la teoría de EOQ, específicamente en Proposición A.3. Ahora, queremos alcanzar una política que tenga

$$\frac{\text{Costo Total de cubrir } T \text{ periodos con un solo pedido}}{T} = \frac{K + h \sum_{t=1}^T I_t}{T} \approx 0$$

O por lo menos minimice esta cantidad.

Haremos esto siguiendo la misma lógica que con PPB: mediante una tabla de iteración, pero ¿cómo sabemos que esta cantidad anteriormente expresada baja y vuelve a subir? Al igual que en PPB, no podemos asegurar convexidad ni unimodalidad porque la demanda no necesariamente será constante, por ende tenemos la posibilidad de caer en óptimos locales.

Receta:

★ Forma general de tabla de inventarios:

Periodo	-1	0	1	...
RB	Enunciado	Enunciado	Enunciado	Enunciado
RP	Enunciado	Enunciado	Enunciado	Enunciado
SS	Enunciado	Enunciado	Enunciado	Enunciado
RN	0	$RB_0 + SS_0 - RP_0$	$RB_1 + SS_1 - RP_1$	...
LOP	Tabla aux	Tabla aux	Tabla aux	Tabla aux
ROP	$LOP_{-1+\tau}$	$LOP_{0+\tau}$	$LOP_{1+\tau}$	...
I	Enunciado	$I_{-1} + RP_0 + ROP_0 - RB_0$	$I_0 + RP_1 + ROP_1 - RB_1$	...

★ Forma general de tabla de iteración:

Pido en	P. satisf.	Q=RN	CT.Ord	Inv	CT.Mant	$\sum \text{Cost}/T$	T
---------	------------	------	--------	-----	---------	----------------------	-----

Nota: La columna de “Inv” no es necesaria pero se incluye para tener constancia del inventario que se va acumulando periodo a periodo.

No se darán más detalles de la forma de la tabla de iteración puesto que esta depende de los lead times y la notación que se maneje en cuanto al nombre de los periodos.

La intuición es que cada vez que se llega a un óptimo en el número de periodos a satisfacer (o sea, el $\sum \text{Cost}/T$ baja y vuelve a subir), el RN asociado se pone como LOP en la tabla de inventarios.

Veamos ejemplos para entender bien cómo se comporta esta conexión entre tablas de costos e inventarios.

Ejercicio 1.17 (Silver Meal con lead time despreciable). Tome una empresa con un lead time (τ) despreciable y la siguiente estructura de demanda para los siguientes periodos

Periodo	1	2	3	4	5	6
Demanda (RB)	40	60	70	20	90	160

Cuadro 1.6: Demanda bruta (RB) por periodo

Y la siguiente estructura de costos

- $K : 300$ [\$].
- $h : 2$ [\$/periodo-und].
- $c : 10$ [\$/und].
- $I_0 : 0$ [unds].

Ajuste un modelo tipo Silver Meal de control de inventarios y reporte su costo total.

Solución: Veamos el siguiente Excel notando cómo se comunican ambas tablas en el desarrollo del ejemplo. [Silver Meal con lead time despreciable.xlsx](#)



1.3. Modelos con demanda estocástica

Una demanda estocástica se diferencia de una determinística porque no se asume que se sabe con exactitud la cantidad de producto que será requerida en cada periodo, no obstante, se sabe que el comportamiento incierto de esta se ajusta a una distribución de probabilidad. Para la mayoría de casos, nos apoyaremos en el Teorema del Límite Central y en la Ley Fuerte de Grandes Números para asumir que la demanda se distribuye normal.

En la vida real, ¿cómo sabemos que una demanda incierta se ajusta a una distribución de probabilidad particular?

Podemos observar el comportamiento histórico de la demanda y hacer pruebas estadísticas de bondad de ajuste (tipo Shapiro-Wilk para distribución normal o Kolmogorov-Smirnov para casos más generales).

1.3.1. Modelo de vendedor de diarios

Este es un método de manejo de inventarios que intenta vender todo el producto que se posee en un único periodo. Lo que se vende a partir de este, se deprecia significativamente. El producto es ordenado al comienzo del periodo, y sólo sirve para satisfacer la demanda de ese periodo, y los costos dependen del inventario final.

Teoría detrás del modelo

Nos ubicamos en un modelo que maneja una demanda incierta D_t , $t \in \mathcal{T}$, donde $\mathcal{T}$ es el conjunto de periodos en donde vamos a operar. Como la demanda es estocástica, D_t

seguirá una distribución de probabilidad, por ende a diferencia de anteriores temas, en este caso tendremos la posibilidad de no poder abastecer totalmente la demanda, o de tener sobrantes. Por esto, definiremos costos unitarios de exceso y de faltantes de inventario C_o, C_u respectivamente.

El objetivo del modelo es escoger Q antes de observar la demanda aleatoria D , minimizando el costo esperado asociado al desbalance: excedentes cuando $Q > D$ y faltantes cuando $Q < D$. Para cuantificarlo definimos la pérdida esperada

$$G(Q) = \mathbb{E}[C_o(Q - D)_+ + C_u(D - Q)_+]$$

donde $(x)_+ = \max\{x, 0\}$ y $C_o, C_u \geq 0$. Para cada realización fija $D = d$, las funciones $(Q - d)_+ = \max\{Q - d, 0\}$ y $(d - Q)_+ = \max\{d - Q, 0\}$ son máximos de funciones afines en Q , por lo tanto son convexas; además, una combinación lineal con pesos no negativos preserva convexidad, así que $C_o(Q - d)_+ + C_u(d - Q)_+$ es convexa en Q . Finalmente, al tomar esperanza sobre D , la convexidad se conserva, de modo que $G(Q)$ es convexa y el problema se reduce a minimizar una función convexa de una variable.

Como $G(Q)$ es convexa, cualquier punto que satisfaga una condición de primer orden es óptimo global. En el caso continuo, podemos derivar $G(Q)$ e igualar a cero. Usando que

$$\frac{d}{dQ}(Q - D)_+ = \mathbf{1}\{D \leq Q\} \quad \frac{d}{dQ}(D - Q)_+ = -\mathbf{1}\{D > Q\}$$

obtenemos

$$G'(Q) = \mathbb{E}[C_o \mathbf{1}\{D \leq Q\} - C_u \mathbf{1}\{D > Q\}] = C_o \mathbb{P}(D \leq Q) - C_u \mathbb{P}(D > Q)$$

Si denotamos por $F(Q) = \mathbb{P}(D \leq Q)$ la función de distribución acumulada de D , entonces

$$G'(Q) = C_o F(Q) - C_u (1 - F(Q))$$

La condición óptima $G'(Q^*) = 0$ implica

$$C_o F(Q^*) = C_u (1 - F(Q^*)) \implies F(Q^*) = \frac{C_u}{C_o + C_u}$$

Por tanto, el nivel óptimo de inventario corresponde al cuantil crítico

$$Q^* = F^{-1}\left(\frac{C_u}{C_o + C_u}\right)$$

En el caso discreto, la condición anterior se interpreta en términos de subgradiantes y puede haber un intervalo de óptimos; una convención estándar es escoger el menor Q tal que $F(Q) \geq \frac{C_u}{C_o + C_u}$. Como D es continua con densidad f , podemos calcular esperanzas condicionando por el valor que toma la demanda.

Los faltantes ocurren únicamente cuando $D \geq Q$, y en ese caso la magnitud del faltante es $D - Q$; por la fórmula de la esperanza de una función de una v.a. continua,

$$\mathbb{E}[\text{Faltantes}] = \mathbb{E}[(D - Q)_+] = \int_Q^\infty (x - Q) f(x) dx$$

De manera análoga, los sobrantes ocurren únicamente cuando $D \leq Q$, y en ese caso la magnitud del sobrante es $Q - D$; por tanto,

$$\mathbb{E}[\text{Sobrantes}] = \mathbb{E}[(Q - D)_+] = \int_{-\infty}^Q (Q - x) f(x) dx$$

Hay distribuciones (como la normal continua) donde calcular estos valores usando la definición es complicado, por ende habrán trucos que explicaremos más adelante para calcular valores esperados y tamaño de pedido óptimo Q^* de forma más directa.

Solución del modelo

Notación Vendedor de diarios

Valores propios del modelo:

- f : Función de masa/densidad de probabilidad de distribución de probabilidad que sigue la demanda.
- F : Función de probabilidad acumulada de distribución de probabilidad que sigue la demanda.
- C_o : Costo unitario de exceso de inventario (el subíndice corresponde a “overproduction”).
- C_u : Costo unitario de inventario faltante (el subíndice corresponde a “underproduction”).
- Q : Número de unidades a ordenar al principio del periodo.
- $G(Q, D)$: Costo total de exceso/escasez de inventario al final de un periodo.
- $G(Q, x)$: Costo total de exceso/escasez de inventario al final de un periodo dado un pedido de x unidades.
- $\mathbb{E}[\text{Sobrantes}]$: Número esperado de unidades sobrantes.
- $\mathbb{E}[\text{Faltantes}]$: Número esperado de unidades faltantes.
- Cantidad que minimiza los costos.
- $F(Q^*)$: Probabilidad acumulada asociada a la cantidad que minimiza los costos.
- v : Precio de venta unitario.
- c : Costo variable unitario.
- r : Valor de recompra unitario.
- Nivel de servicio Tipo I = Tipo 1 = α
- Nivel de servicio tipo II = β

Interpretaciones de NSI:

1. Relación crítica.
2. Probabilidad de no tener faltantes, la probabilidad de tener faltantes estará dada por $1 - \alpha$.
3. Probabilidad de tener sobrantes.
4. Nivel de servicio tipo I.
5. Proporción de ciclos sin faltantes.

Interpretaciones de NSII:

1. Proporción de la demanda que es cubierta con las existencias.

Ecuaciones Vendedor de diarios

$$C_u = v - c$$

$$C_o = c - r$$

$$F(Q^*) = \frac{C_u}{C_o + C_u} = \frac{v - c}{v - r}$$

$$Q^* = F^{-1}\left(\frac{C_u}{C_o + C_u}\right)$$

$$\mathbb{E}[\text{Faltantes}] = \int_Q^\infty (Q - D)f(x)dx$$

$$\mathbb{E}[\text{Sobrantes}] = \int_{-\infty}^Q (Q - D)f(x)dx$$

$$\mathbb{E}[\text{Demanda}] = \mathbb{E}[\text{Distr Prob}]$$

$$\alpha = \frac{\text{Ciclos sin faltantes}}{\text{Ciclos totales}} = F(Q)$$

$$\beta = 1 - \frac{\text{Faltantes esperados por ciclo}}{\text{Demanda esperada en el ciclo}} = 1 - \frac{\mathbb{E}[\text{Faltantes}]}{\mathbb{E}[\text{Demanda}]} = 1 - \frac{\mathbb{E}[\text{Faltantes}]}{\mathbb{E}[\text{Distr Prob}]}$$

$$\begin{aligned} \text{Costos totales} &= G(Q) = C_o \mathbb{E}[(Q - D)_+] + C_u \mathbb{E}[(D - Q)_+] \\ &= \text{Costos totales de sobrantes} + \text{Costos totales de faltantes} \\ &= C_o \mathbb{E}[\text{Sobrantes}] + C_u \mathbb{E}[\text{Faltantes}] \end{aligned}$$

Receta (caso continuo): Dados parámetros de distribución y costos encontrar Q^* , valores esperados de faltantes y sobrantes y niveles de servicio.

Parámetros en temporalidad correcta

c en unds correctas
v en unds correctas
r en unds correctas

C_o
C_u

.....

★ **Distr. Normal:**

$F(Q^*)$
Z
Q^*
$L(Z)$
$L(-Z)$
$\mathbb{E}[Faltantes]$
$\mathbb{E}[Sobrantes]$

★ **Distr. Uniforme**

$F(Q^*)$
Q^*
$\mathbb{E}[Faltantes]$
$\mathbb{E}[Sobrantes]$

.....

$NSI = \alpha$
$NSII = \beta$

1. Establecer parámetros según la distribución en las mismas unidades.

★ **Uniforme:**

- I. Mínimo a
- II. Máximo b

★ **Normal:**

- I. Media μ
- II. Desviación σ

2. Establecer costo variable unitario c , precio de venta unitario v y costo de reventa r .
3. Encontrar costo unitario de exceso de inventario

$$C_u = v - c$$

y costo unitario de inventario faltante

$$C_o = c - r$$

4. Encontrar política óptima:

★ **Uniforme:**

- I. Encontrar probabilidad acumulada asociada a las unidades óptimas

$$F(Q^*) = \frac{C_u}{C_o + C_u} = \frac{v - c}{v - r}$$

Calcular las unidades óptimas asociadas

$$Q^* = F(Q^*)(b - a) + a$$

★ **Normal:**

- I. Encontrar probabilidad acumulada asociada a las unidades óptimas

$$F(Q^*) = \frac{C_u}{C_o + C_u} = \frac{v - c}{v - r}$$

- II. Estandarización de la probabilidad

$$Z = \text{DISTR.NORM.ESTAND.INV}(F(Q^*))$$

- III. Encontrar cantidad óptima

$$Q^* = \mu + Z\sigma$$

- IV. Encontrar
- $L(Z)$
- y
- $L(-Z)$

$$L(Z) = \text{DISTR.NORM}(z; 0; 1; 0) - z * (1 - \text{DISTR.NORM.ESTAND}(z))$$

$$L(-Z) = \text{DISTR.NORM}(-z; 0; 1; 0) + z * (1 - \text{DISTR.NORM.ESTAND}(-z))$$

5. Encontrar valores esperados de faltantes y sobrantes según la distribución

★ **Uniforme:**

$$\mathbb{E}[\text{Sobrantes}] = \frac{(Q - a)^2}{2(b - a)}$$

$$\mathbb{E}[\text{Faltantes}] = \frac{(Q - b)^2}{2(b - a)}$$

★ **Normal:**

$$\mathbb{E}[\text{Sobrantes}] = \sigma L(-Z)$$

$$\mathbb{E}[\text{Faltantes}] = \sigma L(Z)$$

6. Encontrar niveles de servicio

$$NSI = \alpha = F(Q^*)$$

★ **Uniforme**

$$\begin{aligned} NSII = \beta &= 1 - \frac{\text{Faltantes esperados por ciclo}}{\text{Demanda esperada en el ciclo}} = 1 - \frac{\mathbb{E}[\text{Faltantes}]}{\mathbb{E}[\text{Demanda}]} \\ &= 1 - \frac{2\mathbb{E}[\text{Faltantes}]}{a + b} \end{aligned}$$

★ **Normal**

$$\begin{aligned}
 NSII = \beta &= 1 - \frac{\text{Faltantes esperados por ciclo}}{\text{Demanda esperada en el ciclo}} = 1 - \frac{\mathbb{E}[Faltantes]}{\mathbb{E}[Demanda]} \\
 &= 1 - \frac{\mathbb{E}[Faltantes]}{\mu}
 \end{aligned}$$

Ejercicio 1.18 (Vendedor de diarios con Uniforme continua). Tome una empresa con costo de venta unitario de \$7.500, costo variable unitario de \$3.500 y costo de reventa unitario de \$2.250. Se sabe que la demanda se distribuye uniforme continua con mínimo 20 unidades y máximo 40 unidades. Ajuste un modelo tipo vendedor de diarios expresando los valores del tamaño óptimo de pedido, los valores esperados de faltantes y sobrantes y los niveles de servicio.

Solución:

Podemos usar la siguiente fórmula teniendo en cuenta la función de probabilidad acumulada de la uniforme continua

$$F(Q^*) = \frac{C_u}{C_o + C_u} = \frac{v - c}{v - r}$$

Pero para sacar Q^* tendremos que sacar la inversa acumulada de la distribución. Como Excel no tiene una función directa para este cálculo, tendremos que hacerlo a mano.

Sea $D \sim \text{Unif}(a, b)$ con $a < b$. Su densidad es

$$f_D(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{en otro caso.} \end{cases}$$

La función de distribución acumulada $F_D(Q) = \mathbb{P}(D \leq Q)$ se obtiene integrando la densidad:

$$F_D(Q) = \int_{-\infty}^Q f_D(x) dx = \begin{cases} 0, & Q < a, \\ \int_a^Q \frac{1}{b-a} dx = \frac{Q-a}{b-a}, & a \leq Q \leq b, \\ 1, & Q > b. \end{cases}$$

Si $a \leq Q \leq b$ y queremos imponer $F_D(Q) = \alpha$, entonces

$$F_D(Q) = \frac{Q-a}{b-a} \implies Q-a = F_D(Q)(b-a) \implies Q = a + F_D(Q)(b-a).$$

De igual forma, si queremos encontrar los valores de $\mathbb{E}[Faltantes]$ y $\mathbb{E}[Sobrantes]$ lo haremos manualmente.

Sea $D \sim \text{Unif}(a, b)$ y suponga $a \leq Q \leq b$. Entonces:

$$\mathbb{E}[Faltantes] = \mathbb{E}[(D-Q)_+] = \int_Q^b (x-Q) \frac{1}{b-a} dx = \frac{1}{b-a} \left[\frac{(x-Q)^2}{2} \right]_Q^b = \frac{(b-Q)^2}{2(b-a)}.$$

$$\mathbb{E}[\text{Sobranes}] = \mathbb{E}[(Q - D)_+] = \int_a^Q (Q - x) \frac{1}{b - a} dx = \frac{1}{b - a} \left[\frac{(Q - x)^2}{2} \right]_a^Q = \frac{(Q - a)^2}{2(b - a)}.$$

El siguiente Excel tiene este ejemplo integrado con las fórmulas directas siguiendo el procedimiento explicado en la “Receta”: [Vendedor de diarios Uniforme continua.xlsx](#).

✎

Ejercicio 1.19 (Vendedor de diarios Normal continua). Tome una empresa con costo de venta unitario de \$7.500, costo variable unitario de \$3.500 y costo de reventa unitario de \$2.250. Se sabe que la demanda se distribuye normal continua con media de 30 unidades y desviación estandar de 10 unidades. Ajuste un modelo tipo vendedor de diarios expresando los valores del tamaño óptimo de pedido, los valores esperados de faltantes y sobranes y los niveles de servicio.

Solución:

Podemos usar la siguiente fórmula considerando la función de probabilidad acumulada de la normal

$$F(Q^*) = \frac{C_u}{C_o + C_u}$$

donde F es la CDF de D

Como $D \sim \mathcal{N}(\mu, \sigma^2)$, tenemos

$$F(Q) = \Phi\left(\frac{Q - \mu}{\sigma}\right).$$

Definimos la estandarización

$$Z := \frac{Q - \mu}{\sigma}.$$

Entonces la ecuación $F(Q^*) = \alpha$ equivale a

$$\Phi(Z^*) = \alpha \implies Z^* = \Phi^{-1}(\alpha), \quad Q^* = \mu + \sigma Z^*.$$

(Esto es exactamente el “truco” de estandarizar para pasar de cuantiles de D a cuantiles de la normal estándar.)

Para faltantes y sobranes, partimos de las identidades generales

$$\mathbb{E}[(D - Q)_+] = \int_Q^\infty (x - Q) f_D(x) dx, \quad \mathbb{E}[(Q - D)_+] = \int_{-\infty}^Q (Q - x) f_D(x) dx,$$

donde f_D es la densidad de D .

Ahora sustituimos $x = \mu + \sigma u$, con $dx = \sigma du$ y $Q = \mu + \sigma z$. Usando φ y Φ como densidad y CDF de la normal estándar:

1) Faltantes:

$$\mathbb{E}[(D - Q)_+] = \int_Q^\infty (x - Q) f_D(x) dx = \sigma \int_z^\infty (u - z) \varphi(u) du =: \sigma L(z),$$

donde la “loss function” estándar puede escribirse como

$$L(z) = \int_z^\infty (u - z)\varphi(u) du = \varphi(z) - z(1 - \Phi(z)).$$

2) Sobrantes:

$$\mathbb{E}[(Q - D)_+] = \int_{-\infty}^Q (Q - x)f_D(x) dx = \sigma \int_{-\infty}^z (z - u)\varphi(u) du = \sigma L(-z) = \sigma(\varphi(z) + z\Phi(z)).$$

En particular, evaluando en el óptimo $z = Z^*$:

$$\mathbb{E}[\text{Faltantes}] = \sigma L(Z^*), \quad \mathbb{E}[\text{Sobrantes}] = \sigma L(-Z^*).$$

¿No entendimos qué acaba de pasar?

Si bien esto es lo que hacemos por detrás, el siguiente Excel resuelve este ejercicio acorde a la “Receta” que explicamos al inicio de la sección, con fórmulas que hacen que no tengamos que integrar y que el procedimiento sea más directo. [Vendedor de diarios Normal continua.xlsx](#).



Como comentario final de este primer caso, notemos que no necesariamente nos preguntarán de estas dos distribuciones. El modelo se extiende a cualquier otra distribución continua con una función de probabilidad acumulada manejable. Vale la pena preguntarnos si esto se puede extender a otros casos. Por ejemplo, ¿cómo se replicaría este ejemplo con los mismos costos iniciales, pero bajo una distribución exponencial con parámetro $\lambda = 4$? ¿De una triangular con los mismos costos y con los parámetros $a = 10, b = 20, c = 40$?

Pregunta extra (tranquil@s, no veremos este caso en el curso): ¿Con demanda que se distribuye Gamma podemos “despejar” Q^* como en la Uniforme o la Exponencial?

Respuesta: En general, no. Con Gamma la regla sigue siendo $F(Q^*) = \alpha$, pero la función de densidad acumulada Gamma no se invierte con una fórmula elemental. Por eso Q^* se calcula numéricamente usando la función de cuantil (inversa de la función de densidad acumulada) en software. Solo en casos especiales como cuando tenemos el parámetro $k = 1$ (Exponencial) sí hay despeje simple.

Receta (caso discreto): Dados parámetros de distribución y costos encontrar Q^* , valores esperados de faltantes y sobrantes y niveles de servicio.

★ **Inicialización:**

v
c
r

Parámetros

6. | $f(x)$ | : Ponemos función de masa de probabilidad asociada al comportamiento de demanda.

◇ **Poisson**

$$f(x_i) = \text{POISSON.DIST}(x_i; \lambda; \text{FALSO})$$

◇ **Uniforme discreta**

$$f(x_i) = \begin{cases} \frac{1}{b-a+1} = \frac{1}{n}, & x_i \in \{a, a+1, \dots, b\} \\ 0, & d.l.c \end{cases}$$

7. | $F(x)$ | : Ponemos función de probabilidad acumulada asociada al comportamiento de demanda.

◇ **Poisson**

$$F(x_i) = \text{POISSON.DIST}(x_i; \lambda; \text{VERDADERO})$$

◇ **Uniforme discreta (aplica para todas en realidad)**

$$F(x_i) = \begin{cases} f(x_1), & i = 1 \\ f(x_i) + F(x_{i-1}), & i > 1 \end{cases}$$

8. | *Diferencia* | : Encontramos la diferencia entre la política óptima y la política asociada a cada x_i

$$Diferencia_i = F(x_i) - F(Q^*)$$

9. Encontramos el primer valor de $F(x)$ que supere el de $F(Q^*)$ y vemos el x asociado. Este será nuestro Q^* .

10. | $Q - D$ (*Sobrantes*) | : $(Q - D_i) = (Q - x_i) = \begin{cases} (Q^* - x_i), & \text{si } Q^* > x_i \\ 0, & d.l.c \end{cases}$

11. | $D - Q$ (*Faltantes*) | : $(D_i - Q) = (x_i - D) = \begin{cases} (x_i - Q^*), & \text{si } x_i > Q^* \\ 0, & d.l.c \end{cases}$

12. Determinamos el punto de convergencia, o sea cuando la columna de Diferencia toma valores constantes (generalmente cuando $F(Q) = 1$). Identificamos el intervalo desde el primer valor hasta la convergencia del método.

13. | $\mathbb{E}[\text{Sobrantes}]$ | : Calculamos

$$=\text{SUMAPRODUCTO}(\text{intervalo convergencia } f(x); \text{ intervalo convergencia } Q-D)$$

14. | $\mathbb{E}[\text{Faltantes}]$ | : Calculamos

$$=\text{SUMAPRODUCTO}(\text{intervalo convergencia } f(x); \text{ intervalo convergencia } D-Q)$$

★ **Encontramos niveles de servicio**

15. NSI:

$$\alpha = F(Q^*)$$

16. NSII:

$$\beta = 1 - \frac{\text{Faltantes esperados por ciclo}}{\text{Demanda esperada en el ciclo}} = 1 - \frac{\mathbb{E}[Faltantes]}{\mathbb{E}[Demanda]}$$

◇ **Poisson**

$$\beta = 1 - \frac{\mathbb{E}[Faltantes]}{\lambda}$$

◇ **Uniforme discreta**

$$\beta = 1 - \frac{2\mathbb{E}[Faltantes]}{a + b}$$

Ejercicio 1.20 (Vendedor de diarios con Poisson). Tome una empresa con costo de venta unitario de \$7.500, costo variable unitario de \$3.500 y costo de reventa unitario de \$2.250. Se sabe que la demanda se distribuye Poisson con tasa de 300 unds mensuales.

- I) Ajuste un modelo tipo vendedor de diarios expresando los valores del tamaño óptimo de pedido, los valores esperados de faltantes y sobrantes y los niveles de servicio para un mes de operación.
- II) Si la empresa cambia de política estableciendo una probabilidad de no tener faltantes de por lo menos 0,98, ¿cuál es el tamaño de pedido óptimo asociado?
- III) Si la empresa establece un tamaño de pedido fijo de 300 unidades, ¿cuál es el nivel de servicio tipo 1?

Solución:

- I) Seguimos paso a paso la receta al principio de la sección y reportamos los datos pedidos.
- II) Como no cambian ni los parámetros ni los costos iniciales, simplemente buscamos el Q tal que $F(Q) > 0,98$.
- III) Como el pedido se vuelve fijo, usamos

$$=\text{POISSON.DIST}(300; \lambda = 300; \text{VERDADERO})$$

Veamos el siguiente Excel en donde están los cálculos descritos anteriormente [Vendedor de diarios Poisson.xlsx](#).

✎

Ejercicio 1.21 (Vendedor de diarios con Uniforme discreta). Tome una empresa con costo de venta unitario de \$7.500, costo variable unitario de \$3.500 y costo de reventa unitario de \$2.250. Se sabe que la demanda se distribuye uniforme discreta con mínimo 50 unidades y máximo 100 unidades. Ajuste un modelo tipo vendedor de diarios expresando

los valores del tamaño óptimo de pedido, los valores esperados de faltantes y sobrantes y los niveles de servicio de operación.

Solución:

Seguimos paso a paso la receta al principio de la sección y reportamos los datos pedidos. Veamos el siguiente Excel en donde están los cálculos descritos anteriormente [Vendedor de diarios Uniforme Discreta.xlsx](#).



1.3.2. Modelo Q–R

En el modelo Q – R monitoreamos el inventario de forma continua. Cada vez que la posición de inventario alcanza el punto de reorden R , se emite un pedido fijo de tamaño Q . Debido al lead time τ , el pedido no llega de inmediato pues durante τ el inventario sigue cayendo al seguir siendo demandado. Cuando arriba el pedido, el inventario se incrementa en Q y el ciclo se repite (Figura 1.9).




Figura 1.9: Comportamiento típico del modelo Q – R : al alcanzar R se ordena Q ; tras τ llega el pedido y el inventario salta en Q .

Nota: Como este modelo es de demanda estocástica, la anterior figura es una simplificación del comportamiento real de la demanda, pues en la práctica, esta no será constante.

Construcción de solución iterativa del modelo en Backorders

El modelo de Backorders (pedidos en atraso) se aplica cuando sí aceptamos la demanda aunque no tengamos inventario, pero la atendemos después, cuando llegue reposición.

La construcción y demostración de este modelo requerirá conocimientos fuera del alcance del curso. Igual los incluiremos y demostraremos en la sección de apéndices. En esta sub-sección teórica solo nos referiremos a los resultados más relevantes.

Comencemos por definir los parámetros que usaremos. Heredamos las interpretaciones de K, h, c, λ, f y F de anteriores modelos e introducimos el costo por unidad faltante p y la demanda media esperada durante el lead time en [unidades] de la compañía $\mu_\tau = \mu \cdot \tau$. La función de costos que queremos minimizar se compondrá por la suma de

1. Costo total por ordenar en un ciclo:

$$K \frac{\lambda}{Q}$$

2. Costo total de adquirir:

$$c\lambda$$

3. Costo total de mantener inventario:

$$\left(\frac{Q}{2} + R - \mu_\tau + n(R) \right) h$$

4. Costo total por unidades faltantes

$$p n(R) \frac{\lambda}{Q}$$

La función de costos totales queda tal que

$$G(Q, R) = K \frac{\lambda}{Q} + c\lambda + \left(\frac{Q}{2} + R - \mu_\tau + n(R) \right) h + p n(R) \frac{\lambda}{Q}$$

Esta función no es convexa para proceder con una minimización estándar. Por la Proposición A.4 esta es biconvexa. Por ende, nuestra intención será optimizar simultáneamente 2 variables: Q y R . Para esto, vamos a sacar derivadas parciales. De los despejes de anexos (A.2.1 y A.14) tendremos

$$Q^*(R) = \sqrt{\frac{2\lambda(K + p n(R))}{h}}$$

$$F(R^*(Q)) = \frac{p\lambda}{hQ + p\lambda}$$

Luego de esto, construiremos una sucesión $\{Q_i, R_i\}$, optimizando primero Q_i y luego R_i . Por la Proposición A.7, esta sucesión converge. Los valores finales (Q^*, R^*) serán los outputs principales del modelo.

¿Y si tenemos que acoplarnos a un nivel de servicio tipo II dado?

En este caso los supuestos generales se mantienen pero cambian las ecuaciones de los óptimos (ver (A.12) y (A.5)). Tendremos en cada iteración

$$Q_i = \frac{n(R)_{i-1}}{1 - F(R)_{i-1}} + \sqrt{\frac{2K\lambda}{h} + \left(\frac{n(R)_{i-1}}{1 - F(R)_{i-1}} \right)^2}$$

$$F(R_i) = \Phi(z_i)$$

Solución del modelo**Notación modelo Q-R**

- $f(x_\tau)$: Función de densidad/masa de probabilidad asociada.
- $F(x_\tau)$: Función de probabilidad acumulada.
- $\mathbb{E}[X_\tau]$: Valor esperado de la distribución de probabilidad asociada teniendo en cuenta el tiempo de entrega.
- $\text{Var}(x_\tau)$: Varianza de la distribución de probabilidad asociada teniendo en cuenta el tiempo de entrega.
- R : Punto de reorden.
- SS : Stock de seguridad.
- $\bar{I}$: Inventario promedio.
- $\mathbb{E}[Faltantes] = n(R)$: Valor esperado de unidades faltantes.
- $\text{NSI} = \alpha$: Nivel de servicio tipo I.
- $\text{NSII} = \beta$: Nivel de servicio tipo II.
- T : Tiempo de ciclo.
- $G(Q, R)$: Función de costos totales promedios esperados.

Interpretaciones de NSI:

1. Relación crítica.
2. Probabilidad de no tener faltantes, la probabilidad de tener faltantes estará dada por $1 - \alpha$.
3. Probabilidad de tener sobrantes.
4. Nivel de servicio tipo I.
5. Proporción de ciclos sin faltantes.

Interpretaciones de NSII:

1. Proporción de la demanda que es cubierta con las existencias.

Ecuaciones modelo Q-R

$$\mathbb{E}[Faltantes] = n(R) = \int_R^{\infty} (x_{\tau} - R) * f(x_{\tau}) dx_{\tau}$$

$$T = Q/\lambda$$

$$NSI = \alpha = F(R)$$

$$NSII = \beta = 1 - \frac{\text{Valor esperado de faltantes en el ciclo}}{\text{Valor esperado de la demanda en el ciclo}} = 1 - \frac{n(R)}{\mu_{\text{ciclo}}} = 1 - \frac{n(R)}{Q}$$

Si nos dan/piden inventario promedio

$$\bar{I} = \frac{Q}{2} + SS$$

Para distr. Normal

$$\mu_{\tau} = \mu * \tau$$

$$\sigma_{\tau} = \sigma * \sqrt{\tau} \iff \sigma_{\tau}^2 = \sigma^2 * \tau$$

$$SS = S - \mu_{\tau}$$

$$Z = \frac{R - \mu_{\tau}}{\sigma_{\tau}} = \text{INV.NORM.ESTAND}(F(R))$$

$$R = \mu_{\tau} + Z\sigma_{\tau}$$

$$L(Z) = \text{DISTR.NORM.ESTAND.N}(Z; \text{FALSO}) - Z * (1 - \text{DISTR.NORM.ESTAND.N}(Z; \text{VERDADERO}))$$

$$n(R) = L(Z) * \sigma_{\tau}$$

$$\mathbb{E}[\text{Sobranes}] = L(-Z) * \sigma_{\tau}$$

Para distr. Uniforme

$$R = F(R) * (b - a) + a$$

$$\mathbb{E}[Faltantes] = \frac{(R - b)^2}{2 * (b - a)}$$

Backorders:

$$G(Q, R) = K \frac{\lambda}{Q} + c\lambda + \left(\frac{Q}{2} + R - \mu_{\tau} \right) h + pn(R) \frac{\lambda}{Q}$$

$$Q = \sqrt{\frac{2\lambda(K + pn(R))}{h}}$$

$$1 - F(R) = \frac{Qh}{p\lambda}$$

Ventas perdidas:

$$G(Q, R) = K \frac{\lambda}{Q} + c\lambda + \left(\frac{Q}{2} + R - \mu_{\tau} + n(R) \right) h + pn(R) \frac{\lambda}{Q}$$

$$Q = \sqrt{\frac{2\lambda(K + pn(R))}{h}}$$

$$1 - F(R) = \frac{Qh}{Qh + p\lambda}$$

Receta Q-R iterativo sin α o β dado: Dar valor óptimo de Q , R , niveles de servicio y probabilidad de faltantes dados costos, λ y σ .

Iteración
Q
F(R)
Z
R
L(Z)
n(R)

★ **Parámetros:** Establecemos los siguientes parámetros en las mismas unidades

1. τ [T]
2. K : Costo por hacer pedido [\$]
3. i : Porcentaje de inventario que se almacena [%].
4. c : Costo unitario [\$/und].
5. h : Costo de mantenimiento de inventario $h = i * c$ [\$/Tiempo-und]
6. p : Costo por unidad faltante [\$/und].
7. Parámetros de la distribución de la demanda.

◇ **Normal:**

- I. Media μ también referida en los ejercicios como λ [unds/T]
- II. Desviación estándar σ [unds/ $\sqrt{T}$]
- III. $\mu_\tau = \mu * \tau = \lambda * \tau$ [unds]
- IV. $\sigma_\tau = \sigma * \sqrt{\tau}$ [unds]

★ **Tabla de iteración**

8. Q : donde i es la iteración que hacemos

$$Q_i = \begin{cases} EOQ = \sqrt{\frac{2 * K * \lambda}{h}}, & \text{si } i = 0 \\ \sqrt{\frac{2 * \lambda * (K + p * n(R)_{i-1})}{h}}, & \text{si } i > 0 \end{cases}$$

9. $F(R)$:

Backorders:

$$F(R)_i = 1 - \frac{Q * h}{p * \lambda}$$

Ventas perdidas:

$$F(R)_i = 1 - \frac{Q * h}{Q * h + p * \lambda}$$

$$10. Z := \text{INV.NORM.ESTAND}(F_i(R))$$

$$11. R :$$

$$R_i = Z\sigma_\tau + \mu_\tau$$

$$12. L(Z) :$$

$$L(Z)_i = \text{DISTR.NORM.ESTAND.N}(Z; \text{FALSO}) - Z * (1 - \text{DISTR.NORM.ESTAND.N}(Z; \text{VERDADERO}))$$

$$13. n(R) :$$

$$n(R)_i = L(Z)_i * \sigma_\tau$$

14. Arrastramos hasta que Q y R convergen.

★ **Niveles de servicio**

$$15. NSI = \alpha = F(R)$$

$$16. NSII = \beta = 1 - \frac{n(R)}{Q}$$

Ejercicio 1.22 (Q-R iterativo). Tome una empresa con un lead time de 25 días, un costo de hacer un pedido de \$70000, un costo de mantener una unidad un día de \$160 y un costo de \$6543 por unidad faltante. Asimismo, se sabe que la demanda se distribuye normal y que tiene media diaria de 24 unds y desviación mensual de 67 unidades. Ajuste un modelo de inventarios tipo Q-R con backorders y reporte el valor del tamaño de lote óptimo, el punto de reorden óptimo, los niveles de servicio y el valor esperado de faltantes. Asuma que un mes tiene 30 días.

Solución:

En este tipo de ejercicios es importante hacer las conversiones de unidades correspondientes para que todos los parámetros queden en unidades consistentes. Notemos que las unidades de la desviación necesitan un ajuste. Por ende, efectuaremos

$$\sigma = 67 \frac{[\text{unds}]}{[\text{mes}]} \cdot \frac{1[\text{mes}]}{30[\text{días}]} \approx 12,232$$

Veamos el siguiente Excel en donde seguimos el procedimiento de la anterior receta para llegar al resultado que se nos pide. [Q-R iterativo.xlsx](#)



Receta Q-R iterativo con β dado (nivel de servicio tipo II): Dar valor óptimo de Q , R , niveles de servicio y probabilidad de faltantes dados costos, λ y σ .

Iteración
Q
n(R)
F(R)
Z
R

★ **Parámetros:** Establecemos los siguientes parámetros en las mismas unidades:

1. τ [T]
2. K : Costo por hacer pedido [\$]
3. i : Porcentaje de inventario que se almacena [%]
4. c : Costo unitario [\$/und]
5. h : Costo de mantenimiento de inventario, $h = i \cdot c$ [\$/und-Tiempo]
6. β : Nivel de servicio tipo II (proporción de la demanda satisfecha sin faltantes)

7. Parámetros de la distribución de la demanda

◇ **Normal:**

- I. Media μ también referida como λ [unds/T]
- II. Desviación estándar σ [unds/ $\sqrt{T}$]
- III. $\mu_\tau = \mu \cdot \tau = \lambda \cdot \tau$ [unds]
- IV. $\sigma_\tau = \sigma \cdot \sqrt{\tau}$ [unds]

★ **Tabla de iteración**

8. Q :

$$Q_i = \begin{cases} EOQ = \sqrt{\frac{2K\lambda}{h}}, & \text{si } i = 0 \\ \frac{n(R)_{i-1}}{1-F(R)_{i-1}} + \sqrt{\frac{2K\lambda}{h} + \left(\frac{n(R)_{i-1}}{1-F(R)_{i-1}}\right)^2}, & \text{si } i > 0 \end{cases}$$

9. $n(R)$:

$$n(R)_i = (1 - \beta) \cdot Q_i$$

10. $F(R)$:

$$F(R)_i = \text{DISTR. NORM. ESTAND}(Z_i; \text{VERDADERO})$$

11. Z : = z tal que $\sigma_\tau \cdot L(z) = n(R)_i$ (sacar con buscar objetivo).

12. R :

$$R_i = Z_i \cdot \sigma_\tau + \mu_\tau$$

13. Repetir la iteración hasta que Q y R converjan.

★ **Niveles de servicio**

$$14. NSII = \beta = 1 - \frac{n(R)}{Q}$$

$$15. NSI = \alpha = F(R)$$

Receta R óptimo dado un Q y un NSI:

1. Inicializar valor de R , luego encontraremos el valor óptimo.
2. Establecer $F(R) = \alpha = \text{DISTR.NORM.N}(R; \mu_\tau; \sigma_\tau; \text{VERDADERO})$
3. Usar buscar objetivo para encontrar un R tal que el NSI objetivo sea igual que el $F(R)$ que acabamos de calcular.

★ **Para calcular el NSII:**

4. Encontramos $Z = \frac{R - \mu_\tau}{\sigma_\tau}$

5. Encontramos

$$L(Z) = \text{DISTR.NORM.ESTAND.N}(Z; \text{FALSO}) - Z * (1 - \text{DISTR.NORM.ESTAND.N}(Z; \text{VERDADERO}))$$

6. Encontrar $n(R) = \sigma_\tau * L(Z)$

7. Podemos usar el Q que nos piden asumir, o si lo piden, $Q = EOQ = \sqrt{\frac{2 * K * \lambda}{h}}$

8. Finalmente, encontramos $\beta = 1 - \frac{n(R)}{Q}$

Ejercicio 1.23 (R^* y β asociado dado un Q). Tome una empresa con un lead time de 25 días, un costo de hacer un pedido de \$70000, un costo de mantener una unidad un día de \$160 y un costo de \$6543 por unidad faltante. Asimismo, se sabe que que la demanda se distribuye normal y que tiene media diaria de 300 unds y desviación diaria de 64 unidades. La empresa maneja una política actual con un tamaño de lote de 100 unidades con el que esperan tener un nivel de servicio tipo 1 del 85 %. Ajuste un modelo de inventarios tipo Q-R con backorders y reporte el valor del punto de reorden óptimo y el porcentaje de demanda cubierto con las existencias.

Solución:

Veamos el siguiente Excel con la solución del ejemplo. [QR para R y beta teniendo Q y NSI.xlsx](#)



Receta R óptimo dado un Q y un NSII

1. Inicializar valor de R , luego encontraremos el valor óptimo.
2. Encontramos $Z = \frac{R - \mu_\tau}{\sigma_\tau}$
3. Encontramos

$$L(Z) = \text{DISTR.NORM.ESTAND.N}(Z; \text{FALSO}) - Z * (1 - \text{DISTR.NORM.ESTAND.N}(Z; \text{VERDADERO}))$$

4. Encontrar $n(R) = \sigma_\tau * L(Z)$

5. Podemos usar el Q que nos piden asumir, o si lo piden, $Q = EOQ = \sqrt{\frac{2 * K * \lambda}{h}}$

6. Finalmente, encontramos $\beta = 1 - \frac{n(R)}{Q}$

7. Usar Buscar objetivo para encontrar un valor de R que haga que el NSII que nos dieron coincida con el que acabamos de calcular.

Ejercicio 1.24 (R^* dado un Q y un NSII). Tome una empresa con un lead time de 25 días, un costo de hacer un pedido de \$70000, un costo de mantener una unidad un día de \$160 y un costo de \$6543 por unidad faltante. Asimismo, se sabe que que la demanda se distribuye normal y que tiene media diaria de 300 unds y desviación diaria de 64 unidades. La empresa maneja el EOQ como tamaño de lote con el que esperan tener un nivel de servicio tipo 1 del 90 %. Ajuste un modelo de inventarios tipo $Q-R$ con backorders y reporte el valor del punto de reorden óptimo.

Solución:

Veamos el siguiente Excel con la solución del ejemplo. [QR para R teniendo Q y NSII.xlsx](#)



1.3.3. Modelo S-T

El modelo de inventarios S-T es un sistema de revisión periódica donde el inventario se inspecciona cada T unidades de tiempo. En cada revisión se emite un pedido para elevar la posición de inventario hasta el nivel objetivo S . La demanda que ocurre entre revisiones va consumiendo inventario y el objetivo es escoger (S, T) para balancear el costo de ordenar, mantener inventario y penalizar faltantes, análogamente a como en $Q-R$ balanceamos Q y R .




Figura 1.10: Comportamiento típico del modelo $S-T$: cada T se revisa y se ordena para alcanzar S ; tras τ llega el pedido y el inventario salta en Q_k .

Para este modelo no haremos énfasis en una forma iterativa de resolverlo. Asumiremos en todo caso que la demanda se distribuye normal y que tenemos acceso al tiempo de ciclo objetivo T .

Notación modelo S-T

- S : Nivel de inventario objetivo.
- T : Tiempo entre ordenes.
- τ : Tiempo de entrega de ordenes.
- SS : Stock de seguridad.
- $n(S)$: Valor esperado de faltantes.
- ★ **Para distr. Normal:**
 - $\mu = \lambda$: Tasa de inventario [unds/Tiempo]
 - σ : Desviación estándar de la distribución [unds/ $\sqrt{\text{Tiempo}}$]
 - $\mu_{T+\tau}$: Parámetro media de la distribución [unds].
 - $\sigma_{T+\tau}$: Parámetro desviación estándar de la distribución [unds].

Interpretaciones de NSI:

1. Relación crítica
2. Probabilidad de no tener faltantes, la probabilidad de tener faltantes estará dada por $1 - \alpha$
3. Probabilidad de tener sobrantes
4. Nivel de servicio tipo I.

Interpretaciones de NSII:

1. Proporción de la demanda que es cubierta con las existencias.

Ecuaciones modelo S-T**Para distr. Normal (solamente manejaremos este caso):**

$$Z = \text{INV.NORM.ESTAND}(\alpha)$$

$$SS = Z\sigma_{T+\tau}$$

$$\mathbb{E}[\text{Faltantes}] = L(Z) * \sigma_{T+\tau}$$

$$\mathbb{E}[\text{Sobrantes}] = L(-Z) * \sigma_{T+\tau}$$

$$S = \lambda\tau + \lambda T + SS = \lambda(T + \tau) + SS = \mu_{T+\tau} + SS$$

$$F(S) = \alpha$$

$$\beta = 1 - \frac{n(S)}{T\lambda}$$

$$Q = T * \lambda$$

$$\mu_{T+\tau} = \lambda * (T + \tau)$$

$$\sigma_{T+\tau} = \sigma * \sqrt{T + \tau}$$

Costos:

$$\text{Costo de preparación} = K/T = K\lambda/Q$$

$$\text{Costo de adquisición} = c * \lambda$$

$$\text{Costo de inventario} = h \left(\frac{Q}{2} + S - \lambda(T + \tau) \right)$$

$$\text{Costo de faltantes} = p \left(\frac{n(S)}{T} \right)$$

Receta si nos dan un nivel α con distr. Normal:

1. Establecemos todos los parámetros de distribución en las mismas unidades y su análogo en unidades $\mu_{T+\tau}$, $\sigma_{T+\tau}$
2. Consideramos nivel de servicio tipo I: α .
3. Encontramos $Z = \text{INV.NORM.ESTAND}(\alpha)$
4. Encontramos $SS = Z * \sigma_{T+\tau}$
5. Encontramos $S = \mu_{T+\tau} + SS$
6. Calculamos

$$L(Z) = \text{DISTR.NORM.ESTAND.N}(Z; \text{FALSO}) - Z * (1 - \text{DISTR.NORM.ESTAND.N}(Z; \text{VERDADERO}))$$

7. Calculamos valor esperado de faltantes $n(S) = L(Z) * \sigma_{T+\tau}$

8. Encontramos el NSII

$$\beta = 1 - \frac{n(S)}{T * \lambda}$$

Ejercicio 1.25. Tome una empresa con un lead time de 25 días, un costo de hacer un pedido de \$70000, un costo de mantener una unidad un día de \$160 y un costo de \$6543 por unidad faltante. Asimismo, se sabe que la demanda se distribuye normal y que tiene media diaria de 300 unds y desviación diaria de 64 unidades. Sabiendo que se ha establecido un tiempo de ciclo de 2 días y que se quiere tener una relación crítica del 90 %, ajuste un modelo tipo S-T reportando el punto objetivo de inventario y el nivel de servicio tipo 2 asociado.

Solución:

Veamos el siguiente Excel con la solución del ejemplo. [S-T teniendo alfa.xlsx](#)



Receta si nos dan un β con distr. Normal:

1. Establecemos λ y σ en las mismas unidades [unds/T] y su análogo en unidades [unds] $\mu_{T+\tau}$, $\sigma_{T+\tau}$.
2. Inicializar valor de S que vamos a encontrar. Luego usaremos buscar objetivo para hacerlo.
3. Encontrar función de probabilidad acumulada asociada al S que encontraremos

$$F(S) = \text{DISTR.NORM.N}(S; \mu_{T+\tau}; \sigma_{T+\tau}; \text{VERDADERO})$$

4. Encontrar $Z = \text{INV.NORM.ESTAND}(F(S))$
5. Calcular $L(Z)$

$$L(Z) = \text{DISTR.NORM.ESTAND.N}(Z; \text{FALSO}) - Z * (1 - \text{DISTR.NORM.ESTAND.N}(Z; \text{VERDADERO}))$$

6. Encontramos valor esperado de faltantes

$$\mathbb{E}[Faltantes] = n(S) = L(Z) * \sigma_{T+\tau}$$

7. Usamos esto para encontrar el β correspondiente a nuestro S .

$$\beta = 1 - \frac{n(S)}{T * \lambda}$$

8. Ahora usamos buscar objetivo para encontrar el S que hace que el resultado que acabamos de encontrar coincida con el β que nos dan en el enunciado: nuestro NSII objetivo.

Ejercicio 1.26. Tome una empresa con un lead time de 25 días, un costo de hacer un pedido de \$70000, un costo de mantener una unidad un día de \$160 y un costo de \$6543 por unidad faltante. Asimismo, se sabe que la demanda se distribuye normal y que tiene media diaria de 300 unds y desviación diaria de 64 unidades. Sabiendo que se ha establecido un tiempo de ciclo de 3 días y que se quiere tener un nivel de servicio tipo 2 del 85 %, ajuste un modelo tipo S-T reportando el punto objetivo de inventario y el nivel de servicio tipo 1 asociado.

Solución:

Veamos el siguiente Excel con la solución del ejemplo. [S-T teniendo beta.xlsx](#)



Capítulo 2

JRP - Reaprovisionamiento Conjunto

En este capítulo introducimos los modelos coordinados para un solo eslabón, donde el objetivo ya no es decidir políticas de inventario ítem por ítem de forma aislada, sino coordinar el reaprovisionamiento cuando varios productos comparten proveedor, transporte o un componente común del proceso logístico. En particular, estudiaremos el Joint Replenishment Problem (JRP), que surge cuando existe una interacción en el costo de ordenar: pedir productos por separado suele ser más costoso que consolidarlos en un pedido conjunto. Esta coordinación busca facilitar la programación, a cambio de un posible aumento en inventarios promedio y una menor capacidad de respuesta. Finalmente, analizaremos dos variantes del problema:

- (i) un ciclo común para todos los productos ($m_j = 1$) y
- (ii) ciclos individuales como múltiplos de un periodo base ($m_j \geq 1$), donde $T_j = m_j T$.

Notemos que el problema en este tema radica en encontrar el tiempo de ciclo óptimo. Por ende, trabajaremos con modelos tipo S-T a lo largo de este capítulo apoyándonos en las ecuaciones del EOQ.

Notación reaprovisionamiento

- j : Producto.
- Q_j : Tamaño de la orden del producto j [unds].
- T : Período de reaprovisionamiento conjunto [T].
- O : Costo de ordenar común [\$].
- K_j : Costo fijo de ordenar el producto j [\$].
- h_j : Costo de mantener j [\$/Tiempo-und].
- i : Tasa de mantenimiento [%/Tiempo].
- c_j : Costo estándar del producto j [\$/unds].
- p_j : Costo por faltante del producto j [\$/unds].

- λ_j : Demanda anual del producto j [unds].
- τ : Lead time [Tiempo].
- $n(S_j)$: Valor esperado de faltantes del producto j [unds].
- $TC = G$: Función de costo total [\$/Tiempo].
- $L(Z)$: Función de pérdida estándar.
- m_j : Factor multiplicador del producto j del periodo base T .
- γ_j : Fracción del lote Q_j tomada como parte del stock de seguridad [%].
- δ_j : Cantidad de stock de seguridad fija del producto j parte del stock de seguridad total [unds].

Interpretaciones de NSI:

1. Relación crítica.
2. Probabilidad de no tener faltantes, la probabilidad de tener faltantes estará dada por $1 - \alpha$.
3. Probabilidad de tener sobrantes.
4. Nivel de servicio tipo I.
5. Proporción de ciclos sin faltantes.

Interpretaciones de NSII:

1. Proporción de la demanda que es cubierta con las existencias.

Diferencia entre γ y δ

γ depende del tamaño de lote, entonces generalmente será presentado en los enunciados con frases del estilo “se toma x fracción del lote de producción como parte del stock de seguridad para el producto 2”, mientras δ al ser una cantidad fija se presenta en términos de datos del enunciado con frases como “los productos 1 y 3 tendrán un stock de seguridad de 10 días de la demanda”.

Puede pasar pero no lo he visto nunca: Cosas como “se toman 10 días de la demanda y además un 5 % del lote a pedir como parte del stock de seguridad para el producto 4”.

¿Por qué nos complicamos la vida con esto?

Porque nos ahorra el tiempo de derivar e igualar a cero y generaliza para todos los casos el cálculo del T^* reduciendolo a una única fórmula.

2.1. Reaprovisionamiento sin coordinar

Ecuaciones reaprovisionamiento sin coordinar

Mantra 1: Importante para no depender de T

$$T = Q/\lambda$$

Caso determinístico:

★ **Parámetros:**

$$SS_j = \text{Nos lo tienen que dar}$$

$$Q_j = EOQ_j = \sqrt{\frac{2(K_j + O)\lambda_j}{h_j}} = \sqrt{\frac{2(K_j + O)\lambda_j}{i_j c_j}}$$

$$\bar{I}_j = Q_j/2 + SS_j$$

★ **Costos:**

$$TC = C.Ordenar + C.Mantener$$

$$\begin{aligned} TC &= \sum_j \frac{\lambda_j}{Q_j} (O + K_j) + \sum_j \bar{I}_j * h_j \\ &= \sum_j \frac{\lambda_j}{Q_j} (O + K_j) + \sum_j \left(\frac{Q_j}{2} + SS_j \right) * i * c_j \end{aligned}$$

Caso estocástico:

★ **Parámetros (ajustado a una distr. normal):**

$$Q_j = EOQ_j = \sqrt{\frac{2(K_j + O)\lambda_j}{h_j}} = \sqrt{\frac{2(K_j + O)\lambda_j}{i_j c_j}}$$

$$S = \mu_{T+\tau} + Z\sigma_{T+\tau} = \mu_{T+\tau} + SS$$

$$SS = Z * \sigma_{T+\tau}$$

Nota: SS está indexado porque depende de la desviación estandar de cada demanda dada su fórmula:

$$Z = \frac{S - \mu_{T+\tau}}{\sigma_{T+\tau}} = \text{DISTR.NORM.INV}(\alpha; 0; 1)$$

$$L(Z) = \text{DISTR.NORM}(z; 0; 1; 0) - z * (1 - \text{DISTR.NORM.ESTAND}(z))$$

$$n(S) = \sigma_{T+\tau} * L(Z)$$

$$NSI = \alpha = \mathbb{P}(x_{T+\tau} \leq S) = F(Q)$$

$$NSII = 1 - \frac{n(S)}{Q} = 1 - \frac{\sigma_{T+\tau} L(Z)}{Q}$$

★ **Costos:**

$$TC = C.Ordenar + C.Mantener + C.Faltantes$$

$$C_{\text{Ordenar}} = \sum_j \frac{\lambda_j}{Q_j} (O + K_j)$$

$$C_{\text{Mantener}} = \sum_j \bar{I}_j * h_j = \sum_j \left(\frac{Q_j}{2} + SS_j \right) i_j c_j$$

$$C_{\text{Faltantes}} = \sum_j \frac{\lambda_j}{Q_j} (p_j n(S_j))$$

$$\begin{aligned} TC &= \sum_j \frac{\lambda_j}{Q_j} (O + K_j) + \sum_j \bar{I}_j * h_j + \sum_j \frac{\lambda_j}{Q_j} (p_j n(S_j)) \\ &= \sum_j \frac{\lambda_j}{Q_j} (O + K_j) + \sum_j \left(\frac{Q_j}{2} + SS_j \right) i_j c_j + \sum_j \frac{\lambda_j}{Q_j} (p_j n(S_j)) \end{aligned}$$

Receta: Diseñar política Up-To-Level (ST) para una serie de productos dado un escenario determinístico.

1. Consideramos matriz inicial que nos da el enunciado, deberían darnos todos los costos y demandas. No necesitaremos la desviación estándar porque es determinístico.
2. Chequear que todo esté en la misma temporalidad, si no lo está, ponerlo en la misma temporalidad.
3. Encontrar matriz de parámetros que necesitaremos para los costos más adelante.

Producto	Producto 1	Producto 2	...
Q	EOQ 2.1	EOQ 2.1	...
SS	Nos dicen	Nos dicen	...
$\bar{I}$	$Q_1/2 + SS_1$	$Q_2/2 + SS_2$	...

$$EOQ = \sqrt{\frac{2K_j \lambda_j}{i_j c_j}} \quad (2.1)$$

4. Encontrar costos

$$TC = C.\text{Ordenar} + C.\text{Mantener}$$

$$C.\text{Ordenar} = \sum_j \frac{\lambda_j}{Q_j} (O + K_j)$$


$$C.\text{Mantener} = \sum_j \bar{I}_j * h_j = \sum_j \left(\frac{Q_j}{2} + SS_j \right) * i_j * c_j$$

$$\begin{aligned}
TC &= \sum_j \frac{\lambda_j}{Q_j} (O + K_j) + \sum_j \bar{I}_j * h_j \\
&= \sum_j \frac{\lambda_j}{Q_j} (O + K_j) + \sum_j \left(\frac{Q_j}{2} + SS_j \right) * i_j * c_j
\end{aligned}$$

Notemos que si queremos discriminar costos por producto, en vez de la sumatoria ponemos un $\forall j$ para cada costo que vayamos a calcular.

2.2. Reaprovisionamiento conjunto $m_j = 1$

La idea esencial de este modelo es buscar un tiempo de ciclo único tal que podamos emitir una orden para todos los productos cada cierto tiempo. Por ejemplo, teniendo dos productos este modelo quedaría tal que



Justificación matemática del modelo

Partimos del JRP determinístico con periodo base $T > 0$ y demandas constantes λ_j , de modo que para cada ítem

$$Q_j = \lambda_j T.$$

El costo total promedio por unidad de tiempo se compone de:

- (i) costo de ordenar conjunto y por ítem
- (ii) costo de mantener inventario promedio. Permitimos que el costo de posesión dependa del ítem, $h_j = i_j c_j$.

En general, aun en un entorno determinístico, podemos incorporar simultáneamente dos tipos de stock de seguridad para cada producto j :

- un componente proporcional al lote (dependiente de Q_j), $SS_j^{(Q)} = \gamma_j Q_j$, y
- un componente constante (independiente de Q_j), $SS_j^{(0)} = \delta_j$,

donde $\gamma_j \in [0, 1)$, $\delta_j \geq 0$.

Bajo esta convención, el inventario promedio del ítem j es

$$\bar{I}_j = \frac{Q_j}{2} + SS_j^{(Q)} + SS_j^{(0)} = \left(\frac{1}{2} + \gamma_j\right) Q_j + \delta_j.$$

Así, la función de costos totales queda

$$\begin{aligned} G(T) &= \frac{1}{T} \left(O + \sum_j K_j \right) + \sum_j h_j \bar{I}_j \\ &= \frac{1}{T} \left(O + \sum_j K_j \right) + \sum_j h_j \left[\left(\frac{1}{2} + \gamma_j\right) Q_j + \delta_j \right]. \end{aligned}$$

Sustituyendo $Q_j = \lambda_j T$:

$$\begin{aligned} G(T) &= \frac{1}{T} \left(O + \sum_j K_j \right) + \sum_j h_j \left[\left(\frac{1}{2} + \gamma_j\right) \lambda_j T + \delta_j \right] \\ &= \frac{1}{T} \left(O + \sum_j K_j \right) + T \sum_j \left(\frac{1}{2} + \gamma_j\right) \lambda_j h_j + \sum_j h_j \delta_j \end{aligned}$$

Definamos, para abreviar,

$$A := O + \sum_j K_j > 0, \quad B := \sum_j \left(\frac{1}{2} + \gamma_j\right) \lambda_j h_j = \sum_j \left(\frac{1}{2} + \gamma_j\right) \lambda_j i_j c_j > 0,$$

$$C := \sum_j h_j \delta_j \geq 0$$

Entonces

$$G(T) = \frac{A}{T} + BT + C.$$

Derivando respecto a T :

$$\frac{dTC}{dT} = -\frac{A}{T^2} + B,$$

y derivando por segunda vez:

$$\frac{d^2TC}{dT^2} = \frac{2A}{T^3} > 0 \quad (\forall T > 0).$$

Por tanto G es convexa en $T > 0$ y el óptimo se obtiene en el punto crítico dado por $\frac{dT C}{dT} = 0$:

$$-\frac{A}{T^2} + B = 0 \implies B = \frac{A}{T^2} \implies T^2 = \frac{A}{B}.$$

Reemplazando A y B :

$$T^* = \sqrt{\frac{O + \sum_j K_j}{\sum_j (\frac{1}{2} + \gamma_j) \lambda_j i_j c_j}}.$$

Finalmente, nótese que el término constante $C = \sum_j h_j \delta_j$ aparece en $TC(T)$ (eleva el nivel del costo total), pero no afecta la derivada ni el valor óptimo de T ; el T^* depende únicamente de las contribuciones que varían con Q_j (y por ende con T): el costo de ordenar $\propto 1/T$ y el costo de mantener el inventario de ciclo más la fracción proporcional del stock de seguridad $\propto T$.

Bajo el régimen estocástico del modelo, aproximamos primero el periodo común T tratando SS_j y $n(S_j)$ como constantes al momento de derivar la función de costos. Es decir, asumimos que estos términos se calculan posteriormente con las ecuaciones del modelo $S-T$, una vez fijado el ciclo común de reaprovisionamiento. Por ende, no modelamos el stock de seguridad mediante una parametrización lineal en Q_j , de modo que tomamos $\gamma_j = 0$ y $\delta_j = 0 \quad \forall j$. Bajo esta convención, las ecuaciones principales del modelo quedan dadas por:

$$G(T) = \frac{1}{T} \left(O + \sum_j K_j \right) + \sum_j \left(\frac{Q_j}{2} + SS_j \right) i_j c_j + \sum_j \frac{p_j n(S_j)}{T}$$

$$T^* = \sqrt{\frac{2 \left(O + \sum_j K_j + \sum_j p_j n(S_j) \right)}{\sum_j i_j c_j \lambda_j}}$$

Solución del modelo

Ecuaciones reaprovisionamiento conjunto $m_j = 1$ bajo política S-T

Mantra 1: Importante para no depender de Q

$$T = Q/\lambda$$

Caso determinístico:

★ Parámetros:

Asumiendo que el stock de seguridad tiene aportes dependientes e independientes de Q tal que

$$SS_j = \frac{1}{2}Q_j + \gamma_j * Q_j + \delta_j = \left(\frac{1}{2} + \gamma_j\right) * \lambda_j * T + \delta_j, \quad \gamma_j \in [0, 1), \quad \delta_j \geq 0 \text{ entonces}$$

$$T^* = \sqrt{\frac{O + \sum_j K_j}{\sum_j (\frac{1}{2} + \gamma_j) \lambda_j i_j c_j}}.$$

★ Costos:

$$TC = C.Oordenar + C.Mantener$$

$$\begin{aligned}
G(T)^* &= \frac{1}{T^*} \left(O + \sum_j K_j \right) + \sum_j \left(\frac{Q_j}{2} + SS_j \right) i_j c_j \\
&= \frac{1}{T^*} \left(O + \sum_j K_j \right) + \sum_j \bar{I} * i_j * c_j \\
&= \frac{1}{T} \left(O + \sum_j K_j \right) + T \sum_j \left(\frac{1}{2} + \gamma_j \right) \lambda_j h_j + \sum_j h_j \delta_j
\end{aligned}$$

Caso estocástico (ajustamos todo a una distr. normal):

★ **Costos:**

$$G(T)^* = \frac{1}{T^*} \left(O + \sum_j K_j \right) + \sum_j \left(\frac{Q_j}{2} + SS_j \right) i_j c_j + \sum_j \frac{p_j n(S_j)}{T^*}$$

★ **Parámetros:**

$$T^* = \sqrt{\frac{2 \left(O + \sum_j K_j + \sum_j p_j n(S_j) \right)}{\sum_j i_j c_j \lambda_j}}$$

$$S = \mu_{T+\tau} + Z \sigma_{T+\tau} = \mu_{T+\tau} + SS$$

$$SS = Z * \sigma_{T+\tau}$$

Nota: SS está indexado porque depende de la desviación estandar de cada demanda dada su fórmula:

$$Z = \frac{S - \mu_{T+\tau}}{\sigma_{T+\tau}} = \text{DISTR.NORM.INV}(\alpha; 0; 1)$$

$$L(Z) = \text{DISTR.NORM}(z; 0; 1; 0) - z * (1 - \text{DISTR.NORM.ESTAND}(z))$$

$$n(S) = \sigma_{T+\tau} * L(Z)$$

$$NSI = \alpha = \mathbb{P}(x_{T+\tau} \leq S) = F(Q)$$

$$NSII = 1 - \frac{n(S)}{\bar{Q}} = 1 - \frac{\sigma_{T+\tau} L(Z)}{\bar{Q}}$$

Receta: Diseñar política Up-To-Level (ST) para una serie de productos (caso determinístico) dados costos y fracciones del stock de seguridad.

1. Considerar matriz de costos, tasas, etc. que nos dan inicialmente.
2. Chequear que todo esté en la misma temporalidad, si no lo está, ponerlo en la misma temporalidad.
3. Sacamos un solo T dado que todos los $m_j = 1$ asumiendo que el stock de seguridad tiene aportes dependientes e independientes de Q tal que $SS_j = \frac{1}{2}Q_j + \gamma_j * Q_j + \delta_j = \left(\frac{1}{2} + \gamma_j\right) * \lambda_j * T + \delta_j$, $\gamma_j \in [0, 1)$, $\delta \geq 0$

$$T^* = \sqrt{\frac{O + \sum_j K_j}{\sum_j \left(\frac{1}{2} + \gamma_j\right) \lambda_j i_j c_j}}$$

4. Pasar T^* a la unidad de tiempo más chiquita (generalmente días) y redondear a entero más cercano. El resultado será un nuevo tiempo T que no es óptimo, pero será usado de ahora en adelante.
5. Sacar matriz de parámetros que usaremos para encontrar costos totales:

Producto	Producto 1	Producto 2	...
Q	$\lambda_1 * T$	$\lambda_2 * T$	...
gamma	γ_1	γ_2	...
delta	δ_1	δ_2	...
SS	$\gamma_1 * Q_1 + \delta_1$	$\gamma_1 * Q_1 + \delta_1$	...
$\bar{I}$	$Q_1/2 + SS_1$	$Q_2/2 + SS_2$	...

6. Sacar costos con parámetros encontrados:

$$G(T) = C.OrdenarIndividual + C.OrdenarConjunto + C.Mantener$$

$$C.OrdenarComn = \frac{O}{T}$$

$$C.OrdenarIndividual = \frac{\sum_j K_j}{T}$$

$$C.Mantener = \sum_j \bar{I}_j h_j = \sum_j \left(\frac{Q_j}{2} + SS_j \right) * i_j * c_j = \sum_j \left(\frac{Q_j}{2} + \gamma_j Q_j \right) i_j c_j + \delta_j i_j c_j$$

$$\begin{aligned}
 G(T) &= \frac{1}{T} \left(O + \sum_j K_j \right) + \sum_j \bar{I}_j h_j \\
 &= \frac{1}{T} \left(O + \sum_j K_j \right) + \sum_j \left(\frac{Q_j}{2} + SS_j \right) * i_j * c_j \\
 &= \frac{1}{T} \left(O + \sum_j K_j \right) + T \sum_j \left(\frac{1}{2} + \gamma_j \right) \lambda_j i_j c_j + \sum_j i_j c_j \delta_j
 \end{aligned}$$

Nota:

El costo de ordenar común O solo se toma una vez. No es uno por cada producto porque como $m_j = 1 \forall j$, todo se pide al tiempo.

Ejercicio 2.1 (Reaprovisionamiento conjunto determinístico con $m_j = 1$). Tome una empresa que comercializa 4 productos y tiene los siguientes costos y parámetros asociados a cada producto.

Item	Demanda diaria	Costo unitario	Costo de ordenar
Producto 1	55	100	600
Producto 2	63	75	850
Producto 3	21	64	345
Producto 4	42	42	756

A su vez se sabe que un pedido se demora 15 días en llegar a la empresa, que se tiene una tasa de retención de inventario de 15 % anual y un costo por cargar cada pedido de \$430. La empresa tiene como regla conservar un stock de seguridad de 10 días de la demanda para todos los productos salvo por el Producto 4. En este caso, se desea conservar el 10 % del tamaño de pedido óptimo.

Ajuste un modelo de reaprovisionamiento conjunto tal que los pedidos se hagan al tiempo para todos los productos. Reporte el costo total de la política óptima. Asuma que un año tiene 365 días en sus cálculos.

Solución:

Veamos el siguiente Excel con la solución del ejemplo. [m_j = 1 deterministico.xlsx](#)



Receta: Diseñar política Up-To-Level (ST) para una serie de productos sujeto a un NSI en específico (caso estocástico), dados costos.

La lógica es llegar a los costos (anuales en general) de la política, y para esto, debemos encontrar todos los parámetros de la función de costos totales promedio.

1. Considerar matriz de costos, tasas, desviaciones, etc. que nos dan inicialmente.
2. Chequear que todo esté en la misma temporalidad, si no lo está, ponerlo en la misma temporalidad.
3. Sacamos un solo T^* dado que todos los $m_j = 1$:

$$T^* = \sqrt{\frac{2 \left(O + \sum_j K_j + \sum_j p_j n(S_j) \right)}{\sum_j i_j c_j \lambda_j}}$$

4. Pasar T^* a la unidad de tiempo más chiquita (generalmente días) y redondear a entero más cercano. Así encontraremos el valor de T .
5. Sacar matriz de parámetros que usaremos para encontrar costos totales:

	Producto 1	Producto 2	...
$T + \tau$	$T + \tau_1$	$T + \tau_2$	...
$\mu(T + \tau)$	$\lambda_1 \cdot (T + \tau_1)$	$\lambda_2 \cdot (T + \tau_2)$	...
$\sigma(T + \tau)$	$\sigma_1 \cdot \sqrt{T + \tau_1}$	$\sigma_2 \cdot \sqrt{T + \tau_2}$	...
Z	Eq 2.2	Eq 2.2	...
$L(Z)$	Eq 2.3	Eq 2.3	...
$S^!$	$\mu_{T+\tau} + \sigma_{T+\tau} \cdot Z$	$\mu_{T+\tau} + \sigma_{T+\tau} \cdot Z$	...
$SS^!$	$\sigma_{T+\tau} \cdot Z$	$\sigma_{T+\tau} \cdot Z$	...
Q	$\lambda_1 \cdot T$	$\lambda_2 \cdot T$	...
$\bar{I}$	$Q_1/2 + SS_1$	$Q_2/2 + SS_2$	...
$n(S)^!$	$\sigma_{T+\tau} \cdot L(Z)$	$\sigma_{T+\tau} \cdot L(Z)$	...

$$Z = \frac{S - \mu_{T+\tau}}{\sigma_{T+\tau}} = \text{DISTR.NORM.INV}(\alpha; 0; 1) \quad (2.2)$$

$$L(Z) = \text{DISTR.NORM}(z; 0; 1; 0) - z * (1 - \text{DISTR.NORM.ESTAND}(z)) \quad (2.3)$$

6. Con esto ya deberíamos tener todo lo necesario para encontrar los costos totales, así pues, computaremos:

$$C_{\text{Ordenar}} = \frac{1}{T} \left(O + \sum_j K_j \right)$$

$$C_{\text{Mantener}} = \sum_j \bar{I}_j h_j = \sum_j \left(\frac{Q_j}{2} + SS_j \right) i_j c_j = \sum_j \left(\frac{\lambda_j * T}{2} + SS_j \right) i_j c_j$$

$$C_{\text{Faltantes}} = \sum_j \frac{p_j n(S_j)}{T}$$

$$G(T) = \frac{1}{T} \left(O + \sum_j K_j \right) + \sum_j \left(\frac{Q_j}{2} + SS_j \right) i_j c_j + \sum_j \frac{p_j n(S_j)}{T}$$

Notemos que si queremos discriminar costos por producto, en vez de la sumatoria ponemos un $\forall j$ para cada costo que vayamos a calcular.

Nota:

El costo de ordenar común O solo se toma una vez. No es uno por cada producto porque como $m_j = 1 \forall j$, todo se pide al tiempo.

Ejercicio 2.2 (Reaprovisionamiento conjunto estocástico con $m_j = 1$). Tome una empresa que comercializa 4 productos y tiene los siguientes costos y parámetros asociados a cada producto.

Item	Demanda diaria	Desviación diaria	Costo unitario	Costo ordenar
P. 1	55	5	100	600
P. 2	63	7	75	850
P. 3	21	4	64	345
P. 4	42	9	42	756

A su vez se sabe que un pedido se demora 15 días en llegar a la empresa, que se tiene una tasa de retención de inventario de 15 % anual y un costo por cargar cada pedido de \$430. Se desea tener un nivel de servicio tipo 1 del 95 %.

¹Esto debe ir indexado para todo item j , no lo puse porque implicaría meterle subíndices a los subíndices y queda feito :/

Ajuste un modelo de reaprovisionamiento conjunto tal que los pedidos se hagan al tiempo para todos los productos. Reporte el costo total de la política óptima y el nivel de inventario objetivo. Asuma que un año tiene 365 días en sus cálculos.

Solución:

Veamos el siguiente Excel con la solución del ejemplo. [m_j = 1 estocástico.xlsx](#)



2.3. Reaprovisionamiento conjunto $m_j \geq 1$

En esta sección extenderemos el caso básico de reaprovisionamiento conjunto (donde todos los ítems se ordenan cada T) a una versión más general del *Joint Replenishment Problem* en la que cada producto puede ordenarse con una frecuencia distinta, pero siempre coordinada sobre un *periodo base*. En particular, introducimos un periodo $T > 0$ y, para cada ítem j , un multiplicador entero

$$m_j \in \mathbb{Z}_{\geq 1}, \quad T_j = m_j T,$$

de modo que el ítem j se revisa/ordena cada T_j unidades de tiempo. Bajo demanda determinística constante λ_j , esto fija el tamaño de lote como

$$Q_j = \lambda_j T_j = \lambda_j m_j T.$$

Con esta parametrización, el costo promedio por unidad de tiempo conserva la estructura típica: un término de ordenar que decrece como $1/T$ y un término de mantener inventario que crece linealmente en T . El costo de ordenar incluye:

- (i) un costo conjunto O incurrido cada vez que hay una orden coordinada (cada T)
- (ii) costos fijos por ítem K_j incurridos únicamente cuando el ítem j es efectivamente ordenado (cada $T_j = m_j T$), lo cual genera contribuciones $\frac{O}{T}$ y $\frac{K_j}{m_j T}$, respectivamente.

Para el costo de mantener, el inventario promedio de cada ítem se compone del inventario de ciclo $Q_j/2$ y de un componente de seguridad. Para capturar distintas políticas sin perder generalidad, permitimos que el stock de seguridad tenga simultáneamente una parte proporcional al lote (dependiente de Q_j) y una parte constante (independiente de Q_j):

$$SS_j = \gamma_j Q_j + \delta_j, \quad \gamma_j, \delta_j \geq 0.$$

La parte proporcional $\gamma_j Q_j$ crece con T al igual que el inventario de ciclo, mientras que la parte constante δ_j solo desplaza el nivel del costo total sin afectar la condición de optimalidad en T .

En consecuencia, para un vector $\vec{m} = (m_1, \dots, m_n)$ fijo, el problema de elegir T se reduce nuevamente a minimizar una función unidimensional de la forma

$$TC(T \mid \vec{m}) = \frac{A(\vec{m})}{T} + B(\vec{m}) T + C(\vec{m}), \quad T > 0,$$

cuyos términos reflejan los costos de ordenar ($A(\vec{m})$), mantener ($B(\vec{m})$) y componentes constantes ($C(\vec{m})$). Esto justifica que, una vez fijadas las frecuencias relativas $\vec{m}$, el óptimo en T se obtiene analíticamente a partir de derivar e igualar a cero. La dificultad adicional frente al caso $m_j = 1$ es que ahora también debemos decidir $\vec{m}$, lo cual introduce una componente entera; esa selección se abordará posteriormente al pasar a las recetas de solución.

Ecuaciones reaprovisionamiento conjunto $m_j \geq 1$ bajo política S-T

Mantra 1: Importante para no depender de Q

$$T = Q/\lambda$$

Caso determinístico

★ **Parámetros:**

$$\text{Producto base} = \arg \min_j \left(\frac{K_j}{c_j \lambda_j} \right)$$

$$m_{j^*} = 1$$

$$m_j = \max \left\{ \text{redondear} \left(\sqrt{\frac{K_j}{\lambda_j c_j} \cdot \frac{\lambda_j^* c_j^*}{O + K_j^*}} \right), 1 \right\}$$

Asumiendo que el stock de seguridad tiene aportes dependientes e independientes de Q tal que

$$SS_j = \frac{1}{2}Q_j + \gamma_j * Q_j + \delta_j = \left(\frac{1}{2} + \gamma_j\right) * \lambda_j * T + \delta_j, \quad \gamma_j \in [0, 1), \quad \delta_j \geq 0 \text{ entonces}$$

$$T^* = \sqrt{\frac{O + \sum_j K_j}{\sum_j \left(\frac{1}{2} + \gamma_j\right) \lambda_j i_j c_j}}.$$

$$T_j = m_j T$$

$$Q_j^* = T_j * \lambda_j$$

$$\bar{I} = \frac{Q_j^*}{2} + SS_j$$

★ **Costos:**

$$CT = C.\text{OrdenarComun} + C.\text{OrdenarIndividual} + C.\text{Mantener}$$

$$C.\text{OrdenarComun}_j = \frac{O}{T}$$

$$C.\text{OrdenarIndividual}_j = \frac{K_j}{T_j}$$

$$C.\text{Mantener} = \bar{I}_j * h_j = \left(\frac{Q_j^*}{2} + SS_j \right) * i_j * c_j$$

$$\begin{aligned} CT &= \frac{O}{T} + \sum_j \frac{K_j}{T_j} + \sum_j \left(\frac{Q_j^*}{2} + SS_j \right) * i_j * c_j \\ &= \frac{O}{T} + \sum_j \frac{K_j}{T_j} + \sum_j \left(\frac{\lambda_j * T_j}{2} + SS_j \right) * i_j * c_j \\ &= \frac{O}{T} + \sum_j \frac{K_j}{T_j} + \sum_j \left(\frac{\lambda_j * T^* * m_j}{2} + SS_j \right) * i_j * c_j \end{aligned}$$

Receta: Diseñar política Up-To-Level (ST) para una serie de productos sujeto a escenario determinístico.

1. Considerar matriz de costos, tasas, desviaciones, etc. que nos dan inicialmente.
2. Chequear que todo esté en la misma temporalidad, si no lo está, ponerlo en la misma temporalidad.
3. Sacar matriz de parámetros que usaremos para encontrar costos totales:

Productos	Producto 1	Producto 2	...
Orden	$\frac{K_j}{c_j \lambda_j}$	$\frac{K_j}{c_j \lambda_j}$	...
Paso intermedio: sacar $j^* = \arg \min_j \{ \frac{\lambda_j c_j}{O + K_j} \}$ y $\frac{\lambda_j^* c_j^*}{O + K_j^*}$			
m_j fórmula	Aplicar 2.4	Aplicar 2.4	...
m_j seleccionado	Poner $m_j^* = 1$	Poner $m_j^* = 1$	...
m_j redondeado	$\max\{1, \text{redondear}(m_j)\}$	$\max\{1, \text{redondear}(m_j)\}$	...
$\frac{K_j}{m_j}$	$\frac{K_j}{(m_j \text{ redondeado})}$	$\frac{K_j}{(m_j \text{ redondeado})}$	...
$m_j h_j \lambda_j$	$(m_j \text{ redondeado}) c_j i_j \lambda_j$	$(m_j \text{ redondeado}) c_j i_j \lambda_j$	...
gamma	γ_1	γ_2	...
delta	δ_1	δ_2	...
Paso intermedio: sacar T^* con 2.5			
Paso intermedio: Sacar T aproximando (Ver Aclaración)			
T_j	$(m_j \text{ redondeado}) * T$	$(m_j \text{ redondeado}) * T$	...
Q	$\lambda_j * T_j$	$\lambda_j * T_j$	...
SS	$\gamma_j * Q_j + \delta_j$	$\gamma_j * Q_j + \delta_j$	...
$\bar{I}$ prom	$Q_j/2 + SS_j$	$Q_j/2 + SS_j$	...

$$m_j = \sqrt{\frac{K_j}{\lambda_j c_j} \cdot \frac{\lambda_j^* c_j^*}{O + K_j^*}} \quad (2.4)$$

$$T^*(\vec{m}) = \sqrt{\frac{\left[O + \sum \left(\frac{K_j}{m_j}\right)\right]}{\sum h_j \lambda_j m_j * (1/2 + \gamma_j)}} = \sqrt{\frac{\left[O + \sum \left(\frac{K_j}{m_j}\right)\right]}{\sum i_j c_j \lambda_j m_j * (1/2 + \gamma_j)}} \quad (2.5)$$

Aclaración: Cuando decimos “aproximar” nos referimos a pasar el valor de T^* a la unidad de tiempo más pequeña, redondear al entero más cercano y volver a la unidad de tiempo que nos pide el enunciado usando el valor redondeado. Este nuevo valor será T , no es óptimo, pero será usado de ahora en adelante.

4. Sacamos costos

$$CT = C.OrdenarComun + C.OrdenarIndividual + C.Mantener$$

$$C.OrdenarComun_j = \frac{O}{T}$$

$$C.OrdenarIndividual_j = \frac{K_j}{T_j}$$

$$C.Mantener = \bar{I}_j * h_j = \left(\frac{Q_j}{2} + SS_j \right) * i_j * c_j$$

$$\begin{aligned} G(T) &= \frac{O}{T} + \sum_j \frac{K_j}{T_j} + \sum_j \left(\frac{Q_j}{2} + SS_j \right) * i_j * c_j \\ &= \frac{O}{T} + \sum_j \frac{K_j}{T_j} + \sum_j \left(\frac{\lambda_j * T_j}{2} + SS_j \right) * i_j * c_j \\ &= \frac{O}{T} + \sum_j \frac{K_j}{T_j} + \sum_j \left(\frac{\lambda_j * T * m_j}{2} + SS_j \right) * i_j * c_j \end{aligned}$$

Ejercicio 2.3 (Reaprovisionamiento conjunto determinístico con $m_j \geq 1$). Tome una empresa que comercializa 4 productos y tiene los siguientes costos y parámetros asociados a cada producto.

Item	Demanda diaria	Costo unitario	Costo de ordenar
Producto 1	55	100	600
Producto 2	63	75	850
Producto 3	21	64	345
Producto 4	42	42	756

A su vez se sabe que un pedido se demora 15 días en llegar a la empresa, que se tiene una tasa de retención de inventario de 15 % anual y un costo por cargar cada pedido de \$430. La empresa tiene como regla conservar un stock de seguridad de 10 días de la demanda para todos los productos salvo por el Producto 4. En este caso, se desea conservar el 10 % del tamaño de pedido óptimo.

Ajuste un modelo de reaprovisionamiento conjunto teniendo en cuenta que no todos los productos deben ser ordenados al tiempo. Reporte el costo total de la política óptima. Asuma que un año tiene 365 días en sus cálculos.

Solución:

Veamos el siguiente Excel con la solución del ejemplo. [m_j ≥ 1 deterministico.xlsx](#)



Receta: Diseñar política Up-To-Level (ST) para una serie de productos sujeto a un NSI en específico (caso estocástico).

1. Considerar matriz de costos, tasas, desviaciones, etc. que nos dan inicialmente.
2. Chequear que todo esté en la misma temporalidad, si no lo está, ponerlo en la misma temporalidad.
3. Sacar matriz de heurística:

Productos	Producto 1	Producto 2	...
Orden	$\frac{K_j}{c_j \lambda_j}$	$\frac{K_j}{c_j \lambda_j}$	...
Paso intermedio: sacar $j^* = \arg \min_j \{ \frac{\lambda_j c_j}{O+K_j} \}$ y $\frac{\lambda_j^* c_j^*}{O+K_j^*}$			
m_j fórmula	Aplicar 2.6	Aplicar 2.6	...
m_j seleccionado	Poner $m_j^* = 1$	Poner $m_j^* = 1$	...
m_j redondeado	$\max\{1, \text{redondear}(m_j)\}$	$\max\{1, \text{redondear}(m_j)\}$	...
$\frac{K_j}{m_j}$	$\frac{K_j}{(m_j \text{ redondeado})}$	$\frac{K_j}{(m_j \text{ redondeado})}$	...
$m_j h_j \lambda_j$	$(m_j \text{ redondeado}) c_j i_j \lambda_j$	$(m_j \text{ redondeado}) c_j i_j \lambda_j$	...
Paso intermedio: sacar T^* con 2.7			
Paso intermedio: Sacar T aproximando (Ver Aclaración)			
T_j	$(m_j \text{ redondeado}) * T$	$(m_j \text{ redondeado}) * T$	...
Q	$\lambda_j * T_j$	$\lambda_j * T_j$	...

$$m_j = \sqrt{\frac{K_j}{\lambda_j c_j} \cdot \frac{\lambda_j^* c_j^*}{O + K_j^*}} \quad (2.6)$$

$$T^*(\vec{m}) = \sqrt{\frac{2 \left[O + \sum \left(\frac{K_j}{m_j} \right) \right]}{\sum h_j \lambda_j m_j}} = \sqrt{\frac{2 \left[O + \sum \left(\frac{K_j}{m_j} \right) \right]}{\sum i_j c_j \lambda_j m_j}} \quad (2.7)$$

Aclaración: Cuando decimos “aproximar” nos referimos a pasar el valor de T^* a la unidad de tiempo más pequeña, redondear al entero más cercano y volver a la unidad de tiempo que nos pide el enunciado usando el valor redondeado. Este nuevo valor será T , no es óptimo, pero será usado de ahora en adelante.

4. Sacar matriz de parámetros de distribución:

	Producto 1	Producto 2	...
$T_j + \tau$	$T_j + \tau_1$	$T_j + \tau_2$	...
$\mu(T_j + \tau)$	$\lambda_1 \cdot (T_j + \tau_1)$	$\lambda_2 \cdot (T_j + \tau_2)$	...
$\sigma(T_j + \tau)$	$\sigma_1 \cdot \sqrt{T_j + \tau_1}$	$\sigma_2 \cdot \sqrt{T_j + \tau_2}$	...
Z	Eq 2.8	Eq 2.8	...
$L(Z)$	Eq 2.9	Eq 2.9	...
$S^!$	$\mu_{T_j+\tau} + \sigma_{T_j+\tau} \cdot Z$	$\mu_{T_j+\tau} + \sigma_{T_j+\tau} \cdot Z$	...
$SS^!$	$\sigma_{T_j+\tau} \cdot Z$	$\sigma_{T_j+\tau} \cdot Z$	...
Q	$\lambda_j \cdot T_j$	$\lambda_j \cdot T_j$	...
$\bar{I}$	$Q_j/2 + SS_j$	$Q_j/2 + SS_j$	...
$n(S)^!$	$\sigma_{T_j+\tau} \cdot L(Z)$	$\sigma_{T_j+\tau} \cdot L(Z)$	...

$$Z_j = \frac{S - \mu_{T_j+\tau}}{\sigma_{T_j+\tau}} = \text{DISTR.NORM.INV}(\alpha; 0; 1) \quad (2.8)$$

$$L(Z) = \text{DISTR.NORM}(z; 0; 1; 0) - z * (1 - \text{DISTR.NORM.ESTAND}(z)) \quad (2.9)$$

5. Sacar costos

$$CT = C.\text{OrdenarComun} + C.\text{OrdenarIndividual} + C.\text{Mantener} + C.\text{Faltantes}$$

$$C.\text{OrdenarComun}_j = \frac{O}{T}$$

$$C.\text{OrdenarIndividual}_j = \frac{K_j}{T_j}$$

$$C.\text{Mantener} = \bar{I}_j * h_j = \left(\frac{Q_j^*}{2} + SS_j \right) * i_j * c_j$$

$$C.\text{Faltantes} = \frac{1}{T_j} (p_j n(S_j))$$

$$\begin{aligned} G(T) &= \frac{O}{T} + \sum_j \frac{K_j}{T_j} + \sum_j \left(\frac{Q_j^*}{2} + SS_j \right) * i_j * c_j + \sum_j \frac{1}{T_j} (p_j n(S_j)) \\ &= \frac{O}{T} + \sum_j \frac{K_j}{T_j} + \sum_j \left(\frac{\lambda_j * T_j}{2} + SS_j \right) * i_j * c_j + \sum_j \frac{1}{T_j} (p_j n(S_j)) \\ &= \frac{O}{T} + \sum_j \frac{K_j}{T_j} + \sum_j \left(\frac{\lambda_j * T * m_j}{2} + SS_j \right) * i_j * c_j + \sum_j \frac{1}{T_j} (p_j n(S_j)) \end{aligned}$$

Ejercicio 2.4 (Reaprovisionamiento conjunto estocástico con $m_j \geq 1$). Tome una empresa que comercializa 4 productos y tiene los siguientes costos y parámetros asociados a cada producto.

Item	Demanda diaria	Desviación diaria	Costo unitario	Costo ordenar
P. 1	55	5	100	600
P. 2	63	7	75	850
P. 3	21	4	64	345
P. 4	42	9	42	756

¹Esto debe ir indexado para todo trabajo j , no lo puse porque implicaría meterle subíndices a los subíndices y queda feito :/

A su vez se sabe que un pedido se demora 15 días en llegar a la empresa, que se tiene una tasa de retención de inventario de 15 % anual y un costo por cargar cada pedido de \$430. Se desea tener un nivel de servicio tipo 1 del 95 %.

Ajuste un modelo de reaprovisionamiento conjunto tal que los pedidos no necesariamente se hagan al tiempo para todos los productos. Reporte el costo total de la política óptima y el nivel de inventario objetivo. Asuma que un año tiene 365 días en sus cálculos.

Solución:

Veamos el siguiente Excel con la solución del ejemplo. [m_j ≥ 1 estocástico.xlsx](#)



Capítulo 3

Coordinación de inventarios

En este capítulo abordamos el problema de coordinación dentro del Joint Replenishment Problem (JRP): partimos de un sistema con múltiples productos que comparten un costo fijo conjunto cada vez que se emite una orden, pero que además tienen costos fijos y de mantenimiento propios. La pregunta central es cómo sincronizar las decisiones de reaprovisionamiento para minimizar el costo conjunto sin inflar excesivamente el inventario promedio. Para construir una base analítica, comenzamos con el caso $1-1$ (un único periodo común para todos los ítems), donde es posible deducir una función de costos promedio y verla como un problema de optimización en una sola variable. Bajo el mismo supuesto del capítulo anterior o sea, que el stock de seguridad se compone de una parte proporcional al lote ($\gamma_j Q_j$) y una parte fija (δ_j) la función resultante conserva la estructura típica que permite estudiar convexidad y obtener una solución cerrada derivando, igualando a cero y despejando el óptimo (que luego se traduce en el lote/periodo correspondiente). Posteriormente pasamos al caso general $1-n$, donde cada producto puede ordenarse cada múltiplo entero del periodo base. En este caso el modelo incorpora variables enteras y deja de ser tratable mediante una optimización continua directa, lo que motiva el uso de heurísticas de coordinación para aproximar soluciones de buena calidad.

3.1. Caso 1-1

Notación coordinación de inventarios 1-1

- K_W : Costo de pedido del centro de distribución [\$].
- K_R : Costo de pedido del minorista [\$].
- c_W : Costo unitario del ítem en el CD [\$/unidad].
- c_R : Costo unitario del ítem en el minorista [\$/unidad].
- c'_W : Costo del ítem en el CD [\$/unidad].
- c'_R : Costo agregado o incremental por ítem en el minorista [\$/unidad].
- i_W : Tasa anual de manejo de inventarios en el CD [\$/Tiempo].

- i_R : Tasa anual de manejo de inventarios en los minoristas [\$/Tiempo].
- n : Cantidad de ciclos del minorista que cabe en un ciclo de abastecimiento de la bodega.
- γ_W : Fracción de Q_R que será parte del SS_W
- ρ_W : Fracción de Q_W que será parte del SS_W
- δ_W : Valor independiente de Q_W y Q_R que será parte del SS_W
- γ_R : Fracción de Q_R que será parte del SS_R
- ρ_R : Fracción de Q_W que será parte del SS_R
- δ_R : Valor independiente de Q_W y Q_R que será parte del SS_R

Comenzamos con el modelo **1–1** bajo una interpretación de cadena de abastecimiento en dos eslabones: una fábrica reabastece a un warehouse (centro de distribución), y a su vez el retailer (minorista) se reabastece desde el warehouse. En este marco, el enfoque 1–1 asume que existe un único periodo común de reaprovisionamiento T que sincroniza las órdenes en el eslabón considerado. Con demanda determinística, esto permite deducir una función de costo promedio y formular un problema de optimización unidimensional para escoger la frecuencia de reaprovisionamiento. En la siguiente figura se muestra la estructura general de estos ejercicios.




Figura 3.1: Estructura general de modelo de coordinación 1–1

En cuanto a cómo se ven los inventarios, como n ciclos de un minorista componen un ciclo del CD, la política general de inventarios se puede ver como en la siguiente figura.




Figura 3.2: Comportamiento y relaciones típicas de modelo de coordinación 1-1

Justificación matemática del modelo

Como ya hemos visto, la idea es minimizar costos de ordenar y almacenar en ambos niveles de la cadena. Así pues, definiremos la función total de costos totales con la misma lógica de anteriores temas.

$$G(Q_W, Q_R) = \frac{K_W \lambda}{Q_W} + i_W c_W \left(\frac{Q_W}{2} + SS_W \right) + \frac{K_R \lambda}{Q_R} + i_R c'_R \left(\frac{Q_R}{2} + SS_R \right)$$

Existen varias convenciones para modelar el costo unitario asociado al *retailer*. En estas notas adoptaremos la siguiente: el costo c_R se interpreta como un costo “total” en el retailer que ya incluye el componente de adquisición desde el warehouse (CD). Por lo tanto, al calcular costos de mantenimiento por eslabón, debemos evitar contabilizar dos veces el mismo valor base c_W . Para ello trabajaremos con un costo diferencial

$$c'_R := c_R - c_W,$$

de modo que c_W captura el valor del inventario mientras está en el warehouse y c'_R representa únicamente el incremento de valor/costo adicional al mover el producto del warehouse al retailer (por ejemplo, transporte, manipulación, margen o valor agregado).

Seguido de esto, al igual que en el capítulo anterior asumiremos que los stocks de seguridad tendrán una parte dependiente del lote a ordenar y otra fija en términos de datos constantes. Como ahora tenemos dos lotes a determinar, asumiremos que los stocks de seguridad del CD y los minoristas siguen la siguiente estructura

$$\begin{aligned} SS_W &= \gamma_W Q_R + \rho_W Q_W + \delta_W, & \gamma_W, \rho_W &\in [0, 1), \quad \delta_W \geq 0 \\ SS_R &= \gamma_R Q_R + \rho_R Q_W + \delta_R, & \gamma_R, \rho_R &\in [0, 1), \quad \delta_R \geq 0 \end{aligned}$$

Reemplacemos estas últimas 3 ecuaciones en la función de costos totales definida anteriormente

$$G(Q_W, Q_R) = \frac{K_W \lambda}{Q_W} + i_W c_W \left(\frac{Q_W}{2} + \gamma_W Q_R + \rho_W Q_W + \delta_W \right) \\ + \frac{K_R \lambda}{Q_R} + i_R (c_R - c_W) \left(\frac{Q_R}{2} + \gamma_R Q_R + \rho_R Q_W + \delta_R \right)$$

Notemos que la anterior función está en términos de dos variables en donde no necesariamente se sigue la regla de que n ciclos del minorista componen un ciclo del CD. Usaremos entonces la ecuación $Q_W = nQ_R$ y llegaremos a

$$G(Q_R, n) = \frac{K_W \lambda}{nQ_R} + i_W c_W \left(\frac{nQ_R}{2} + \gamma_W Q_R + \rho_W nQ_R + \delta_W \right) \\ + \frac{K_R \lambda}{Q_R} + i_R (c_R - c_W) \left(\frac{Q_R}{2} + \gamma_R Q_R + \rho_R nQ_R + \delta_R \right)$$

Ahora, a pesar de que se respeta la lógica de coordinación, todavía seguimos teniendo la función de costos en términos de 2 variables. Veamos si podemos asegurar un óptimo único de la función probando convexidad. Para esto, sacaremos la matriz Hessiana y veremos si es definida positiva. Partamos de la anterior función y agrupemos términos (solo para facilitar derivadas)

$$G(Q_R, n) = \lambda \left(\frac{K_R}{Q_R} + \frac{K_W}{nQ_R} \right) + i_W c_W \left[Q_R \left(\gamma_W + n \left(\frac{1}{2} + \rho_W \right) \right) + \delta_W \right] \\ + i_R (c_R - c_W) \left[Q_R \left(\frac{1}{2} + \gamma_R + \rho_R n \right) + \delta_R \right].$$

Derivamos parcialmente

$$\frac{\partial G}{\partial Q_R} = -\lambda \left(\frac{K_R}{Q_R^2} + \frac{K_W}{nQ_R^2} \right) + i_W c_W \left(\gamma_W + n \left(\frac{1}{2} + \rho_W \right) \right) + i_R (c_R - c_W) \left(\frac{1}{2} + \gamma_R + \rho_R n \right), \\ \frac{\partial G}{\partial n} = -\frac{\lambda K_W}{Q_R n^2} + Q_R i_W c_W \left(\frac{1}{2} + \rho_W \right) + Q_R i_R (c_R - c_W) \rho_R.$$

Sacamos segundas derivadas (Hessiana)

$$\frac{\partial^2 G}{\partial Q_R^2} = \frac{2\lambda}{Q_R^3} \left(K_R + \frac{K_W}{n} \right), \\ \frac{\partial^2 G}{\partial n^2} = \frac{2\lambda K_W}{Q_R n^3}, \\ \frac{\partial^2 G}{\partial Q_R \partial n} = \frac{\partial^2 G}{\partial n \partial Q_R} = \frac{\lambda K_W}{Q_R^2 n^2} + i_W c_W \left(\frac{1}{2} + \rho_W \right) + i_R (c_R - c_W) \rho_R.$$

Análisis de convexidad: Para $Q_R > 0$ y $n > 0$ se tiene

$$\frac{\partial^2 G}{\partial Q_R^2} > 0, \quad \frac{\partial^2 G}{\partial n^2} > 0.$$

La convexidad conjunta requiere además que el determinante de la Hessiana sea no negativo:

$$\det(\nabla^2 G) = \left[\frac{2\lambda}{Q_R^3} \left(K_R + \frac{K_W}{n} \right) \right] \left[\frac{2\lambda K_W}{Q_R n^3} \right] - \left[\frac{\lambda K_W}{Q_R^2 n^2} + i_W c_W \left(\frac{1}{2} + \rho_W \right) + i_R (c_R - c_W) \rho_R \right]^2.$$

Por tanto:

- G es convexa en Q_R si n se considera fijo (pues $\frac{\partial^2 G}{\partial Q_R^2} > 0$).
- G es convexa en n si Q_R se considera fijo (pues $\frac{\partial^2 G}{\partial n^2} > 0$).
- La convexidad conjunta en (Q_R, n) no puede afirmarse en general sin imponer condiciones adicionales, ya que depende de si $\det(\nabla^2 G) \geq 0$ para todo (Q_R, n) en el dominio.

Ejemplo 3.1 (Difícil de optimizar). Tomemos una empresa que coordina reaprovisionamientos en una estructura bajo el esquema 1-1. Para ilustrar que, aun cuando el problema es bien comportado en una variable, la convexidad (y por ende el análisis) no necesariamente se mantiene de manera conjunta en (Q_R, n) , consideremos los siguientes parámetros: demanda $\lambda = 1000$, costos fijos $K_W = 5000$ y $K_R = 7000$ y $i_W = i_R = 1\%$, $c_W = 100$, $c_R = 500$ y tomamos $\rho_W = \rho_R = \gamma_W = \gamma_R = \delta_W = \delta_R = 0$. En este escenario, el costo total promedio se reduce a

$$G(Q_R, n) = \lambda \left(\frac{K_R}{Q_R} + \frac{K_W}{n Q_R} \right) + \frac{i_W c_W}{2} n Q_R = \frac{1}{Q_R} + \frac{1}{n Q_R} + 5 n Q_R, \quad Q_R > 0, \quad n > 0.$$




Figura 3.3: Gráfica función con de costos totales en $\mathbb{R}^3$

Al graficar esta función (Figura 3.3), se observa que el costo decrece al empujar n hacia valores pequeños, pero simultáneamente requiere valores cada vez mayores de Q_R para sostener dicha disminución; esto sugiere que el problema puede no tener un minimizador alcanzable en el dominio continuo $(Q_R, n) \in (0, \infty)^2$. Para sustentar esta intuición, analizamos primero la curvatura conjunta mediante la Hessiana.

Las derivadas de segundo orden son

$$G_{Q_R Q_R} = \frac{2}{Q_R^3} \left(1 + \frac{1}{n}\right), \quad G_{nn} = \frac{2}{Q_R n^3}, \quad G_{Q_R n} = \frac{1}{Q_R^2 n^2} + 5,$$

por lo que la Hessiana es

$$\nabla^2 G(Q_R, n) = \begin{pmatrix} \frac{2}{Q_R^3} \left(1 + \frac{1}{n}\right) & \frac{1}{Q_R^2 n^2} + 5 \\ \frac{1}{Q_R^2 n^2} + 5 & \frac{2}{Q_R n^3} \end{pmatrix}.$$

Aunque $G_{Q_R Q_R} > 0$ y $G_{nn} > 0$ para $Q_R > 0$ y $n > 0$, la convexidad conjunta exige además $\det(\nabla^2 G) \geq 0$. Evaluando en $(Q_R, n) = (1, 1)$,

$$G_{Q_R Q_R}(1, 1) = 4, \quad G_{nn}(1, 1) = 2, \quad G_{Q_R n}(1, 1) = 6,$$

y en consecuencia

$$\det(\nabla^2 G)(1, 1) = 4 \cdot 2 - 6^2 = -28 < 0.$$

Esto prueba que la Hessiana es indefinida en ese punto y, por tanto, que $G(Q_R, n)$ no es convexa de manera conjunta en (Q_R, n) .

Es así como cambiaremos de enfoque: optimizaremos sobre Q_R y haremos una búsqueda discreta local para encontrar el n que minimice costos. Esto significa que en principio, trataremos a n como parámetro dado y la expresión de Q_R quedará generalizada de la siguiente forma:

Partimos de

$$G(Q_R, n) = \lambda \left(\frac{K_R}{Q_R} + \frac{K_W}{n Q_R} \right) + i_W c_W \left[Q_R \left(\gamma_W + n \left(\frac{1}{2} + \rho_W \right) \right) + \delta_W \right] \\ + i_R (c_R - c_W) \left[Q_R \left(\frac{1}{2} + \gamma_R + \rho_R n \right) + \delta_R \right].$$

Derivando respecto a Q_R (tratando n como parámetro fijo):

$$\frac{\partial G}{\partial Q_R} = -\lambda \left(\frac{K_R}{Q_R^2} + \frac{K_W}{n Q_R^2} \right) + i_W c_W \left(\gamma_W + n \left(\frac{1}{2} + \rho_W \right) \right) + i_R (c_R - c_W) \left(\frac{1}{2} + \gamma_R + \rho_R n \right).$$

Imponiendo condición de primer orden $\frac{\partial G}{\partial Q_R} = 0$:

$$\lambda \left(\frac{K_R}{Q_R^2} + \frac{K_W}{n Q_R^2} \right) = i_W c_W \left(\gamma_W + n \left(\frac{1}{2} + \rho_W \right) \right) + i_R (c_R - c_W) \left(\frac{1}{2} + \gamma_R + \rho_R n \right).$$

Factorizando $1/Q_R^2$ en el lado izquierdo:

$$\frac{\lambda}{Q_R^2} \left(K_R + \frac{K_W}{n} \right) = i_W c_W \left(\gamma_W + n \left(\frac{1}{2} + \rho_W \right) \right) + i_R (c_R - c_W) \left(\frac{1}{2} + \gamma_R + \rho_R n \right).$$

Despejando Q_R^2 y luego Q_R :

$$Q_R^2 = \frac{\lambda \left(K_R + \frac{K_W}{n} \right)}{i_W c_W \left(\gamma_W + n \left(\frac{1}{2} + \rho_W \right) \right) + i_R (c_R - c_W) \left(\frac{1}{2} + \gamma_R + \rho_R n \right)},$$

$$Q_R^* = \sqrt{\frac{\lambda \left(K_R + \frac{K_W}{n} \right)}{i_W c_W \left(\gamma_W + n \left(\frac{1}{2} + \rho_W \right) \right) + i_R (c_R - c_W) \left(\frac{1}{2} + \gamma_R + \rho_R n \right)}}.$$

¿Y el caso estocástico?

En el caso estocástico, la diferencia central es que debemos incorporar el costo esperado de faltantes. Para evitar tratar el stock de seguridad como una cantidad determinística dentro de la derivación, trabajaremos directamente con los faltantes esperados:

$$E_W[\text{Faltantes}] \quad \text{y} \quad E_R[\text{Faltantes}].$$

Estos valores no salen de la estructura de coordinación por sí solos: dependen de la distribución de demanda que se esté usando, del nivel de servicio, del lead time y de la política de inventario elegida. Por esta razón, la solución del caso estocástico depende explícitamente del modelo probabilístico que se adopte.

Partimos de la función de costos:

$$\begin{aligned} CT(Q_R, Q_W) &= \frac{K_W \lambda}{Q_W} + i_W c_W \left(\frac{Q_W}{2} \right) + p_W \left(\frac{E_W[\text{Faltantes}] \lambda}{Q_W} \right) \\ &+ \frac{K_R \lambda}{Q_R} + i_R (c_R - c_W) \left(\frac{Q_R}{2} \right) + (p_R - p_W) \left(\frac{E_R[\text{Faltantes}] \lambda}{Q_R} \right). \end{aligned}$$

Como estamos en una estructura de coordinación 1-1, imponemos:

$$Q_W = n Q_R.$$

Reemplazando, obtenemos:

$$\begin{aligned} CT(Q_R, n) &= \frac{K_W \lambda}{n Q_R} + i_W c_W \left(\frac{n Q_R}{2} \right) + p_W \left(\frac{E_W[\text{Faltantes}] \lambda}{n Q_R} \right) \\ &+ \frac{K_R \lambda}{Q_R} + i_R (c_R - c_W) \left(\frac{Q_R}{2} \right) + (p_R - p_W) \left(\frac{E_R[\text{Faltantes}] \lambda}{Q_R} \right). \end{aligned}$$

Agrupando términos, para un n fijo podemos escribir:

$$CT(Q_R, n) = \frac{A(n)}{Q_R} + B(n)Q_R,$$

donde

$$A(n) = \lambda \left(\frac{K_W + p_W E_W[\text{Faltantes}]}{n} + K_R + (p_R - p_W) E_R[\text{Faltantes}] \right),$$

y

$$B(n) = \frac{i_W c_W n}{2} + \frac{i_R (c_R - c_W)}{2}.$$

Ahora derivamos respecto a Q_R :

$$\frac{\partial CT}{\partial Q_R} = -\frac{A(n)}{Q_R^2} + B(n).$$

Igualamos a cero:

$$-\frac{A(n)}{Q_R^2} + B(n) = 0.$$

Entonces,

$$B(n) = \frac{A(n)}{Q_R^2}.$$

Despejando,

$$Q_R^*(n) = \sqrt{\frac{A(n)}{B(n)}}.$$

Por tanto,

$$Q_R^*(n) = \sqrt{\frac{2\lambda \left(\frac{K_W + p_W E_W[\text{Faltantes}]}{n} + K_R + (p_R - p_W) E_R[\text{Faltantes}] \right)}{i_W c_W n + i_R (c_R - c_W)}}.$$

Una vez encontrado $Q_R^*(n)$, recuperamos el lote del centro de distribución mediante:

$$Q_W^*(n) = n Q_R^*(n).$$

Como n debe ser entero, evaluamos distintos valores de $n = 1, 2, 3, \dots$, calculamos el costo total correspondiente y reportamos el valor que minimice la función.

Nota: dependencia de la distribución

En el caso estocástico, los términos $E_W[\text{Faltantes}]$, $E_R[\text{Faltantes}]$, SS_W y SS_R dependen de la distribución de demanda asumida. Por ejemplo, no se calculan igual bajo demanda normal o uniforme. En anteriores capítulos hemos explicado cómo encontrar los valores esperados para estos dos casos, pero no necesariamente se deberían limitar a preguntarnos por estas distribuciones.

Ecuaciones coordinación 1-1 (caso determinístico)

Mantra 1:

$$Q_R = \lambda * T_R$$

Relaciones de coordinación:

$$Q_W = \lambda * T_W = \lambda * n * T_R$$

Relación entre bodega (Warehouse) y minoristas (Retailers)

$$T_W = nT_R$$

$$Q_W = nQ_R$$

Stocks de seguridad: Asumimos las siguientes estructuras para estos

$$SS_W = \gamma_W Q_R + \rho_W Q_W + \delta_W, \quad \gamma_W, \rho_W \in [0, 1), \quad \delta_W \geq 0$$

$$SS_R = \gamma_R Q_R + \rho_R Q_W + \delta_R, \quad \gamma_R, \rho_R \in [0, 1), \quad \delta_R \geq 0$$

Inventario promedio total

$$\frac{Q_W}{2} + SS_W$$

Inventario promedio minorista

$$\frac{Q_R}{2} + SS_R$$

Costos:

★ **Costo total de mantener**

$$\begin{aligned} & iC'_W \left(\frac{Q_W}{2} + SS_W \right) + iC'_R \left(\frac{Q_R}{2} + SS_R \right) \\ &= iC_W \left(\frac{Q_W}{2} + SS_W \right) + i(C_R - C_W) \left(\frac{Q_R}{2} + SS_R \right) \\ &= iC_W \left(\frac{Q_W}{2} + SS_W \right) + i(C_R - C_W) \left(\frac{nQ_W}{2} + SS_R \right) \end{aligned}$$

★ **Costo total de realizar pedido**

$$\begin{aligned} \frac{K_W \lambda}{Q_W} + \frac{K_R \lambda}{Q_R} &= \frac{K_W \lambda}{nQ_R} + \frac{K_R \lambda}{Q_R} \\ &= \frac{\lambda}{Q_R} (K_R + K_W) \end{aligned}$$

★ **Costo total**

$$CT = C.\text{Realizar} + C.\text{Mantener}$$

$$\begin{aligned} G(Q_W, n) &= \frac{K_W \lambda}{Q_W} + i_W C'_W \left(\frac{Q_W}{2} + SS_W \right) + \frac{K_R \lambda}{Q_R} + i_R C'_R \left(\frac{Q_R}{2} + SS_R \right) \\ &= \frac{K_W \lambda}{Q_W} + i_W C_W \left(\frac{Q_W}{2} + SS_W \right) + \frac{K_R \lambda}{Q_R} + i_R (C_R - C_W) \left(\frac{Q_R}{2} + SS_R \right) \\ &= \frac{K_W \lambda}{n Q_R} + i_W C_W \left(\frac{n Q_R}{2} + SS_W \right) + \frac{K_R \lambda}{Q_R} + i_R (C_R - C_W) \left(\frac{Q_R}{2} + SS_R \right) \end{aligned}$$

Ecuaciones coordinación 1-1 (caso estocástico)

Mantra 1:

$$Q_R = \lambda T_R$$

Relaciones de coordinación:

$$Q_W = \lambda T_W = \lambda n T_R$$

Relación entre bodega (Warehouse) y minorista (Retailer):

$$T_W = n T_R$$

$$Q_W = n Q_R$$

Demanda aleatoria y niveles de pedido hasta:

Sea D_W la demanda aleatoria relevante para la bodega durante su periodo de protección, y sea D_R la demanda aleatoria relevante para el minorista durante su periodo de protección.

$$S_W = F_W^{-1}(\alpha_W), \quad S_R = F_R^{-1}(\alpha_R),$$

donde F_W y F_R son las funciones de distribución acumulada de D_W y D_R , respectivamente.

Stocks de seguridad:

$$SS_W = S_W - \mathbb{E}[D_W], \quad SS_R = S_R - \mathbb{E}[D_R].$$

Si la demanda es normal:

$$D_W \sim N(\mu_W, \sigma_W^2), \quad D_R \sim N(\mu_R, \sigma_R^2),$$

entonces:

$$S_W = \mu_W + z_W \sigma_W, \quad S_R = \mu_R + z_R \sigma_R,$$

$$SS_W = z_W \sigma_W, \quad SS_R = z_R \sigma_R.$$

Si la demanda es uniforme:

$$D_W \sim U(a_W, b_W), \quad D_R \sim U(a_R, b_R),$$

entonces:

$$S_W = a_W + \alpha_W(b_W - a_W), \quad S_R = a_R + \alpha_R(b_R - a_R),$$

$$SS_W = \left(\alpha_W - \frac{1}{2}\right)(b_W - a_W), \quad SS_R = \left(\alpha_R - \frac{1}{2}\right)(b_R - a_R).$$

Faltantes esperados:

$$\eta_W = E_W[\text{Faltantes}] = \mathbb{E}[(D_W - S_W)^+],$$

$$\eta_R = E_R[\text{Faltantes}] = \mathbb{E}[(D_R - S_R)^+].$$

Si la demanda es uniforme:

$$D_W \sim U(a_W, b_W), \quad D_R \sim U(a_R, b_R),$$

entonces:

$$\eta_W = \frac{(b_W - S_W)^2}{2(b_W - a_W)}, \quad \eta_R = \frac{(b_R - S_R)^2}{2(b_R - a_R)}.$$

o, con los niveles de servicio:

$$\eta_W = \frac{(1 - \alpha_W)^2(b_W - a_W)}{2}, \quad \eta_R = \frac{(1 - \alpha_R)^2(b_R - a_R)}{2}.$$

Si la demanda es normal, recordemos que:

$$\eta_W = L(Z_W)\sigma_W, \quad \eta_R = L(Z_R)\sigma_R.$$

Inventario promedio total:

$$\frac{Q_W}{2} + SS_W.$$

Inventario promedio minorista:

$$\frac{Q_R}{2} + SS_R.$$

Costos:

★ **Costo total de mantener**

$$\begin{aligned} & i_W C'_W \left(\frac{Q_W}{2} + SS_W \right) + i_R C'_R \left(\frac{Q_R}{2} + SS_R \right) \\ &= i_W C_W \left(\frac{Q_W}{2} + SS_W \right) + i_R (C_R - C_W) \left(\frac{Q_R}{2} + SS_R \right) \\ &= i_W C_W \left(\frac{nQ_R}{2} + SS_W \right) + i_R (C_R - C_W) \left(\frac{Q_R}{2} + SS_R \right). \end{aligned}$$

★ Costo total de realizar pedido

$$\frac{K_W \lambda}{Q_W} + \frac{K_R \lambda}{Q_R} = \frac{K_W \lambda}{n Q_R} + \frac{K_R \lambda}{Q_R}.$$

★ Costo esperado de faltantes

$$p_W \left(\frac{\eta_W \lambda}{Q_W} \right) + (p_R - p_W) \left(\frac{\eta_R \lambda}{Q_R} \right) = p_W \left(\frac{\eta_W \lambda}{n Q_R} \right) + (p_R - p_W) \left(\frac{\eta_R \lambda}{Q_R} \right).$$

★ Costo total

$$CT = C.\text{Realizar} + C.\text{Mantener} + C.\text{Faltantes}.$$

$$G(Q_R, n) = \frac{K_W \lambda}{n Q_R} + i_W C_W \left(\frac{n Q_R}{2} + S S_W \right) + p_W \left(\frac{\eta_W \lambda}{n Q_R} \right) + \frac{K_R \lambda}{Q_R} + i_R (C_R - C_W) \left(\frac{Q_R}{2} + S S_R \right) + (p_R - p_W) \left(\frac{\eta_R \lambda}{Q_R} \right).$$

Lote óptimo del minorista para un n fijo:

$$Q_R^*(n) = \sqrt{\frac{2\lambda \left(\frac{K_W + p_W \eta_W}{n} + K_R + (p_R - p_W) \eta_R \right)}{i_W C_W n + i_R (C_R - C_W)}}.$$

Receta (caso determinístico): Suponiendo que nos dan info. de costos, tasa de demanda y tasa de retención de inventario.

1. Poner todo en una misma temporalidad (usar las conversiones que nos dan).
2. Reemplazar en la ecuación de costos $Q_W = n Q_R$
3. Identificar stocks de seguridad. Asumiremos que los stocks de seguridad son combinaciones lineales de Q_R , Q_W y también de la tasa de demanda λ :

$$S S_W = \gamma_W Q_R + \rho_W Q_W + \delta_W, \quad \gamma_W, \rho_W \in [0, 1), \quad \delta_W \geq 0$$

$$S S_R = \gamma_R Q_R + \rho_R Q_W + \delta_R, \quad \gamma_R, \rho_R \in [0, 1), \quad \delta_R \geq 0$$

4. Inicializar valor de n^* .
5. Derivar función de costos totales con respecto a Q_R y despejar Q_R , o equivalentemente, usar la ecuación que dedujimos anteriormente:

$$Q_R^* = \sqrt{\frac{\lambda \left(K_R + \frac{K_W}{n} \right)}{i_W C_W \left(\gamma_W + n \left(\frac{1}{2} + \rho_W \right) \right) + i_R (C_R - C_W) \left(\frac{1}{2} + \gamma_R + \rho_R n \right)}}$$

6. Dejar expresados T_R, Q_W en función de n^* y Q_R :

$$Q_R = \lambda T_R \quad \Rightarrow \quad T_R = \frac{Q_R}{\lambda}, \quad Q_W = n Q_R$$

7. Expresar función de costos con los parámetros que dejamos expresados.
8. Solver para minimizar función de costos tal que $n^* \in \mathbb{N}$ y $n^* \geq 1$ o hacer malla discreta de valores de n y elegir el que minimice los costos totales:

$$G(Q_R, n) = \lambda \left(\frac{K_R}{Q_R} + \frac{K_W}{nQ_R} \right) + i_W c_W \left[Q_R \left(\gamma_W + n \left(\frac{1}{2} + \rho_W \right) \right) + \delta_W \right] \\ + i_R (c_R - c_W) \left[Q_R \left(\frac{1}{2} + \gamma_R + \rho_R n \right) + \delta_R \right]$$

Costos individuales:

$$C.\text{Adq}_W = \frac{\lambda K_W}{Q_W}, \quad C.\text{Adq}_R = \frac{\lambda K_R}{Q_R}$$

$$C.\text{Mant}_W = i_W c_W \left[Q_R \left(\gamma_W + n \left(\frac{1}{2} + \rho_W \right) \right) + \delta_W \right]$$

$$C.\text{Mant}_R = i_R (c_R - c_W) \left[Q_R \left(\frac{1}{2} + \gamma_R + \rho_R n \right) + \delta_R \right]$$

Ejercicio 3.1. Tome una empresa en donde la media de la demanda anual en el CD es de 134400, el costo unitario del producto es de \$1.2, el costo de ordenar es de \$220 y la tasa de mantenimiento de inventario es del 20 % anual.

En cuanto al minorista que es abastecido por este CD, se sabe que tiene un costo unitario de \$3.2, un costo de ordenar de \$80 y una tasa de mantenimiento de inventario del 20 % anual.

La empresa tiene como política interna retener 1/4 del tamaño de lote del CD en el stock de seguridad del minorista y 1 semana de la demanda en el stock de seguridad del CD. Ajuste un modelo de coordinación de inventarios y reporte el costo total anual. Asuma que un año tiene 50 semanas para realizar sus cálculos.

Solución:

Veamos el siguiente Excel con la solución al ejercicio. [Coordinación 1-1.xlsx](#)



Receta (caso estocástico: normal o uniforme): Suponiendo que nos dan info. de costos, tasa de demanda, tasa de retención de inventario y la distribución de demanda relevante para bodega y minorista.

1. Poner todo en una misma temporalidad.
2. Identificar la relación de coordinación:

$$Q_W = nQ_R, \quad T_W = nT_R.$$

3. Identificar la distribución de demanda relevante para cada nivel:

$$D_W \quad \text{y} \quad D_R.$$

4. Calcular S_W , S_R , SS_W , SS_R , η_W y η_R , donde:

$$\eta_W = E_W[\text{Faltantes}], \quad \eta_R = E_R[\text{Faltantes}].$$

Caso normal:

Si

$$D_W \sim N(\mu_W, \sigma_W^2), \quad D_R \sim N(\mu_R, \sigma_R^2),$$

entonces:

$$z_W = \text{inv.norm.estand}(\alpha_W), \quad z_R = \text{inv.norm.estand}(\alpha_R).$$

$$S_W = \mu_W + z_W \sigma_W, \quad S_R = \mu_R + z_R \sigma_R.$$

$$SS_W = z_W \sigma_W, \quad SS_R = z_R \sigma_R.$$

$$\eta_W = \sigma_W L(z_W),$$

$$\eta_R = \sigma_R L(z_R).$$

Caso uniforme:

Si

$$D_W \sim U(a_W, b_W), \quad D_R \sim U(a_R, b_R),$$

entonces:

$$S_W = a_W + \alpha_W(b_W - a_W), \quad S_R = a_R + \alpha_R(b_R - a_R).$$

$$SS_W = \left(\alpha_W - \frac{1}{2}\right)(b_W - a_W), \quad SS_R = \left(\alpha_R - \frac{1}{2}\right)(b_R - a_R).$$

$$\eta_W = \frac{(b_W - S_W)^2}{2(b_W - a_W)} = \frac{(1 - \alpha_W)^2(b_W - a_W)}{2},$$

$$\eta_R = \frac{(b_R - S_R)^2}{2(b_R - a_R)} = \frac{(1 - \alpha_R)^2(b_R - a_R)}{2}.$$

5. Inicializar un valor de $n \in \mathbb{N}$, con $n \geq 1$.

6. Para un n fijo, calcular:

$$Q_R^*(n) = \sqrt{\frac{2\lambda \left(\frac{K_W + p_W \eta_W}{n} + K_R + (p_R - p_W) \eta_R \right)}{i_W c_W n + i_R (c_R - c_W)}}.$$

7. Calcular los valores asociados:

$$Q_W^*(n) = n Q_R^*(n),$$

$$T_R^*(n) = \frac{Q_R^*(n)}{\lambda}, \quad T_W^*(n) = n T_R^*(n).$$

8. Evaluar la función de costos totales:

$$\begin{aligned} G(Q_R, n) &= \frac{K_W \lambda}{n Q_R} + i_W c_W \left(\frac{n Q_R}{2} + S S_W \right) + p_W \left(\frac{\eta_W \lambda}{n Q_R} \right) \\ &\quad + \frac{K_R \lambda}{Q_R} + i_R (c_R - c_W) \left(\frac{Q_R}{2} + S S_R \right) + (p_R - p_W) \left(\frac{\eta_R \lambda}{Q_R} \right). \end{aligned}$$

9. Hacer malla discreta sobre:

$$n = 1, 2, 3, \dots$$

y escoger:

$$n^* = \arg \min_{n \in \mathbb{N}, n \geq 1} G(Q_R^*(n), n).$$

10. Reportar:

$$Q_R^* = Q_R^*(n^*), \quad Q_W^* = n^* Q_R^*,$$

$$T_R^* = \frac{Q_R^*}{\lambda}, \quad T_W^* = n^* T_R^*.$$

Costos individuales:

$$C.\text{Adq}_W = \frac{\lambda K_W}{Q_W}, \quad C.\text{Adq}_R = \frac{\lambda K_R}{Q_R}.$$

$$C.\text{Mant}_W = i_W c_W \left(\frac{Q_W}{2} + S S_W \right) = i_W c_W \left(\frac{n Q_R}{2} + S S_W \right),$$

$$C.\text{Mant}_R = i_R (c_R - c_W) \left(\frac{Q_R}{2} + S S_R \right).$$

$$C.\text{Falt}_W = p_W \left(\frac{\eta_W \lambda}{Q_W} \right) = p_W \left(\frac{\eta_W \lambda}{n Q_R} \right).$$

$$C.\text{Falt}_R = (p_R - p_W) \left(\frac{\eta_R \lambda}{Q_R} \right).$$

3.2. Caso 1-n

En este caso tendremos una bodega y $n > 1$ minoristas. En este caso, no podemos derivar una función para encontrar un tamaño de lote óptimo, por ende usaremos la heurística de Shwarz para encontrar tiempos de ciclo para lograr un abastecimiento.

Notación coordinación 1-n

- λ_0 : Tasa de consumo asociada a la bodega [unds/Tiempo].
- T_0 : Tiempo de ciclo de consumo asociado a la bodega [Tiempo].
- K_0 : Costo de ordenar del CD [\$].
- h_0 : Costos asociados al mantenimiento unitario de la bodega [\$/Tiempo-und].
- λ_j : Tasa de consumo asociada al j -ésimo minorista [unds/Tiempo].
- T_j : Tiempo de ciclo de consumo asociado al j -ésimo minorista [Tiempo].
- K_j : Costo de ordenar del j -ésimo minorista [\$].
- h_j : Costos asociados al mantenimiento unitario del j -ésimo minorista [\$/Tiempo-und].
- SS_j : Stock de seguridad del j -ésimo minorista [unds].

Ecuaciones coordinación 1-n

Heurística:

$$T_j^* = \sqrt{\frac{2K_j}{h_j\lambda_j}}$$

$$T_0 = \begin{cases} T_0^*, & \text{si } J = \emptyset \\ \sqrt{\frac{2(K_0 + \sum_{j \in J} K_j)}{\lambda_0 h_0 + \sum_{j \in J} \lambda_j h_j}}, & \text{si } J \neq \emptyset \end{cases}$$

$$\begin{aligned} \min CT_j &= \frac{n_j K_j}{T_0} + h_j \left(\frac{\lambda_j T_0}{2n_j} + SS_j \right) \\ &= \frac{K_j}{T_j} + h_j \left(\frac{\lambda_j T_j}{2} + SS_j \right) \end{aligned}$$

Si SS_j es una fracción γ_j de Q_j :

$$= \frac{K_j}{T_j} + h_j \lambda_j T_j \left(\frac{1}{2} + \gamma_j \right)$$

Costos:

$$\begin{aligned} N &= \text{Cantidad de minoristas} + \text{Cantidad de bodegas} \\ &= \text{Cantidad de minoristas} + 1 \end{aligned}$$

★ Costo de adquirir

$$\sum_{j=0}^N \frac{K_j}{T_j}$$

★ Costo de mantener

$$\sum_{j=0}^N h_j \left(\frac{\lambda_j T_0}{2n_j} + SS_j \right)$$

★ Costo total

$$\sum_{j=0}^N \frac{n_j K_j}{T_0} + h_j \left(\frac{\lambda_j T_0}{2n_j} + SS_j \right)$$

Receta (caso determinístico): Suponiendo que tenemos λ, K y h de todos los minoristas y de la bodega.

1. Poner h_j y λ_j en las misma temporalidad $\forall j$.
2. Aplicar heurística de Shwarz: primero encontraremos parámetros iniciales $T_j^* \forall j$ y luego los recalcularemos para llegar a los finales $T_j \forall j$

a) Encontrar todos los T_j^*

$$T_j^* = \sqrt{\frac{2K_j}{h_j \lambda_j}}$$

b) Armar conjunto J

$$J = \{j : T_j^* > T_0^*\}$$

c) Recalcular T_0

$$T_0 = \begin{cases} T_0^*, & \text{si } J = \emptyset \\ \sqrt{\frac{2 \left(K_0 + \sum_{j \in J} K_j \right)}{\lambda_0 h_0 + \sum_{j \in J} \lambda_j h_j}}, & \text{si } J \neq \emptyset \end{cases}$$

d) Inicializar valor de $n_j \forall j$. El de la bodega siempre será 1 y no se deberá cambiar aún si hay mejores valores al hacer la optimización.

e) Sacar valores de SS .

f) Poner función objetivo de costo total para cada j :

$$CT_j = \sum_{j=0}^N \frac{n_j K_j}{T_0} + h_j \left(\frac{\lambda_j T_0}{2n_j} + SS_j \right)$$

g) Solver o malla discreta para minimizar función de costos tal que $n_j^* \in \mathbb{N}$ y $n_j^* \geq 1$.

3. Calcular los $T_j \forall j$:

$$T_j = T_0 / n_j$$

4. Calcular $Q_j = T_j * \lambda_j$

5. Calcular costo total: Este será la suma de los costos totales para cada j que calculamos anteriormente:

$$CT = \sum_{j=0}^N CT_j = \sum_{j=0}^N \frac{n_j K_j}{T_0} + h_j \left(\frac{\lambda_j T_0}{2n_j} + SS_j \right)$$

Ejercicio 3.2. Tome una empresa con los siguientes parámetros

Nombre	λ_j [und/año]	K_j [\$]	h_j [\$/und-año]
Bodega	???	40	11
Minorista 1	993	202	172
Minorista 2	304	283	43
Minorista 3	542	144	378
Minorista 4	859	408	498
Minorista 5	478	84	441

- (i) Encuentre el valor de λ_0 .
- (ii) Ajuste un modelo de coordinación especificando los costos totales y tiempos de ciclo óptimos.

Solución:

- (i) Aplicamos $\lambda_0 = \sum_{j \neq 0} \lambda_j$
- (ii) Veamos el siguiente Excel con la solución del apartado. [Coordinación 1-n.xlsx](#)



3.3. Ejemplos de ejercicios anidados

En esta sección veremos un par de ejemplos de ejercicios anidados, donde se combinan ideas de las dos secciones anteriores. La intuición general es la siguiente: primero se prioriza uno de los dos esquemas (ya sea 1-1 o 1-n) y se aplica su receta completa hasta obtener un tiempo de ciclo óptimo. Luego, ese tiempo de ciclo se toma como input para continuar con el resto de eslabones del sistema, completando el análisis del modelo “en cascada” a partir del ciclo óptimo hallado en la primera etapa.

3.3.1. Caso 1-1-n con énfasis en 1-1

Receta: Dados costos de todos los eslabones.

Primera parte: 1-1:

1. Poner todo en una misma temporalidad (usar las conversiones que nos dan).
2. Reemplazar en la ecuación de costos $Q_W = nQ_R$

3. Identificar stocks de seguridad. Asumiremos que los stocks de seguridad son combinaciones lineales de Q_R , Q_W y también de la tasa de demanda λ :

$$SS_W = \gamma_W Q_R + \rho_W Q_W + \delta_W, \quad \gamma_W, \rho_W \in [0, 1), \quad \delta_W \geq 0$$

$$SS_R = \gamma_R Q_R + \rho_R Q_W + \delta_R, \quad \gamma_R, \rho_R \in [0, 1), \quad \delta_R \geq 0$$

4. Inicializar valor de n^* .
5. Derivar función de costos totales con respecto a Q_R y despejar Q_R , o equivalentemente, usar la ecuación que dedujimos anteriormente:

$$Q_R^* = \sqrt{\frac{\lambda \left(K_R + \frac{K_W}{n} \right)}{i_W c_W \left(\gamma_W + n \left(\frac{1}{2} + \rho_W \right) \right) + i_R (c_R - c_W) \left(\frac{1}{2} + \gamma_R + \rho_R n \right)}}$$

6. Dejar expresados T_R, Q_W en función de n^* y Q_R :

$$Q_R = \lambda T_R \quad \Rightarrow \quad T_R = \frac{Q_R}{\lambda}, \quad Q_W = n Q_R$$

7. Expresar función de costos con los parámetros que dejamos expresados.
8. Solver para minimizar función de costos tal que $n^* \in \mathbb{N}$ y $n^* \geq 1$ o hacer malla discreta de valores de n y elegir el que minimice los costos totales:

$$G(Q_R, n) = \lambda \left(\frac{K_R}{Q_R} + \frac{K_W}{n Q_R} \right) + i_W c_W \left[Q_R \left(\gamma_W + n \left(\frac{1}{2} + \rho_W \right) \right) + \delta_W \right] \\ + i_R (c_R - c_W) \left[Q_R \left(\frac{1}{2} + \gamma_R + \rho_R n \right) + \delta_R \right]$$

Costos individuales:

$$C.\text{Adq}_W = \frac{\lambda K_W}{Q_W}, \quad C.\text{Adq}_R = \frac{\lambda K_R}{Q_R}$$

$$C.\text{Mant}_W = i_W c_W \left[Q_R \left(\gamma_W + n \left(\frac{1}{2} + \rho_W \right) \right) + \delta_W \right]$$

$$C.\text{Mant}_R = i_R (c_R - c_W) \left[Q_R \left(\frac{1}{2} + \gamma_R + \rho_R n \right) + \delta_R \right]$$


Segunda parte: 1–n

9. Considerar parámetros y costos de este eslabón.
10. Tomar T_R como el T_0 para el siguiente eslabón.
11. Sacar SS .

12. Sacar tabla solo para minoristas

Minorista	n	T	Q	C.Ord	C.Mant	C.Total
j	Optimizar	T_0/n_j	$T_j \lambda_j$	$\frac{K_j}{T_j}$	$h_j \left(\frac{\lambda_j T_0}{2n_j} + SS_j \right)$	$\sum \text{Costos}$

Ejercicio 3.3. Tome una empresa con la siguiente estructura de cadena de suministro



Con los siguientes parámetros por eslabón

	Bodega	CD
Costo del producto [\$/und]	20000	25000
Costo fijo de ordenar [\$]	500000	40000
Tasa anual de mantener inventario	0,15	0,15

	Minorista 1	Minorista 2
Demanda [und/mes]	300	240
Costo del producto [\$/und]	120000	100000
Costo fijo de ordenar [\$]	22000	24000
Tasa anual de mantener inventario	0,2	0,2

Se sabe que la empresa tiene como política retener $1/4$ del tamaño de lote de la bodega como su stock de seguridad. El minorista 1 retiene 10 días de su demanda mientras que el minorista 2 retiene 8 días de la demanda en sus respectivos stocks de seguridad. Ajuste un modelo de coordinación de inventarios haciendo énfasis en la relación bodega-CD tal que optimice los costos totales de operación. Reporte los costos desagregados de cada eslabón. Asuma que un mes tiene 30 días en sus cálculos.

Solución:

Veamos el siguiente Excel con la solución del ejercicio. [Coordinación \(1-1\)-n.xlsx](#)



3.3.2. Caso 1-1-n con énfasis en 1-n

Parte 1: 1-n

1. Poner h_j y λ_j en las misma temporalidad $\forall j$.
2. Aplicar heurística de Shwarz: primero encontraremos parámetros iniciales $T_j^* \forall j$ y luego los recalcularemos para llegar a los finales $T_j \forall j$

- a) Encontrar todos los T_j^*

$$T_j^* = \sqrt{\frac{2K_j}{h_j \lambda_j}}$$

- b) Armar conjunto J

$$J = \{j : T_j^* > T_0^*\}$$

- c) Recalcular T_0

$$T_0 = \begin{cases} T_0^*, & \text{si } J = \emptyset \\ \sqrt{\frac{2(K_0 + \sum_{j \in J} K_j)}{\lambda_0 h_0 + \sum_{j \in J} \lambda_j h_j}}, & \text{si } J \neq \emptyset \end{cases}$$

- d) Inicializar valor de $n_j \forall j$. En este caso, optimizaremos todos y solo incluiremos minoristas en el cálculo.
- e) Sacar valores de SS .
- f) Poner función objetivo de costo total para cada j :

$$CT_j = \sum_{j=0}^N \frac{n_j K_j}{T_0} + h_j \left(\frac{\lambda_j T_0}{2n_j} + SS_j \right)$$

- g) Solver o malla discreta para minimizar función de costos tal que $n_j^* \in \mathbb{N}$ y $n_j^* \geq 1$.

3. Calcular los $T_j \forall j$:

$$T_j = T_0 / n_j$$

4. Calcular $Q_j = T_j * \lambda_j$

5. Calcular costo total: Este será la suma de los costos totales para cada j que calculamos anteriormente:

$$CT = \sum_{j=0}^N CT_j = \sum_{j=0}^N \frac{n_j K_j}{T_0} + h_j \left(\frac{\lambda_j T_0}{2n_j} + SS_j \right)$$

Parte 2: 1–1

5. Considerar parámetros y costos de este eslabón.
6. Tomar T_0 como T_R .
7. Tomar $\lambda = \sum_j \lambda_j$
8. Sacar fracciones y constantes de los stocks de seguridad:
 - γ_W : Fracción de Q_R que será parte del SS_W
 - ρ_W : Fracción de Q_W que será parte del SS_W
 - δ_W : Valor independiente de Q_W y Q_R que será parte del SS_W
 - γ_R : Fracción de Q_R que será parte del SS_R
 - ρ_R : Fracción de Q_W que será parte del SS_R
 - δ_R : Valor independiente de Q_W y Q_R que será parte del SS_R
9. Sacar tabla de costos totales


Minorista	n	T	Q	C.Ord	C.Mant	C.Total
R	Optimizar	T_0	$T_R \lambda$	$\frac{K_R}{T_R}$	Ec 3.1	$\sum$ Costos R
Q	1	$n_R T_R$	$T_Q \lambda$	$\frac{K_Q}{T_Q}$	Ec 3.2	$\sum$ Costos W

$$C.Mant_R = i_R(c_R - c_W) \left[Q_R \left(\frac{1}{2} + \gamma_R + \rho_R n_R \right) + \delta_R \right] \quad (3.1)$$

$$C.Mant_W = i_W c_W \left[Q_R \left(\gamma_W + n_R \left(\frac{1}{2} + \rho_W \right) \right) + \delta_W \right] \quad (3.2)$$

10. Elegir n_R para minimizar $\sum$ Costos W + $\sum$ Costos R.

Ejercicio 3.4. Tome una empresa con la siguiente estructura de cadena de suministro



Con los siguientes parámetros por eslabón

	Bodega	CD
Costo del producto [\$/und]	20000	25000
Costo fijo de ordenar [\$]	500000	40000
Tasa anual de mantener inventario	0,15	0,15

	Minorista 1	Minorista 2
Demanda [und/mes]	300	240
Costo del producto [\$/und]	120000	100000
Costo fijo de ordenar [\$]	22000	24000
Tasa anual de mantener inventario	0,2	0,2

Se sabe que la empresa tiene como política retener 1/4 del tamaño de lote de la bodega como su stock de seguridad. El minorista 1 retiene 10 días de su demanda mientras que el minorista 2 retiene 8 días de la demanda en sus respectivos stocks de seguridad. Ajuste un modelo de coordinación de inventarios haciendo énfasis en la relación CD–minoristas tal que optimice los costos totales de operación. Reporte los costos desagregados de cada eslabón. Asuma que un mes tiene 30 días en sus cálculos.

Solución:

Veamos el siguiente Excel con la solución del ejercicio. [Coordinación 1–\(1–n\).xlsx](#)



3.3.3. Caso 1-n-1

Receta:

★ Parte 1-n

1. Identificamos parámetros básicos para todos los niveles de la cadena

Eslabón	K [\$/pedido]	c [\$/und]	i [%/Tiempo]	λ [unds/Tiempo]	SS [unds]
Copiamos de enunciado					

2. Ponemos todo en la misma temporalidad y en mismas unidades.
3. Siempre operaremos yendo de distribuidores a distribuidos.
4. Aplicamos heurística de Shwarz:

a) Encontrar todos los T_j^*

$$T_j^* = \sqrt{\frac{2K_j}{h_j \lambda_j}}$$

b) Armar conjunto J

$$J = \{j : T_j^* > T_0^*\}$$

c) Recalcular T_0

$$T_0 = \begin{cases} T_0^*, & \text{si } J = \emptyset \\ \sqrt{\frac{2 \left(K_0 + \sum_{j \in J} K_j \right)}{\lambda_0 h_0 + \sum_{j \in J} \lambda_j h_j}}, & \text{si } J \neq \emptyset \end{cases}$$

d) Inicializar valor de $n_j \forall j$.

Nombre	n	T	Q	C. Orden	C. Mant
CD 1	Inicializar	$T_j = T_0/n$	$\lambda_R * T_j$	K_R/T_j	$i_R * c_R * (Q_R/2 + SS_R)$
...					

e) Poner función objetivo de costo total para cada j :

$$CT_j = \frac{n_j K_j}{T_0} + h_j \left(\frac{\lambda_j T_0}{2n_j} + SS_j \right)$$

f) Solver para minimizar función de costos tal que $n_j^* \in \mathbb{N}$ y $n_j^* \geq 1$

★ Parte 1-1

5. Pasamos al siguiente eslabón por cada fila de la anterior matriz que acabamos de crear. Se heredará el T_j del proveedor de cada minorista como T_0 para cada minorista y repetiremos la heurística desde la tabla final

- Identificamos el T_j del proveedor de cada minorista. Este será el T_0 de cada minorista.
- Creamos, llenamos y optimizamos la siguiente tabla para todos los minoristas encontrando el n óptimo.

Nombre	n	T	Q	C. Orden	C. Mant
M1	Inicializar	$T_j = T_0/n$	$\lambda_{M1} * T_j$	K_{M1}/T_j	$i_{M1} * c_{M1} * (Q_{M1}/2 + SS_{M1})$
...					

6. Repetir los pasos anteriores para todos los minoristas asociados a los establecimientos que los proveen.

Capítulo 4

Modo de transporte

En esta sección introducimos el problema de *modo de transporte* cuando el tamaño de embarque Q (y por ende el tiempo de ciclo T) no viene dado. La lógica central es que Q y T están ligados por $Q = \lambda T$, y que el costo unitario efectivo del sistema incorpora el flete $r(Q)$, el cual depende del propio tamaño de embarque a través de restricciones de capacidad (por ejemplo, $\#veh(Q) = \lceil Q/C \rceil$) y de costos fijos por despacho. En consecuencia, el problema general se plantea como una minimización sobre Q :

$$\min_{Q \in \mathbb{Z}_{\geq 1}} CT(Q), \quad \text{con } T = \frac{Q}{\lambda},$$

donde $CT(Q)$ agrega costos de mantener inventario (típicamente crecientes en Q), costos por ciclo típicamente decrecientes en $1/Q$ y los términos asociados al transporte mediante $r(Q)$, cuando no tenemos acceso al tiempo de ciclo, procedemos con una búsqueda local entera en Q para determinar los demás parámetros. Como este modelo tiene parámetros enteros, no podemos definir un costo mínimo global pues el problema de optimización no es convexo ni unimodal. Cuando, en cambio, el tiempo de ciclo T sí es conocido (o está fijado por decisiones externas), el problema se simplifica: basta calcular $Q = \lambda T$ y evaluar los parámetros operativos inducidos (número de vehículos/contenedores, flete unitario, costo unitario efectivo, etc.) para finalmente obtener los costos totales del sistema bajo ese ciclo.

Notación Modo de transporte

- λ : Demanda [unds/Tiempo].
- r : Flete transporte [\$ /unds].
- τ : Tiempo de tránsito [Tiempo].
- T : Tiempo de ciclo de aprovisionamiento [Tiempo].
- f : Frecuencia de ciclo de aprovisionamiento [1/Tiempo].
- Q : Tamaño de la orden [unds].
- SS_k : Stock de seguridad en el eslabón k de la cadena [unds].

- I : Conjunto de metodos de transporte.
- J : Conjunto de metodos de carga
- i : Método de transporte.
- j : Método de carga.
- $\#_i$: Cantidad de transportes i que usaremos.
- $\#_j$: Cantidad de transportes j que usaremos.
- P : Costos totales por pedido [\$/pedido].
- K : Costos totales por método de transporte o método de carga [\$/und transporte] [\$/und carga].
- U : Costos totales por unidad [\$/und].

Ecuaciones Modo de transporte

Mantra 1:

$$Q_R = \lambda * T_R$$

$$C' = C + r$$

$$\#_i = \text{REDONDEAR.MAS} \left(\frac{Q}{\text{Capacidad}_i}; 0 \right)$$

$$\#_j = \text{REDONDEAR.MAS} \left(\frac{Q}{\text{Capacidad}_j}; 0 \right)$$

$$\text{Costos totales}_{ij} = (P_i + P_j) + (K_i * \#_i + K_j * \#_j) + (U_i + U_j) * Q \quad \forall (i, j) \in I \times J$$

NOTA RE IMPORTANTE: No confundir Costos totales_{ij} con CT. Costos totales_{ij} es el numerador de la ecuación de r mientras CT son los costos totales de la política.

$$r_{ij} = \frac{\text{Costos totales}_{ij}}{Q} = \frac{\text{Costos totales}_{ij}}{T * \lambda}$$

$$\tau_{ij} = \tau_i + \tau_j$$

Receta: Modelo de modo de transporte, asumiendo que tenemos costos en cada parte de la cadena de suministro y un tiempo de ciclo dado. Asumimos que tenemos un modo de transporte i y de carga j .

Indexaremos los modos de transporte en $i \in I = \{1, 2, \dots, n\}$ y los modos de carga en $j \in J = \{1, 2, \dots, m\}$

1. Poner todo en misma temporalidad y en unidades comparables con factores de conversión que nos da el enunciado.
2. Encontrar tasa de consumo lambda λ .
3. Encontrar tiempo de reaprovisionamiento T .

4. Encontrar tamaño de lote teniendo en cuenta el modo de transporte

$$Q = \lambda * T$$

5. PASO MÁS IMPORTANTE: Identificar qué costos están por unidad, por unidad de transporte/carga o por pedido. Usaremos la siguiente notación:

- P : Costos totales por pedido [\$/pedido].
- K : Costos totales por método de transporte o método de carga [\$/und transporte] [\$/und carga].
- U : Costos totales por unidad [\$/und].

6. Crear combinaciones entre métodos de transporte y carga y encontrar costos unitarios para encontrar r

i	j	Q	$\#_i$	$\#_j$	Costos totales	τ total	r
1	1	Copiamos	Eq. 4.1	Eq. 4.2	Eq. 4.3	Eq. 4.4	Eq. 4.5
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

$$\#_i = \text{REDONDEAR.MAS} \left(\frac{Q}{\text{Capacidad}_i}; 0 \right) \quad (4.1)$$

$$\#_j = \text{REDONDEAR.MAS} \left(\frac{Q}{\text{Capacidad}_j}; 0 \right) \quad (4.2)$$

$$\text{Costos totales}_{ij} = (P_i + P_j) + (K_i * \#_i + K_j * \#_j) + (U_i + U_j) * Q \quad \forall (i, j) \in I \times J \quad (4.3)$$

$$\tau_{ij} = \tau_i + \tau_j \quad (4.4)$$

$$r_{ij} = \frac{\text{Costos totales}_{ij}}{Q} = \frac{\text{Costos totales}_{ij}}{T * \lambda} \quad (4.5)$$

7. Encontrar parámetros de costos para todos los niveles de la cadena. La mayoría de veces nos los dan, pero incluimos fórmulas por si hay que despejar

★ **Planta:**

Parámetro	Fórmula
i_{Pl}	h_{Pl}/C_{Pl}
C_{Pl}	h_{Pl}/i_{Pl}
SS_{Pl}	Enunciado

★ **Tránsito:**

Parámetro	Fórmula
i_{Tr}	h_{Tr}/C_{Tr}
C_{Tr}	h_{Tr}/i_{Tr}
SS_{Tr}	Enunciado

★ **CD:**

Parámetro	Fórmula
i_{CD}	Enunciado
C'_{CD}	$h_{CD}/i_{CD} + r$
SS_{CD}	Enunciado

8. Tabla de costos

i	j	C.M.PI	C.M.Tránsito	C.Transporte	C.M CD	CT
1	1	Eq. 4.6	Eq. 4.7	Eq. 4.8	Eq. 4.9	Suma

$$C.M.PI_{ij} = i_{Pl} * C_{Pl} * \left(\frac{Q}{2} + SS_{Pl} \right) \quad (4.6)$$

$$C.M.Tránsito_{ij} = i_{Tr} * C_{Tr} * \lambda * \tau_{ij} \quad (4.7)$$

$$C.Transporte_{ij} = \frac{1}{T} * (\text{Costos totales})_{ij} = \lambda * r_{ij} \quad (4.8)$$

$$\begin{aligned} C.M CD_{ij} &= i_{CD} * (C'_{CD}) * (Q/2 + SS_{CD}) \\ &= i_{CD} * (C_{CD} + r_{ij}) * (Q/2 + SS_{CD}) \end{aligned} \quad (4.9)$$

Ejercicio 4.1. Tome una empresa con dos métodos de transportar su mercancía: terrestre y aéreo, y dos métodos de carga: robots y operarios con los siguientes costos y parámetros

M. T	CF x veh	CV	τ	Capacidad de carga	Emisiones CO ₂
Unidades	[\$/veh]	[\$/und]	[años]	[unds]	[kg por und]
Terrestre	\$ 1.500.000	0,1	0,01111111	1.200.000	0,05
Aéreo	\$ 3.500.000	0,5	0,00277778	1.500.000	0,2

M. C	CF	τ	Capacidad de carga	Costo por el servicio
Unidades	[\$/pedido]	[años]	[unds]	[\$/und carga]
Robots	\$ 2.000.000,00	0,00277778	180.000	350.000,00
Operarios	\$ 400.000,00	0,00833333	67.500	110.000,00

Nota: Por políticas ambientalistas, se cobrará \$10 por cada kg de CO₂.

También se sabe que la planta tiene una demanda anual de 54 millones de unidades. retención de inventario del 30 %, tránsito un 32 % y el centro de distribución un 38 %.

En cuanto a los costos unitarios, se maneja uno de \$80 en planta y en tránsito.

Finalmente, la planta contempla un stock de seguridad de 10 días de la demanda mientras que el CD tiene uno de 12 días de la demanda.

Encuentre la combinación Transporte–Carga que minimice los costos totales reporte esta cantidad ajustando su modelo a un tiempo de ciclo de 18 días. Considere que un año tiene 360 días.

Solución:

Veamos el siguiente Excel con la solución del ejercicio. [Modo de transporte con T.xlsx](#)



Receta: Modelo iterativo cuando no tenemos Q ni T . Como estaremos trabajando con iteraciones, denotamos con k la k -ésima iteración y con i el i -ésimo modo de transporte.

1. Considerar costos y demanda inicial del problema.
2. Encontrar parámetros para inventarios de cada eslabón de la cadena

★ **Planta:**

Parámetro	Fórmula
i_{Pl}	h_{Pl}/C_{Pl}
C_{Pl}	h_{Pl}/i_{Pl}
SS_{Pl}	Enunciado

★ **Tránsito:**

Parámetro	Fórmula
i_{Tr}	h_{Tr}/C_{Tr}
C_{Tr}	h_{Tr}/i_{Tr}
SS_{Tr}	Enunciado

★ **CD:**

Parámetro	Fórmula
i_{CD}	h_{CD}/C_{CD}
C_{CD}	Dejar en blanco porque no tenemos r
SS_{CD}	Enunciado

3. Crear tabla de iteración

Indice	Transp	Q	$\#_i$	CT_i	r	c'_{CD}	C.Pl	C.Trnst	C.Tporte	C.CD	CT
--------	--------	-----	--------	--------	-----	-----------	------	---------	----------	------	----

donde

4. | Indice $_k$ | : Hacemos una secuencia larga $\{k\}_{k=1}^N$.
5. | Transp | : Ponemos nombre de método del i -ésimo modo de transporte (solo por claridad).
6. | Q_k | : Crear con respecto a lo que diga el enunciado.

7. | $\#_{ik}$ | :

$$\#_{ik} = \text{REDONDEAR.MAS} \left(\frac{Q_k}{\text{Capacidad}_i}; 0 \right)$$

8. PASO MÁS IMPORTANTE: Identificar qué costos están por unidad, por unidad de transporte/carga o por pedido. Usaremos la siguiente notación:

- P : Costos totales por pedido [\$/pedido].
- K : Costos totales por método de transporte o método de carga [\$/und transporte] [\$/und carga].
- U : Costos totales por unidad [\$/und].

9. | CT_{ik} | :

$$\text{Costos totales}_{ik} = (P_i) + (K_i * \#_{ik}) + (U_i) * Q_k \quad \forall (i, j) \in I \times K$$

10. | r_{ik} | :

$$r_{ik} = \frac{\text{Costos totales}_{ik}}{Q_k} = \frac{\text{Costos totales}_{ik}}{T\lambda}$$

11. | c'_{CD} | :

$$c'_{CD} = c_{CD} + r_{ik}$$

12. | $C.PI$ | :

$$C.M.Tránsito_{ik} = i_{Tr} * C_{Tr} * \lambda * \tau_i$$

13. | $C.Trnst$ | :

$$C.M.Tránsito_{ik} = i_{Tr} * C_{Tr} * \lambda * \tau_i$$

14. | $C.Tporte$ | :

$$C.Transporte_{ik} = \frac{1}{T} * (\text{Costos totales})_{ij} = \lambda * r_{ik}$$

15. | $C.CD$ | :

$$\begin{aligned} C.M.CD_{ik} &= i_{CD} * (C'_{CD}) * (Q/2 + SS_{CD}) \\ &= i_{CD} * (C_{CD} + r_{ik}) * (Q/2 + SS_{CD}) \end{aligned}$$

16. | CT | :

$$\sum \text{Costos}$$

Ejercicio 4.2. Tome una empresa con la siguiente información de parámetros y costos

Transporte	τ	Capacidad	K	Costo de Alquiler
Unidades	[años]	[unds/vehículo]	[\$/pedido]	[\$/vehículo]
Terrestre	0,01	33333	450000	1800000

Planta		
i	0,25	[%/año]
C	720	[\$/und]
SS	60000	[und]

Tránsito		
i	0,1	[%/año]
C	720	[\$/und]

CD			
i	0,12		[%/año]
SS	Terrestre	20000	[und]

Además, se sabe que la empresa tiene una demanda anual de 9000000 y que el tamaño de lote siempre se pide en múltiplos de 10000.

Ajuste un modelo de modo de transporte encontrando y reportando el costo total de la política óptima y el tamaño de lote óptimo.

Solución:

Veamos el siguiente Excel con la solución del ejercicio. [Modo de transporte sin T.xlsx](#)



¿Qué pasa si tenemos más de un método de transporte?

Hacemos otra tabla de iteración con los demás métodos de transporte y comparamos costos totales.

Capítulo 5

Ruta más corta

En logística y en modelos de transporte es común representar el sistema como una red o grafo donde los nodos son ubicaciones relevantes (intersecciones, bodegas, clientes) y los arcos representan trayectos posibles con un costo asociado (distancia, tiempo o dinero). Un problema fundamental en este contexto es encontrar, desde un origen dado (por ejemplo, un centro de distribución), la secuencia de arcos que minimiza el costo total hasta un destino (o incluso hasta todos los destinos posibles). Aunque este problema puede formularse como un modelo de optimización en redes, en la práctica se resuelve con algoritmos especializados mucho más eficientes. En particular, cuando los costos de los arcos son no negativos (caso típico en distancias y tiempos), el algoritmo de Dijkstra permite calcular de manera exacta y en tiempo polinomial las distancias mínimas desde el origen, entregando además la estructura de caminos óptimos. Esta herramienta será clave como bloque de construcción para problemas más complejos de distribución, donde primero necesitamos definir costos mínimos entre puntos antes de decidir rutas completas.

5.1. Algoritmo Dijkstra

Dijkstra es un algoritmo para hallar caminos de costo mínimo desde un nodo origen s hacia todos los demás nodos en un grafo ponderado con pesos no negativos. La idea central es mantener una estimación $d(v)$ de la mejor distancia conocida a cada nodo v e ir “confirmando” distancias en orden creciente: en cada iteración se selecciona el nodo no confirmado con menor $d(\cdot)$ y se fija su valor como óptimo, pues cualquier ruta alternativa tendría que pasar por nodos con distancia estimada mayor o igual. Luego, se actualizan las estimaciones de sus vecinos v evaluando si $d(u) + w(u, v)$ mejora a $d(v)$; si mejora, se reemplaza $d(v)$ y se guarda el predecesor para reconstruir el camino. Al finalizar, $d(v)$ contiene el costo mínimo desde s y los predecesores determinan la ruta correspondiente.

Ejemplo 5.1 (Ejemplo corto: dos iteraciones de Dijkstra). Consideremos una empresa de transporte que desea minimizar el costo total de mover una carga desde el nodo origen s hasta el nodo destino t . Modelamos la red como un grafo dirigido $G = (V, E)$ donde cada arco $(u, v) \in E$ tiene un costo no negativo $c(u, v) \geq 0$.

Comencemos definiendo una red con un conjunto de vértices $V = \{s, a, b, t\}$ y los arcos

con sus respectivos costos:

$$c(s, a) = 2, \quad c(s, b) = 5, \quad c(a, b) = 1, \quad c(a, t) = 6, \quad c(b, t) = 2.$$

Buscamos la ruta de costo mínimo desde s hasta t .

Inicialización. Definimos $d(v)$ como el mejor costo conocido desde s hasta v . Inicialmente:

$$d(s) = 0, \quad d(a) = \infty, \quad d(b) = \infty, \quad d(t) = \infty.$$

Además, mantenemos un conjunto S de nodos confirmados (aquellos cuyo valor $d(\cdot)$ ya no mejorará).

Iteración 1 (confirmar s). El nodo con menor distancia provisional es s (pues $d(s) = 0$). Lo confirmamos: $S \leftarrow \{s\}$. Actualizamos sus aristas salientes:

$$d(a) \leftarrow \min\{d(a), d(s) + c(s, a)\} = \min\{\infty, 0 + 2\} = 2,$$

$$d(b) \leftarrow \min\{d(b), d(s) + c(s, b)\} = \min\{\infty, 0 + 5\} = 5.$$

En este punto: $d(a) = 2$, $d(b) = 5$, $d(t) = \infty$.

Iteración 2 (confirmar a). Ahora el menor provisional es a (pues $d(a) = 2$). Confirmamos: $S \leftarrow \{s, a\}$. Actualizamos desde a :

$$d(b) \leftarrow \min\{d(b), d(a) + c(a, b)\} = \min\{5, 2 + 1\} = 3,$$

$$d(t) \leftarrow \min\{d(t), d(a) + c(a, t)\} = \min\{\infty, 2 + 6\} = 8.$$

En este punto: $d(b) = 3$, $d(t) = 8$.

Iteración 3 (confirmar b y cerrar en t). Confirmamos b (menor provisional: $d(b) = 3$) y actualizamos hacia t :

$$d(t) \leftarrow \min\{d(t), d(b) + c(b, t)\} = \min\{8, 3 + 2\} = 5.$$

Por lo tanto, el costo mínimo desde s hasta t es $d(t) = 5$ y la ruta correspondiente es $s \rightarrow a \rightarrow b \rightarrow t$.

La idea principal de este ejemplo es que Dijkstra funciona porque todos los costos son no negativos, entonces una vez confirmamos un nodo u , su valor $d(u)$ ya no puede mejorar.

En este curso se presenta Dijkstra en su versión “simple” usando un conjunto de nodos no visitados, lo cual lleva a seleccionar el siguiente nodo mínimo en $O(n)$ por iteración y, en total, a una complejidad $O(n^2)$. Al implementar Dijkstra con una cola de prioridad (heap), extraemos el mínimo en $O(\log n)$ y el costo total baja típicamente a $O((n+m) \log n)$ (con $m = |E|$), lo cual es especialmente útil en grafos grandes y dispersos.

Ahora, explicaremos la lógica del algoritmo mediante un pseudo-código que se puede editar en cualquier ejercicio que contemple

- Restricciones fuertes, que hacen inviable un arco.
- Restricciones débiles, que no hacen inviables los arcos, pero penalizan atributos que acumulamos.

- Restricciones de máximo, que tienen un “techo” de ocurrencias y a partir de este, los arcos que violan la restricción son penalizados o quedan infactibles.

Nota: A pesar de que la implementación de Dijkstra que haremos a continuación es robusta en el sentido de que puede extrapolarse “fácilmente” a muchos tipos de ejercicio con distintas restricciones, desgraciadamente no retorna el orden de marcado de los nodos a lo largo de las iteraciones.

Algoritmo 1 Dijkstra con restricciones y atributos acumulables

```

1: Cargar Excel como DataFrame usando pandas.
2: Crear grafo  $G = (V, E)$ .
3: Cargar atributos.
4: [EDITAR] Especificar atributos a actualizar y a considerar en dichas actualizaciones.
5: [EDITAR] Opcional: graficar el grafo.

6: Def DIJKSTRA( $G$ ,  $inicio$ ,  $fin$ ,  $max\_parametro = [EDITAR]$ .)
7:    $heap \leftarrow []$ 
8:   Inicializar diccionarios de parámetros a acumular.
9:   [EDITAR] Ejemplo:  $cost = \{(n,k): float('inf') \text{ for } n \text{ in } \dots\}$ 
10:  Inicializar valores en el momento de inicio de operación.
11:  [EDITAR] Ejemplo:  $cost[(inicio,0)] = 0$ 
12:   $ruta[(inicio,0)] \leftarrow [inicio]$ 
13:   $heapq.heappush(heap, ([EDITAR] valores\_iniciales, inicio, 0))$ 

14:  while  $heap$  no esté vacío do
15:    [EDITAR]  $param\_actuales, actual, k\_actual \leftarrow heapq.heappop(heap)$ 
16:    if  $actual == fin$  then
17:      break
18:    end if

19:    for  $vecino$  in  $sucesores(actual)$  do
20:       $arista \leftarrow G[actual][vecino]$ 
21:      1) Restricciones fuertes
22:      [EDITAR] Especificar verificación/actualización de restricciones fuertes
      (si se violan: continue).
23:      2) Restricciones débiles / penalizaciones
24:      [EDITAR] Especificar penalizaciones (multiplicar/sumar) y su efecto so-
      bre atributos.
25:      3) Restricciones de máximo / contadores
26:      [EDITAR] Actualizar contadores y descartar si excede el máximo permi-
      tido.
27:      Acumular atributos dadas las restricciones y penalizaciones.
28:      [EDITAR] Especificar qué atributos se acumulan y cómo se actualizan.
29:      [EDITAR] Comparar con lo mejor guardado y, si mejora, actualizar y
      hacer  $heappush$ .
30:    end for
31:  end while

32:  Retornar ruta y parámetros acumulados.
33: end Def

```

En caso de que nos pregunten el orden de marcado, basta con inicializar una lista antes del **while** e ir añadiendo el “destino” de la arista que se mete en el último **heappush**.

Como esta sección se maneja principalmente en Python, trabajaremos casi todo en notebooks.

5.1.1. Networkx

NetworkX es una librería de Python para crear, manipular y analizar grafos (nodos y aristas), tanto dirigidos como no dirigidos, con atributos como pesos y capacidades. Para este tema es útil porque implementa algoritmos clásicos de caminos mínimos (por ejemplo, Dijkstra), permitiéndonos resolver instancias reales de forma rápida y confiable sin reprogramar todo desde cero. Además, facilita la visualización, la extracción de rutas y la verificación de resultados para validar nuestros modelos y ejemplos.

Comencemos dando una “cajita de herramientas” de las principales funciones que estaremos usando a lo largo de este capítulo.

Cajita de herramientas: funciones que usaremos más adelante

Función	Parámetros	Qué devuelve / para qué sirve
<code>pd.read_excel</code>	<code>path, sheet_name</code>	Carga un Excel y devuelve un <code>DataFrame</code> .
<code>df.head</code>	<code>n</code>	Muestra las primeras filas del <code>DataFrame</code> (inspección rápida).
<code>df.iterrows</code>	-	Iterador (<code>i, fila</code>); <code>fila</code> es una <code>Series</code> .
<code>nx.DiGraph()</code>	-	Crea un grafo dirigido vacío <code>G</code> .
<code>G.add_edge(u, v, **attr)</code>	<code>u, v, atributos</code>	Agrega el arco <code>u->v</code> y guarda <code>attr</code> como atributos de la arista (costo, tiempo, etc.).
<code>G.successors(u)</code>	<code>u</code>	Itera vecinos alcanzables desde <code>u</code> (arcos salientes).
<code>G[u][v]</code>	<code>u, v</code>	Diccionario de atributos de la arista <code>u->v</code> . Ej: <code>G[u][v]["Costo"]</code> .
<code>nx.spring_layout(G, seed=...)</code>	<code>G, seed</code>	Devuelve <code>pos</code> : diccionario con coordenadas para dibujar el grafo.
<code>nx.draw(G, pos, ...)</code>	<code>G, pos, opciones</code>	Dibuja el grafo (no retorna nada).
<code>nx.get_edge_attributes(G, "Costo")</code>	<code>G, "Costo"</code>	Devuelve <code>\{(u,v): costo\}</code> para etiquetar aristas.
<code>nx.draw_networkx_edge_labels(G, pos, edge_labels)</code>	<code>G, pos, edge_labels</code>	Dibuja etiquetas sobre las aristas (por ejemplo, el costo).
<code>heapq.heappush(heap, item)</code>	<code>heap, item</code>	Inserta <code>item</code> en el heap (cola de prioridad).
<code>heapq.heappop(heap)</code>	<code>heap</code>	Extrae el <i>mínimo</i> del heap.
<code>zip(path[:-1], path[1:])</code>	<code>path</code>	Pares consecutivos (<code>u,v</code>) para recorrer aristas del camino.

5.1.2. Implementación con código

Ejercicio 5.1 (Ruta más corta con restricciones operativas (café de exportación)). Tome una empresa colombiana de logística, AndesCargo S.A.S., dedicada al transporte de café desde centros de consolidación en el interior del país hacia puertos y centros de distribución en la costa, y eventualmente hacia clientes internacionales.

La red de transporte se modela como un grafo dirigido $G = (V, A)$, donde cada nodo $v \in V$ es una ciudad y cada arco $(i, j) \in A$ representa un tramo disponible entre dos ciudades. Para cada arco (i, j) se dispone de los siguientes atributos en el Excel de `Rutas_cafe`:

$$d_{ij} \text{ (km)}, \quad v_{ij} \text{ (km/h)}, \quad \text{peajes}_{ij}, \quad \text{aduanas}_{ij} \in \{0, 1\}, \quad \text{clima_sensible}_{ij} \in \{0, 1\},$$

$$\text{cap}_{ij} \text{ (ton)}, \quad [\text{vent_ini}_{ij}, \text{vent_fin}_{ij}] \text{ (h)}$$

Además, el tiempo de viaje por arco se calcula como

$$t_{ij} = \frac{d_{ij}}{v_{ij}}.$$

La empresa calcula el costo monetario del arco (i, j) como

$$C_{ij} = c_f + c_{km} d_{ij} + \text{peajes}_{ij} + \text{penalizaciones}_{ij}.$$

y las penalizaciones se definen así:

- Si el tramo pasa por control aduanal (por ejemplo, zona portuaria/internacional), entonces el costo del tramo aumenta en un 15%:

$$\text{si } \text{aduanas}_{ij} = 1 \Rightarrow C_{ij} \leftarrow 1,15 C_{ij}.$$

En las últimas semanas, la empresa ha tenido incidentes y ajustes operativos, por lo que impone:

- No se permite usar tramos excesivamente largos por riesgo de siniestro:

$$d_{ij} \geq 1500$$

- Para evitar deterioro del café, a lo largo de toda la ruta se permite atravesar como máximo 3 tramos marcados como sensibles al clima:

$$\sum_{(i,j) \in \text{ruta}} \text{clima_sensible}_{ij} \leq 3.$$

- Algunos tramos solo operan en una ventana horaria $[\text{vent_ini}_{ij}, \text{vent_fin}_{ij}]$. Si el vehículo intenta entrar al tramo fuera de la ventana, el tramo se considera no disponible. (Para este ejercicio, asuma que la operación comienza a las 0:00 y el tiempo se acumula sin esperas).

Si dos rutas tienen el mismo costo total, elija la de menor tiempo total.

Responda lo siguiente. En todos los incisos, reporte: (a) ruta, (b) costo total, (c) distancia total, (d) tiempo total.

- (1) Implemente el algoritmo de Dijkstra para encontrar la ruta de **menor costo** desde BOG hasta BAQ, considerando todas las restricciones y penalizaciones anteriores.

- (II) Ahora el destino final es **SMR**, pero por requisitos de consolidación aduanera la ruta debe pasar por **BAQ**. Ajuste su solución conservando todas las restricciones del inciso (i).
- (III) Un nuevo cliente en **HOU** quiere comenzar a operar, pero su infraestructura de recepción estará lista en aproximadamente 100 horas. Por lo tanto, el envío no puede llegar antes de 100 horas:

$$T(\text{ruta}) \geq 100.$$

Olvide todas las restricciones anteriores (aduana, clima, ventanas, distancia máxima, capacidad, etc.) y ajuste un modelo/algorithm de ruta que encuentre el camino de menor costo que cumpla $T \geq 100$ desde **BOG** hasta **HOU**. Reporte costo, distancia y tiempo total.

Solución:

Veamos la base de datos en el siguiente Excel. [Rutas_cafe.xlsx](#)

Y la solución al ejercicio en el siguiente notebook. [Ejemplo Dijkstra.ipynb](#)



Capítulo 6

Ruteo

En el capítulo anterior estudiamos el problema de ruta más corta: dado un origen y un destino, buscamos el camino de costo mínimo en una red, típicamente con costos no negativos, usando algoritmos eficientes como Dijkstra. En este capítulo damos un salto natural: pasamos de conectar un par de puntos a construir recorridos sobre un conjunto de nodos, minimizando distancia, tiempo o costo total. Para fijar ideas, comenzaremos con el Traveling Salesman Problem (TSP): hallar un solo subtour que visite todos los clientes exactamente una vez y regrese al depósito. Sobre este marco introduciremos tres heurísticas constructivas clásicas (barrido geométrico, vecino más cercano e inserción), cuyo objetivo es producir rápidamente un subtour razonable. Luego ampliaremos el paradigma al Vehicle Routing Problem (VRP), donde ya no buscamos un único subtour sino un conjunto de rutas que parten y regresan al depósito y atienden a todos los clientes bajo restricciones operativas (capacidad, tiempos, retornos, etc.). En este contexto estudiaremos la heurística de ahorros de Clarke–Wright y sus generalizaciones, diseñada precisamente para construir múltiples rutas factibles y mejorar su costo mediante fusiones guiadas por la matriz de ahorros.

A partir de ahora dejaremos las recetas un poco de lado dado que hay múltiples formas de organizar las tablas de actualización y asignación de rutas. Haremos mucho más énfasis en generalizar los pseudocódigos de cada algoritmo para llegar a una lógica de actualización extrapolable a cualquier ejercicio que tengamos.

6.1. Barrido geométrico


Este será el primer método de ruteo que veremos y por ende, el más intuitivo. La idea general es ubicar el centro de distribución en el “centro” (0 grados) y a partir de este, ir agregando clientes en un orden de recorrido por grados. Este puede ser en sentido horario o antihorario.

Receta: Barrido geométrico dada una matriz de distancias.

1. Encontrar matriz de distancias.
2. Inicializar subtour principal $0 - 0$.

3. Comenzar barrido en cero grados.
4. Barrer hasta encontrar primer nodo i no visitado.
5. Chequear restricciones propias del problema. Si se cumplen, proceder con la actualización de ruta. Si no, cerrar subtour.
6. Agregar nodo en el subtour $0 - \dots - i - 0$.
7. Volver al paso 4 hasta haber explorado todos los nodos.

Ejercicio 6.1. Tome una empresa distribuidora ubicada en el centro de la ciudad. Esta cuenta con el siguiente mapa en su distribución de demanda así como las etiquetas de los clientes (**Nota:** las etiquetas de los clientes no dictaminan el orden de recorrido).



A su vez, se ha llegado a la siguiente matriz de distancias (km).

	0	1	2	3	4	5	6	7
0	0	420	500	610	720	650	780	840
1	420	0	300	410	520	480	610	690
2	500	300	0	280	430	390	520	600
3	610	410	280	0	350	310	440	520
4	720	520	430	350	0	260	390	470
5	650	480	390	310	260	0	330	410
6	780	610	520	440	390	330	0	240
7	840	690	600	520	470	410	240	0

Ajuste un algoritmo de barrido geométrico en sentido antihorario, asuma que no hay restricciones adicionales en este problema. Reporte el orden y la distancia total recorrida

de la ruta que se asigna para abastecer a todos los clientes expresando cómo se actualiza la distancia total y la ruta en cada iteración.

Solución:

Veamos la solución a este problema en el siguiente Excel. [Barrido geométrico.xlsx](#)



6.2. Vecino más cercano

La idea principal de esta heurística es ir añadiendo nodos conforme se minimice la distancia hacia el nodo futuro dado el paso actual.

Receta: Vecino más cercano dada una matriz de distancias.

1. Encontrar matriz de distancias.
2. Inicializar subtour principal $0 - 0$ situando el nodo inicial como el depósito/fábrica.
3. Identificar arco que presente menor distancia dado el nodo actual.
4. Si se cumplen restricciones del problema, seleccionar arco y actualizar subtour poniendo el nodo de destino al final del subtour actual $0 - \dots - i - 0$.
5. Volver al paso 3 y repetir hasta que se hayan cubierto todos los nodos.

Ejercicio 6.2. Tome una empresa distribuidora con la siguiente matriz de distancias a sus diferentes clientes.

	0	1	2	3	4	5	6	7
0	0	420	500	610	720	650	780	840
1	420	0	300	410	520	480	610	690
2	500	300	0	280	430	390	520	600
3	610	410	280	0	350	310	440	520
4	720	520	430	350	0	260	390	470
5	650	480	390	310	260	0	330	410
6	780	610	520	440	390	330	0	240
7	840	690	600	520	470	410	240	0

Ajuste un algoritmo de vecino más cercano para encontrar una ruta que pase por todos los clientes. Asuma que no hay restricciones adicionales en este problema. Reporte el orden y la distancia total de transporte de la ruta que se asigna para abastecer cada cliente expresando cómo se actualiza la distancia total y la ruta en cada iteración.

Solución:

Veamos la solución a este problema en el siguiente Excel. [Vecino más cercano.xlsx](#)



6.3. Heurística de inserción

La idea de este algoritmo es no limitarnos a agregar nuevos nodos al final de cada subtour, sino poder agregarlos en cualquier parte de este, ya sea al inicio, en la mitad, en el penúltimo lugar, o al final del subtour.

Receta: Heurística de inserción dada una matriz de distancias.

1. Consideramos $D = (d_{ij})$ entre el depósito 0 y los clientes $1, \dots, n$.
2. Inicializamos con el subtour $T : 0 - 0$ y marca todos los clientes como no visitados.
3. Entre los no visitados, elegimos el cliente k que esté más cerca de cualquier nodo que ya esté en el subtour:

$$k = \arg \min_{u \text{ no visitado}} \min_{v \in T} d_{uv}.$$

(Si hay empate, lo rompemos con la regla que establezca el enunciado. Si no establecen nada, lo elegimos arbitrariamente.)

4. Probamos insertarlo en cada “hueco” del subtour (entre dos nodos consecutivos (i, j)) y calculamos cuánto aumentaría la distancia total:

$$\Delta(i, k, j) = d_{ik} + d_{kj} - d_{ij}.$$

Inserta k en el hueco que deje el menor Δ .

5. Chequeamos restricciones propias del problema. Si al insertar k se viola capacidad/tiempos/etc., entonces no lo insertamos: cerramos la ruta actual y empieza otra desde 0. Si no se viola nada, confirmamos la inserción.
6. Repetimos los pasos 3–5 hasta que todos los clientes queden insertados.

Ejercicio 6.3. Tome una empresa distribuidora con la siguiente matriz de distancias a sus diferentes clientes.

	0	1	2	3	4	5	6	7
0	0	420	500	610	720	650	780	840
1	420	0	300	410	520	480	610	690
2	500	300	0	280	430	390	520	600
3	610	410	280	0	350	310	440	520
4	720	520	430	350	0	260	390	470
5	650	480	390	310	260	0	330	410
6	780	610	520	440	390	330	0	240
7	840	690	600	520	470	410	240	0

Ajuste un algoritmo de inserción para encontrar una ruta que pase por todos los clientes. Asuma que no hay restricciones adicionales en este problema. Reporte el orden y la distancia total de transporte de la ruta que se asigna para abastecer cada cliente expresando cómo se actualiza la distancia total y la ruta en cada iteración.

Solución:

Veamos la solución a este problema en el siguiente Excel. [Vecino más cercano.xlsx](#)



Nota: Si nos fijamos, esta es la única heurística en donde podemos fijar el número de rutas que deseamos desde el inicio.

6.4. Clarke & Wright

Nuevo paradigma (del TSP al VRP)

Hasta ahora trabajamos sobre el TSP: construíamos un solo tour guiándonos directamente por la matriz de distancias (d_{ij}) (vecino más cercano, inserción, etc.). A partir de esta sección damos el salto al VRP: ya no buscamos un tour único, sino un conjunto de rutas que parten y regresan al depósito, y cuya construcción se hará por fusiones sucesivas de rutas. Para esto cambia la información que guía el algoritmo: en lugar de ordenar arcos por distancia, construiremos y ordenaremos una matriz de ahorros $S = (s_{ij})$, donde s_{ij} cuantifica el beneficio de conectar i con j y así reemplazar dos conexiones al depósito por el arco directo (i, j) . Por la misma lógica, los pares que involucran al depósito o son triviales no generan fusión y se fijan en cero: $s_{0i} = s_{i0} = s_{ii} = 0$, de modo que esos casos no compitan en el ordenamiento de ahorros.

En cuanto a la siguiente receta, nos apoyaremos en la macro `VRP_Spreadsheet_Solver.xslm` desarrollada por Güneş Erdoğan. Para ver cómo funciona, consultar manual proporcionado en los recursos del curso.

Receta: Clarke & Wright dada una matriz de ahorros.

0. Plantear problema y solucionarlo en la macro.
1. Considerar matriz de ahorros.
2. Inicializar subtours $0-i-0$ para todo cliente i .
3. Encontrar arco (i, j) con ahorro máximo asociado en esta matriz.
4. Chequear restricciones para hacer posible fusión:
 - a) Los nodos i y j no están en el mismo subtour.
 - b) Existen las conexiones $(i, 0)$ y $(0, j)$.
 - c) No se violan restricciones propias del problema (la macro brilla acá porque acumula tiempo, distancia, carga y costo automáticamente).

5. Ir a la parte de solución de la macro, borrar la solución planteada por la heurística de esta y actualizar ruta.
6. Si se viola alguna de estas restricciones, tachar el arco. Si no, generar fusión de rutas agregando arco $i - j$ a la ruta $0 - \dots - i - j - \dots - 0$ y tachar fila y columna en la matriz de ahorros. Las filas y columnas tachadas quedarán infactibles de ahora en adelante.
7. Volver al paso 3 hasta que se cierre subtour. Luego, continuar con el siguiente siguiendo la misma lógica hasta haber recorrido todos los clientes.

Algoritmo 2 Clarke & Wright con ahorros

```

1: Definir nodos  $V = \{0, 1, \dots, n\}$  (0 es depósito) y cargar matriz  $C = (c_{ij})$ .
2: [EDITAR] Cargar datos opcionales: demanda  $q_i$ , capacidad  $Q$ , ventanas  $[a_i, b_i]$ , tiempos de servicio, etc.

1) Inicialización: una ruta por cliente
3:  $\mathcal{R} \leftarrow \emptyset$ 
4: for  $i = 1$  hasta  $n$  do
5:    $R_i \leftarrow [0, i, 0]$ ; agregar  $R_i$  a  $\mathcal{R}$ 
6:   [EDITAR] Inicializar atributos de  $R_i$  (carga, tiempos, factibilidad, etc.).
7: end for

2) Calcular ahorros y ordenar
8:  $S \leftarrow []$ 
9: for  $1 \leq i < j \leq n$  do
10:    $s_{ij} \leftarrow c_{0i} + c_{0j} - c_{ij}$ 
11:   [EDITAR] Regla:  $s_{0i} = s_{i0} = s_{ii} = 0$  (casos triviales/no comparables).
12:   Agregar  $(i, j, s_{ij})$  a  $S$ 
13: end for
14: Ordenar  $S$  de mayor a menor según  $s_{ij}$ 

3) Fusiones guiadas por  $S$ 
15: for cada  $(i, j, s_{ij})$  en  $S$  do
16:   Identificar rutas actuales  $R_i$  y  $R_j$  (rutas que contienen a  $i$  y  $j$ )
17:   if  $R_i = R_j$  then
18:     continue
19:   end if
20:   Verificar si nodos candidatos son extremos, o sea
21:   (i) Existe  $(i, 0)$ .
22:   (ii) Existe  $(0, j)$ .
23:   (iii)  $i$  y  $j$  no están en la misma ruta.
24:   (iv) [EDITAR] Evaluar restricciones del problema (capacidad, ventanas, precedencias, etc.).
25:   if [EDITAR] NoFactible( $R_i, R_j, i, j$ ) then
26:     continue
27:   end if
28:   Fusionar  $R_i$  y  $R_j$  en una nueva ruta  $R_{ij}$ 
29:   Actualizar  $\mathcal{R}$ : eliminar  $R_i, R_j$  y agregar  $R_{ij}$ 
30:   [EDITAR] Actualizar atributos de  $R_{ij}$  (carga, tiempos, factibilidad, etc.).
31: end for
32: return  $\mathcal{R}$ 

```

Ejercicio 6.4. Tome una empresa con 5 clientes abastecidos desde un único centro de distribución que opera las 24 horas del día. La empresa cuenta con un producto con precio de \$100. Cada cliente cuenta con una demanda de unidades que debe ser totalmente satisfecha expresada en la siguiente tabla.

Cliente	Demanda (unidades)
1	120
2	80
3	150
4	60
5	90

Así como sus ubicaciones geográficas presentadas en la siguiente tabla, es importante saber que la empresa tiene un costo de \$5 por recorrer cada km.

Nodo	Ciudad	Latitud	Longitud
0 (CD)	Bogotá	4.7110	-74.0721
1	Medellín	6.2442	-75.5812
2	Cali	3.4516	-76.5320
3	Barranquilla	10.9685	-74.7813
4	Cartagena	10.3910	-75.4794
5	Bucaramanga	7.1193	-73.1227

Asimismo, cada cliente tiene una ventana de atención fija en donde pueden recibir la visita de dos camiones de la empresa con capacidad máxima de 250 unidades, autonomía de 100 kms y velocidad promedio de 30 kms/hr.

Cliente	Inicio	Fin
Camión	7:30	15:00
1	08:00	10:00
2	09:00	12:00
3	10:00	13:00
4	08:30	11:00
5	11:00	14:00

Es importante considerar que al visitar cada cliente, la empresa se demora 10 minutos en descargar la mercancía y tramitar el papeleo de la recepción de pedido.

Genere las dos rutas que ayuden a minimizar distancias totales dado el algoritmo de Clarke & Wright. Expresé iteración a iteración cómo se construyen estas.

Nota: Considere distancias euclidianas al realizar sus cálculos. En caso de empates, seleccione el arco (i, j) con menor índice i .

Solución:

Veamos los dos siguientes documentos de Excel donde se expresa la solución y cómo nos apoyamos de la macro para llegar a ella. [Macro VRP.xlsm](#), [Clarke & Wright.xlsx](#)



6.5. PyVRP

PyVRP es una librería de Python que sirve para resolver problemas de ruteo de vehículos. O sea, para responder preguntas del tipo: dado un conjunto de clientes, depósitos, vehículos, demandas, distancias, tiempos y restricciones operativas, ¿qué rutas deberían seguir los vehículos para atender a los clientes de la mejor forma posible?

Actualmente permite modelar variantes bastante ricas del VRP, incluyendo problemas con capacidades de vehículos, ventanas de tiempo, múltiples depósitos, flotas heterogéneas, límites de duración o distancia, recargas durante las rutas, clientes opcionales y restricciones asociadas a grupos de clientes.

Desde el punto de vista algorítmico, PyVRP implementa métodos de búsqueda local iterada. La idea es partir de una solución inicial, mejorarla localmente, perturbarla para escapar de óptimos locales, volverla a mejorar y repetir el proceso hasta cumplir un criterio de parada. Al final se retorna la mejor solución encontrada durante la búsqueda.

6.5.1. Motivación: ruteo de vehículos en cadena de suministro

En su versión más básica, el problema busca decidir qué clientes visita cada vehículo y en qué orden lo hace. Sin embargo, en aplicaciones reales esta decisión suele estar acompañada de restricciones operativas adicionales. Por ejemplo, los vehículos tienen capacidad limitada, los clientes pueden tener ventanas de tiempo, los conductores pueden tener jornadas máximas, algunas rutas pueden estar bloqueadas y ciertos clientes pueden ser más importantes que otros desde el punto de vista económico.

Por esta razón, el ruteo de vehículos no debe entenderse únicamente como un problema de encontrar caminos cortos. En realidad, es un problema de diseño de rutas factibles y eficientes, donde se deben coordinar recursos limitados, tiempos de operación, demandas de los clientes y costos logísticos.

De manera general, el flujo de trabajo puede resumirse como:

Datos del problema $\longrightarrow$ Modelo de ruteo $\longrightarrow$ Solución $\longrightarrow$ Reporte de resultados.

Esta secuencia será importante a lo largo de la sección. En algunos ejercicios construiremos las rutas desde cero; en otros, partiremos de rutas existentes y resolveremos un subproblema de reoptimización; y en otros, el modelo deberá decidir incluso qué clientes conviene visitar y cuáles no. Aunque los ejercicios cambien, la lógica computacional de PyVRP se mantendrá relativamente estable.

6.5.2. Preparación de datos para PyVRP

Antes de construir un modelo en PyVRP, es necesario preparar los datos del problema. La preparación de datos consiste en traducir la información operativa del problema a estructuras computacionales. Por ejemplo, una tabla de clientes debe convertirse en una

lista de nodos; una matriz de tiempos debe convertirse en arcos entre nodos; y las ventanas de tiempo escritas como horas deben convertirse a valores numéricos.

Lectura de archivos

El primer paso consiste en leer los archivos que contienen la información del problema. Usualmente se tiene una tabla de clientes, una tabla de vehículos y una matriz de distancias o tiempos. En algunos ejercicios, toda la información está en un archivo de Excel; en otros, los clientes y la matriz se encuentran en archivos separados.

Si los datos están en archivos de texto separados por tabulaciones, se puede usar:

```
import pandas as pd

clientes = pd.read_csv("clientes.txt", delimiter="\t")
matriz_tiempos = pd.read_csv("tiempos.txt", delimiter="\t")
```

Si los datos están en un archivo de Excel con varias hojas, se puede usar:

```
archivo = "datos_vrp.xlsx"

df_clientes = pd.read_excel(archivo, sheet_name="Clientes")
df_flota = pd.read_excel(archivo, sheet_name="Flota")
df_distancias = pd.read_excel(archivo, sheet_name="Distancias", index_col=0)
```

Después de leer los datos, es recomendable revisar las primeras filas:

```
print(df_clientes.head())
print(df_flota.head())
print(df_distancias.head())
```

Esta revisión permite verificar que las columnas fueron leídas correctamente, que los nombres coinciden con lo esperado y que no hay problemas de formato. En problemas de ruteo, esta revisión inicial es importante porque los errores de datos suelen propagarse al resto del modelo.

Identificación de columnas relevantes

Una vez cargados los archivos, se deben identificar las columnas relevantes para el modelo. En una tabla de clientes, algunas columnas comunes son:

- ID: identificador del cliente o depósito.
- Latitud y Longitud: coordenadas geográficas.
- Demanda: unidades que deben entregarse o recogerse.

- **Inicio_Ventana**: inicio de la ventana de tiempo.
- **Fin_Ventana**: fin de la ventana de tiempo.
- **Ruta**: ruta actual del cliente, si existe una solución previa.
- **Posicion_en_la_ruta**: orden del cliente dentro de una ruta existente.

No todos los ejercicios usan todas estas columnas. Por ejemplo, en un VRP estándar puede bastar con el identificador del cliente, la demanda y la matriz de distancias. En cambio, en un problema de reoptimización, columnas como **Ruta** y **Posicion_en_la_ruta** son necesarias para reconstruir rutas existentes.

Una práctica útil es separar explícitamente los subconjuntos de clientes según el papel que cumplen en el problema:

```
clientes_asignados = clientes[clientes["Ruta"] != "No asignada"]
clientes_no_asignados = clientes[clientes["Ruta"] == "No asignada"]
clientes_con_ventana = clientes[clientes["Inicio_Ventana"].notna()]
```

Esta clasificación permite distinguir entre clientes que ya hacen parte de una ruta, clientes pendientes por asignar y clientes con restricciones horarias especiales.

Identificación de perfiles operativos

Un perfil operativo corresponde a una categoría que modifica la forma en que un nodo o recurso puede participar en la solución.

Por ejemplo, los clientes pueden tener perfiles distintos según su zona, tipo de servicio, segmento comercial o compatibilidad con la flota. Un cliente puede pertenecer a una zona específica, requerir solo entrega, solo recogida, o ambas operaciones en una misma visita. También puede pertenecer a una categoría que imponga restricciones adicionales, como ventanas horarias especiales o restricciones de acceso para ciertos vehículos.

De forma similar, los vehículos pueden tener perfiles distintos según su capacidad, costo fijo, costo variable, autonomía, velocidad promedio, depósito de salida, depósito de llegada o conjunto de clientes que pueden atender. En términos prácticos, cada fila de una tabla de flota puede entenderse como un perfil de vehículo.

Por esta razón, durante la preparación de datos conviene separar explícitamente los perfiles relevantes del problema. Por ejemplo:

```
clientes_zona_1 = clientes[clientes["Zona"] == "Zona 1"]
clientes_zona_2 = clientes[clientes["Zona"] == "Zona 2"]

clientes_entrega = clientes[clientes["Entrega"] > 0]
clientes_recogida = clientes[clientes["Recogida"] > 0]
clientes_mixtos = clientes[
    (clientes["Entrega"] > 0) & (clientes["Recogida"] > 0)
]
```

También puede ser útil separar vehículos por depósito o tipo de operación:

```
vehiculos_cd_1 = flota[flota["Deposito"] == "CD1"]
vehiculos_cd_2 = flota[flota["Deposito"] == "CD2"]
```

Esta clasificación no siempre aparece directamente como una restricción de PyVRP. A veces se usa para decidir qué clientes entran a un modelo, qué vehículos se agregan y qué matriz de distancias corresponde a cada subproblema. Por ejemplo, si dos zonas operan de manera independiente, puede ser más claro construir un modelo separado para cada zona en lugar de mezclar todos los clientes en una sola instancia.

En resumen, los perfiles operativos ayudan a responder preguntas como:

- ¿Qué clientes pertenecen a cada zona?
- ¿Qué vehículos pueden atender a cada grupo de clientes?
- ¿Qué clientes tienen entrega, recogida o ambas?
- ¿Qué matriz de distancias corresponde a cada subconjunto?
- ¿Conviene resolver un único modelo o varios subproblemas independientes?

Conversión de ventanas de tiempo

Las ventanas de tiempo suelen venir en formato horario, por ejemplo 08:00, 11:30 o 14:00. Sin embargo, PyVRP trabaja con valores numéricos. Por eso, una práctica común es convertir las horas a minutos desde medianoche.

Por ejemplo:

$$08 : 00 \mapsto 480, \quad 11 : 30 \mapsto 690, \quad 14 : 00 \mapsto 840.$$

Una función útil para hacer esta conversión es:

```
def hora_a_minutos(hora):
    if pd.isna(hora):
        return None

    if isinstance(hora, str):
        h, m = hora.split(":")
        return int(h) * 60 + int(m)

    return hora.hour * 60 + hora.minute
```

Luego se aplica a las columnas correspondientes:

```
clientes["tw_early"] = clientes["Inicio_Ventana"].apply(hora_a_minutos)
clientes["tw_late"] = clientes["Fin_Ventana"].apply(hora_a_minutos)
```

Cuando un cliente no tiene ventana de tiempo explícita, se le puede asignar una ventana amplia, correspondiente a toda la jornada de operación:

```
INICIO_JORNADA = 8 * 60
FIN_JORNADA = 18 * 60
```

```
clientes["tw_early"] = clientes["tw_early"].fillna(INICIO_JORNADA)
clientes["tw_late"] = clientes["tw_late"].fillna(FIN_JORNADA)
```

Esto significa que los clientes sin restricción horaria explícita pueden ser atendidos en cualquier momento dentro de la jornada. En cambio, los clientes con ventana definida conservan su intervalo específico.

Diccionarios de índices

Cuando se trabaja con matrices, es necesario saber qué fila y qué columna corresponden a cada cliente. Para esto es útil construir diccionarios que permitan pasar de identificadores a índices y de índices a identificadores.

Por ejemplo:

```
clientes_a_idx = {}
idx_a_clientes = {}

for index, row in clientes.iterrows():
    clientes_a_idx[row["ID"]] = index
    idx_a_clientes[index] = row["ID"]
```

El primer diccionario permite obtener el índice asociado a un cliente:

```
clientes_a_idx["Cliente_1"]
```

El segundo permite recuperar el identificador de un cliente a partir de su índice:

```
idx_a_clientes[1]
```

Estos diccionarios son útiles porque muchas veces el problema se describe con nombres o códigos de clientes, mientras que las matrices y listas de Python trabajan con posiciones numéricas.

También se puede construir un diccionario de tiempos de viaje entre pares de clientes:

```

tiempos_viaje = {}

for i in range(len(clientes)):
    for j in range(len(clientes)):
        if i != j:
            cliente_i = clientes.loc[i, "ID"]
            cliente_j = clientes.loc[j, "ID"]

            tiempo = matriz_tiempos.loc[
                matriz_tiempos["ID"] == cliente_i, cliente_j
            ].values[0]

            tiempos_viaje[(cliente_i, cliente_j)] = int(tiempo)

```

Con esta estructura, el tiempo entre dos nodos puede consultarse directamente:

```
tiempos_viaje[("Cliente_1", "Deposito")]
```

Esta forma de almacenar tiempos es especialmente conveniente cuando se desea evaluar rutas existentes o calcular manualmente la duración de una secuencia de visitas.

Consistencia entre nodos y matrices

Uno de los errores más comunes al construir modelos de ruteo consiste en usar una matriz cuyo orden no coincide con el orden de los nodos del modelo. Si la matriz está organizada como:

$$\text{Depósito}, C_1, C_2, \dots, C_n,$$

entonces los nodos deben agregarse al modelo en ese mismo orden.

Por ejemplo:

```

depot = m.add_depot(x=0, y=0, name="Deposito")

clients = []

for _, row in clientes_sin_deposito.iterrows():
    client = m.add_client(
        x=0,
        y=0,
        delivery=int(row["Demanda"]),
        tw_early=int(row["tw_early"]),
        tw_late=int(row["tw_late"]),
        name=row["ID"],

```

```

    )

    clients.append(client)

locations = [depot] + clients

```

La lista `locations` debe tener el mismo orden que la matriz. Luego, al agregar los arcos, se usa ese orden para consultar las entradas correspondientes:

```

for i, origen in enumerate(locations):
    for j, destino in enumerate(locations):
        if i == j:
            continue

        tiempo = matriz[i][j]

        m.add_edge(
            origen,
            destino,
            distance=int(tiempo),
            duration=int(tiempo),
        )

```

Si el orden no coincide, el modelo puede seguir corriendo, pero las distancias o tiempos quedarán asociados a pares incorrectos de nodos. Por ejemplo, el tiempo que realmente corresponde a $C_1 \rightarrow C_2$ podría terminar siendo usado para $C_3 \rightarrow C_5$. Este tipo de error es difícil de detectar porque no necesariamente hace que el código pare de correr, sino que de una solución equivocada.

Filtrado de clientes según el objetivo del ejercicio

No todos los ejercicios requieren agregar todos los clientes al modelo. En algunos casos, PyVRP se usa para resolver el problema completo desde cero. En otros, se usa solamente para resolver un subproblema.

Por ejemplo, en un problema de reoptimización puede haber clientes ya asignados a rutas existentes y clientes todavía no asignados. En ese caso, puede ser necesario filtrar solamente los clientes que deben entrar al nuevo modelo:

```

clientes_pendientes = clientes[clientes["Ruta"] == "No asignada"]

```

También puede ocurrir que algunos clientes deban retirarse de rutas existentes y volver a optimizarse junto con los no asignados:

```

clientes_retirados = ["Cliente_A", "Cliente_B"]

```

```
clientes_a_reoptimizar = clientes[
    (clientes["Ruta"] == "No asignada")
    | (clientes["ID"].isin(clientes_retirados))
]
```

Esta lógica cambia según el ejercicio. Lo importante es identificar primero qué pregunta se quiere responder. Si el problema busca construir rutas desde cero, entran todos los clientes. Si busca ajustar una operación existente, entran solamente los clientes afectados por la decisión.

6.5.3. La arquitectura de PyVRP

La idea central es que el modelo se construye progresivamente: primero se crea un objeto principal, luego se agregan los depósitos, los clientes, los vehículos y las conexiones entre nodos. Finalmente, se ejecuta el algoritmo de solución y se interpreta el resultado.

El flujo general puede resumirse como:

Modelo $\longrightarrow$ Depósitos $\longrightarrow$ Clientes $\longrightarrow$ Vehículos $\longrightarrow$ Arcos $\longrightarrow$ Solución.

En términos de código, la estructura básica es:

```
from pyvrp import Model
from pyvrp.stop import MaxIterations

m = Model()

# 1. Agregar deposito
# 2. Agregar clientes
# 3. Agregar vehiculos
# 4. Agregar arcos
# 5. Resolver
# 6. Interpretar solucion
```

Esta arquitectura se mantiene en la mayoría de ejercicios. Lo que cambia entre problemas es la forma en que se preparan los datos, qué restricciones se activan y cómo se interpreta la solución final.

Inicialización del modelo

Todo problema en PyVRP comienza creando un objeto de tipo `Model`. Este objeto funciona como el contenedor principal del problema. En él se almacenan los depósitos, clientes, vehículos, ubicaciones, arcos y demás elementos necesarios para construir las rutas.

La inicialización es sencilla:

```
from pyvrp import Model
```

```
m = Model()
```

A partir de este objeto se agregan todos los demás componentes del sistema. Por eso, el modelo debe crearse antes de definir depósitos, clientes, vehículos o arcos.

Una vez creado el modelo, se pueden consultar algunos de sus elementos mediante atributos como:

```
m.depots  
m.clients  
m.locations  
m.vehicle_types
```

Estos atributos permiten revisar qué objetos han sido agregados al modelo. Por ejemplo, `m.clients` contiene la lista de clientes registrados y `m.depots` contiene la lista de depósitos.

Configuración del depósito

El depósito es el punto desde el cual salen y al cual regresan los vehículos. En PyVRP, el depósito se agrega mediante el método `add_depot`. Este puede incluir información como ubicación, nombre y ventana de tiempo.

Un ejemplo básico es:

```
depot = m.add_depot(  
    x=0,  
    y=0,  
    name="Deposito",  
)
```

Si el depósito tiene una ventana de operación, también se pueden incluir los tiempos de apertura y cierre:

```
depot = m.add_depot(  
    x=0,  
    y=0,  
    name="Deposito Central",  
    tw_early=480,  
    tw_late=1080,  
)
```

En este ejemplo, el depósito opera desde el minuto 480 hasta el minuto 1080, lo cual corresponde a una jornada de 8:00 a.m. a 6:00 p.m. si los tiempos se miden en minutos desde medianoche.

Cuando se trabaja con matrices de distancias o tiempos, las coordenadas del depósito pueden ser ficticias. En ese caso, los valores de desplazamiento no dependen de las coordenadas, sino de los arcos que se agregan posteriormente al modelo.

Configuración de clientes

Los clientes representan los puntos que deben ser visitados. En PyVRP, cada cliente se agrega mediante el método `add_client`. Un cliente puede tener demanda de entrega, cantidad de recogida, tiempo de servicio y ventana de tiempo.

Un ejemplo básico es:

```
client = m.add_client(  
    x=10,  
    y=5,  
    delivery=5,  
    service_duration=10,  
    tw_early=0,  
    tw_late=120,  
    name="Cliente 1",  
)
```

En este bloque, el cliente tiene una demanda de entrega igual a 5, un tiempo de servicio de 10 unidades de tiempo y una ventana de tiempo entre 0 y 120. La ventana de tiempo indica el intervalo dentro del cual el servicio puede comenzar.

Cuando el problema incluye recogidas y entregas simultáneamente, se pueden usar los atributos `delivery` y `pickup`:

```
client = m.add_client(  
    x=10,  
    y=5,  
    delivery=5,  
    pickup=2,  
    service_duration=10,  
    name="Cliente 1",  
)
```

En este caso, el vehículo entrega 5 unidades y recoge 2 unidades en el mismo cliente. Esto afecta la evolución de la carga a lo largo de la ruta.

En problemas más avanzados, los clientes también pueden ser opcionales. Esto se modela usando el atributo `required=False`. Además, puede asignarse un premio o beneficio por visitar al cliente mediante el atributo `prize`. Esta lógica permite representar casos donde no necesariamente conviene atender a todos los clientes.

```
client = m.add_client(  

```

```

    x=10,
    y=5,
    delivery=5,
    service_duration=10,
    prize=1000,
    required=False,
    name="Cliente 1",
)

```

En este tipo de modelo, PyVRP decide si vale la pena visitar al cliente dependiendo del beneficio asociado y de los costos de incluirlo en alguna ruta.

Además de sus atributos numéricos, los clientes pueden tener un perfil operativo. Este perfil no siempre entra directamente como un argumento de `add_client`, pero sí afecta la forma en que el cliente se incorpora al modelo. Por ejemplo, un cliente puede pertenecer a una zona específica, tener un tipo de servicio particular, pertenecer a un segmento comercial o presentar restricciones de compatibilidad con ciertos vehículos.

En términos de datos, este perfil suele aparecer como una columna adicional en la tabla de clientes:

ID, Zona, Tipo_Cliente, Entrega, Recogida, Inicio_Ventana, Fin_Ventana

A partir de estas columnas, el programador puede filtrar clientes o construir subproblemas. Por ejemplo, si cada centro de distribución atiende únicamente a los clientes de su zona, entonces el perfil de zona permite decidir qué clientes entran al modelo asociado a cada centro:

```

clientes_cd_1 = clientes[clientes["Zona"] == "CD1"]
clientes_cd_2 = clientes[clientes["Zona"] == "CD2"]

```

De esta forma, el perfil del cliente funciona como una capa de interpretación previa. El cliente sigue siendo agregado con `add_client`, pero no todos los clientes necesariamente entran al mismo modelo.

Configuración de vehículos

Los vehículos representan los recursos disponibles para realizar las rutas. En PyVRP, se agregan mediante el método `add_vehicle_type`. Esto permite definir uno o varios tipos de vehículos, cada uno con sus propias características operativas.

Un ejemplo básico es:

```

m.add_vehicle_type(
    num_available=2,
    capacity=20,
)

```

```
    start_depot=depot,  
    end_depot=depot,  
    fixed_cost=100,  
)
```

Este bloque indica que hay dos vehículos disponibles, cada uno con capacidad máxima de 20 unidades. Ambos salen del depósito y regresan al mismo depósito. Además, usar un vehículo genera un costo fijo de 100.

También se pueden incluir restricciones adicionales, como duración máxima de jornada, distancia máxima o costos variables:

```
m.add_vehicle_type(  
    num_available=2,  
    capacity=20,  
    start_depot=depot,  
    end_depot=depot,  
    fixed_cost=100,  
    unit_distance_cost=5,  
    max_distance=200,  
    shift_duration=480,  
)
```

En este caso, cada vehículo tiene una distancia máxima de 200, una jornada máxima de 480 minutos y un costo variable de 5 unidades monetarias por unidad de distancia recorrida.

La configuración de vehículos es importante porque define qué rutas son factibles. Una ruta puede ser corta en distancia, pero infactible si excede la capacidad del vehículo, la duración máxima del turno o la autonomía permitida.

Cada tipo de vehículo agregado con `add_vehicle_type` puede interpretarse como un perfil de vehículo. Este perfil resume las características operativas de un grupo de vehículos iguales: capacidad, cantidad disponible, costo fijo, costo variable, duración máxima, distancia máxima y depósitos asociados.

Por ejemplo, dos vehículos pueden pertenecer a la misma flota, pero tener perfiles distintos:

- un vehículo pequeño, barato y de menor capacidad;
- un vehículo grande, más costoso y de mayor capacidad;
- un vehículo asignado exclusivamente a un depósito;
- un vehículo compatible únicamente con ciertos tipos de cliente.

En código, esta diferencia se representa agregando varios tipos de vehículo:

```
m.add_vehicle_type(
    num_available=1,
    capacity=20,
    start_depot=deposito,
    end_depot=deposito,
    fixed_cost=80,
    unit_distance_cost=3,
    name="Vehiculo pequeno",
)

m.add_vehicle_type(
    num_available=1,
    capacity=40,
    start_depot=deposito,
    end_depot=deposito,
    fixed_cost=140,
    unit_distance_cost=5,
    name="Vehiculo grande",
)
```

En este caso, PyVRP puede escoger qué tipo de vehículo utilizar según la estructura de costos y las restricciones de capacidad. Por eso, definir correctamente los perfiles de vehículos es parte del modelado: no todos los vehículos representan el mismo recurso operativo.

Cuando existen restricciones de compatibilidad entre vehículos y clientes, hay que tener especial cuidado. Algunas versiones o formulaciones permiten manejar compatibilidades de forma directa; en otros casos, una estrategia más didáctica es separar el problema en subproblemas. Por ejemplo, si cierto vehículo no puede atender cierto tipo de cliente, se puede construir un modelo únicamente con los clientes compatibles con ese perfil de vehículo.

Nota: ventanas de tiempo y duración de ruta

Es importante distinguir entre tres objetos temporales. Primero, la ventana de tiempo del depósito, definida mediante `tw_early` y `tw_late` en `add_depot`, indica cuándo puede iniciar o finalizar la operación asociada al depósito. Segundo, la ventana de tiempo de cada cliente, definida mediante `tw_early` y `tw_late` en `add_client`, indica el intervalo en el cual puede comenzar el servicio en ese cliente. Tercero, la duración máxima del turno del vehículo, definida mediante `shift_duration` en `add_vehicle_type`, limita cuánto puede durar una ruta completa.

Configuración de arcos

Los arcos representan los desplazamientos permitidos entre nodos. Cada arco conecta un origen con un destino y puede tener una distancia, una duración o ambos valores. En PyVRP, los arcos se agregan mediante el método `add_edge`.

Si se trabaja con coordenadas, la distancia puede calcularse directamente a partir de las ubicaciones. Por ejemplo, usando distancia Manhattan:

```
for origen in m.locations:
    for destino in m.locations:
        if origen == destino:
            continue

        dist = abs(origen.x - destino.x) + abs(origen.y - destino.y)

        m.add_edge(
            origen,
            destino,
            distance=int(dist),
            duration=int(dist),
        )
```

Sin embargo, en muchos ejercicios de ruteo se trabaja con una matriz de distancias o tiempos. En ese caso, el código típico es:

```
locations = [depot] + clients

for i, origen in enumerate(locations):
    for j, destino in enumerate(locations):
        if i == j:
            continue

        m.add_edge(
            origen,
            destino,
            distance=int(dist_matrix[i][j]),
            duration=int(time_matrix[i][j]),
        )
```

Aquí, `dist_matrix[i][j]` representa la distancia entre el nodo *i* y el nodo *j*, mientras que `time_matrix[i][j]` representa la duración del desplazamiento. Es fundamental que el orden de la lista `locations` coincida con el orden de filas y columnas de las matrices.

También puede haber arcos bloqueados o prohibidos. En ese caso, una forma natural de modelarlos es no agregarlos al modelo:

```
if (origen_id, destino_id) in arcos_bloqueados:
    continue
```

Si un arco no se agrega, PyVRP no podrá utilizarlo dentro de ninguna ruta.

Resolución del modelo

Una vez agregados los depósitos, clientes, vehículos y arcos, el modelo ya está listo para resolverse. Para esto se utiliza el método `solve`. Este método requiere un criterio de parada, que indica cuándo debe detenerse la búsqueda.

Por ejemplo, se puede detener el algoritmo después de cierto número de iteraciones:

```
from pyvrp.stop import MaxIterations

res = m.solve(
    stop=MaxIterations(2000),
    seed=42,
    display=True,
)
```

También es posible usar un límite de tiempo en segundos:

```
from pyvrp.stop import MaxRuntime

res = m.solve(
    stop=MaxRuntime(1),
    seed=42,
    display=True,
)
```

El objeto `res` contiene la información de la solución encontrada. En particular, `res.best` almacena la mejor solución observada durante la búsqueda.

Es importante recordar que PyVRP utiliza algoritmos heurísticos y metaheurísticos. Por lo tanto, aumentar el tiempo de corrida o el número de iteraciones puede mejorar la calidad de la solución, especialmente en instancias grandes o con muchas restricciones.

Importancia de la semilla (`seed`)

La semilla no modifica los datos, las restricciones ni la función objetivo del modelo. Su función es controlar la parte aleatoria del algoritmo para facilitar la reproducibilidad. Esto es importante cuando vayan a calificar nuestra solución.

Lectura de la solución

Después de resolver el modelo, se debe interpretar la solución. Esta etapa es fundamental porque la salida computacional debe traducirse a decisiones logísticas: qué rutas se usan, qué clientes visita cada vehículo, cuánto dura cada ruta y cuál es el costo total.

Algunas consultas útiles son:

```

res.best.is_feasible()
res.best.num_routes()
res.best.distance()
res.best.duration()
res.best.fixed_vehicle_cost()

```

Estas funciones permiten revisar si la solución es factible, cuántas rutas utiliza, cuál es la distancia total recorrida, cuál es la duración total y cuál es el costo fijo asociado a los vehículos usados.

Para obtener las rutas, se puede iterar sobre `res.best.routes()`:

```

for route in res.best.routes():
    print(route)

```

Una forma más legible de reportar la secuencia de visitas es reconstruir la ruta incluyendo el depósito al inicio y al final:

```

rutas = []

for route in res.best.routes():
    secuencia = (
        [m.depots[route.start_depot()].name]
        + [m.clients[client.idx].name for client in route]
        + [m.depots[route.end_depot()].name]
    )

    rutas.append(secuencia)

print(rutas)

```

El resultado puede interpretarse como una lista de rutas del tipo:

$$\text{Depósito} \rightarrow C_3 \rightarrow C_1 \rightarrow C_5 \rightarrow \text{Depósito}.$$

En ejercicios aplicados, esta lectura debe complementarse con indicadores adicionales como demanda atendida, carga del vehículo, horarios de llegada, clientes no visitados, penalizaciones o utilidad económica, dependiendo del tipo de problema estudiado.

6.5.4. Casos de aplicación

Una vez presentada la lógica general de preparación de datos y la arquitectura básica de PyVRP, podemos estudiar distintos tipos de ejercicios. La idea no es memorizar un único código, sino reconocer qué elementos del flujo de trabajo se mantienen y cuáles cambian según la naturaleza del problema.

Caso 1: VRP estándar desde cero

En este primer caso estudiaremos la estructura básica de un problema de ruteo de vehículos construido desde cero. La idea es partir de una empresa con un depósito central, un conjunto de clientes que deben ser atendidos y una flota disponible para realizar las entregas. A diferencia de otros escenarios más complejos, aquí asumimos que todos los clientes deben ser visitados y que no existe una solución previa que debamos modificar.

Ejercicio 6.5. Tome una empresa que distribuye productos desde un único centro de distribución hacia un conjunto de clientes ubicados en diferentes puntos de la ciudad. Cada cliente tiene una demanda conocida, un tiempo de servicio asociado y, en algunos casos, una ventana de tiempo dentro de la cual debe ser atendido. La empresa cuenta con una flota limitada de vehículos, cada uno con capacidad máxima, costo fijo de operación, costo variable por distancia recorrida y una duración máxima de jornada.

En el Excel [Datos VRP Básico.xlsx](#) se suministra la información que será necesaria en tres hojas principales:

- **Clientes:** contiene el identificador de cada cliente, su demanda, su tiempo de servicio y sus ventanas de tiempo.
- **Flota:** contiene la información de los tipos de vehículos disponibles, incluyendo capacidad, cantidad disponible, costos y duración máxima de operación.
- **Distancias:** contiene la matriz de distancias entre el depósito y los clientes.

A partir de esta información, construya un modelo en PyVRP que determine las rutas que debe realizar la flota para atender a todos los clientes. En particular, se busca responder las siguientes preguntas:

1. ¿Qué clientes debe visitar cada vehículo?
2. ¿En qué orden deben ser visitados los clientes dentro de cada ruta?
3. ¿Cuántos vehículos se utilizan en la solución?
4. ¿Cuál es la distancia total recorrida por la flota?
5. ¿Cuál es el costo total de operación de las rutas?

Solución:

Veamos el siguiente notebook de Python que contiene la solución del ejercicio. [Solución VRP Básico.iypnb](#)



Caso 2: Reoptimización de rutas existentes

En este segundo caso estudiaremos un problema de ruteo en el que la empresa no parte desde cero. A diferencia del caso anterior, ya existe una planeación inicial de rutas: algunos clientes ya están asignados a vehículos y tienen una posición definida dentro de su ruta. Sin embargo, por cambios operativos, clientes nuevos o ajustes de último momento, la empresa necesita revisar una parte de la solución y reoptimizar el sistema.

Ejercicio 6.6. Tome una empresa que realiza entregas diarias desde un único centro de distribución. Al inicio del día, la empresa ya cuenta con una planeación preliminar de rutas: varios clientes están asignados a rutas específicas y tienen una posición definida dentro de la secuencia de visita. Sin embargo, durante la operación aparecen nuevos clientes que no han sido asignados y, además, algunos clientes previamente programados deben ser retirados de sus rutas originales para ser reubicados.

En el Excel [Datos Reoptimización VRP.xlsx](#) se suministra la información necesaria en tres hojas principales:

- **Clientes:** contiene el identificador de cada cliente, su demanda, sus ventanas de tiempo, la ruta asignada inicialmente y su posición dentro de dicha ruta.
- **Flota:** contiene la información de los vehículos disponibles, incluyendo capacidad, cantidad disponible, costos y duración máxima de operación.
- **Tiempos:** contiene la matriz de tiempos de viaje entre el depósito y los clientes.

A partir de esta información, construya una metodología de solución que permita evaluar la operación actual y reoptimizar los clientes pendientes. En particular, se debe identificar qué clientes ya pertenecen a rutas existentes, qué clientes no han sido asignados y qué clientes deben retirarse de sus rutas originales para ser considerados nuevamente dentro del modelo.

El objetivo es construir un subproblema en PyVRP que asigne los clientes pendientes a nuevas rutas factibles, respetando las restricciones de capacidad, ventanas de tiempo y duración máxima de operación. La solución final debe combinar la información de las rutas que se conservan con las nuevas rutas generadas por el modelo.

En particular, se busca responder las siguientes preguntas:

1. ¿Qué rutas existentes se conservan después del ajuste operativo?
2. ¿Qué clientes deben ser reoptimizados?
3. ¿Qué nuevas rutas propone PyVRP para atender los clientes pendientes?
4. ¿Cuál es la duración total de las rutas conservadas y de las rutas nuevas?
5. ¿Cuál es el impacto del ajuste sobre la operación total?

Solución:

Veamos el siguiente notebook de Python que contiene la solución del ejercicio. [Solución Reoptimización VRP.ipynb](#)



Caso 3: selección económica de clientes

En este tercer caso estudiaremos un problema de ruteo en el que no todos los clientes deben ser atendidos obligatoriamente. A diferencia de los casos anteriores, la empresa debe decidir cuáles clientes conviene visitar y cuáles puede dejar por fuera, teniendo en cuenta los ingresos generados por cada visita, los costos de operación de las rutas y las penalizaciones asociadas a no atender ciertos clientes.

La idea de este caso es entender cómo PyVRP puede usarse para modelar problemas donde el objetivo no es simplemente minimizar distancia o atender a todos los clientes, sino construir rutas que generen una buena utilidad económica. Para esto, algunos clientes se modelan como opcionales y se les asigna un valor o premio asociado a su visita.

Ejercicio 6.7. Tome una empresa que distribuye y recoge productos desde un único centro de distribución. Cada cliente puede generar ingresos por entregas realizadas, ingresos por recogidas efectuadas o penalizaciones en caso de no ser atendido. Sin embargo, visitar a un cliente también implica costos de operación, pues los vehículos consumen tiempo, distancia y recursos de la flota.

La empresa cuenta con una flota limitada de vehículos y debe decidir qué clientes atender para maximizar el beneficio neto de la operación. Algunos clientes pueden no ser visitados si el costo de incluirlos en una ruta supera el beneficio económico de atenderlos. Además, ciertas conexiones entre nodos pueden estar bloqueadas, por lo que no todos los desplazamientos son permitidos.

En el Excel [Datos VRP Clientes Opcionales.xlsx](#) se suministra la información necesaria en cuatro hojas principales:

- **Clientes:** contiene el identificador de cada cliente, sus coordenadas, demanda de entrega, cantidad de recogida, ventanas de tiempo, tiempo de servicio, ingreso unitario y penalización por no visita.
- **Flota:** contiene la información de los vehículos disponibles, incluyendo capacidad, cantidad disponible, costos y duración máxima de operación.
- **Distancias:** contiene la matriz de distancias entre el depósito y los clientes.
- **ArcosBloqueados:** contiene los pares de nodos entre los cuales no está permitido viajar directamente.

A partir de esta información, construya un modelo en PyVRP que determine qué clientes deben ser visitados y qué rutas debe realizar la flota. Para esto, los clientes deben modelarse como opcionales y se debe asignar a cada uno un premio asociado al beneficio económico de visitarlo.

En particular, si visitar al cliente i genera un ingreso I_i y ahorra una penalización P_i , entonces el valor económico de incluirlo en la solución puede representarse como:

$$\text{premio}_i = I_i + P_i.$$

La solución debe reportar las rutas generadas, los clientes visitados, los clientes no visitados, los ingresos obtenidos, las penalizaciones pagadas, los costos operativos y la utilidad neta de la operación.

En particular, se busca responder las siguientes preguntas:

1. ¿Qué clientes decide visitar el modelo?
2. ¿Qué clientes quedan sin atender?
3. ¿Qué rutas realiza la flota?
4. ¿Cuál es el ingreso total obtenido por los clientes visitados?
5. ¿Cuál es la penalización total asociada a los clientes no visitados?
6. ¿Cuál es el costo total de operación?
7. ¿Cuál es la utilidad neta de la solución?

Solución:

Veamos el siguiente notebook de Python que contiene la solución del ejercicio. [Solución VRP Clientes Opcionales.ipynb](#)



Caso 4: múltiples depósitos, retornos cruzados e índices locales

En este último caso estudiaremos un escenario en el que los datos ya no vienen organizados de forma cómoda para el modelo. A diferencia de los casos anteriores, ahora existe una matriz global de distancias con todos los nodos del sistema, pero los clientes deben separarse según el depósito que puede atenderlos. Además, los vehículos no terminan su ruta en el mismo depósito del que salieron, sino en el depósito contrario.

La idea principal del caso es mostrar que, cuando se construyen subproblemas a partir de una matriz global, los índices del Excel, los índices de la matriz y los índices internos de PyVRP no necesariamente coinciden. Por eso, debemos crear listas y diccionarios explícitos que traduzcan correctamente entre nodos y posiciones.

Ejercicio 6.8. Tome una empresa con dos centros de distribución, llamados `Deposito_1` y `Deposito_2`. La empresa atiende un conjunto de clientes distribuidos en dos zonas. Los clientes de la primera zona solo pueden ser atendidos por vehículos que salen de `Deposito_1`, mientras que los clientes de la segunda zona solo pueden ser atendidos por vehículos que salen de `Deposito_2`.

Adicionalmente, al finalizar la operación, los vehículos no regresan al depósito de origen. Los vehículos que salen de `Deposito_1` deben terminar en `Deposito_2`, y los vehículos que salen de `Deposito_2` deben terminar en `Deposito_1`.

En el Excel [Datos VRP Depósitos Cruzados.xlsx](#) se suministra la información necesaria en tres hojas principales:

- **Clientes:** contiene el identificador de cada cliente, su zona, demanda, tiempo de servicio y ventana de tiempo.
- **Flota:** contiene la información de los vehículos disponibles para cada depósito.
- **Distancias:** contiene la matriz global de distancias entre ambos depósitos y todos los clientes.

A partir de esta información, construya dos modelos en PyVRP, uno por cada depósito de salida, que determinen las rutas necesarias para atender a los clientes de cada zona. En particular, se busca responder las siguientes preguntas:

1. ¿Qué clientes son atendidos por los vehículos que salen de cada depósito?
2. ¿Qué rutas se construyen para cada subproblema?
3. ¿Cómo se garantiza que los vehículos terminen en el depósito contrario?
4. ¿Cómo se manejan correctamente los índices entre la matriz global y el modelo local?
5. ¿Cuál es la distancia y el costo total de la operación?

Solución:

La solución se construye resolviendo dos subproblemas independientes. Para cada uno, se filtran los clientes permitidos, se agregan ambos depósitos al modelo y se define explícitamente cuál es el depósito de salida y cuál es el depósito de llegada.

La parte más importante del código es no asumir que los índices del modelo coinciden con los nombres de los nodos en la matriz. Por eso, se construye una lista explícita de identificadores:

```
ids_modelo = [depot_salida_id, depot_llegada_id]

for cliente_id in clientes_permitidos:
    ids_modelo.append(cliente_id)
```

Luego, al agregar los nodos al modelo, se mantiene exactamente el mismo orden:

```
locations = [depot_salida, depot_llegada] + clientes_modelo
```

Así, cuando se agregan los arcos, los índices i y j no se usan directamente como nombres de clientes. Primero se traducen usando `ids_modelo`:

```
for i, origen in enumerate(locations):
    for j, destino in enumerate(locations):

        if i != j:
            origen_id = ids_modelo[i]
            destino_id = ids_modelo[j]

            distancia = distancias.loc[origen_id, destino_id]

            m.add_edge(
                origen,
                destino,
                distance=int(distancia),
                duration=int(distancia),
            )
```

Este bloque es clave porque permite usar una matriz global, aunque cada modelo trabaje solamente con un subconjunto de clientes.

La segunda parte importante es la definición de vehículos con depósito de salida y depósito de llegada distintos. Para los vehículos que salen del primer depósito y terminan en el segundo, se usa:

```
m.add_vehicle_type(
    num_available=1,
    capacity=capacidad,
    start_depot=depot_1,
    end_depot=depot_2,
    fixed_cost=costo_fijo,
    unit_distance_cost=costo_km,
)
```

Y para los vehículos que salen del segundo depósito y terminan en el primero:

```
m.add_vehicle_type(
    num_available=1,
    capacity=capacidad,
    start_depot=depot_2,
    end_depot=depot_1,
    fixed_cost=costo_fijo,
    unit_distance_cost=costo_km,
)
```

De esta forma, PyVRP construye rutas abiertas entre depósitos distintos. La estructura general del modelo sigue siendo la misma que en los casos anteriores, pero ahora la preparación de datos es más delicada porque cada subproblema tiene índices locales contruidos a partir de una matriz global.

Veamos el siguiente notebook de Python que contiene la solución del ejercicio. [Solución VRP Depósitos Cruzados.ipynb](#)



Capítulo 7

Localización

Hasta este punto hemos estudiado decisiones asociadas al movimiento dentro de una red logística. Primero vimos cómo encontrar la ruta más corta entre dos puntos mediante el algoritmo de Dijkstra; luego estudiamos problemas de ruteo, donde una flota debe recorrer varios clientes de forma eficiente. Sin embargo, todavía queda una pregunta previa y de mayor alcance estratégico: ¿dónde debería ubicarse una instalación dentro de la red? Este capítulo aborda precisamente esa decisión. En lugar de preguntarnos solamente cómo movernos entre puntos existentes, estudiaremos cómo escoger la ubicación de un nuevo centro de distribución, almacén o punto de atención, teniendo en cuenta distancias, demanda, pesos relativos y criterios de eficiencia.

7.1. Medidas de distancia en problemas de localización

Antes de estudiar algoritmos de localización, necesitamos precisar qué significa medir la distancia entre dos puntos. Matemáticamente, una medida de distancia o métrica es una función d que toma dos puntos del plano y devuelve un número real no negativo:

$$d : \mathbb{R}^2 \times \mathbb{R}^2 \rightarrow \mathbb{R}_{\geq 0}.$$

Para que d sea considerada una distancia en sentido formal, debe satisfacer las siguientes propiedades para cualesquiera puntos $p, q, r \in \mathbb{R}^2$:

1. No negatividad:

$$d(p, q) \geq 0.$$

2. Identidad de los indiscernibles:

$$d(p, q) = 0 \iff p = q.$$

3. Simetría:

$$d(p, q) = d(q, p).$$

4. Desigualdad triangular:


$$d(p, r) \leq d(p, q) + d(q, r).$$

Estas propiedades formalizan la idea intuitiva de separación entre puntos. Sin embargo, en problemas de localización no todas las funciones usadas como “distancia” cumplen necesariamente estas propiedades. Por ejemplo, la distancia euclidiana al cuadrado es útil para construir modelos algebraicamente simples, pero no es una métrica en sentido estricto porque no satisface la desigualdad triangular. Aun así, puede ser conveniente desde el punto de vista de modelado.

7.1.1. Distancia rectilínea o Manhattan

La distancia rectilínea, también conocida como distancia Manhattan, mide el desplazamiento total en sentido horizontal y vertical. Es útil cuando el movimiento ocurre sobre una red tipo cuadrícula, como calles ortogonales.

$$d_1((x, y), (a_i, b_i)) = |x - a_i| + |y - b_i|.$$




Movimiento horizontal + vertical

7.1.2. Distancia euclidiana

La distancia euclidiana mide la separación en línea recta entre dos puntos. Es la noción geométrica más común de distancia.

$$d_2((x, y), (a_i, b_i)) = \sqrt{(x - a_i)^2 + (y - b_i)^2}.$$




Movimiento en línea recta

7.1.3. Distancia euclidiana al cuadrado

La distancia euclidiana al cuadrado no representa directamente una distancia recorrida, pero aparece en modelos de localización porque simplifica el problema algebraicamente. Penaliza con mayor fuerza a los puntos lejanos.

$$d_2^2((x, y), (a_i, b_i)) = (x - a_i)^2 + (y - b_i)^2.$$



7.1.4. Comparación de medidas

La medida de distancia debe escogerse según el contexto del problema. No existe una única forma correcta de medir cercanía: depende del tipo de red, de la interpretación logística y del modelo que se quiera resolver.

Medida	Fórmula	Ventaja	Desventaja
Rectilínea o Manhattan	$ x - a_i + y - b_i $	Representa bien ciudades tipo manilla.	Puede sobreestimar la distancia real.
Euclidiana	$\sqrt{(x - a_i)^2 + (y - b_i)^2}$	Es intuitiva y geométrica.	Puede ignorar restricciones de la red.
Euclidiana al cuadrado	$(x - a_i)^2 + (y - b_i)^2$	Facilita soluciones algebraicas.	No representa distancia recorrida directa.

La medida de distancia no solo cambia la interpretación logística del problema, sino también la estructura matemática de la función objetivo. Por esta razón, cada distancia suele conducir a un método de solución distinto: la distancia rectilínea lleva a la mediana

ponderada, la distancia euclidiana al cuadrado al método de gravedad y la distancia euclidiana al algoritmo de Weiszfeld.

7.2. Método alternativo: mediana ponderada

El método alternativo encuentra una ubicación (x^*, y^*) minimizando la suma de distancias rectilíneas ponderadas; para ello, busca la mediana ponderada de las coordenadas en X y en Y por separado.

Receta (método alternativo). Encontrar la ubicación óptima (x^*, y^*) bajo distancia rectilínea ponderada.

1. **Setup.** Partimos de una tabla con puntos de demanda $i = 1, \dots, n$, coordenadas (a_i, b_i) y pesos w_i . En aplicaciones, los pesos pueden representar demanda, número de viajes, volumen transportado o importancia relativa del cliente.
2. **Ordenar por coordenada X .** Tomar la tabla inicial y ordenar los puntos de menor a mayor según su coordenada a_i . En este paso solo se usa la coordenada en X .
3. **Calcular pesos acumulados en X .** Para la tabla ordenada por X , calcular la suma acumulada de pesos:

$$W_k^{\text{acum}} = \sum_{j=1}^k w_j.$$

4. **Ordenar por coordenada Y .** Repetir el proceso anterior, pero ahora ordenando los puntos de menor a mayor según su coordenada b_i .
5. **Calcular pesos acumulados en Y .** Para la tabla ordenada por Y , calcular nuevamente la suma acumulada de pesos.
6. **Calcular el valor medio.** Calcular

$$m = \frac{\sum_i w_i}{2}.$$

7. **Encontrar x^* .** En la tabla ordenada por X , tomar la primera coordenada a_i cuyo peso acumulado sea mayor o igual a m . Esa coordenada será:

$$x^*.$$

8. **Encontrar y^* .** En la tabla ordenada por Y , tomar la primera coordenada b_i cuyo peso acumulado sea mayor o igual a m . Esa coordenada será:

$$y^*.$$

9. **Calcular la distancia rectilínea ponderada.** Para cada punto i , calcular la distancia ponderada desde (a_i, b_i) hasta la ubicación encontrada:

$$D_i = |a_i - x^*|w_i + |b_i - y^*|w_i.$$

10. **Calcular la distancia total.** Sumar las distancias ponderadas de todos los puntos:

$$D_{\text{ida}} = \sum_i D_i.$$

Si el problema considera viaje de ida y vuelta, se reporta:

$$D_{\text{total}} = 2D_{\text{ida}}.$$

Ejercicio 7.1. Tome una empresa que desea abrir un nuevo centro de distribución para atender una red de puntos de venta ubicados en diferentes coordenadas de una ciudad. Para cada punto de venta se conoce su ubicación en el plano, dada por las coordenadas X y Y en kilómetros, y el número esperado de pedidos al año.

La empresa desea encontrar una ubicación (x^*, y^*) para el nuevo centro de distribución usando el método alternativo de localización con distancia rectilínea ponderada. Para ello, se suministra la siguiente información:

Punto de venta	X [km]	Y [km]	No. Pedidos [viajes/año]
1	242	471	23
2	550	204	61
3	296	917	31
4	212	622	62
5	507	649	23
6	369	993	31
7	513	510	47
8	505	653	57
9	346	881	69
10	825	385	32
11	339	977	29
12	665	537	59
13	646	864	56
14	342	238	37
15	783	847	79

A partir de esta información, encuentre la ubicación óptima (x^*, y^*) del nuevo centro de distribución usando el método alternativo. En particular, se busca responder las siguientes preguntas:

1. ¿Cuál es el valor medio $m = \frac{\sum_i w_i}{2}$?
2. ¿Cuál es la coordenada óptima x^* obtenida al ordenar los puntos por X ?
3. ¿Cuál es la coordenada óptima y^* obtenida al ordenar los puntos por Y ?
4. ¿Cuál es la distancia rectilínea ponderada total desde los puntos de venta hasta la ubicación encontrada?

5. Si se consideran viajes de ida y vuelta, ¿cuál es la distancia total recorrida?

Solución:

Veamos la solución del ejercicio en el siguiente Excel. [Solución Método Alternativo.xlsx](#)



7.3. Método de gravedad

El método de gravedad encuentra una ubicación (x^*, y^*) minimizando la suma ponderada de distancias euclidianas al cuadrado. Es decir, resuelve el problema

$$\min_{x^*, y^*} \sum_{i=1}^n w_i [(x^* - x_i)^2 + (y^* - y_i)^2],$$

donde (x_i, y_i) son las coordenadas del punto i y w_i es su peso. Como la función objetivo es cuadrática, podemos derivar respecto a x y y , igualar a cero y obtener directamente:

$$x^* = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i}, \quad y^* = \frac{\sum_{i=1}^n w_i y_i}{\sum_{i=1}^n w_i}.$$

En otras palabras, la ubicación óptima corresponde al promedio ponderado de las coordenadas de los puntos de demanda.

Receta:

1. Identificar matriz inicial.
2. Llenar matriz auxiliar:

Punto de venta	Coordenada x_i	Coordenada y_i	Peso w_i	$w_i \cdot x_i$	$w_i \cdot y_i$
1	x_1	y_1	w_1	$w_1 \cdot x_1$	$w_1 \cdot y_1$
2	x_2	y_2	w_2	$w_2 \cdot x_2$	$w_2 \cdot y_2$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	x_n	y_n	w_n	$w_n \cdot x_n$	$w_n \cdot y_n$

3. Encontrar coordenadas de localización óptimas (x^*, y^*) usando:

$$x^* = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i}, \quad y^* = \frac{\sum_{i=1}^n w_i y_i}{\sum_{i=1}^n w_i}.$$

Notemos que el numerador y denominador de estas fórmulas ya las tenemos en la anterior tabla. Solo tenemos que sacar la suma.

4. Con esta información, sacamos una nueva tabla para encontrar distancia recorrida:

Punto de venta	Distancia al cuadrado recorrida en X	Distancia al cuadrado recorrida en Y	Suma ponderada
1	$(x^* - x_1)^2$	$(y^* - y_1)^2$	$[(x^* - x_1)^2 + (y^* - y_1)^2] w_1$
2	$(x^* - x_2)^2$	$(y^* - y_2)^2$	$[(x^* - x_2)^2 + (y^* - y_2)^2] w_2$
$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	$(x^* - x_n)^2$	$(y^* - y_n)^2$	$[(x^* - x_n)^2 + (y^* - y_n)^2] w_n$

Ejercicio 7.2. Tome una empresa que desea abrir un nuevo centro de distribución para atender una red de puntos de venta ubicados en diferentes coordenadas de una ciudad. Para cada punto de venta se conoce su ubicación en el plano, dada por las coordenadas X y Y en kilómetros, y el número esperado de pedidos al año. Este número de pedidos se usará como peso w_i , pues representa la importancia relativa de cada punto dentro de la red.

A diferencia del ejercicio anterior, ahora la empresa desea encontrar la ubicación (x^*, y^*) del nuevo centro de distribución usando el método de gravedad. Para esto, se asumirá una distancia euclidiana al cuadrado ponderada, de modo que la función objetivo a minimizar es:

$$\min_{x^*, y^*} \sum_{i=1}^n w_i [(x^* - x_i)^2 + (y^* - y_i)^2],$$

donde (x_i, y_i) representa la ubicación del punto de venta i , y w_i corresponde al número de pedidos esperados al año.

Se suministra la siguiente información:

Punto de venta	X [km]	Y [km]	No. Pedidos [viajes/año]
1	242	471	23
2	550	204	61
3	296	917	31
4	212	622	62
5	507	649	23
6	369	993	31
7	513	510	47
8	505	653	57
9	346	881	69
10	825	385	32
11	339	977	29
12	665	537	59
13	646	864	56
14	342	238	37
15	783	847	79

A partir de esta información, encuentre la ubicación óptima (x^*, y^*) del nuevo centro de distribución usando el método de gravedad. En particular, se busca responder las siguientes preguntas:

1. ¿Cuál es la coordenada óptima x^* ?
2. ¿Cuál es la coordenada óptima y^* ?
3. ¿Cuál es el valor total de la distancia euclidiana al cuadrado ponderada?

Solución:

Veamos el siguiente Excel que contiene la solución del ejercicio. [Solución Método de Gravedad.xlsx](#)



7.4. Algoritmo de Weiszfeld

El método de Weiszfeld permite encontrar una ubicación (x^*, y^*) que minimiza la suma de distancias euclidianas ponderadas. Como este problema no se resuelve directamente con un promedio ponderado, partimos de un punto inicial y actualizamos iterativamente las coordenadas hasta alcanzar convergencia.

Receta:

1. Usar una tabla “transpuesta” con respecto a como lo hemos trabajado anteriormente:

Punto de venta j	1	2	$\dots$	n
Coordenada en $X : a_j$	a_1	a_2	$\dots$	a_n
Coordenada en $Y : b_j$	b_1	b_2	$\dots$	b_n

Aclaración de notación importante: Si nos fijamos, ahora denotamos los puntos de venta iniciales con a_j y b_j . Esto se debe a que al tener que iterar, llegaremos a una matriz indexada en filas con el índice i y en columnas con el índice j .

2. Inicializamos iteración 0 de primera parte de matriz de iteraciones:

Iteración	x_i	y_i
0	Sol. inicial	Sol. inicial

Esta solución inicial en ambas coordenadas puede estar dada por el óptimo de otro método. De igual forma, se debería llegar a un mismo óptimo sin importar en qué valor se comience, siempre y cuando no se llegue a un $(x_i, y_i) = (a_j, b_j)$ dentro de la matriz inicial.

3. Inicializar tabla $g_j(x_i, y_i)$ usando la fórmula

$$g_j(x_i, y_i) = \frac{w_j}{\sqrt{(x_i - a_j)^2 + (y_i - b_j)^2}}$$

En el caso de la iteración 0, esto quedaría tal que

Iteración	$g_j(x_i, y_i)$			
0	$\frac{w_1}{\sqrt{(x_0 - a_1)^2 + (y_0 - b_1)^2}}$	$\frac{w_2}{\sqrt{(x_0 - a_2)^2 + (y_0 - b_2)^2}}$	$\dots$	$\frac{w_n}{\sqrt{(x_0 - a_n)^2 + (y_0 - b_n)^2}}$

4. Actualizamos la siguiente iteración de los puntos (x, y) en la iteración 1 con respecto a los valores de g de la anterior iteración usando la fórmula

$$x_{i+1} = \frac{\sum_j a_j g_j(x_i, y_i)}{\sum_j g_j(x_i, y_i)}, \quad y_{i+1} = \frac{\sum_j b_j g_j(x_i, y_i)}{\sum_j g_j(x_i, y_i)}$$

Iteración	x_i	y_i
0	Sol. inicial	Sol. inicial
1	$\frac{\sum_j a_j g_j(x_0, y_0)}{\sum_j g_j(x_0, y_0)}$	$\frac{\sum_j b_j g_j(x_0, y_0)}{\sum_j g_j(x_0, y_0)}$

5. Nos devolvemos al paso 3 y 4. Los repetimos hasta lograr una convergencia del método a un (x^*, y^*) . Se pueden detener las iteraciones estableciendo un umbral de paro (si el cambio entre iteraciones es menor a un $\varepsilon > 0$) o con un máximo de iteraciones.

Ejercicio 7.3. Tome una empresa que desea abrir un nuevo centro de distribución para atender una red de puntos de venta ubicados en diferentes coordenadas de una ciudad. Para cada punto de venta se conoce su ubicación en el plano, dada por las coordenadas X y Y en kilómetros, y el número esperado de pedidos al año.

La empresa desea encontrar la ubicación (x^*, y^*) del nuevo centro de distribución usando el método de Weiszfeld con 50 iteraciones.

Se suministra la siguiente información:

Punto de venta	X [km]	Y [km]	No. Pedidos [viajes/año]
1	242	471	23
2	550	204	61
3	296	917	31
4	212	622	62
5	507	649	23
6	369	993	31
7	513	510	47
8	505	653	57
9	346	881	69
10	825	385	32
11	339	977	29
12	665	537	59
13	646	864	56
14	342	238	37
15	783	847	79

A partir de esta información, encuentre la ubicación (x^*, y^*) del nuevo centro de distribución usando el método de Weiszfeld. Use como punto inicial el centro de gravedad ponderado.

En particular, se busca responder las siguientes preguntas:

1. ¿Cuál es el punto inicial (x_0, y_0) obtenido mediante el centro de gravedad?
2. ¿Cómo evolucionan las coordenadas (x_k, y_k) a lo largo de las iteraciones?
3. ¿Cuál es la ubicación final (x^*, y^*) obtenida por el método de Weiszfeld?
4. ¿Cuál es la distancia euclidiana ponderada desde cada punto de venta hasta (x^*, y^*) ?
5. ¿Cuál es la distancia euclidiana ponderada total asociada a la solución?

Solución:

Veamos el siguiente Excel que contiene la solución del ejercicio. [Solución Método de Weiszfeld.xlsx](#)

Capítulo 8

Diseño de ruta

Nos hemos enfocado en cómo recorrer clientes (ordenar visitas y construir rutas). En esta sección cambiamos el foco a cómo estructurar la operación: decidir qué nodos funcionan como centros de distribución y cómo se asignan los clientes, balanceando costos fijos de apertura y costos variables de atención. Para esto trabajaremos algoritmos incrementales tipo ADD/DROP, donde vamos ajustando la matriz de costos y verificando las restricciones propias del enunciado a medida que construimos una solución factible.

Es importante saber que trabajaremos con dos criterios para detener los siguientes dos algoritmos. Uno “fuerte” que será que se cumplan las restricciones propias del problema y otro “suave” que será minimizar costos totales: apenas veamos que la función de costos deja de bajar, detenemos las iteraciones. Bajo esta óptica, intentaremos garantizar en todo caso que se cumplan las restricciones propias del problema. Cuando esto ocurra, si la función de costos totales no ha subido, seguimos iterando hasta que esto ocurra.

Cambio de paradigma con respecto a Clarke & Wright

En este capítulo cambiará nuestra función objetivo: en vez de maximizar ahorros, pasaremos a minimizar costos.

En cuanto a recetas, las explicaremos de forma general dado que la forma en la que se verifican condiciones y se actualizan los parámetros en cada iteración puede ser hecha de múltiples formas y puede que para algunas personas automatizarlo sea más difícil que hacer ciertas partes de forma manual. En la solución de los ejercicios presentaremos una forma de automatizarlo.

8.1. Algoritmo ADD

Como lo dice el nombre del algoritmo, su idea central es empezar con todos los posibles centros de distribución cerrados e ir abriéndolos conforme vaya disminuyendo el costo y la asignación propuesta se vuelva factible.

Receta: Algoritmo ADD dada una matriz de costos.

1. Creamos matriz de clientes y posibles centros de distribución asignando costos variables y fijos correspondientemente. En este caso, asumiremos que todos los nodos pueden convertirse en centros de distribución:

i/j	1	2	...	$\sum CV_j$	CF	CT
1	CV_{11}	CV_{12}	...	$\sum CV_j$	CF_1	$CT_1 = CF_1 + \sum CV_j$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

Cuadro 8.1: Tabla de inicialización ADD

2. Escoger punto de venta con menor costo total asociado y abrirlo. Al hacerlo, actualizar tabla secundaria de puntos de venta abiertos y de chequeo de restricciones propias del problema.

i/j	1	...	N	Restricción 1	...	Restricción N
PV abierto 1	CV_{11}	...	CV_{1N}	Info R1	...	Info RN
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

Cuadro 8.2: Tabla de actualización de costos y restricciones

3. Siguiente iteración: Supongamos que en la anterior iteración abrimos el centro k con costo fijo asociado CF_k^* . Actualizar tabla de iteraciones

i/j	1	2	...	$\sum CV_j$	CF	CT
1	CV_{11}^*	CV_{12}^*	...	$\sum CV_j^*$	CF_1^*	$CT_1^* = CF_1^* + \sum CV_j^*$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

Cuadro 8.3: Tabla de iteración promedio ADD

Donde

$$CV_{ij}^* = \min\{CV_{ij}, CV_{kj}\}$$

$$CF_i^* = CF_i + CF_k^*$$

Nota súper importante: CF_k^* es el costo total de la anterior iteración asociado al nodo k . No el costo fijo de abrir ese punto de venta. ¿Cuál es la diferencia? En las tablas de iteraciones, los costos fijos se acumulan. En la tabla de actualización de costos y restricciones no.

4. Elegir el PV que minimice costos totales, abrirlo y actualizar tabla 8.2.
5. Volver al paso 3 y seguir hasta que se llegue a la factibilidad del problema.
6. Si los costos totales no han subido, seguir iterando hasta que esto ocurra. Si esto ya ocurrió, finalizar algoritmo.

Algoritmo 3 Heurística ADD con matriz de costos

- 1: Definir nodos $V = \{1, \dots, n\}$ (cada nodo puede ser cliente y candidato a centro).
- 2: Cargar costos variables CV_{ij} (servir cliente j desde centro i) y costos fijos CF_i (abrir centro i).
- 3: **[EDITAR]** Cargar restricciones del problema (capacidad, cobertura, presupuesto, ventanas, etc.).

1) Inicialización

- 4: Centros abiertos $\mathcal{O} \leftarrow \emptyset$
- 5: **[EDITAR]** Matriz actual de costos: $CV_{ij}^* \leftarrow CV_{ij}$ (si no hay centros abiertos, es la matriz base).
- 6: Construir tabla de iteración: $CT_i \leftarrow CF_i + \sum_{j \in V} CV_{ij}^* \quad \triangleright$ costo total si abrimos i

2) Abrir el mejor centro inicial

- 7: $k \leftarrow \arg \min_i CT_i$
- 8: $\mathcal{O} \leftarrow \mathcal{O} \cup \{k\}$
- 9: **[EDITAR]** Actualizar tabla secundaria (costos por cliente + chequeo de restricciones).
- 10: $CT^{\text{prev}} \leftarrow CT_k$

3) Iteraciones ADD

- 11: **while** **[EDITAR]** NoFactible($\mathcal{O}$) **or** **[EDITAR]** Mejora(CT^{prev} , CT^{nuevo}) **do**
- 12: **[EDITAR]** Actualizar matriz de costos con el nuevo centro abierto:
- 13: $CV_{ij}^* \leftarrow \min\{CV_{ij}^*, CV_{kj}\} \quad \forall i, j \quad \triangleright$ (equivalente a “mejor costo disponible”)
- 14: **Evaluar cada candidato a abrir**
- 15: **for** $i \in V \setminus \mathcal{O}$ **do**
- 16: **[EDITAR]** Costo variable resultante si también abrimos i :
- 17: $CV_j^{(i)} \leftarrow \min\{CV_{kj}^*, CV_{ij}\} \quad \forall j$
- 18: $CT_i \leftarrow \left(\sum_{m \in \mathcal{O}} CF_m \right) + CF_i + \sum_{j \in V} CV_j^{(i)}$
- 19: **[EDITAR]** Chequear restricciones si se abre i (capacidad, cobertura, etc.).
- 20: **end for**
- 21: $k \leftarrow \arg \min_{i \in V \setminus \mathcal{O}} CT_i$
- 22: **if** **[EDITAR]** ViolaRestricciones($k, \mathcal{O}$) **then**
- 23: **break**
- 24: **end if**
- 25: **if** $CT_k > CT^{\text{prev}}$ **and** **[EDITAR]** YaEsFactible($\mathcal{O}$) **then**
- 26: **break**
- 27: **end if**
- 28: $\mathcal{O} \leftarrow \mathcal{O} \cup \{k\}; CT^{\text{prev}} \leftarrow CT_k$
- 29: **[EDITAR]** Actualizar tabla secundaria (costos por cliente + restricciones).
- 30: **end while**
- 31: **return** $\mathcal{O}$ y **[EDITAR]** asignación cliente $\rightarrow$ centro usando CV^*

Ejercicio 8.1. Tome una empresa que tiene 6 puntos de venta con las siguientes demandas ya sean centros de producción o no, y capacidades de producción y costos fijos de

apertura en caso de ser abiertas como puntos de venta.

PV	CF	Demanda	Capacidad
PV 1	2400	180	250
PV 2	2600	220	250
PV 3	2200	160	400
PV 4	2800	140	200
PV 5	2300	200	300

Asimismo, se tienen estas tablas de distancias mínimas.

	PV 1	PV 2	PV 3	PV 4	PV 5
PV 1	0	6	4	8	7
PV 2	6	0	5	7	6
PV 3	4	5	0	4	3
PV 4	8	7	4	0	5
PV 5	7	6	3	5	0

Se sabe que a la empresa le cuesta \$10 recorrer cada unidad de distancia y \$1 por producir cada unidad de producto.

Ajuste un algoritmo de apertura de centros siguiendo el algoritmo ADD con el fin de minimizar costos totales. Reporte iteración a iteración los puntos de venta abiertos así como el costo total incurrido.

Solución:

Veamos el siguiente Excel con la solución del ejercicio. [Ejemplo ADD.xlsx](#)



¿Cómo nos pueden complicar la vida?

Si bien este ejemplo tiene restricción de capacidad, puede que en el parcial aparezca un ejemplo con una matriz de costos más complicada. Vale la pena preguntarse: ¿Qué pasaría si la empresa tiene varios productos? ¿Qué pasaría si para cada producto se tiene un costo diferente? ¿Y si la empresa tiene un descuento en los costos dada una condición adicional? ¿Cómo cambiaría la matriz de costos en cada uno de estos escenarios?

Y más importante aún, ¿Qué pasaría si hay 15 clientes? ¿Podríamos generar las iteraciones en poco tiempo?

Estos escenarios pueden salir y es importante saber qué hacer en cada uno de ellos.

8.2. Algoritmo DROP

Similar al algoritmo ADD, la idea central detrás del algoritmo DROP está en su nombre: empezar con todos los puntos de venta abiertos e ir cerrando uno a uno hasta que se llegue a la infactibilidad del problema sin perder de vista el objetivo principal: minimizar costos de operación.

Receta: Algoritmo DROP dada una matriz de costos.

Explicaremos este algoritmo usando dos matrices

1. Inicializar tabla de costos variables y restricciones.

i/j	1	2	...	N	Restricción 1	...	Restricción M	Factible
1	CV_{11}	CV_{12}	...	CV_{1N}	...	...	...	Si/No
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

Cuadro 8.4: Tabla de costos variables

2. Inicializar tabla de costos totales

i	CF	C. Transp	CF p abiertos	CT
1	CF_1	Segundo menor CV_{i1}	$\sum_i CF_i - CF_1$	C. Trans + CF p abiertos
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

Cuadro 8.5: Tabla de costos totales

3. Elegir el punto de venta que tenga menor costo total (supongamos la fila k , donde CF_k^* = fila k de la columna “CF p abiertos”), copiar y pegar tabla de costos variables, borrar fila asociada de esta matriz pegada.
4. Evaluar factibilidad de la solución actual. Si esta es factible, proceder con el cálculo de los costos. Si no, terminar el algoritmo y reportar solución óptima según la heurística.
5. Encontrar punto de venta que atiende a k .
6. Actualizar Tabla de costos totales tal que

i	CF	C. Transp	CF p abiertos	P. k cerrado	CT
1	CF_1	Segundo menor CV_{i1}	$CF_k^* - CF_1$	Ver Intuición	C.T+CF.p+P. k .Cerr
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

Cuadro 8.6: Tabla de costos totales al elegir el primer punto de venta k a cerrar

Intuición: Este es el costo por abastecer este punto de venta en caso de cerrar el i asociado. Si el punto i para el que estamos evaluando el costo no atiende al punto

k , dejamos el mínimo de la columna k . Si el punto i está abasteciendo al punto k que ya cerramos, ponemos el segundo costo menor.

En palabras puede ser un poco confuso, por eso incluiremos un ejercicio para que se pueda ver la lógica de cómo lo calculamos.

7. Volver al paso 3 y seguir el algoritmo hasta llegar a infactibilidad, o hasta que los costos totales vuelvan a subir.

Algoritmo 4 Heurística DROP con matriz de costos

```

1: Definir nodos  $V = \{1, \dots, n\}$  (cada nodo puede ser cliente y candidato a centro).
2: Cargar costos variables  $CV_{ij}$  y costos fijos  $CF_i$ .
3: [EDITAR] Cargar restricciones del problema (capacidad, cobertura, presupuesto,
   ventanas, etc.).

   1) Inicialización: “todos abiertos”
4: Centros abiertos  $\mathcal{O} \leftarrow V$ 
5: [EDITAR] Asignación inicial cliente→centro: típicamente  $a(j) = \arg \min_{i \in \mathcal{O}} CV_{ij}$ .
6: [EDITAR] Calcular costo total inicial:  $CT(\mathcal{O}) = \sum_{i \in \mathcal{O}} CF_i + \sum_{j \in V} CV_{a(j),j}$ .
7: [EDITAR] Verificar factibilidad inicial.

   2) Iteraciones DROP: intentar cerrar un centro por vez
8: while true do
9:    $CT^{\text{prev}} \leftarrow CT(\mathcal{O})$ 
10:  MejorCandidato  $\leftarrow \text{None}$ ,    $CT^{\text{best}} \leftarrow +\infty$ 

11:  for cada  $k \in \mathcal{O}$  do                                     ▷ probar cerrar  $k$ 
12:     $\mathcal{O}' \leftarrow \mathcal{O} \setminus \{k\}$ 
13:    [EDITAR] Reasignar clientes con  $\mathcal{O}'$ :  $a'(j) = \arg \min_{i \in \mathcal{O}'} CV_{ij}$ .
14:    [EDITAR] Chequear restricciones bajo  $\mathcal{O}'$  (capacidad, cobertura, etc.).
15:    if [EDITAR] NoFactible( $\mathcal{O}', a'$ ) then
16:      continue
17:    end if
18:     $CT' \leftarrow \sum_{i \in \mathcal{O}'} CF_i + \sum_{j \in V} CV_{a'(j),j}$ 
19:    if  $CT' < CT^{\text{best}}$  then
20:       $CT^{\text{best}} \leftarrow CT'$ ;   MejorCandidato  $\leftarrow k$ 
21:    end if
22:  end for

23:  if MejorCandidato = None then
24:    break
25:  end if
26:  if  $CT^{\text{best}} \geq CT^{\text{prev}}$  then                                     ▷ ya no mejora
27:    break
28:  end if
29:   $\mathcal{O} \leftarrow \mathcal{O} \setminus \{\text{MejorCandidato}\}$ 
30:  [EDITAR] Actualizar asignación  $a(\cdot)$  y tabla secundaria de restricciones/costos.
31: end while
32: return  $\mathcal{O}$  y [EDITAR] asignación final cliente→centro

```

Ejercicio 8.2. Tome una empresa que tiene 6 puntos de venta con las siguientes demandas ya sean centros de producción o no, y capacidades de producción y costos fijos de apertura en caso de ser abiertas como puntos de venta.

PV	CF	Demanda	Capacidad
PV 1	2400	180	250
PV 2	2600	220	250
PV 3	2200	160	400
PV 4	2800	140	200
PV 5	2300	200	300

Asimismo, se tienen estas tablas de distancias mínimas.

	PV 1	PV 2	PV 3	PV 4	PV 5
PV 1	0	6	4	8	7
PV 2	6	0	5	7	6
PV 3	4	5	0	4	3
PV 4	8	7	4	0	5
PV 5	7	6	3	5	0

Se sabe que a la empresa le cuesta \$10 recorrer cada unidad de distancia y \$1 por producir cada unidad de producto.

Ajuste un algoritmo de cierre de centros siguiendo el algoritmo DROP con el fin de minimizar costos totales. Reporte iteración a iteración los puntos de venta abiertos así como el costo total incurrido.

Solución:

Veamos el siguiente Excel con la solución del ejercicio. [Ejemplo DROP.xlsx](#)



¿Cómo nos pueden complicar la vida?

Básicamente de la misma forma que en ADD. Sobre todo, poniendo muchos clientes para tener que hacer varias iteraciones adicionales.

8.3. Formulación básica de diseño de red

En diseño de red, una de las preguntas más importantes es decidir qué instalaciones abrir y qué clientes asignar a cada instalación. En su versión más básica, no asumiremos restricciones de capacidad, ni límites en el número de clientes que puede atender una instalación. Tampoco asumiremos una forma específica para calcular los costos. Simplemente supondremos que se tiene una matriz de costos C_{ij} , donde C_{ij} representa el costo de atender al cliente j desde la instalación i .

Sea I el conjunto de posibles instalaciones y sea J el conjunto de clientes o puntos de demanda.

Parámetros

F_i : costo fijo de abrir la instalación i ,

C_{ij} : costo de atender al cliente j desde la instalación i .

Variables de decisión

$$y_i = \begin{cases} 1, & \text{si se abre la instalación } i, \\ 0, & \text{en caso contrario.} \end{cases}$$

$$x_{ij} = \begin{cases} 1, & \text{si el cliente } j \text{ es atendido desde la instalación } i, \\ 0, & \text{en caso contrario.} \end{cases}$$

Función objetivo

El objetivo es minimizar la suma de los costos fijos de apertura y los costos de asignación:

$$\text{mín} \sum_{i \in I} F_i y_i + \sum_{i \in I} \sum_{j \in J} C_{ij} x_{ij}.$$

Restricciones

Cada cliente debe ser asignado a exactamente una instalación:

$$\sum_{i \in I} x_{ij} = 1 \quad \forall j \in J.$$

Un cliente solo puede ser asignado a una instalación si dicha instalación está abierta:

$$x_{ij} \leq y_i \quad \forall i \in I, j \in J.$$

Finalmente, las variables son binarias:

$$x_{ij} \in \{0, 1\} \quad \forall i \in I, j \in J,$$

$$y_i \in \{0, 1\} \quad \forall i \in I.$$

Modelo completo

$$\begin{aligned}
 \text{mín} \quad & \sum_{i \in I} F_i y_i + \sum_{i \in I} \sum_{j \in J} C_{ij} x_{ij} \\
 \text{s.a.} \quad & \sum_{i \in I} x_{ij} = 1 & \forall j \in J, \\
 & x_{ij} \leq y_i & \forall i \in I, j \in J, \\
 & x_{ij} \in \{0, 1\} & \forall i \in I, j \in J, \\
 & y_i \in \{0, 1\} & \forall i \in I.
 \end{aligned}$$

Esta formulación es deliberadamente simple. La matriz C_{ij} puede venir directamente del enunciado, de una matriz de distancias, de costos de transporte, de costos logísticos totales o de cualquier otra fuente. En esta primera versión no nos interesa cómo se construye C_{ij} , sino cómo usarla para decidir qué instalaciones abrir y cómo asignar clientes.

Ejercicio 8.3 (Centros de distribución no son puntos de venta). Tome una empresa que desea diseñar una red básica de atención para un conjunto de clientes. La empresa cuenta con varias instalaciones candidatas, pero no necesariamente debe abrirlas todas. Si una instalación se abre, puede atender cualquier número de clientes.

Para cada instalación candidata se conoce un costo fijo de apertura F_i . Además, se tiene una matriz de costos C_{ij} , donde C_{ij} representa el costo de atender al cliente j desde la instalación i .

En el Excel [Datos diseño de red básico.xlsx](#) se suministra la información necesaria en tres hojas:

- **Instalaciones:** contiene las instalaciones candidatas y su costo fijo de apertura.
- **Clientes:** contiene los clientes que deben ser atendidos.
- **Costos:** contiene la matriz de costos C_{ij} .

A partir de esta información, formule y resuelva un modelo de programación lineal entera mixta en PuLP que determine qué instalaciones abrir y qué cliente asignar a cada instalación. En particular, se busca responder:

1. ¿Qué instalaciones deben abrirse?
2. ¿A qué instalación se asigna cada cliente?
3. ¿Cuál es el costo fijo total de apertura?
4. ¿Cuál es el costo total de asignación?
5. ¿Cuál es el costo total de la red?

Solución:

Veamos el siguiente notebook de Python que contiene la solución del ejercicio. [Solución diseño de red básico con PuLP.ipynb](#)



Ejercicio 8.4 (Calcular costos y capacidad máxima). Tome una empresa que desea rediseñar su red de distribución. Actualmente tiene un conjunto de clientes N , y la decisión consiste en escoger uno o varios de estos clientes para convertirlos en centros de distribución. Un cliente convertido en centro puede atenderse a sí mismo y también atender a otros clientes.

La empresa maneja varios productos $p \in P$. Para cada cliente j y producto p , se conoce una demanda q_{jp} . Además, cada posible centro i pertenece a una localidad $\ell(i)$, y esta localidad afecta el costo fijo de convertir al cliente i en centro de distribución.

Para construir el modelo, se deben calcular dos tipos de costos:

$$F_i = A_i r_{\ell(i)} + T_{\ell(i)} + K_i,$$

donde A_i es el área requerida para convertir el cliente i en centro, $r_{\ell(i)}$ es el costo de arriendo por metro cuadrado en su localidad, $T_{\ell(i)}$ es un impuesto fijo anual de la localidad y K_i es el costo de adecuación del punto.

El costo variable de atender al cliente j con el producto p desde el centro i se calcula como:

$$C_{ijp} = q_{jp} (\tau_p d_{ij} + h_p),$$

donde d_{ij} es la distancia entre i y j , τ_p es el costo de transporte por unidad-kilómetro del producto p , y h_p es el costo de manejo por unidad del producto p . Si $i = j$, se toma:

$$C_{iip} = 0,$$

pues un centro de distribución que se atiende a sí mismo no incurre en costo adicional de transporte o asignación. Cada centro i tiene capacidad máxima Q_i , medida en unidades totales atendidas.

Formule un modelo de programación lineal entera mixta que determine qué clientes deben convertirse en centros de distribución y desde qué centro debe atenderse la demanda de cada cliente y producto.

Solución: Sea N el conjunto de clientes, que también actúa como conjunto de posibles centros de distribución, y sea P el conjunto de productos.

$$y_i = \begin{cases} 1, & \text{si el cliente } i \text{ se convierte en centro de distribución,} \\ 0, & \text{en caso contrario.} \end{cases}$$

$$x_{ijp} = \begin{cases} 1, & \text{si la demanda del cliente } j \text{ del producto } p \text{ es atendida desde el centro } i, \\ 0, & \text{en caso contrario.} \end{cases}$$

El objetivo es minimizar el costo fijo de abrir centros y el costo variable de asignar clientes y productos:

$$\min \sum_{i \in N} F_i y_i + \sum_{i \in N} \sum_{j \in N} \sum_{p \in P} C_{ijp} x_{ijp}.$$

Cada demanda cliente-producto debe ser atendida por exactamente un centro:

$$\sum_{i \in N} x_{ijp} = 1 \quad \forall j \in N, p \in P.$$

Una demanda solo puede asignarse a un centro que esté abierto:

$$x_{ijp} \leq y_i \quad \forall i, j \in N, p \in P.$$

La capacidad total atendida por cada centro no puede superar su capacidad máxima:

$$\sum_{j \in N} \sum_{p \in P} q_{jp} x_{ijp} \leq Q_i y_i \quad \forall i \in N.$$

Finalmente, las variables son binarias:

$$x_{ijp} \in \{0, 1\} \quad \forall i, j \in N, p \in P,$$

$$y_i \in \{0, 1\} \quad \forall i \in N.$$

Por tanto, el modelo completo queda:

$$\begin{aligned} \min \quad & \sum_{i \in N} F_i y_i + \sum_{i \in N} \sum_{j \in N} \sum_{p \in P} C_{ijp} x_{ijp} \\ \text{s.a.} \quad & \sum_{i \in N} x_{ijp} = 1 && \forall j \in N, p \in P, \\ & x_{ijp} \leq y_i && \forall i, j \in N, p \in P, \\ & \sum_{j \in N} \sum_{p \in P} q_{jp} x_{ijp} \leq Q_i y_i && \forall i \in N, \\ & x_{ijp} \in \{0, 1\} && \forall i, j \in N, p \in P, \\ & y_i \in \{0, 1\} && \forall i \in N. \end{aligned}$$

En este modelo, la diferencia frente al caso básico es que ahora los centros candidatos salen del mismo conjunto de clientes, existen múltiples productos y la asignación se decide para cada par cliente-producto. Además, los costos no vienen dados directamente: primero se calcula F_i con la información de localidad y adecuación, y luego se calcula C_{ijp} con demanda, distancia y características del producto.

Veamos el siguiente Excel y notebook de Python, donde se muestran las transformaciones de datos necesarias para construir las tablas que entran al modelo de PuLP, así como la implementación completa del MIP de diseño de red multiproducto.

[Datos y transformaciones diseño de red multiproducto.xlsx](#)

[Solución diseño de red multiproducto con PuLP.ipynb](#)



Ejercicio 8.5. Tome una empresa que desea rediseñar su red de distribución a partir de un conjunto de puntos de venta N . Algunos de estos puntos pueden operar como centros de distribución, pero la empresa ya tiene dos puntos que obligatoriamente deben abrirse como centros iniciales. Denotemos estos centros por m_1 y m_2 .

Los clientes se dividen inicialmente en dos conjuntos disjuntos S_1 y S_2 . El centro m_1 solo puede atender clientes pertenecientes a S_1 , mientras que el centro m_2 solo puede atender clientes pertenecientes a S_2 . Además, algunos puntos de venta adicionales pueden abrirse como nuevos centros de distribución, pero con un costo fijo mayor. Si un punto adicional se abre como centro, este puede atenderse a sí mismo y, como máximo, a un cliente adicional, sin importar a qué conjunto pertenezca dicho cliente.

El Excel [Datos red con CDs obligatorios.xlsx](#) contiene una tabla de costos fijos F_i para cada centro candidato i , y una matriz de costos variables C_{ij} , donde C_{ij} representa el costo de atender al cliente j desde el centro i . Se usa la convención:

$$C_{ii} = 0,$$

pues si un punto de venta se convierte en centro de distribución, atenderse a sí mismo no genera costo variable adicional.

Formule un modelo de programación lineal entera mixta que determine qué puntos adicionales abrir como centros de distribución y cómo asignar cada cliente a un centro.

Solución:

Sea N el conjunto de puntos de venta, $M = \{m_1, m_2\}$ el conjunto de centros obligatorios y $O \subseteq N \setminus M$ el conjunto de puntos que pueden abrirse opcionalmente como centros adicionales. Definimos el conjunto de centros candidatos como

$$K = M \cup O.$$

Las variables de decisión son:

$$y_i = \begin{cases} 1, & \text{si el punto } i \text{ opera como centro de distribución,} \\ 0, & \text{en caso contrario,} \end{cases} \quad \forall i \in K.$$

$$x_{ij} = \begin{cases} 1, & \text{si el cliente } j \text{ es atendido desde el centro } i, \\ 0, & \text{en caso contrario,} \end{cases} \quad \forall i \in K, j \in N.$$

El objetivo es minimizar costos fijos de apertura y costos variables de asignación:

$$\min \sum_{i \in K} F_i y_i + \sum_{i \in K} \sum_{j \in N} C_{ij} x_{ij}.$$

Cada cliente debe ser atendido por exactamente un centro:

$$\sum_{i \in K} x_{ij} = 1 \quad \forall j \in N.$$

Un cliente solo puede asignarse a un centro abierto:

$$x_{ij} \leq y_i \quad \forall i \in K, j \in N.$$

Los dos centros iniciales deben estar abiertos obligatoriamente:

$$y_{m_1} = 1, \quad y_{m_2} = 1.$$

El centro m_1 solo puede atender clientes del conjunto S_1 , y el centro m_2 solo puede atender clientes del conjunto S_2 :

$$x_{m_1 j} = 0 \quad \forall j \in N \setminus S_1,$$

$$x_{m_2 j} = 0 \quad \forall j \in N \setminus S_2.$$

Si un punto adicional se abre como centro, debe atenderse a sí mismo:

$$x_{ii} = y_i \quad \forall i \in O.$$

Además, un centro adicional puede atender como máximo a un cliente distinto de sí mismo:

$$\sum_{\substack{j \in N \\ j \neq i}} x_{ij} \leq y_i \quad \forall i \in O.$$

Finalmente, las variables son binarias:

$$x_{ij} \in \{0, 1\} \quad \forall i \in K, j \in N,$$

$$y_i \in \{0, 1\} \quad \forall i \in K.$$

Por tanto, el modelo completo queda:

$$\begin{aligned} \text{mín} \quad & \sum_{i \in K} F_i y_i + \sum_{i \in K} \sum_{j \in N} C_{ij} x_{ij} \\ \text{s.a.} \quad & \sum_{i \in K} x_{ij} = 1 && \forall j \in N, \\ & x_{ij} \leq y_i && \forall i \in K, j \in N, \\ & y_{m_1} = 1, \\ & y_{m_2} = 1, \\ & x_{m_1 j} = 0 && \forall j \in N \setminus S_1, \\ & x_{m_2 j} = 0 && \forall j \in N \setminus S_2, \\ & x_{ii} = y_i && \forall i \in O, \\ & \sum_{\substack{j \in N \\ j \neq i}} x_{ij} \leq y_i && \forall i \in O, \\ & x_{ij} \in \{0, 1\} && \forall i \in K, j \in N, \\ & y_i \in \{0, 1\} && \forall i \in K. \end{aligned}$$

La idea de esta formulación es que los centros iniciales garantizan cobertura base sobre sus conjuntos permitidos, mientras que los centros adicionales funcionan como aperturas puntuales de apoyo. Estos nuevos centros tienen mayor costo fijo, pero pueden reducir costos variables si conviene que se atiendan a sí mismos y a un cliente adicional.

Veamos el siguiente notebook de Python que contiene la solución del ejercicio. [Solución red con CDs obligatorios con PuLP.ipynb](#)



Si podemos llegar siempre al óptimo con optimización lineal entera mixta, ¿por qué usamos heurísticas?

Cuando el problema crece, el modelo puede volverse muy difícil de resolver. Más clientes, más centros candidatos, más productos y más restricciones implican más variables binarias y más combinaciones posibles.

En problemas pequeños, un solver puede encontrar y certificar la solución óptima. Pero en instancias grandes, esperar esa certificación puede ser demasiado costoso en tiempo. En esos casos, las heurísticas se vuelven una alternativa muy útil: no prometen optimalidad global, pero suelen encontrar soluciones razonablemente buenas con un costo computacional mucho menor.

Apéndice A

Demostraciones Cap 1

A.1. EOQ y EPL

Proposición A.1 (Existencia de γ tal que $T = \gamma Q$). Consideremos un ciclo de inventario de duración total T que se divide en m tramos consecutivos con duraciones

$$T_1, \dots, T_m, \quad \sum_{j=1}^m T_j = T$$

En el tramo j , la demanda es constante a tasa $\lambda_j \geq 0$ (permitiendo tramos ociosos con $\lambda_j = 0$)

Supongamos además que el enunciado fija la estructura temporal del ciclo, es decir, existen constantes $a_1, \dots, a_m$ tales que

$$T_j = a_j T, \quad a_j \geq 0, \quad \sum_{j=1}^m a_j = 1$$

Bajo el supuesto EOQ de no faltantes y ciclo cerrado (el inventario al final del ciclo vuelve a 0), existe una constante $\gamma > 0$ tal que

$$T = \gamma Q$$

donde Q es el tamaño de lote pedido por ciclo

Demostración. Como el ciclo es cerrado y no hay faltantes, toda unidad ordenada al inicio del ciclo se consume dentro del mismo ciclo. Por tanto, el tamaño de lote Q coincide con el consumo total acumulado a lo largo del ciclo

En el tramo j , la demanda es constante a tasa λ_j durante T_j , así que la cantidad consumida en dicho tramo es

$$\lambda_j T_j$$

Si el tramo es ocioso ($\lambda_j = 0$), entonces $\lambda_j T_j = 0$ y, en particular, no hay consumo en ese intervalo

Sumando el consumo de todos los tramos obtenemos el consumo total del ciclo:

$$Q = \sum_{j=1}^m \lambda_j T_j$$

Usando la estructura temporal fija $T_j = a_j T$ se tiene

$$Q = \sum_{j=1}^m \lambda_j (a_j T) = T \sum_{j=1}^m a_j \lambda_j$$

Defina

$$\Lambda := \sum_{j=1}^m a_j \lambda_j$$

Entonces

$$Q = \Lambda T$$

Si $\Lambda > 0$ (equivalentemente, existe al menos un tramo con demanda positiva), podemos despejar

$$T = \frac{1}{\Lambda} Q$$

Definiendo

$$\gamma := \frac{1}{\Lambda} > 0$$

concluimos que

$$T = \gamma Q$$

□

Comentarios

- Los tramos ociosos no afectan el resultado porque, al tener $\lambda_j = 0$, aportan 0 a la suma $\sum_{j=1}^m \lambda_j T_j$
- La proporcionalidad $T = \gamma Q$ proviene de dos hechos: (i) el consumo total del ciclo es Q y (ii) los T_j son fracciones fijas de T
- Si $\Lambda = 0$ (demanda cero en todos los tramos), no existe una relación informativa entre T y Q porque no hay consumo en el ciclo

Proposición A.2 (Función de costos totales univariada es convexa). Supongamos que, tras eliminar T usando la relación $T = \gamma Q$ (con $\gamma > 0$ constante) y expresar el inventario promedio como una función lineal del lote,

$$\bar{I}(Q) = \alpha Q \quad \text{con } \alpha \in [0, 1]$$

la función de costos totales queda de la forma

$$G(Q) = \frac{K}{T} + \frac{cQ}{T} + h \bar{I}(Q) = \frac{K}{\gamma Q} + \frac{cQ}{\gamma Q} + h\alpha Q \quad (Q > 0)$$

Entonces $G(Q)$ es convexa en su dominio $Q > 0$

Demostración. Para $Q > 0$ reescribimos

$$G(Q) = \frac{K}{\gamma} \frac{1}{Q} + \frac{c}{\gamma} + h\alpha Q$$

Derivando,

$$G'(Q) = -\frac{K}{\gamma} \frac{1}{Q^2} + h\alpha$$

y derivando de nuevo,

$$G''(Q) = \frac{2K}{\gamma} \frac{1}{Q^3}$$

Como $K > 0$, $\gamma > 0$ y $Q > 0$, se tiene $G''(Q) > 0$ para todo $Q > 0$. Por tanto, $G(Q)$ es estrictamente convexa en $Q > 0$. Esto asegura que al derivar, igualar a cero y despejar para Q , se encuentra el único mínimo global de la función. $\square$

Proposición A.3 (Derivar e igualar a 0 da lo mismo que igualar primer y tercer término). Consideremos la función de costos

$$G(Q) = \frac{K}{T} + \frac{cQ}{T} + h\bar{I}(Q), \quad Q > 0$$

Supongamos que en el problema se cumple que $T = \gamma Q$ para alguna constante $\gamma > 0$ y que el inventario promedio toma la forma

$$\bar{I}(Q) = \alpha Q \quad \text{con } \alpha \in [0, 1]$$

Entonces el Q^* que se obtiene al igualar el primer y el tercer término de $G(Q)$,

$$\frac{K}{T} = h\bar{I}(Q),$$

coincide con el Q^* que se obtiene al derivar $G(Q)$ respecto a Q e imponer la condición de primer orden $G'(Q) = 0$

Demostración. Usando $T = \gamma Q$ y $\bar{I}(Q) = \alpha Q$ se obtiene, para $Q > 0$,

$$G(Q) = \frac{K}{\gamma Q} + \frac{cQ}{\gamma Q} + h\alpha Q = \frac{K}{\gamma Q} + \frac{c}{\gamma} + h\alpha Q$$

El segundo término $\frac{c}{\gamma}$ es constante en Q , por lo que no afecta la minimización

Método A: igualar primer y tercer término

$$\frac{K}{T} = h\bar{I}(Q) \iff \frac{K}{\gamma Q} = h(\alpha Q) \iff \frac{K}{\gamma} = h\alpha Q^2 \iff Q^* = \sqrt{\frac{K}{\gamma h\alpha}}$$

Método B: derivar e igualar a cero

Derivando $G(Q) = \frac{K}{\gamma Q} + \frac{c}{\gamma} + h\alpha Q$ se obtiene

$$G'(Q) = -\frac{K}{\gamma Q^2} + h\alpha$$

La condición de primer orden $G'(Q) = 0$ implica

$$-\frac{K}{\gamma Q^2} + h\alpha = 0 \iff \frac{K}{\gamma Q^2} = h\alpha \iff \frac{K}{\gamma} = h\alpha Q^2 \iff Q^* = \sqrt{\frac{K}{\gamma h\alpha}}$$

Ambos métodos producen el mismo Q^* , por lo que son equivalentes en este contexto $\square$

A.2. Algoritmo iterativo (Q, R) con backorders

Sea $\lambda > 0$ la tasa media de demanda (unidades/tiempo) y $\tau > 0$ el lead time constante. Definimos la demanda acumulada durante el lead time como una variable aleatoria

$$X_\tau \geq 0, \quad \mathbb{E}[X_\tau] =: \mu_\tau < \infty,$$

con función de distribución F . Cuando exista, denotamos por f su densidad.

Costos:

$$K > 0, \quad h > 0, \quad p > 0$$

Bajo una política (Q, R) , cuando la posición de inventario cae a R o menos, se emite un pedido de tamaño fijo $Q > 0$, que llega tras τ .

La magnitud estocástica esencial asociada a R es el valor esperado de faltantes:

$$n(R) := \mathbb{E}[(X_\tau - R)^+].$$

Si X_τ tiene función de densidad de probabilidad f , entonces

$$n(R) = \int_R^\infty (x - R) f(x) dx.$$

Bajo la suposición de que cada ciclo consume tiene un valor esperado de consumo de Q unidades, el tiempo esperado de ciclo es

$$\mathbb{E}[T] = \frac{Q}{\lambda}.$$

Como ya hemos definido, el costo promedio de largo plazo para (Q, R) con backorders es

$$G(Q, R) = \frac{\lambda K}{Q} + \frac{h}{2}Q + h(R - \mu_\tau) + \frac{p\lambda}{Q} n(R), \quad Q > 0, R \in \mathbb{R}. \quad (\text{A.1})$$

Aquí, $\frac{\lambda K}{Q}$ es el costo fijo por unidad de tiempo, $\frac{h}{2}Q$ corresponde al inventario promedio tipo “serrucho”, $h(R - \mu_\tau)$ es el costo del safety stock $SS = R - \mu_\tau$, y $\frac{p\lambda}{Q}n(R)$ es la penalización promedio de faltantes por unidad de tiempo.

Proposición A.4 (Biconvexidad de G). Supongamos que X_τ tiene función de densidad de probabilidad $f \geq 0$. Entonces:

1. Para R fijo, la función $Q \mapsto G(Q, R)$ es estrictamente convexa en $Q > 0$.
2. Para Q fijo, la función $R \mapsto G(Q, R)$ es convexa en $R \in \mathbb{R}$.

En particular, G es biconvexa (convexa en cada bloque por separado).

Demostración. (1) Si R está fijo, $n(R)$ es constante y los términos dependientes de Q son

$$G(Q | R) = \frac{\lambda(K + p n(R))}{Q} + \frac{h}{2}Q + \text{cte.}$$

Derivando dos veces:

$$\frac{\partial^2}{\partial Q^2} G(Q | R) = \frac{2\lambda(K + p n(R))}{Q^3} > 0,$$

luego $G(\cdot, R)$ es estrictamente convexa en $Q > 0$.

(2) Si Q está fijo, basta analizar

$$G(R | Q) = hR + \frac{p\lambda}{Q} n(R) + \text{cte.}$$

Mostraremos que n es convexa. Sea $n(R) = \int_R^\infty (x - R)f(x) dx$. Entonces

$$n'(R) = - \int_R^\infty f(x) dx = -(1 - F(R)), \quad n''(R) = f(R) \geq 0,$$

por lo cual n es convexa y por ende $G(\cdot | Q)$ es convexa. $\square$

Proposición A.5 (Minimización alternada exacta). Definamos la iteración $\{(Q_i, R_i)\}_{i \geq 0}$ por

$$Q_i \in \arg \min_{Q > 0} G(Q, R_{i-1}), \quad R_i \in \arg \min_{R \in \mathbb{R}} G(Q_i, R).$$

Entonces el algoritmo corresponde a un esquema de minimización alternada por bloques (block coordinate descent / alternate convex search).

Proposición A.6 (Monotonía del costo). Si en cada paso se resuelven exactamente los subproblemas anteriores, entonces

$$G(Q_i, R_i) \leq G(Q_{i-1}, R_{i-1}) \quad \text{para todo } i \geq 1.$$

En particular, $\{G(Q_i, R_i)\}$ es una sucesión no creciente.

Demostración. Por definición de Q_i como minimizador de $G(\cdot, R_{i-1})$,

$$G(Q_i, R_{i-1}) \leq G(Q_{i-1}, R_{i-1}).$$

Luego, por definición de R_i como minimizador de $G(Q_i, \cdot)$,

$$G(Q_i, R_i) \leq G(Q_i, R_{i-1}).$$

Encadenando:

$$G(Q_i, R_i) \leq G(Q_i, R_{i-1}) \leq G(Q_{i-1}, R_{i-1}). \quad \square$$

Proposición A.7 (Convergencia del valor de G y acotamiento de iterados). Suponga $K, h, p, \lambda > 0$ y $\mu_\tau < \infty$. Si el algoritmo de la Proposición A.5 se ejecuta con soluciones exactas de cada subproblema, entonces:

1. La sucesión $\{G(Q_i, R_i)\}$ converge a algún valor finito G_∞ .
2. Los iterados $\{(Q_i, R_i)\}$ permanecen en una región acotada (una región de nivel de G).

3. Toda subsucesión convergente de $\{(Q_i, R_i)\}$ converge a un punto (Q^*, R^*) que es óptimo por coordenadas, o sea,

$$Q^* \in \arg \min_{Q > 0} G(Q, R^*), \quad R^* \in \arg \min_{R \in \mathbb{R}} G(Q^*, R).$$

Demostración. (1) Por la Proposición A.6, $\{G(Q_i, R_i)\}$ es no creciente. Además, $G(Q, R)$ está acotada inferiormente: como $K, h, p, \lambda > 0$ y $n(R) \geq 0$, se tiene $G(Q, R) \geq -h\mu_\tau$ a partir de (A.1) asumiendo $R \geq 0$. Por tanto, una sucesión monótona acotada inferiormente converge, entonces existe $G_\infty = \lim_{i \rightarrow \infty} G(Q_i, R_i)$.

(2) Fijemos $c := G(Q_0, R_0)$. Por monotonicidad, $G(Q_i, R_i) \leq c$ para todo i , es decir, (Q_i, R_i) pertenece a la región de nivel $\mathcal{L}_c := \{(Q, R) : G(Q, R) \leq c\}$. Mostremos que $\mathcal{L}_c$ fuerza acotamiento de Q y R :

Acotamiento de Q : Si $Q \rightarrow 0^+$, entonces $\frac{\lambda K}{Q} \rightarrow \infty$, de modo que $G(Q, R) \rightarrow \infty$. Si $Q \rightarrow \infty$, entonces $\frac{h}{2}Q \rightarrow \infty$, de modo que $G(Q, R) \rightarrow \infty$. Por tanto, en $\mathcal{L}_c$ debe cumplirse $Q \in [Q_{\min}, Q_{\max}]$ para algunos $0 < Q_{\min} < Q_{\max} < \infty$.

Acotamiento de R : Si $R \rightarrow \infty$, el término $h(R - \mu_\tau) \rightarrow \infty$, luego $G(Q, R) \rightarrow \infty$. Si $R \rightarrow -\infty$, como $X_\tau \geq 0$ se tiene $(X_\tau - R)^+ \geq -R$, por lo cual $n(R) \geq -R$ y entonces

$$G(Q, R) \geq \frac{\lambda K}{Q} + \frac{h}{2}Q + h(R - \mu_\tau) + \frac{p\lambda}{Q}(-R) = \frac{\lambda K}{Q} + \frac{h}{2}Q - h\mu_\tau + R\left(h - \frac{p\lambda}{Q}\right)$$

En cualquier región de nivel donde Q ya está acotado y lejos de 0, el término lineal en R impide que $R \rightarrow -\infty$ manteniendo $G(Q, R) \leq c$ (la intuición acá es que el costo de faltantes crece sin control cuando esto ocurre). En consecuencia, R también queda acotado en $\mathcal{L}_c$.

Concluimos que $\{(Q_i, R_i)\} \subset \mathcal{L}_c$ es acotada.

(3) Como $\{(Q_i, R_i)\}$ es acotada, puede haber una subsucesión convergente $(Q_{i_k}, R_{i_k}) \rightarrow (Q^*, R^*)$. Dado que cada paso del algoritmo resuelve exactamente el subproblema en el bloque correspondiente, y G es continua, el límite hereda optimalidad por coordenadas: Q^* minimiza $G(\cdot, R^*)$ y R^* minimiza $G(Q^*, \cdot)$. $\square$

Moraleja: Qué se garantiza y qué no.

Las Proposiciones A.6–A.7 garantizan que el método es “bien comportado”: el costo promedio no aumenta, converge en valor, y los puntos límite son óptimos por coordenadas (puntos estacionarios por bloques). Sin embargo, la biconvexidad no implica convexidad conjunta en (Q, R) , por lo cual en general no se puede garantizar que el punto límite sea el óptimo global.

A.2.1. Óptimos de modelo cuando no tenemos β

Despeje de Q (con R fijo). Si fijamos R , entonces $n(R)$ es constante. Los términos de $G(Q, R)$ que dependen de Q son

$$K \frac{\lambda}{Q} + \frac{h}{2}Q + p n(R) \frac{\lambda}{Q} = \frac{\lambda(K + p n(R))}{Q} + \frac{h}{2}Q.$$

Derivando respecto a Q e igualando a cero:

$$-\frac{\lambda(K + p n(R))}{Q^2} + \frac{h}{2} = 0 \implies Q^2 = \frac{2\lambda(K + p n(R))}{h}.$$

Por tanto,

$$Q^*(R) = \sqrt{\frac{2\lambda(K + p n(R))}{h}}$$

Despeje de R (con Q fijo). Si fijamos Q , los términos de $G(Q, R)$ que dependen de R son

$$hR + h n(R) + p \frac{\lambda}{Q} n(R),$$

por lo cual

$$G(R | Q) = hR + \left(h + p \frac{\lambda}{Q}\right) n(R) + \text{cte.}$$

Usando que

$$n'(R) = -(1 - F(R)),$$

se obtiene

$$\frac{d}{dR} G(R | Q) = h + \left(h + p \frac{\lambda}{Q}\right) n'(R) = h - \left(h + p \frac{\lambda}{Q}\right) (1 - F(R)).$$

Igualando a cero:

$$h = \left(h + p \frac{\lambda}{Q}\right) (1 - F(R)) \implies 1 - F(R) = \frac{h}{h + p \frac{\lambda}{Q}}.$$

Por tanto,

$$F(R^*(Q)) = 1 - \frac{h}{h + p \frac{\lambda}{Q}} = \frac{p \frac{\lambda}{Q}}{h + p \frac{\lambda}{Q}} = \frac{p\lambda}{hQ + p\lambda}$$

Equivalentemente, si F^{-1} existe,

$$R^*(Q) = F^{-1}\left(\frac{p\lambda}{hQ + p\lambda}\right)$$

Caso Normal (si aplica). Si $X_\tau \sim \mathcal{N}(\mu_\tau, \sigma_\tau^2)$, entonces

$$R^*(Q) = \mu_\tau + \sigma_\tau z, \quad z = \Phi^{-1}\left(\frac{p\lambda}{hQ + p\lambda}\right)$$

A.3. Modelo (Q, R) iterativo dado un valor de β bajo normalidad

Suponemos un sistema de revisión continua con política (Q, R) y backorders. La demanda acumulada durante el lead time τ se modela como

$$X_\tau \sim \mathcal{N}(\mu_\tau, \sigma_\tau^2), \quad \mu_\tau = \mu \tau, \quad \sigma_\tau = \sigma \sqrt{\tau}.$$

Denotamos por $\Phi(\cdot)$ y $\phi(\cdot)$ la CDF y PDF de la normal estándar. Introducimos la estandarización

$$z := \frac{R - \mu_\tau}{\sigma_\tau}, \quad \Longleftrightarrow \quad R = \mu_\tau + \sigma_\tau z. \quad (\text{A.2})$$

En particular,

$$F(R) = \mathbb{P}(X_\tau \leq R) = \Phi(z). \quad (\text{A.3})$$

Escasez esperada y función “loss”

Definimos la escasez esperada al arribo como

$$n(R) := \mathbb{E}[(X_\tau - R)^+]. \quad (\text{A.4})$$

Bajo normalidad, esta cantidad se expresa mediante la función *loss* normal

$$L(z) := \phi(z) - z(1 - \Phi(z)), \quad (\text{A.5})$$

y satisface

$$n(R) = \sigma_\tau L(z). \quad (\text{A.6})$$

Además, el exceso esperado condicionado a que ocurra escasez queda

$$m(R) := \frac{n(R)}{1 - F(R)} = \frac{\sigma_\tau L(z)}{1 - \Phi(z)}. \quad (\text{A.7})$$

Restricción de fill rate (nivel de servicio tipo II)

En esta variante se fija $\beta \in (0, 1)$, definido por

$$\beta = 1 - \frac{n(R)}{Q} \quad \Longleftrightarrow \quad n(R) = (1 - \beta) Q. \quad (\text{A.8})$$

Bajo normalidad, usando (A.6), la restricción equivale a

$$\sigma_\tau L(z) = (1 - \beta) Q. \quad (\text{A.9})$$

Costo relevante

El costo relevante promedio por unidad de tiempo (ignorando términos constantes independientes de Q y R) es

$$G(Q, R) = \frac{\lambda K}{Q} + h \left(\frac{Q}{2} + R - \mu_\tau \right), \quad Q > 0, R \in \mathbb{R}, \quad (\text{A.10})$$

sujeto a la restricción (A.8).

Actualizaciones iterativas (despejes)

A partir de las condiciones de optimalidad del problema restringido, se obtiene la siguiente actualización cerrada para Q en función de z :

$$Q_i = m(z_{i-1}) + \sqrt{\frac{2K\lambda}{h} + m(z_{i-1})^2}, \quad m(z) := \frac{\sigma_\tau L(z)}{1 - \Phi(z)}. \quad (\text{A.11})$$

Luego, dada la actualización Q_i , el parámetro z_i se obtiene de la restricción que el beta sea igual al dado:

$$\sigma_\tau L(z_i) = (1 - \beta) Q_i. \quad (\text{A.12})$$

Finalmente, el punto de reorden se recupera mediante

$$R_i = \mu_\tau + \sigma_\tau z_i. \quad (\text{A.13})$$

Por construcción, el valor correspondiente de la CDF es

$$F(R_i) = \Phi(z_i). \quad (\text{A.14})$$