

Modelos Probabilísticos

Notas de Clase Primer Corte

Juan Esteban Salamanca

Última modificación: 19 de enero de 2025

Este es un trabajo en proceso. Puede tener errores.

Hecho por un estudiante de pregrado. Use esta información bajo su propia responsabilidad.

Índice general

1. Repaso e introducción	5
1.1. Repaso de Probabilidad	5
1.1.1. Variable aleatoria exponencial	7
1.1.2. Proceso de Poisson	9
1.2. Distribuciones de Probabilidad	11
1.2.1. Distribuciones de variables continuas	12
1.2.2. Distribuciones de variables discretas	13
1.3. Introducción a Procesos Estocásticos	15
1.3.1. Definiciones fundamentales Procesos Estocásticos	15
2. Cadenas de Markov	17
2.1. Fundamentos Cadenas de Markov (CM)	17
2.2. Cadenas de Markov en Tiempo Discreto	18
2.2.1. Fundamentos CMTD	18
2.2.2. Ejemplos modelación CMTD	19
2.3. Cadenas de Markov en Tiempo Continuo	29
2.3.1. Fundamentos CMTC	29
2.3.2. Ejemplos CMTC	30
A. Formulaciones Matemáticas	35
A.1. Grafos	35
A.2. Matrices	37
A.3. Formulaciones generales:	37
B. CMTC y CMTD desde la cardinalidad	39
B.1. Introducción a la cardinalidad de conjuntos	39
B.2. Relación con las Cadenas de Markov	41

Capítulo 1

Repaso e introducción

En este capítulo abordaremos los conceptos principales ya aprendidos en Proba I que serán usados a lo largo de este curso añadiendo ciertos resultados nuevos que se derivan directamente de estos conceptos. Luego, procederemos a introducir conceptos básicos de procesos estocásticos para entrar al siguiente capítulo ya entendidos.

1.1. Repaso de Probabilidad

Usaremos la P cursiva ($\mathcal{P}$) para denotar la probabilidad de que ocurra un evento específico a lo largo de estas notas.

Definición 1.1 (Experimento aleatorio). Un experimento aleatorio es un proceso o procedimiento que, bajo condiciones bien definidas, produce un resultado que no puede predecirse con certeza antes de realizarse. Sin embargo, el conjunto de resultados posibles del experimento está claramente definido.

Propiedades:

1. **Resultados bien definidos:** Cada ejecución del experimento tiene un resultado único que pertenece a un conjunto claramente definido, llamado el *espacio muestral* Ω .
2. **Incertidumbre:** Antes de realizar el experimento, no se puede predecir con certeza cuál será el resultado específico.
3. **Repetibilidad:** El experimento puede repetirse bajo las mismas condiciones, produciendo resultados potencialmente diferentes pero consistentes con las probabilidades asociadas.

Definición 1.2 (Espacio Muestral). Definimos un espacio muestral Ω como el conjunto de todos los resultados posibles de un experimento aleatorio.

Propiedades:

- $\mathcal{P}(A) \geq 0$ para cualquier evento A .

- $\mathcal{P}(\Omega) = 1$.
- Si $A_1, A_2, \dots$ son eventos disjuntos, entonces $\mathcal{P}(\bigcup_i A_i) = \sum_i \mathcal{P}(A_i)$.

Ejemplo 1.1 (Lanzamiento de un dado). Supongamos que lanzamos un dado estándar de seis caras. El espacio muestral asociado a este experimento es:

$$\Omega = \{1, 2, 3, 4, 5, 6\}.$$

Cada número representa el resultado que puede observarse en el lanzamiento.

Ejemplo 1.2 (Lanzamiento de dos dados). Supongamos que lanzamos dos dados de seis caras. El espacio muestral asociado a este experimento dejaría de estar compuesto por números enteros y pasaría a ser un conjunto de tuplas:

$$\Omega = \{(i, j) : i, j \in \{1, 2, 3, 4, 5, 6\}\}.$$

Notemos que en este segundo ejemplo el resultado de nuestro experimento depende de dos elementos cuyo comportamiento no conocemos a ciencia cierta. Más adelante, conoceremos estos elementos como *Variable de estado*. La correcta identificación de estos elementos será determinante en el capítulo 2. Por ahora, no nos adelantemos y sigamos con este repaso de Proba I.

Definición 1.3 (Variable aleatoria). Denominamos una variable aleatoria (V.A) a una función que asigna un valor numérico a cada resultado posible de un experimento aleatorio. Formalmente, es una función $f : \Omega \rightarrow \mathbb{R}$.

Existen dos tipos principales de variables aleatorias:

- **Variable aleatoria discreta:** Es aquella que toma un conjunto finito o numerable de valores. Por ejemplo, el número de caras al lanzar dos monedas es una variable discreta que puede tomar los valores $\{0, 1, 2\}$.
- **Variable aleatoria continua:** Es aquella que puede tomar cualquier valor en un intervalo de números reales. Por ejemplo, la temperatura en una ciudad a lo largo del día es una variable continua que puede tomar valores en un rango como $[-10, 40]$.

Definición 1.4 (Función de densidad [masa] de probabilidad). Definimos la función de densidad [masa] de probabilidad (FDP [FMP]) como una función que describe la distribución de probabilidad de una variable aleatoria continua [discreta].

Formalmente, es una función:

$$f : \mathbb{R} \rightarrow \mathbb{R}_+ \quad [\mathcal{P} : \mathbb{R} \rightarrow [0, 1]]$$

que tiene las siguientes propiedades:

Ya con estas bases de probabilidad, nos enfocaremos en dos variables que serán vitales a lo largo del curso.

Propiedad	Continua	[Discreta]
1. No negatividad	$f(x) \geq 0$	$\mathcal{P}(x) \geq 0$
2. Normalización	$\int_{-\infty}^{\infty} f(x) dx = 1$	$\sum_{x \in S} \mathcal{P}(x) = 1$, S es el conjunto de valores posibles
3. Probabilidad exacta	$\mathcal{P}(X = x) = 0$	$\mathcal{P}(X = x) = \mathcal{P}(x)$
4. Probabilidad en intervalo	$\mathcal{P}(a \leq X \leq b) = \int_a^b f(x) dx$	$\mathcal{P}(X \in A) = \sum_{x \in A} \mathcal{P}(x)$, A es un subconjunto discreto de S

Cuadro 1.1: Propiedades de las funciones de densidad y masa de probabilidad

1.1.1. Variable aleatoria exponencial

Definición 1.5 (Variable aleatoria exponencial). Tomemos una variable aleatoria continua no negativa X con un parámetro λ , $\lambda > 0$. Diremos que esta es una V.A exponencial si su FDP está dada por

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{si } x \geq 0, \\ 0, & \text{si } x < 0. \end{cases}$$

Y si consecuentemente su función de probabilidad acumulada está dada por

$$F_X(x) = \mathcal{P}(X \leq x) = \begin{cases} 1 - e^{-\lambda x}, & \text{si } x \geq 0, \\ 0, & \text{si } x < 0. \end{cases}$$

Recordemos que el valor esperado y la varianza de esta V.A serán

$$\mathbb{E}[X] = 1/\lambda$$

$$\text{Var}[X] = 1/\lambda^2$$


Repasemos algunas propiedades de esta variable:

1. **No memoria:** Formalmente, se expresa como

$$\mathcal{P}(X > s + t \mid X > t) = \mathcal{P}(X > s) \quad \forall s, t \geq 0$$

Si no se entendió por medio de la definición, ahondemos en su significado por medio de un ejemplo.


Ejemplo 1.3. Supongamos que tenemos un bien cuya vida útil está dada por una variable aleatoria exponencial X . La probabilidad de que este bien sobreviva un



La probabilidad de que el bien sobreviva este intervalo de tiempo

Figura 1.1: Representación del intervalo de tiempo entre t y $t + s$.

tiempo s , dado que ya sobrevivió un tiempo t hasta este momento es la misma que la probabilidad de que el bien sobreviva un tiempo s dado que nos encontramos al inicio de la vida útil. Veamos el siguiente diagrama



Es la misma de que el bien sobreviva este intervalo de tiempo

Figura 1.2: Representación del intervalo de tiempo entre 0 y s .

2.

Teorema 1.1 (Suma de exponenciales). Supongamos que tenemos n variables exponenciales aleatorias e idénticamente distribuidas (iid)

$$X_i \quad (i = 1, 2, \dots, n)$$

Con el mismo parámetro λ . Establezcamos la nueva variable

$$Z_n = X_1 + X_2 + \dots + X_n$$

entonces $Z_n \sim \text{Erl}(n, \lambda)$

3.

Teorema 1.2 (Mínimo de exponenciales). Sean $X_i \quad (i = 1, 2, \dots, n)$ V.A.s exponenciales iid. Si definimos una nueva V.A.

$$X = \min\{X_1, X_2, \dots, X_n\}$$

esta tendrá por parámetro $\lambda = \sum_{i=1}^n \lambda_i$, donde cada λ_i es el parámetro de su respectiva variable X_i . Por ende:

$$X \sim \text{Exp}(\lambda) \implies X \sim \text{Exp}\left(\sum_{i=1}^n \lambda_i\right)$$

Este último teorema será muy útil cuando estemos modelando eventos en competencia.

4.

Teorema 1.3 (Primera ocurrencia entre exponenciales). Sean X_i ($i = 1, 2, \dots, n$) variables aleatorias exponenciales independientes e idénticamente distribuidas. Si definimos una nueva variable aleatoria

$$X = \min\{X_1, X_2, \dots, X_n\},$$

entonces la probabilidad de que el evento i ocurra primero estará dado por:

$$\mathcal{P}(i) = \frac{\lambda_i}{\sum_{j=1}^n \lambda_j},$$

donde λ_i es el parámetro de cada variable aleatoria X_i .

Corolario: Sean X_1, X_2 variables aleatorias exponenciales iid con parámetros λ_1, λ_2 . Entonces, la probabilidad de que X_1 sea menor que X_2 está dada por:

$$\mathcal{P}(X_1 < X_2) = \frac{\lambda_1}{\lambda_1 + \lambda_2}.$$

Definición 1.6 (Proceso de conteo). Un proceso $\{N(t), t \geq 0\}$ es de conteo si $N(t)$ representa el número de posibles eventos que pueden ocurrir hasta el t -ésimo instante. Un proceso $N(t)$ debe satisfacer:

- * $N(t) \geq 0$,
- * $N(t) \in \mathbb{Z}$,
- * Si $s \leq t$, entonces $N(s) \leq N(t)$,
- * Si $s \leq t$, entonces $N(t) - N(s)$ representa el número de eventos que ocurren en el intervalo $(s, t]$.

1.1.2. Proceso de Poisson

Definición 1.7 (Proceso de Poisson). Un proceso de conteo $\{N(t), t \geq 0\}$ es de Poisson con una tasa $\lambda, \lambda > 0$, si:

- * $N(0) = 0$,
- * **Propiedad:** Tiene incrementos independientes: Los eventos que ocurren en intervalos disjuntos de tiempo son independientes,
- * **Propiedad:** Tiene incrementos estacionarios: El número de eventos que ocurren en un intervalo de tiempo depende únicamente de la longitud del intervalo, no de la posición en el tiempo.
- * El número de eventos en un intervalo de tiempo de longitud t sigue una distribución Poisson con media λt , donde λ es la tasa de eventos por unidad de tiempo.

Definición 1.8 (Distribución de Poisson). Una variable aleatoria X con parámetro λ sigue una distribución de Poisson si tiene una FMP

$$\mathcal{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k = 0, 1, 2, \dots$$

Notemos que dada la variable anteriormente definida:

$$\mathbb{E}[X] = \lambda$$

$$\text{Var}[X] = \lambda$$

Distinción: Notemos que la distribución de Poisson da la probabilidad de que ocurra un evento una cierta cantidad de veces en un intervalo fijo dado por el parámetro λ , mientras que un proceso de Poisson describe cómo se comporta el sistema en un intervalo de tiempo dado por t . En este caso, se seguirá teniendo una distribución de Poisson; no obstante, se tendrá un nuevo parámetro $\lambda_{\text{efectivo}} = \lambda t$.

Teorema 1.4 (Suma de variables Poisson). Sean $X_i \sim \text{Poisson}(\lambda_i)$, $i = 1, \dots, n$, variables aleatorias iid. Entonces, si definimos

$$Z = \sum_{i=1}^n X_i \quad \Rightarrow \quad Z \sim \text{Poisson}\left(\sum_{i=1}^n \lambda_i\right).$$

Ejemplo 1.4. En una sala de maternidad hay 7 mujeres embarazadas: 3 de ellas esperan niños, y las restantes 4 esperan niñas. Se sabe que el tiempo de parto para los niños es en promedio de 6 horas, mientras que para las niñas es de 5 horas. Asumiendo que estos tiempos son independientes y exponencialmente distribuidos, ¿cuál es la probabilidad de que el primer bebé sea niño, y que este nazca dentro de la siguiente hora?

Solución: Partamos el problema en dos, teniendo en cuenta la independencia de los eventos.

Primera probabilidad: Que el primer bebé sea niño.

Definimos la variable X : *Nacimiento de un niño de primeras*.

Como se nos pide algo relacionado con eventos discretos y no con el tiempo, notamos que:

$$X \sim \text{Poisson}(\lambda_{xy}),$$

donde la tasa final se verá afectada por la cantidad de mujeres embarazadas.

$$\lambda_{xx} = \frac{4}{5}, \quad \lambda_{xy} = \frac{3}{6} = \frac{1}{2}.$$

Por lo tanto, la probabilidad de que esto ocurra, usando un teorema conocido, es:

$$P(X = xy) = \frac{\lambda_{xy}}{\lambda_{xx} + \lambda_{xy}} = \frac{\frac{1}{2}}{\frac{1}{2} + \frac{4}{5}} = \frac{15}{39} \approx 0,38.$$

2. Segunda probabilidad: Que nazca dentro de la siguiente hora.

Definimos T : *Tiempo hasta que nazca el siguiente bebé*, donde:

$$T \sim \text{Exp}\left(\frac{3}{6} + \frac{4}{5}\right).$$

Calculamos:

$$P(T \leq 1) = 1 - e^{-(\frac{1}{2} + \frac{4}{5}) \cdot 1} = 0,72.$$

3. Multiplicamos ambas probabilidades.

Finalmente, la probabilidad que nos piden es:

$$P = 0,72 \cdot 0,38 = 0,27.$$

Recapitulemos lo aprendido hasta el momento

Variable	Poisson	Exponencial
Naturaleza del dominio	Discreto	Continuo
Probabilidad de un valor	$\mathcal{P}(X = n) = e^{-\lambda} \frac{\lambda^n}{n!}$	$\mathcal{P}(X = t) = 0$
Probabilidad acumulada	$\mathcal{P}(X \leq n) = \sum_{n=0}^k e^{-\lambda} \frac{\lambda^n}{n!}$	$\mathcal{P}(X \leq t) = 1 - e^{-\lambda t}$
Suma	$Z = \sum_i X_i$ $\Rightarrow Z \sim \text{Poisson} \left(\sum_i \lambda_i \right)$	$T = \sum_{i=1}^n X_i$ $\Rightarrow T \sim \text{Erl}(n, \lambda)$
Mínimo	No aplica	$M = \min\{X_1, \dots, X_n\}$ $\Rightarrow M \sim \text{Exp} \left(\sum_i \lambda_i \right)$
Valor esperado	$\mathbb{E}[X] = \lambda$	$\mathbb{E}[X] = \frac{1}{\lambda}$
Varianza	$\text{Var}[X] = \lambda$	$\text{Var}[X] = \frac{1}{\lambda^2}$

Cuadro 1.2: Resumen de las propiedades de las distribuciones de Poisson y exponencial.

En general, el curso tomará el parámetro λ como el $\lambda_{\text{efectivo}} = \lambda t$, dependiendo del intervalo que se esté trabajando.

Tip útil: Las unidades de la tasa (λ) deben tener el tiempo en el denominador sin importar si estamos hablando de un proceso de Poisson o de una variable Exponencial. Por ejemplo, si nos dicen que los buses en una estación pasan cada μ minutos, la tasa es de μ^{-1} . Esta es la tasa que debe aparecer en las formulaciones que hagamos más adelante. No se debe caer en el error común de creer que solo porque ya nos dan la letra griega, ya sea λ, μ, σ , etc. esa es la tasa que debemos poner en la formulación. Siempre debemos fijarnos en las unidades de la misma.

1.2. Distribuciones de Probabilidad

Esta sección se destina a exponer todas las distribuciones de probabilidad que pueden salir a lo largo del curso. A diferencia de la Exponencial y la Poisson que acaban de ser explicadas a cabalidad, estas no son tan determinantes. Así pues, solamente se describirán por encima. Personalmente, recomendaría tener total claridad de la Binomial y saber de

qué se trata la Bernoulli y la uniforme. Estas han sido las únicas que he visto en los ejercicios que vemos a lo largo del curso.

1.2.1. Distribuciones de variables continuas

Definición 1.9 (Distribución Uniforme Continua). Una variable aleatoria X sigue una distribución uniforme continua en el intervalo $[a, b]$, denotada como $X \sim U(a, b)$, si su función de densidad de probabilidad está dada por:

$$f_X(x) = \begin{cases} \frac{1}{b-a}, & \text{si } a \leq x \leq b, \\ 0, & \text{en otro caso.} \end{cases}$$

Propiedades:

- Valor esperado: $\mathbb{E}[X] = \frac{a+b}{2}$.
- Varianza: $\text{Var}[X] = \frac{(b-a)^2}{12}$.
- Función de distribución acumulada (FDA):

$$F_X(x) = \begin{cases} 0, & \text{si } x < a, \\ \frac{x-a}{b-a}, & \text{si } a \leq x \leq b, \\ 1, & \text{si } x > b. \end{cases}$$

Definición 1.10 (Distribución Lognormal). Una variable aleatoria X sigue una distribución lognormal con parámetros μ y σ^2 , denotada como $X \sim \text{Lognormal}(\mu, \sigma^2)$, si su logaritmo natural $\ln(X)$ sigue una distribución normal $\mathcal{N}(\mu, \sigma^2)$.

Propiedades:

- Función de densidad de probabilidad:

$$f_X(x) = \frac{1}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln(x) - \mu)^2}{2\sigma^2}\right), \quad x > 0.$$

- Valor esperado: $\mathbb{E}[X] = e^{\mu + \frac{\sigma^2}{2}}$.
- Varianza: $\text{Var}[X] = (e^{\sigma^2} - 1) e^{2\mu + \sigma^2}$.

Definición 1.11 (Distribución Triangular). Una variable aleatoria X sigue una distribución triangular en el intervalo $[a, b]$ con moda c , denotada como $X \sim \text{Triangular}(a, b, c)$, si su función de densidad de probabilidad está dada por:

$$f_X(x) = \begin{cases} \frac{2(x-a)}{(b-a)(c-a)}, & \text{si } a \leq x \leq c, \\ \frac{2(b-x)}{(b-a)(b-c)}, & \text{si } c < x \leq b, \\ 0, & \text{en otro caso.} \end{cases}$$

Propiedades:

- Valor esperado: $\mathbb{E}[X] = \frac{a+b+c}{3}$.
- Varianza: $\text{Var}[X] = \frac{a^2+b^2+c^2-ab-ac-bc}{18}$.

Definición 1.12 (Distribución Erlang). Una variable aleatoria T sigue una distribución Erlang con parámetros n y λ , denotada como $T \sim \text{Erl}(n, \lambda)$, si es la suma de n variables aleatorias exponenciales independientes con parámetro λ .

Propiedades:

- Función de densidad de probabilidad:

$$f_T(t) = \frac{\lambda^n t^{n-1} e^{-\lambda t}}{(n-1)!}, \quad t \geq 0.$$

- Valor esperado: $\mathbb{E}[T] = \frac{n}{\lambda}$.
- Varianza: $\text{Var}[T] = \frac{n}{\lambda^2}$.

1.2.2. Distribuciones de variables discretas

Definición 1.13 (Distribución Bernoulli). Una variable aleatoria X sigue una distribución Bernoulli con parámetro p , denotada como $X \sim \text{Bernoulli}(p)$, si toma el valor 1 con probabilidad p y el valor 0 con probabilidad $1 - p$.

Propiedades:

- Función de probabilidad de masa (FPM):

$$\mathcal{P}(X = x) = \begin{cases} p, & \text{si } x = 1, \\ 1 - p, & \text{si } x = 0. \end{cases}$$

- Valor esperado: $\mathbb{E}[X] = p$.
- Varianza: $\text{Var}[X] = p(1 - p)$.

Nota: Esta distribución no es tan importante en el curso, no obstante al ser la base de otras que si lo serán es bueno tenerla en cuenta.

Definición 1.14 (Distribución Geométrica). Una variable aleatoria X sigue una distribución geométrica con parámetro p , denotada como $X \sim \text{Geom}(p)$, si representa el número de ensayos hasta el primer éxito en una secuencia de ensayos de Bernoulli independientes.

Propiedades:

- FPM:

$$\mathcal{P}(X = k) = (1 - p)^{k-1} p, \quad k = 1, 2, 3, \dots$$

- Valor esperado: $\mathbb{E}[X] = \frac{1}{p}$.

- Varianza: $\text{Var}[X] = \frac{1-p}{p^2}$.

Definición 1.15 (Distribución Binomial). Una variable aleatoria X sigue una distribución binomial con parámetros n y p , denotada como $X \sim \text{Binomial}(n, p)$, si representa el número de éxitos en n ensayos de Bernoulli independientes con probabilidad de éxito p .

Propiedades:

- FPM:

$$\mathcal{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n.$$

- Valor esperado: $\mathbb{E}[X] = np$.
- Varianza: $\text{Var}[X] = np(1-p)$.

Nota importante: Esta distribución es de las más importantes que se verán a lo largo del curso. Es muy recomendable aprenderse de memoria la forma en la que esta funciona o tenerla a la mano.

Definición 1.16 (Distribución Binomial Negativa). Una variable aleatoria X sigue una distribución binomial negativa con parámetros r y p , denotada como $X \sim \text{BinomialNeg}(r, p)$, si representa el número de ensayos necesarios para observar r éxitos en una secuencia de ensayos de Bernoulli independientes con probabilidad de éxito p .

Propiedades:

- FPM:

$$\mathcal{P}(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, \dots$$

- Valor esperado: $\mathbb{E}[X] = \frac{r}{p}$.
- Varianza: $\text{Var}[X] = \frac{r(1-p)}{p^2}$.

Definición 1.17 (Distribución Uniforme Discreta). Una variable aleatoria X sigue una distribución uniforme discreta en los valores $\{1, 2, \dots, n\}$, denotada como $X \sim \text{U}\{1, \dots, n\}$, si todos los valores posibles tienen la misma probabilidad.

Propiedades:

- FPM:

$$\mathcal{P}(X = k) = \frac{1}{n}, \quad k = 1, 2, \dots, n.$$

- Valor esperado: $\mathbb{E}[X] = \frac{n+1}{2}$.
- Varianza: $\text{Var}[X] = \frac{n^2-1}{12}$.

1.3. Introducción a Procesos Estocásticos

En esta sección trabajaremos las principales definiciones que serán usadas a lo largo del curso. Podrá parecer mucho que entender o memorizar, pero considerando que son las bases para todos los temas que se vienen, se recomienda tener total claridad en los siguientes conceptos.

1.3.1. Definiciones fundamentales Procesos Estocásticos

Definición 1.18 (Proceso estocástico). Definimos un proceso estocástico como un modelo probabilístico que describe el comportamiento de un sistema que evoluciona a lo largo del tiempo con cierto grado de incertidumbre.

Notemos que dada esta definición, solo conoceremos a ciencia cierta el estado actual del sistema que estemos observando y solo podremos especular del resto de manera probabilística. Modelar estos problemas nos será de especial interés.

A lo largo del curso estaremos trabajando con dos tipos de procesos estocásticos: discretos y continuos. La correcta identificación del tipo de proceso estocástico será vital en las actividades del curso. Pero antes de ahondar en este tema, cabe hacerse la pregunta: ¿Cómo expresamos que el sistema está evolucionando?

Definición 1.19 (Variable de estado). Denotamos por $X(t)$ [X_n] a una variable aleatoria referente al estado del sistema en el t -ésimo instante [n -ésimo momento] representado por un proceso estocástico continuo [discreto].

Definición 1.20 (Proceso estocástico discreto). Denotamos por $\{X_n, n \geq 0\}$ al proceso estocástico asociado a un sistema que es observado en n momentos.

Definición 1.21 (Proceso estocástico continuo). Denotamos por $\{X(t), t \geq 0\}$ al proceso estocástico asociado a un sistema que es observado en t instantes.

Definición 1.22 (Espacio de estado). Similar al espacio muestral de un experimento aleatorio, denotamos por S_X al conjunto de posibles valores que puede tomar nuestra variable de estado $X(t)$ [o X_n en el caso discreto].

Ejemplo 1.5. Supongamos que estudiamos el número de personas en una fila de un banco a lo largo de las horas operacionales del banco.

- **Variable de estado:**

X_n el número de personas en la fila en la n -ésima hora.

- **Espacio de estado:** Ya que el número de personas en la fila debe ser un número natural, definimos

$$S_X = \{0, 1, 2, \dots, \infty\}$$

Notemos cómo a pesar de que se nos pide trabajar en temas de tiempo, la variable de estado es discreta pues el número de horas es contable.

Ejemplo 1.6. Supongamos que estudiamos el nivel de agua en un río a lo largo del tiempo.

■ **Variable de estado:**

$X(t)$: la altura del agua en el río en metros en el t -ésimo instante.

- **Espacio de estado:** Ya que la altura del agua es una cantidad no negativa y puede tomar cualquier valor en el continuo.

$$S_X = [0, \infty)$$

Ejemplo 1.7. Supongamos que estudiamos el número de automóviles y motocicletas que llegan a una intersección en contables franjas horarias.

■ **Variables de estado:**

- X_n : el número de automóviles que han llegado a la intersección en la n -ésima franja horaria.
- Y_n : el número de motocicletas que han llegado a la intersección en la n -ésima franja horaria.

- **Espacio de estado:** Ya que tanto el número de automóviles como el de motocicletas deben ser números naturales, definimos

$$S_X = S_Y = \{0, 1, 2, \dots, \infty\}.$$

Notemos que no necesariamente tendremos una única variable de estado en nuestros problemas.

Nota: El hecho que un sistema tenga una(s) variable(s) de estado discreta(s) no implica que su espacio de estados sea discreto también. Por ejemplo, si en este sistema no quisiéramos evaluar el número de vehículos sino la edad del conductor del próximo vehículo que llegue a la intersección suponiendo que esta se distribuye normal con media μ_1, μ_2 y desviación estándar σ_1, σ_2 para los conductores de automóviles y motocicletas respectivamente.

Ejemplo 1.8. Supongamos que estudiamos la temperatura y la humedad en una región a lo largo del tiempo.

■ **Variables de estado:**

- $X(t)$: la temperatura en grados Celsius en el t -ésimo instante.
- $Y(t)$: la humedad relativa en porcentaje en el t -ésimo instante.

■ **Espacio de estado:**

- Ya que la temperatura puede tomar cualquier valor en el continuo.

$$S_X = (-\infty, \infty)$$

- Ya que la humedad relativa se mide en porcentaje y está restringida a un rango.

$$S_Y = [0, 100]$$

Capítulo 2

Cadenas de Markov

Ya teniendo bases de procesos estocásticos, procederemos a introducir un tipo que serán motivo de estudio y de evaluación en el primer parcial.

2.1. Fundamentos Cadenas de Markov (CM)

Definición 2.1 (Proceso de Markov). Definimos un proceso de Markov como un proceso estocástico con la propiedad de que el futuro del sistema es solamente condicionado por su estado actual. Esta propiedad es usualmente denominada Propiedad de Markov o Propiedad de No Memoria.

Definición 2.2 (Cadena de Markov). Nos referiremos a una Cadena de Markov cuando un Proceso de Markov representa un sistema que tiene una cantidad finita o contable de estados.

Definición 2.3 (Matriz Estocástica). Decimos que una matriz M es estocástica si cada una de sus filas es una distribución de probabilidad. O sea si

1. Todos los elementos de la matriz cumplen $p_{ij} \geq 0$.
2. La suma de las probabilidades de cada fila es 1, es decir:

$$\sum_{j=1}^m p_{ij} = 1, \quad \text{para todo } i = 1, \dots, m.$$

A pesar de que la primera parte de la definición pueda sonar un poco oscura al principio, esta resulta bastante intuitiva al notar que se pueden asociar dibujitos o diagramas a los sistemas que describen las Cadenas de Markov. Ahondaremos en esto más adelante en los ejemplos que demos.

2.2. Cadenas de Markov en Tiempo Discreto

2.2.1. Fundamentos CMTD

Definición 2.4 (Cadena de Markov en tiempo Discreto (CMTD)). Decimos que una CMTD es una CM definida sobre un sistema observado durante finitos o contables momentos a lo largo del tiempo, que cumple con la propiedad de no memoria. Es decir que se tiene

$$\mathcal{P}(X_{n+1} = j \mid X_n = i, X_{n-1} = i_1, X_{n-2} = i_2, \dots, X_0 = i_0) = \mathcal{P}(X_{n+1} = j \mid X_n = i)$$

Definición 2.5 (Probabilidad de transición CMTD). Sea $\{X_n, n \geq 0\}$ una CMTD, la probabilidad de transición es la probabilidad de que el sistema pase del estado i al estado j en un único paso, y se denota como:

$$p_{ij} = \mathcal{P}(X_{n+1} = j \mid X_n = i).$$

Definición 2.6 (CMTD homogénea). Decimos que una CMTD es homogénea si la probabilidad de transición entre un estado i y un estado j es la misma sin importar en qué momento en el tiempo se encuentre el sistema.

Formalmente, sea $\{X_n, n \geq 0\}$ una CMTD, esta se denomina homogénea si

$$\mathcal{P}(X_{n+1} = j \mid X_n = i) = \mathcal{P}(X_0 = j \mid X_1 = i)$$

Definición 2.7 (Matriz de transición). La matriz de transición de una CMTD contiene las probabilidades de transición de todos los estados i a todos los estados j , y se denota por $\mathbb{P}_{i \rightarrow j}$, donde:

$$\mathbb{P}_{i \rightarrow j} = \begin{pmatrix} p_{11} & p_{12} & \dots & p_{1m} \\ p_{21} & p_{22} & \dots & p_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ p_{m1} & p_{m2} & \dots & p_{mm} \end{pmatrix}.$$

Propiedad: Las matrices de transición en las CMTD son estocásticas y cuadradas.

Supuestos CMTD

Al modelar CMTD SIEMPRE se debe incluir el supuesto de no memoria y el de homogeneidad. En caso de que se tenga una distribución, se debe incluir que cierta parte del problema se modela con respecto a esta en los supuestos. En los siguientes ejemplos no se incluye la enunciación explícita de supuestos para enfocar más la respuesta a la forma de atacar el problema, pero en el parcial es probable que los pidan.

Hasta este punto, el concepto se ha tornado bastante abstracto teniendo solamente definiciones y propiedades. Cimentemos un poco lo aprendido en lo que llevamos de las notas con varios ejemplos. Estos serán trabajados con descripciones extensas para intentar lograr el mejor entendimiento posible en conceptos que se ven en clase y que no se recuerdan en las soluciones de las bases de problemas.

2.2.2. Ejemplos modelación CMTD

Ejemplo 2.1 (Introductorio). Un canal de reportaje da un pronóstico del tiempo de los próximos días. Este expresa que si se tiene un día soleado, al día siguiente se tendrá un día lluvioso con probabilidad de 0,4 y un día nublado con probabilidad de 0,1. Si se tiene un día lluvioso, al siguiente día se tendrá un día soleado con probabilidad de 0,2 y un día lluvioso con probabilidad 0,1. Si se tiene un día nublado, al siguiente día se tendrá un día nublado con probabilidad de 0,9 y un día soleado con probabilidad de 0,1. Modele este sistema como una CMTD estableciendo claramente todos sus supuestos y componentes.

Solución: Notemos que esta situación es fácilmente representada por medio de un dibujo, la definición de una matriz de transición o inclusive una formulación general. Empezaremos con los primeros dos métodos dado que son los que primero se ven en clase.

1. **Temporalidad:** Notemos que este problema da bastante explícita la temporalidad, pues explica que el sistema cambia cada día. Como el conjunto de días es contable, esta Cadena de Markov será de tiempo discreto.
2. **Variable de estado:** Identificamos la variable de estado como eso que el sistema está intentando describir a lo largo del tiempo. Como hablamos del cambio del clima diariamente, definimos

X_n : Estado del clima en el n -ésimo día.

3. **Espacio de Estado:** Ya habiendo definido la variable de estado, es mucho más fácil definir su espacio de estado pues solamente pensamos en los posibles valores que esta puede tomar. Así pues, definimos

$$S_X = \{\text{Soleado, Nublado, Lluvioso}\}$$

Notemos que a definimos el conjunto con palabras, pero podríamos definirlo también como


$$S_X = \{1, 2, 3\}$$

donde 1 hace referencia al estado “Soleado”, 2 hace referencia a “Nublado” y 3 hace referencia a “Lluvioso”.

Por simplicidad usaremos la primera definición.

4. **Probabilidades de transición:** Podemos hacer un grafo para explicar este sistema en donde los nodos serán los estados que acabamos de definir y las aristas explicarán las relaciones entre estados. Arriba de estas, se pondrán las probabilidades de transición de un estado $i \in S_X$ a un estado $j \in S_X$:

Figura 2.1: Grafo Clima



Notemos que todas las aristas (flechas) que salen de cada nodo (cajita) tienen asociados pesos (probabilidades) que suman 1 a pesar de que en el enunciado no nos dan explícitamente todas las probabilidades de transición. Esta propiedad se debe mantener en TODOS los problemas que veamos con CMTD. Normalmente esta forma de expresar las probabilidades de transición es buena al principio para entender la forma de modelar. Pero en parciales se piden matrices o formulaciones generales.

Veremos la forma matricial de las probabilidades de transición de este problema a continuación:

$$\mathbb{P}_{i \rightarrow j} = \begin{array}{c|ccc} & S & L & N \\ \hline S & 0,5 & 0,4 & 0,1 \\ L & 0,2 & 0,7 & 0,1 \\ N & 0,1 & 0,0 & 0,9 \end{array}$$

Cada entrada p_{ij} de esta matriz debe interpretarse como la probabilidad de transición del estado $i \in S_X$ a un estado $j \in S_X$. Por ejemplo, la probabilidad de que mañana sea un día nublado ($N \in S_X$) dado que hoy fue un día lluvioso ($L \in S_X$) estará dado por $p_{LN} = 0,1$.

Nota importante: Notemos del anterior ejemplo que la probabilidad de ir a un estado j dado que el sistema se encuentra en un estado i NO NECESARIAMENTE es la misma de ir al estado i dado que el sistema se encuentra en un estado j . Esto quiere decir que generalmente

$$p_{ij} \neq p_{ji}, \quad i, j \in S_X$$

Ejemplo 2.2 (Varias variables de estado). Considere una pila de libros sobre un escritorio; en particular se tienen 3 libros diferentes, la Ilíada, la Odisea y la Eneida. Suponga que el dueño de los libros escoge un libro cada noche para leer de forma aleatoria, siguiendo una distribución de probabilidad. Al día siguiente, por la mañana, el dueño deja el

libro que tomó durante la noche en la parte superior de la pila de libros. Para representar la posición del libro en la pila usted ha decidido que la posición superior de la pila es la 0, la posición intermedia es la 1, y la posición inferior es la 2. Con estas posiciones, usted ha descubierto que el libro seleccionado cada noche se escoge de forma aleatoria así: con probabilidad de 0.49 se elige el libro de la parte superior ($\mathcal{P}(X = 0) = 0,49$) y el libro del medio con probabilidad de 0.42 ($\mathcal{P}(X = 1) = 0,42$).

Modele el comportamiento de la pila de libros como una cadena de Markov. Incluya claramente la temporalidad, la definición de todas las variables, espacios de estados y la matriz de transición.

Solución:

1. **Identificación del contexto (Opcional):** Notemos que en este ejemplo nos dan las probabilidades de transición de forma explícita. Por ende, no necesitaremos hacer uso de variables auxiliares.
2. **Temporalidad:** Para este ejercicio nos es de interés evaluar la evolución de las posiciones de los libros. Observemos que estas son solo tres, por ende son contables y sugieren el moldeamiento del sistema por medio de una CMTD.
3. **Variable de Estado:** A diferencia del anterior ejemplo, acá es necesario tener más de una variable para modelar el sistema

X_n : Posición de La Iliada en el n -ésimo día.

Y_n : Posición de La Odisea en el n -ésimo día.

Z_n : Posición de La Eneada en el n -ésimo día.

Recordemos que estas variables deben dictar el comportamiento del sistema que será registrado dentro de una matriz. Es por esto que los rótulos deberán considerar los valores que las variables tomen en todo momento. Así pues, usaremos la operación matemática del producto cartesiano para convertir las variables “sueltas” en tuplas tal que

$$W_n = X_n \times Y_n \times Z_n$$

4. **Espacio de estado:** Como los tres libros tienen las mismas posibles posiciones, estableceremos

$$S_X = S_Y = S_Z = \{0, 1, 2\}$$

Y claramente tenemos que considerar el espacio de estado de W_n

$$S_W = S_X \times S_Y \times S_Z$$

5. **Probabilidades de transición:** En este caso seguiremos la estrategia empleada en el último ejemplo de poner las probabilidades que se nos dan en el enunciado en la matriz y completar los espacios en blanco teniendo en cuenta que la matriz debe

ser estocástica.

$$P_{(i,j,k) \rightarrow (i',j',k')} =$$

	(0, 1, 2)	(0, 2, 1)	(1, 0, 2)	(1, 2, 0)	(2, 1, 0)	(2, 0, 1)
(0, 1, 2)	0,49	0	0,42	0,09	0	0
(0, 2, 1)	0	0,49	0,09	0,42	0	0
(1, 0, 2)	0,42	0	0,49	0	0,09	0
(1, 2, 0)	0	0	0	0,49	0,42	0,09
(2, 1, 0)	0	0	0,09	0	0,49	0,42
(2, 0, 1)	0,09	0	0	0	0,42	0,49

Ejemplo 2.3 (Distribuciones). Una empresa de seguros para automóviles clasifica a sus clientes de acuerdo a 4 niveles de riesgo que determinan el valor de la póliza anual. Dependiendo del número de accidentes que un cliente tenga en un año, su nivel de riesgo cambia de acuerdo a la Tabla 2.1. Por ejemplo, si el nivel de riesgo actual de un cliente es 1 y tiene 0 accidentes en el año, su nivel de riesgo sigue en 1, si tiene 1 accidente cambia a 2, si tiene 2 accidentes a 3 y si tiene 3 accidentes o más cambia a 4. Estudios de la compañía han permitido determinar que los accidentes de un cliente siguen una distribución Poisson con tasa λ accidentes/año.

Riesgo actual	0 accidentes	1 accidente	2 accidentes	3 o más accidentes
1	1	2	3	4
2	2	3	4	4
3	3	4	4	4
4	4	4	4	4

Cuadro 2.1: Cambio en los niveles de riesgo de acuerdo al número de accidentes en un año.

Defina y desarrolle un modelo que represente el comportamiento de un cliente de la aseguradora. Recuerde que si $X(t) \sim \text{Poisson}(\lambda)$,

$$P(X(t) = k) = \frac{(\lambda t)^k e^{-\lambda t}}{k!}, \quad k \geq 0.$$

Solución: Procederemos de forma metódica al igual que el anterior ejemplo.

1. **Identificación de contexto (opcional):** Notemos que a pesar de que se nos dan tasas con las unidades correctas y ya listas para usar (ver **Tip útil**), el enunciado no nos da explícitas las probabilidades de transición entre estados como si ocurrió anteriormente. Por el contrario, nos dicen que estas se modelan de acuerdo a una distribución de probabilidad de tipo Poisson. Normalmente en este tipo de ejercicios, no podemos proceder con el modelamiento del sistema usando únicamente variables del tipo X_n como lo hicimos anteriormente. Así pues, tendremos que usar un nuevo tipo de variables “auxiliares” que definen esta distribución de probabilidad.
2. **Temporalidad:** No debemos caer en el error de pensar que solamente porque nos dan una tasa λ ya se trata de un problema continuo. Acá la clave está en entender que el sistema sufre cambios al inicio de cada año, pues es cuando los usuarios pasan de una categoría a otra. Por ende, este sistema será modelado como una CMTD.

3. **Variable de estado:** Lo primero que se nos viene a la cabeza es definir algo por el estilo de “Sea Y_n : El nivel de riesgo del cliente en el n -ésimo año”. Si hacemos esto no estamos teniendo en cuenta ni el número de accidentes, ni la distribución que se nos da en el enunciado.

Por ende, pensaremos el problema así: Modelaremos los accidentes por medio de una variable auxiliar $\mathcal{T}_n$ que describe una distribución Poisson. Usaremos esta información para definir las probabilidades de transición. Luego, conectaremos estas probabilidades de transición con los niveles de riesgo de los clientes por medio de una variable X_n como la que usamos en el anterior ejemplo. Definimos entonces

$\mathcal{T}_n$: Número de accidentes que tiene el usuario en el n -ésimo año.

$$\mathcal{T}_n \sim PP(\lambda) \quad \text{tal que} \quad \mathcal{P}(\mathcal{T} = k) = \frac{(\lambda t)^k e^{-\lambda t}}{k!}$$

X_n : Nivel de riesgo de un cliente en el n -ésimo año.

4. **Espacio de estado:** Notemos que mientras que un cliente puede tener un número muy grande de accidentes, los niveles de riesgo son dados de forma explícita en el enunciado:

$$S_{\mathcal{T}} = \{1, 2, 3, \dots, \infty\}$$

$$S_X = \{1, 2, 3, 4\}$$

5. **Probabilidades de transición:** Ahora, simplemente es tomar lo que ya definimos, tener en cuenta lo que dice la tabla del enunciado, y ponerlo en una matriz de transición. En estos casos es mejor no complicarse la vida con dibujos pues dado que estamos definiendo una distribución de probabilidad, podemos cometer errores.

	1	2	3	4
1	$\mathcal{P}(\mathcal{T}_n = 0)$	$\mathcal{P}(\mathcal{T}_n = 1)$	$\mathcal{P}(\mathcal{T}_n = 2)$	$\mathcal{P}(\mathcal{T}_n \geq 3)$
2	$\mathcal{P}(\mathcal{T}_n = 0)$	0	$\mathcal{P}(\mathcal{T}_n = 1)$	$\mathcal{P}(\mathcal{T}_n \geq 2)$
3	0	$\mathcal{P}(\mathcal{T}_n = 0)$	0	$\mathcal{P}(\mathcal{T}_n \geq 1)$
4	0	0	$\mathcal{P}(\mathcal{T}_n = 0)$	$\mathcal{P}(\mathcal{T}_n \geq 1)$

Acumulación de probabilidades: Notemos que en el anterior ejemplo cubrimos todos los posibles valores de accidentes en la matriz de transición: la probabilidad de que una persona tenga 200 accidentes en un año puede ser muy baja, pero es existente y si no la consideramos, la matriz dejará de ser estocástica. Así pues, al trabajar con distribuciones de probabilidad, debemos asegurarnos de que la matriz de transición sea completa y refleje adecuadamente todos los posibles eventos, incluso aquellos con probabilidades extremadamente bajas. Normalmente los enunciados dan pistas sobre cuándo acumular las probabilidades diciendo que un resultado se mantiene “para cierto número de eventos o más”.

En este ejemplo, a partir de cierto número de accidentes dependiendo de la categoría actual, esta pasaba a ser inmediatamente del tipo de riesgo 4 para el siguiente año.

Intuición variables auxiliares: Este tipo de variables serán muy útiles cuando nos dicen que cierta parte del ejercicio sigue una distribución de probabilidad. Estas tendrán asociada una descripción y un espacio de estado al igual que las variables “normales”. No obstante, se deberá definir la distribución de probabilidad que tengan asociada. Esto es

debido a que en realidad, no nos interesan los valores de este tipo de variables en sí. Nos interesa la probabilidad de que la variable auxiliar tome estos valores. Estas dictarán el conjunto de probabilidades de transición que irán dentro de la matriz.

Por ejemplo, en el anterior ejercicio no nos interesaba expresar el número de accidentes de las personas $\mathcal{T}_n$. Nos interesaba saber la probabilidad de que ocurrieran una cierta cantidad de estos. Si nos fijamos en la matriz de transición, veremos que los rótulos de la misma corresponden al espacio de estados de nuestra variable “normal” X_n , no a los de la variable auxiliar $\mathcal{T}_n$. No obstante, las probabilidades de transición están determinadas por la distribución que siguen los accidentes de las personas.

Ejemplo 2.4 (Inventarios con oferta). DACL es una empresa de mensajería y entrega con operaciones en todo el país. DACL está interesada en ampliar su flota de vehículos en los municipios más remotos del país. Para decidir sobre la magnitud de la ampliación, DACL necesita estudiar el comportamiento de uno de sus centros de acopio en el municipio de Simijaca, Cundinamarca.

El centro de acopio presta atención al público todos los días de la semana de 8 a.m. a 6 p.m. En esta franja las personas llegan al centro de acopio a dejar los paquetes que necesitan ser transportados, siempre y cuando el centro de acopio pueda recibirlos, pues en su bodega caben máximo m paquetes. En caso de que en la bodega ya haya m paquetes, la persona deberá volver algún otro día. Después de analizar el comportamiento de los envíos por los últimos años, DACL sabe que las personas llegan al centro de acopio siguiendo un proceso de Poisson con tasa λh^{-1} .

Todas las noches un vehículo de DACL con capacidad para cargar hasta k paquetes ($k < m$) pasa por el centro de acopio y se lleva los paquetes que pueda cargar. Así, si en la bodega hay k o menos paquetes, el vehículo se lleva todos los paquetes que hay, pero si en la bodega hay más de k paquetes, el vehículo se lleva solo k de ellos.


Formule el modelo que le permita a DACL estudiar el centro de acopio al finalizar la jornada.

Solución:

1. **Identificación del contexto (opcional):** Este ejercicio, modela la llegada y salida de paquetes de una agencia. Normalmente, este tipo de ejercicios es conocido como uno de inventario pues modela el comportamiento de este mismo a lo largo del tiempo. Notemos que este tipo de ejercicios es considerado uno de “oferta” pues la variable que sigue una distribución de probabilidad modela la llegada de paquetes.
2. **Temporalidad:** Si nos preguntamos cada cuánto nos interesa registrar los cambios en el sistema, nos daremos cuenta que dado el comportamiento del camión que recoge los libros, es necesario registrar el estado del sistema diariamente. Así pues, como los días son contables, este será un problema de índole discreta.
3. **Variables de estado:** Al igual que en el anterior ejercicio, notemos que se nos da unas probabilidades de transición implícitas en una distribución Poisson. Por ende, procederemos definiendo una variable auxiliar que nos dicte las probabilidades de transición.

Para este tipo de problemas, es útil definir claramente si la variable describe el comportamiento al final o al inicio del n -ésimo periodo. Se sugiere fuertemente que

se defina al final puesto que simplifica la modelación. Viendo el problema como la siguiente línea del tiempo:



Así pues, definimos

X_n : Número de paquetes en la bodega al final del n -ésimo día

$\mathcal{T}_n$: Oferta o número de paquetes que llegan a la agencia a lo largo del n -ésimo día

$$\mathcal{T}_n \sim PP(\lambda) \quad \text{tal que} \quad \mathcal{P}(\mathcal{T} = k) = \frac{(\lambda t)^k e^{-\lambda t}}{k!}$$

4. **Espacio de estado:** A pesar de que la capacidad de paquetes esté acotada, tendremos que seguir considerando la posible oferta de más de m paquetes, solamente que si hay una oferta de más de m paquetes, se acumularán las probabilidades:

$$S_X = \{1, 2, 3, \dots, m\}$$

$$S_{\mathcal{T}} = \{1, 2, 3, \dots, \infty\}$$

5. **Probabilidades de transición:** Para esta última parte, es práctico plantear varias relaciones entre elementos del problema, pues facilitarán la formulación general más adelante. Recordemos que estamos modelando las probabilidades de transición a un paso $i \rightarrow j$

a) Relaciones de inventarios entre días.

- 1) La cantidad de paquetes al día siguiente si hay más de k paquetes actualmente:

$$j = i - k + \mathcal{T} \implies \mathcal{T} = j + k - i, \quad i < k$$

- 2) La cantidad de paquetes al día siguiente si hay menos de k paquetes actualmente:

$$j = i - i + \mathcal{T} \implies \mathcal{T} = j, \quad i \geq k$$

b) Acumulación de probabilidades.

- 1) La oferta de paquetes no sobrepasa la capacidad de almacenamiento máxima:

$$\mathcal{P}(\mathcal{T} = \alpha), \quad j < m$$

- 2) La oferta de paquetes no sobrepasa la capacidad de almacenamiento máxima. Notemos que en este caso tendremos que acumular las probabilidades:

$$\mathcal{P}(\mathcal{T} \geq \alpha), \quad j = m$$

Como no tenemos claridad del valor de m , es mejor proceder con una formulación general combinando cada posibilidad del apartado a) con cada posibilidad del apartado b) pues normalmente así salen todos los posibles casos de ejercicios tipo inventario:

$$\mathbb{P}_{i \rightarrow j} = \begin{cases} \mathcal{P}(\mathcal{T} = j + k - i) & \text{si } i > k, j < m, \\ \mathcal{P}(\mathcal{T} = j) & \text{si } i \leq k, j < m, \\ \mathcal{P}(\mathcal{T} \geq j + k - i) & \text{si } i > k, j = m, \\ \mathcal{P}(\mathcal{T} \geq j) & \text{si } i \leq k, j = m, \\ 0 & \text{d.l.c.} \end{cases}$$

Ejemplo 2.5 (Inventarios demanda). **MarketMaster** es una empresa emergente que se dedica a la comercialización de todo tipo de productos a través de internet. El área de logística ha notado que el manejo de inventarios representa una gran parte de los costos operativos de la compañía, por lo que está interesada en saber cómo se comportan los productos que manejan. Especialmente, ha notado que los libros son los productos que acarrearán el mayor costo.

Se ha estimado que el número de personas que ingresan a la página para comprar libros sigue una distribución de Poisson con tasa $\lambda \text{semanas}^{-1}$, y cada cliente solo compra un libro. Cuando las unidades en inventario no son suficientes para satisfacer la demanda de la semana, MarketMaster puede comprometerse hasta con a clientes para entregarles su libro al inicio de la semana siguiente.

La política actual de manejo de inventario de MarketMaster dicta que al final de la semana se revisa cuántas unidades de libros hay en el almacén, y si el número es menor a m , se hace un pedido al proveedor del número de unidades necesarias para hacer las entregas pendientes de la semana y completar k unidades en inventario. Cada unidad que se pide (incluidas las que se piden para satisfacer los faltantes) están disponibles al inicio de la siguiente semana.

Modele el funcionamiento del inventario de MarketMaster como una cadena de Markov. Enuncie todos los supuestos necesarios para su elaboración y defina claramente todos los componentes de este.

Solución:

1. **Identificación de contexto (opcional):** Notemos que a diferencia del anterior ejemplo, esta vez no llegan elementos a nuestro inventario de acuerdo a una distribución, sino que se van. Por esta razón, decidimos categorizar este tipo de problemas como uno de inventario con demanda, pues ahora nuestra variable auxiliar modelará el egreso de inventario.
2. **Temporalidad:** Por medio de un análisis análogo al del anterior problema, podemos notar que debemos modelar una CMTD.
3. **Variable de estado:** Como ya describimos, a pesar de seguir necesitando una variable auxiliar, esta será empleada de forma contraria a como se empleó en el ejemplo anterior. La variable “normal” seguirá la misma lógica para que el problema tenga sentido:

X_n : Número de libros en el almacén al final de la n -ésima semana


$\mathcal{D}_n$: Demanda semanal de libros. $\mathcal{D}_n \sim PP(\lambda)$ tal que $\mathcal{P}(\mathcal{D} = k) = \frac{(\lambda t)^k e^{-\lambda t}}{k!}$

4. **Espacio de estado:** En este caso, debemos tener en cuenta la posible “deuda” en la que la compañía incurre si se compromete a vender más libros de los que tiene. En este caso, expondremos este cambio en la variable de estado X_n , teniendo en cuenta que máximo habrán k unidades en el inventario pues es a lo que completaremos con el pedido si hay menos de m libros. La definición de espacios de estado quedaría tal que:

$$S_X = \{-a, -a + 1, -a + 2, \dots, 0, 1, 2, \dots, m, m + 1, \dots, k\}$$

$$S_{\mathcal{D}} = \{0, 1, 2, \dots, \infty\}$$

5. **Probabilidades de transición:** Para saber los posibles estados de transición, podemos representar esta situación con un dibujito para lograr mayor claridad antes de construir la formulación matemática:



Ahora que tenemos más claridad acerca del problema, vamos a volver a establecer ciertas relaciones entre el estado actual i y el inmediatamente futuro j :

a) Relaciones de inventarios entre días

- 1) $j = i - \mathcal{D} \implies \mathcal{D} = i - j, \quad i > m$
- 2) $j = k - \mathcal{D} \implies \mathcal{D} = k - j, \quad i \leq m$

b) Acumulaciones de probabilidad

- 1) $\mathcal{P}(\mathcal{D} = \alpha), \quad j > -a$
- 2) $\mathcal{P}(\mathcal{D} \geq \alpha), \quad j = -a$

Finalmente, al igual que en el anterior ejercicio, dado que ya pusimos las relaciones necesarias para expresar condiciones sobre el estado actual y el futuro, procederemos a simplemente combinar las restricciones de relaciones con las de acumulaciones de probabilidad. Esto dará como resultado

$$\mathbb{P}_{i \rightarrow j} = \begin{cases} \mathcal{P}(\mathcal{D} = i - j), & i > m, j > -a, \\ \mathcal{P}(\mathcal{D} = k - j), & i \leq m, j > -a, \\ \mathcal{P}(\mathcal{D} \geq i - j), & i > m, j = -a, \\ \mathcal{P}(\mathcal{D} \geq k - j), & i \leq m, j = -a, \\ 0, & \text{d.l.c.} \end{cases}$$

Ejemplo 2.6 (Distribución Binomial). Actualmente se encuentra en etapa de diseño el tren de cercanías que conectará a varias ciudades al norte de Bogotá. Para evaluar diseños alternativos se le ha pedido crear algunos modelos que puedan dar luces sobre

el desempeño operativo del tren. En particular, se busca tener un modelo que capture la dinámica de ingreso y salida de pasajeros con requerimientos especiales a los trenes en cada estación. Para esto se cuenta con información que permite estimar que en cada estación un pasajero con requerimientos especiales se baja con probabilidad b . Es decir, si el tren llega a la estación con K pasajeros de este tipo, se bajan en esa estación h pasajeros con probabilidad:

$$p_{K,h} = \binom{K}{h} b^h (1-b)^{K-h}.$$

Además, en cada estación se sube 1 pasajero con requerimientos especiales con probabilidad q , y con la probabilidad restante no se sube ninguno. Como se busca estimar la capacidad del tren para este tipo de pasajeros, no se consideran restricciones de capacidad.

Formule una cadena de Markov que le permita describir la evolución del número de pasajeros con requerimientos especiales en el tren tras visitar cada estación. Defina explícitamente todos los componentes de su modelo.

Solución:

1. **Identificación de contexto (opcional):** Este es, a mi parecer, el tipo de ejercicios más difíciles en modelación discreta dado que normalmente no dicen de forma explícita que se necesita una variable auxiliar binomial para la modelación. Ejemplos como el nacimiento/muerte de ganado, llegada y partida de personas en paradas de buses, y elementos que se pueden averiar cada determinado periodo de tiempo fijo sugieren el uso de variables auxiliares binomiales.
2. **Temporalidad:** A pesar de que se puede llegar a pensar que los pasajeros se pueden montar en cualquier momento y proceder a modelar este problema como uno continuo, debemos identificar que en realidad la subida y bajada de pasajeros está regulada por las estaciones a las que llega el bus las cuales son contables, por ende discretas. Así pues, este problema debe modelarse como una CMTD.

3. Variables de estado:

X_n : Número de pasajeros en el tren en la n -ésima estación.

$\mathcal{T}_n$: Pasajeros que se bajan del tren en la n -ésima estación.

$$\mathcal{T}_n \sim \text{Binom}(b), \text{ tal que } \mathcal{P}_{K,h} = \binom{K}{h} b^h (1-b)^{K-h}.$$

4. Espacio de estado:

$$S_X = \{1, 2, \dots, \infty\}$$

$$S_{\mathcal{T}} = \{1, 2, \dots, \infty\}$$

5. **Probabilidades de transición:** Notemos que no se nos dan indicios del tamaño de la matriz que debemos expresar. Así pues, necesitamos proceder por medio de una formulación general. Formular con distribuciones puede ser confuso al principio, no obstante, se recomienda hacer uso del método de imaginarse la matriz y sus bordes

explicado en los apéndices para facilitar este proceso. Así pues, llegaremos a una formulación tal que

$$\mathbb{P}_{i \rightarrow i'} = \begin{cases} \mathcal{P}_{i,0}(1-q) + \mathcal{P}_{i,1}q, & \text{si } i = i', \\ \mathcal{P}_{i,0}q, & \text{si } i = i' - 1, \\ \mathcal{P}_{i,u}(1-q) + \mathcal{P}_{i,u+1}q, & \text{si } i = i' + u, \\ 0, & \text{d.l.c.} \end{cases}$$

2.3. Cadenas de Markov en Tiempo Continuo

2.3.1. Fundamentos CMTC

Definición 2.8 (Cadena de Markov en Tiempo Continuo (CTMC)). Sea $\{X(t), t \geq 0\}$ un proceso estocástico. Decimos que esta es una cadena de Markov en tiempo continuo si tiene un espacio de estados S que toma valores en los números enteros no negativos y cumple con la propiedad de no memoria: para todo $s, t \geq 0$ y para cualquier $i, j \in S$, la probabilidad condicional de transición está dada por:

$$\mathcal{P}(X(t+s) = j \mid X(s) = i, X(u) = x(u), 0 \leq u < s) = \mathcal{P}(X(t+s) = j \mid X(s) = i).$$

En otras palabras, una CMTC es un modelo en el que el sistema evoluciona continuamente en el tiempo y el estado futuro depende únicamente del estado actual, sin importar cómo se llegó a ese estado (propiedad de no memoria). Esto significa que el presente encapsula toda la información relevante del pasado.

Definición 2.9 (Probabilidad de transición CMTC). Sea $\{X(t), t \geq 0\}$ una CMTC, la probabilidad de transición es la probabilidad de que el sistema pase del estado i al estado j después de un tiempo t , y se denota como:

$$p_{ij}(t) = \mathcal{P}(X(t) = j \mid X(0) = i).$$

Definición 2.10 (CMTC homogénea). Una CTMC es homogénea en el tiempo si la probabilidad de transición depende únicamente del tiempo transcurrido t , y no del tiempo absoluto s . Formalmente:

$$\mathcal{P}(X(t+s) = j \mid X(s) = i) = \mathcal{P}(X(t) = j \mid X(0) = i).$$

Definición 2.11 (Matriz generadora). La matriz generadora de una CMTC contiene las tasas de transición instantáneas entre todos los estados i y j . Se denota por $\mathbb{Q}_{i \rightarrow j}$, donde:

$$\mathbb{Q}_{i \rightarrow j} = \begin{pmatrix} q_{11} & q_{12} & \cdots & q_{1m} \\ q_{21} & q_{22} & \cdots & q_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ q_{m1} & q_{m2} & \cdots & q_{mm} \end{pmatrix}.$$

Las entradas q_{ij} de la matriz generadora $\mathbb{Q}$ están definidas como:

$$q_{ij} = \begin{cases} \lambda_{ij}, & \text{si } i \neq j, \\ -\sum_{k \neq i} \lambda_{ik}, & \text{si } i = j, \end{cases}$$

En otras palabras y de forma menos formal:

- λ_{ij} representa la tasa de transición del estado i al estado j .
- q_{ii} (elementos diagonales) corresponde a la tasa total de salida del estado i .

Propiedad: Las matrices generadoras son cuadradas pero no estocásticas. En este caso, la suma de cada fila debe dar 0.

Supuestos CMTC

Análogamente a lo que ocurrió con el caso discreto, al modelar CMTC SIEMPRE se debe incluir el supuesto de no memoria y el de homogeneidad en el tiempo. En caso de que nos digan que los tiempos se distribuyen de forma exponencial o según un proceso de Poisson, también tendremos que establecerlo.

Volveremos a omitir la reiteración de estos supuestos en la solución de los siguientes ejercicios para darle más enfoque a la lógica detrás de las soluciones.

2.3.2. Ejemplos CMTC

Ejemplo 2.7 (Introductorio). Una pequeña empresa que ofrece sus servicios de mensajería urbana cuenta con una línea conmutada para atender las llamadas de sus clientes. En el horario de máximo flujo de llamadas (12m a 2 pm) los clientes llaman de acuerdo con un proceso de Poisson con una tasa de dos llamadas por minuto. Las llamadas tienen un tiempo de duración exponencial con media de 1 minuto, y son atendidas por alguna de las 2 encargadas del establecimiento.

La línea conmutada tiene capacidad de recibir como máximo 4 llamadas, así que si la llamada entra al conmutador y las dos operadoras están ocupadas, el cliente escucha un “ameno y entretenido” mensaje pregrabado en el cual se solicita que se mantenga en la línea para ser atendido. Suponga que los clientes son impacientes, y que cada uno de ellos está dispuesto a esperar mientras oye este mensaje durante un tiempo exponencial con media de 1 minuto.

Emplee una CMTC para modelar el estado del sistema de espera para la empresa de mensajería. Defina claramente la variable y sus posibles estados. Muestre el grafo asociado.

Solución:

1. **Identificación de contexto (opcional):** Identificamos este problema como uno en donde tenemos tasas de llegadas y salidas del sistema. Enfatizemos en el hecho que al no necesitar convertir las tasas que nos dan en probabilidades, no debemos hacer uso de variables auxiliares.
2. **Temporalidad:** Notemos que el sistema está habilitado en todo momento para recibir llamadas. Como estas pueden llegar en cualquier momento y no se restringen a un conjunto contable, establecemos que el sistema debe modelarse como una CMTC.
3. **Variable de estado:**

$X(t)$: Número de clientes en llamada en el sistema en el t -ésimo instante.

4. Espacio de estado:

$$S_X = \{0, 1, 2, 3, 4\}$$

5. Probabilidades de transición:

Como no nos dan las tasas rotuladas en el enunciado, las definiremos tal que:


θ : Tasa de llamadas que llegan al sistema; $\theta = 1/2$ [llamada * min⁻¹]

μ : Tasa de duración de llamadas; $\mu = 1$ [llamada * min⁻¹]

ϕ : Tasa de espera de los clientes; $\phi = 1$ [cliente * min⁻¹]

Se recomienda leer el **Tip útil** en caso de no entender por qué se definen las tasas de esta forma.

Ahora, con las tasas bien definidas, procederemos a hacer el grafo que se nos pide. Para esto tendremos en cuenta el **Teorema 1.2** pues hay probabilidades de transición que necesitan esta teoría. Por ejemplo, si hay 2 personas en llamada ambos con una tasa de duración μ , la tasa a la que decrecerá el número de personas en llamada estará dado por una “competencia” o mínimo entre las dos tasas, o sea 2μ . El grafo completo quedaría tal que



Ejemplo 2.8 (Tasas “mal” dadas). Sherlock Holmes decide abrir un nuevo despacho en el que ayuda a los habitantes de Meiringen a resolver sus pequeños misterios. Las llegadas de habitantes al despacho siguen un $PP(\lambda)$ y el tiempo promedio que Sherlock demora atendiendo cada caso es de $1/\mu$ el cual sigue una distribución exponencial. Tenga en cuenta que la capacidad del despacho es de 3 habitantes (dos en sala de espera y uno en servicio). Sin embargo, hay veces en que los habitantes se cansan de esperar y deciden irse, cada persona se irá con un tiempo exponencial de media σ minutos. Suponga que cuando una persona llega al despacho y ve que está lleno no puede entrar al despacho.

Desarrolle un modelo de cadena de Markov sobre la anterior situación. Defina la variable de estado, el espacio de estados, el grafo y la matriz generadora.

Solución:

1. **Identificación de contexto (opcional):** Lo interesante de este ejercicio son las formas en las que nos dan las tasas. Debemos ser muy cuidadosos al usarlas en nuestra modelación y fijarnos en las unidades (ver **Tip útil**).
2. **Temporalidad:** Identificamos que las puertas de la oficina están abiertas en todo momento. O sea que el sistema puede sufrir cambios en cualquier instante, por ende modelaremos este sistema como una CMT.

3. Variable de estado:


$X(t)$: Número de clientes en la oficina en el t -ésimo instante

4. **Espacio de Estado:** Recordemos que a pesar de que la temporalidad sea no contable o continua, el espacio de estados siempre será discreto.

$$S_X = \{0, 1, 2, 3\}$$

5. Probabilidades de transición:

Grafo:



Matriz generadora:

$$Q_{i \rightarrow j} = \begin{array}{c|cccc} & 0 & 1 & 2 & 3 \\ \hline 0 & -\lambda & \lambda & 0 & 0 \\ 1 & \mu & -(\mu + \lambda) & \lambda & 0 \\ 2 & 0 & \mu + \sigma^{-1} & -(\lambda + \mu + \sigma^{-1}) & \lambda \\ 3 & 0 & 0 & \mu + 2\sigma^{-1} & -(\mu + 2\sigma^{-1}) \end{array}$$

Ejemplo 2.9 (Varias variables de estado). Dog Garden es una guardería canina ubicada en la calle 98 con carrera 8 en la ciudad de Bogotá. Dada la cantidad de perritos dentro de la guardería, el encargado de *Dog Garden* tiene como objetivo estudiar la ocupación de la guardería para aquellos perritos menores a los 15kg (tamaño pequeño) y para aquellos de más de 15kg (tamaño grande).

De acuerdo con observaciones de las últimas semanas, se ha estimado que los perros pequeños llegan a la guardería siguiendo un proceso de Poisson con tasa de μ horas⁻¹, mientras que los perros grandes llegan a la guardería en promedio cada $1/\lambda$ horas siguiendo una distribución exponencial. Sin embargo, se ha observado en ocasiones que el número de perros pequeños es mucho mayor con respecto al número de perros grandes. Por esta razón, en un intento por balancear el número de perros en la guardería, el encargado de *Dog Garden* ha establecido que la tarifa de estadía para los perros grandes se reduce en un 80% siempre que haya más perros pequeños que grandes.

Esta reducción en tarifa de la guardería causa que la llegada de perros grandes a la misma siga un proceso de Poisson α veces mayor al de los perros pequeños. Cuando el número de perros pequeños dentro de la guardería es menor o igual al de los perros grandes, tanto la tarifa como el proceso de llegada para los perros grandes vuelven a sus valores originales. En promedio, se ha estimado que el tiempo que dura un perro pequeño en la guardería es de β minutos, mientras que el tiempo que dura un perro grande en la guardería es de γ días.

Solución:**1. Variable de estado:**

$X(t)$: Cantidad de perros pequeños en el t -ésimo instante

$Y(t)$: Cantidad de perros grandes en el t -ésimo instante

$$Z(t) = X(t) \times Y(t)$$

2. Espacio de estado:

$$S_X = S_Y = \{1, 2, \dots, N\}$$

$$S_Z = (i, j) \in S_X \times S_Y \quad \text{tal que } i + j \leq N$$

3. Formulación general:

$$\mathbb{Q}_{(i,j) \rightarrow (i',j')} = \begin{cases} \mu, & i = i' - 1, \quad i < N, \quad j = j', \quad i' \leq j' \\ \lambda^{-1}, & i = i', \quad j = j' - 1, \quad i \leq j, \quad j < N \\ \mu + \alpha, & i = i' - 1, \quad j = j', \quad i > j, \quad j < N \\ i\beta, & i = i' + 1, \quad j = j', \quad i \geq 1, \quad \forall j \in S_Y \\ j\gamma, & i = i', \quad j = j' + 1, \quad j \geq 1, \quad \forall i \in S_X \\ 0, & \text{d.l.c} \end{cases}$$

Ejemplo 2.10 (Mínimos). Como parte del plan de reactivación económica, y con el propósito de brindar diversión y entretenimiento sanos, *Cine Colombia* volvió recargado de energía para atender a todos los amantes del cine. Con el fin de cumplir con los protocolos de bioseguridad y el aforo permitido, Munir Falah, presidente de la compañía, está interesado en conocer la ocupación de la taquilla y de la zona de confitería de uno de los principales cinemas de la ciudad.

Se ha estimado que la llegada de personas al cinema sigue un proceso de Poisson (λ personas/hora), y con una probabilidad de p el usuario compra las boletas a través del portal web, por lo cual podrá dirigirse directamente a la zona de confitería. De lo contrario, se dirigirá a la taquilla donde uno de los K funcionarios que trabaja en esta zona lo atenderá. En promedio, un usuario tarda $1/\mu$ horas en elegir qué película desea ver y pagar. Adicionalmente, se ha estimado que con una probabilidad de r el usuario no encontrará boletas disponibles, por lo cual deberá volver otro día; de lo contrario, se dirigirá a la confitería.

En la zona de confitería hay M cajas disponibles donde los usuarios podrán adquirir los alimentos y en promedio un usuario tarda $1/\gamma$ horas comprando lo que va a consumir. La alcaldía de la ciudad ha decretado que, de acuerdo a las normas de bioseguridad, máximo pueden haber N personas en el cinema.

Formule un modelo que le permita a Munir Falah estudiar la ocupación de la taquilla y la confitería a lo largo del tiempo. Defina claramente todos los componentes de su modelo, y los supuestos necesarios.

Solución:

1. **Identificación de contexto (opcional):** Hay una forma alternativa para modelar situaciones donde la atención a los clientes es limitada por el número de operarios disponibles y es usando las operaciones mín o máx. Este sera uno de esos ejemplos donde combinaremos el **Teorema 1.2** con el operador mín para expresar la tasa en la cual se desocupa un counter de cine.
2. **Temporalidad:** Dado que las puertas del cine están siempre abiertas, el cliente puede entrar en cualquier instante. Al tener un sistema en un conjunto de tiempo continuo o no contable, modelaremos el comportamiento como una CMTC.

3. **Variable de estado:**

$X(t)$: Cantidad de personas en confitería en el t -ésimo instante

$Y(t)$: Cantidad de personas en taquilla en el t -ésimo instante

$$Z(t) = X(t) \times Y(t)$$

4. **Espacio de estado:**

$$S_X = S_Y = \{0, 1, \dots, N\}$$

$$S_Z = S_X \times S_Y$$

5. **Probabilidades de transición:**

$$Q_{(i,j) \rightarrow (i',j')} = \begin{cases} \lambda(1-p), & i' = i+1, \quad j' = j+1, \quad i < N, \quad j < N \\ \lambda p, & i' = i, \quad j' = j+1, \quad \forall i \in S_X, \quad j < N \\ r\mu \min(i, K), & i' = i-1, \quad j' = j, \quad i > 0, \quad \forall j \in S_Y \\ (1-r)\mu \min(j, K), & i' = i, \quad j' = j+1, \quad \forall i \in S_X, \quad j < N \\ \gamma \min(j, M), & i' = i, \quad j' = j-1, \quad j > 0, \quad \forall i \in S_X \\ 0, & \text{d.l.c.} \end{cases}$$

Apéndice A

Formulaciones Matemáticas

Este capítulo está dedicado a hablar acerca de la notación de todas las posibles formas de expresar las probabilidades de transición en Cadenas de Markov.

A.1. Grafos

Los grafos son la primera representación de un sistema que se verá en el curso. Estos sirven tanto para procesos continuos como discretos. Como se dice en el primer ejemplo expuesto en las notas, esta forma de representar el problema es muy práctica cuando sabemos el número de estados y cuando las probabilidades de transición son explícitas. No obstante, es la manera menos formal de representar el problema, haciéndola muy poco eficaz a la hora de programar el problema en un entorno como R o Python. Es por esto que será empleada solamente a modo introductorio mientras nos acostumbramos a modelar de formalmente.

Componentes:

1. **Nodos (Vértices):** Representan los elementos individuales del grafo. En nuestro contexto, los posibles estados del sistema. Se suelen dibujar como círculos, cuadrados o puntos.
2. **Aristas (Edges):** Representan las conexiones entre los nodos. Se suelen dibujar como flechas puesto que todos los grafos que serán dibujados son dirigidos.
3. **Pesos (Costos):** Se usan para identificar las probabilidades de transición de un estado a otro en CMTD o las tasas de transición en las matrices generadoras dada una CMTC.


Propiedades:

1. **Normalización en CMTD:** La suma de probabilidades de las flechas que salen de cada Vértice en un grafo asociado a una CMTD debe dar 1.
2. **Bucles (CMTD):** Si una flecha sale de un estado i y vuelve a introducirse a este mismo estado, significa que con la correspondiente probabilidad, el sistema seguirá


en el i -ésimo estado en el siguiente momento en el que se observe el sistema. En CMTC NO hay bucles bajo ninguna circunstancia.

3. **Inexistencia de flechas:** Si un estado i no está conectado mediante una flecha directamente al estado j , la probabilidad de transición en un paso será de 0 entre estos estados.
4. **Llegadas al sistema en CMTC (Tip):** Generalmente, los ejercicios de CMTC que exigen el uso de un grafo para su solución poseen un número de llegadas a un sistema que siempre están definidas por una misma tasa. Esto a pesar de no ser una ley que siempre se cumple, es útil para identificar una parte del grafo al principio.

Ejemplo A.1 (Grafo CMTD).



Ejemplo A.2 (Grafo CMTC).



A.2. Matrices

La siguiente posible forma de expresar las probabilidades de transición en caso de una matriz de probabilidades o las tasas de transición de las matrices generadores. Como lo dice el nombre, son matrices. Dependiendo de la temporalidad del sistema esta será denotada por $\mathbb{P}$ o por $\mathbb{Q}$ (como se explica en la caracterización de las Cadenas de Markov). Esta notación es bastante simple y lo único que se tiene que considerar son los rótulos de la matriz: esos nombrecitos que aparecerán antes de cada fila o columna referente al estado del sistema actual y próximo respectivamente: la mnemotecnía de esta notación es bastante sencilla: la fila indica el estado actual y la columna el posible próximo estado.

A.3. Formulaciones generales:

Esta es probablemente la forma más complicada de expresar las probabilidades de transición. Así pues, en esencia es lo mismo que aprendimos en Opti: una función a trozos con un “0, d.l.c” al final. No obstante, muchas personas tienen problemas en adaptar la lógica del problema a este tipo de expresiones.

Una buena forma de atacar el problema es hacerse la pregunta “¿Qué puede pasar?” repetidamente antes empezar el ejercicio, e ir registrando los posibles eventos. Esta forma es bastante intuitiva y para mucha gente esto es suficiente para tener la formulación perfecta (si este es su caso, sálgase de este apéndice que daré tips para gente que no le fluye tanto). No obstante, corremos el riesgo de olvidarnos de casos importantes, lo que puede restar puntos en las actividades.

Es por esto que complementaremos este primer enfoque mediante la imaginación de una matriz: supongamos que nuestro espacio de estados tiene dimensión M . A pesar de no saber qué número es este (puesto que a veces el enunciado no lo especifica), la idea es fijar una dimensión y empezar a ver qué pasaría con las probabilidades en los bordes y en las esquinas de la matriz. ¿Hay algún borde que sea siempre 0? ¿En alguna esquina toca acumular probabilidades? ¿Alguna línea de formulación deja de servir en algún borde? Preguntarnos esto desarrolla cierta intuición para conocer el comportamiento de sistema en ocasiones “límite” donde a veces se nos olvidan detalles.

Finalmente, podemos ver los índices de nuestro primer intento de formulación y preguntarnos ¿Acaso quedan índices flotando? ¿Es consistente que i esté entre ciertos valores y que j esté entre otros? ¿Es consistente que en algunos casos i sea mayor que j ? ¿En cuáles? Y con base a estas preguntas ir corrigiendo y perfeccionando la formulación.

A pesar de que este proceso puede parecer tortuoso y complicado, es más que todo para desarrollar la intuición. Con el paso de los ejemplos (bastantes ejemplos) se podrá llegar

a agilizar el proceso. Este aprendizaje claramente dependerá de la solución de bastantes ejemplos como ya se sugirió.

Tips: Supongamos una matriz de transición $\mathbb{P}_{(i,j) \rightarrow (i',j')}$

1. Si queda un índice con igualdad con su estado futuro, podemos precisar los valores que estos toman tal que:

$$i = i' \implies i = i', \forall i \in S_X$$

Y no dejamos volando el rango de valores de i . Normalmente, esta relación se da por obvia, suponiendo que si se deja en igualdad esta expresión y si se deja “flotando” el índice i , entonces será válido para cualquiera de sus valores. No obstante, el preguntarse si esto es real cada vez que se tiene, puede llevar a darse cuenta de errores.

2. El incremento en un valor k de una variable normalmente sugiere el rango en el que esta debe estar:

$$i' = i + k \implies i < N - k$$

donde N es el valor máximo que alcanza i .

3. Lo mismo pasa con el caso contrario:

$$i' = i - k \implies i > n + k$$

donde n es el valor mínimo que alcanza i .

4. Evitemos contradicciones entre índices. No tiene sentido decir lo siguiente:

$$i' = i + 1, \quad \underline{i < 3}, \quad \underline{i > j}, \quad j' = j - 1, \quad \underline{j > 5}$$

A pesar de tener bien especificados los posibles valores de los índices, es totalmente contradictorio decir que las propiedades subrayadas se pueden cumplir.

Para terminar, resumiré en una frase lo que le diría a alguien que apenas va a empezar a hacer formulaciones generales:

Pregúntese qué puede pasar antes de empezar a formular, luego imagínese la matriz con un tamaño pequeño para ver qué pasa en los bordes y casos exóticos, no deje índices volando y revise que la definición de los índices no se contradiga.

Apéndice B

CMTC y CMTD desde la cardinalidad

Este capítulo estará destinado a explicar un poco la intuición detrás de la identificación de casos discretos o continuos de Cadenas de Markov. Este tendrá una considerable carga de rigurosidad matemática pues es un tema que iind nunca explicó.

A lo largo de los años a los matemáticos les ha interesado saber qué tamaño tienen ciertos conjuntos. Sabemos que el conjunto $A = \{1, 2, 3, 4\}$ tiene 4 elementos, y el conjunto vacío $\emptyset$ no tiene ninguno. No obstante esta incógnita se hace más tortuosa cada vez que ampliamos nuestra búsqueda, ¿cuál es el tamaño del conjunto de los números naturales $\mathbb{N}$? ¿Y el del intervalo real $[0, 1]$? Sabemos que ambos son infinitos. ¿Cuál de los dos es más grande y por qué? ¿Qué tiene que ver todo esto con la identificación de la temporalidad de las Cadenas de Markov?

B.1. Introducción a la cardinalidad de conjuntos

Definición B.1 (Cardinalidad de un conjunto). La cardinalidad de un conjunto es una medida del “tamaño” o la cantidad de elementos en el conjunto, que puede ser finito o infinito.

Definición B.2 (Equipotencia entre conjuntos.). Dos conjuntos A y B son *equipotentes* si existe una *bijección* entre ellos, es decir, tienen el mismo número de elementos. Esto se aplica tanto a conjuntos finitos como infinitos.

Definición B.3 (Conjunto numerable o equipotente con los números naturales). Un conjunto A es *numerable o contable* (o tiene cardinalidad equipotente con los números naturales) si existe una *bijección* (una correspondencia uno a uno) entre A y el conjunto de los números naturales $\mathbb{N}$. Esto implica que los elementos de A pueden ser listados como una secuencia infinita:

$$A = \{a_1, a_2, a_3, \dots\}.$$

Ejemplos:

- $\mathbb{N} = \{1, 2, 3, \dots\},$

- $\mathbb{Z} = \{\dots, -2, -1, 0, 1, 2, \dots\}$ (enteros),
- El conjunto $\mathbb{Q}$ (números racionales) también es numerable.

Definición B.4 (Cardinalidad del continuo o equipotente con los números reales). Un conjunto B tiene la *cardinalidad del continuo* (o es equipotente con los números reales $\mathbb{R}$) si existe una *bijección* entre B y $\mathbb{R}$, o con cualquier intervalo infinito de los reales, como $[0, 1]$.

Se denota por $\mathfrak{c}$ (la cardinalidad del continuo).

Ejemplos:

- $[0, 1]$, el intervalo real cerrado,
- $\mathbb{R}$, el conjunto de todos los números reales,
- $(0, 1)$, el intervalo abierto.

Teorema B.1. La cantidad de números reales en el intervalo $(0, 1)$ es mayor que la cantidad de números naturales.

Demostración. Basada en el argumento diagonal de Cantor.

Procedamos por contradicción. Supongamos que podemos hacer una lista con todos los números reales del intervalo $(0, 1)$. Es decir, que existe una manera de emparejar cada número real con un número natural, de tal forma que no quede ningún número sin listar.

Para visualizar esta lista, imaginemos que cada número real está escrito en forma decimal, como una secuencia de dígitos:

$$s_1 = 0.d_{11}d_{12}d_{13}\dots,$$

$$s_2 = 0.d_{21}d_{22}d_{23}\dots,$$

$$s_3 = 0.d_{31}d_{32}d_{33}\dots,$$

y así sucesivamente. Aquí, s_1 es el primer número de la lista, s_2 es el segundo, y así con los demás.

Ahora construiremos un nuevo número c que no está en esta lista. Este número lo definimos eligiendo sus dígitos de manera que sea diferente de cada número de la lista en al menos una posición de la siguiente forma:

El primer dígito de c , c_1 , será distinto del primer dígito de s_1 . El segundo dígito de c , c_2 , será distinto del segundo dígito de s_2 . El tercer dígito de c , c_3 , será distinto del tercer dígito de s_3 . Y así sucesivamente.

Por ejemplo, si el n -ésimo dígito de s_n es 5, elegimos el n -ésimo dígito de c como 6. Si no es 5, elegimos 5. Así garantizamos que c sea diferente de s_n en su n -ésima posición.

De esta forma, el número c no puede estar en la lista porque difiere de cada número s_n en al menos un dígito. Esto contradice nuestra suposición inicial de que era posible listar todos los números reales del intervalo $(0, 1)$.

Por lo tanto, concluimos que no se pueden enumerar todos los números reales en $(0, 1)$. Esto demuestra que hay "más" números reales en $(0, 1)$ que números naturales. $\square$

Corolario Para cualquier intervalo (a, b) , donde $a < b$, este tendrá una mayor cardinalidad que la de los números naturales.

Demostración. Dado un intervalo (a, b) , podemos construir una función biyectiva que mapea los números del intervalo (a, b) al intervalo $(0, 1)$. Una función lineal de este tipo está dada por:

$$f(x) = \frac{x - a}{b - a},$$

donde f transforma $x \in (a, b)$ a un número $f(x) \in (0, 1)$. Esta función es continua, estrictamente creciente, y sobreyectiva, lo que significa que cada número en (a, b) tiene un único correspondiente en $(0, 1)$ y viceversa.

Dado que hemos demostrado que el intervalo $(0, 1)$ tiene una cardinalidad mayor que $\mathbb{N}$, y que existe una correspondencia uno a uno entre los elementos de (a, b) y $(0, 1)$, se concluye que (a, b) también tiene una cardinalidad mayor que $\mathbb{N}$.

Por lo tanto, hay más números reales en (a, b) que números naturales. $\square$

B.2. Relación con las Cadenas de Markov

En una CMTC, los cambios del sistema pueden ocurrir en cualquier instante de tiempo. Esto implica que el conjunto de instantes de tiempo, denotado como T , tiene la cardinalidad del continuo, es decir, es equipotente al conjunto de los números reales $\mathbb{R}$. Matemáticamente, podemos escribir:

$$T = [0, \infty) \quad \text{o algún subconjunto de } \mathbb{R}.$$

Dado que T tiene cardinalidad infinita no numerable ($\mathfrak{c}$), los estados del sistema pueden cambiar en cualquier momento dentro de este intervalo continuo de tiempo. Por esta razón, el sistema se modela como una Cadena de Markov de Tiempo Continuo.

En una CMTD, los cambios del sistema se observan en instantes de tiempo discretos. Si consideramos el caso finito, el conjunto de instantes de tiempo, denotado como N , contiene un número finito de elementos. Matemáticamente, podemos escribir:

$$N = \{n_1, n_2, \dots, n_k\},$$

donde $n_1, n_2, \dots, n_k$ representan los momentos discretos y k es el número total de instantes de tiempo.

Aunque en este caso N no tiene la misma cardinalidad que los números naturales ($\mathbb{N}$), ya que es finito, sigue siendo un conjunto discreto porque sus elementos están claramente separados y no forman un continuo. Es decir, los instantes de tiempo pertenecen a un conjunto donde los elementos son distinguibles y no están densamente distribuidos.

Dado que N es finito y discreto, los estados del sistema solo cambian en estos momentos específicos, y el sistema se modela como una Cadena de Markov de Tiempo Discreto en el caso finito.

Ejemplo B.1. Ejemplo B.1. Supongamos que estamos modelando la llegada y salida de personas a un banco que recibe clientes en todo momento con las puertas abiertas. Acá,

el sistema puede cambiar en cualquier instante: Una persona puede llegar en el segundo 0, otra puede llegar en el segundo 1.5, otra en el segundo 2.399999 y así. En realidad no podemos enumerar todos los instantes en donde pueden entrar o salir clientes, pues este es un intervalo real (a, b) . No es contable. Por ende este sistema será modelado como una CMTC.

Propiedad en CMTC: Además, en una CMTC asumimos que dos eventos (por ejemplo, la salida de dos personas del banco) no pueden ocurrir exactamente al mismo tiempo. Esto se debe a que incluso si los eventos parecen simultáneos, el modelo supone que uno sucede antes que el otro por una fracción infinitesimal de tiempo. Es decir, los tiempos de los eventos son diferentes, aunque la diferencia entre ellos sea extremadamente pequeña. Por esta razón, el sistema es consistente con la naturaleza continua del tiempo, donde los cambios ocurren en puntos únicos dentro del intervalo.

Ejemplo B.2. Tomemos el ejemplo B.1 y cambiemos una sola cosa: el banco cambiará su forma de operar. Este va a permanecer con sus puertas cerradas en casi todo momento, dejando un pequeño espacio para que la gente salga y entre al finalizar cada hora.

Este sistema ahora experimenta cambios cada hora. Sin importar que el horario laboral dure más de 24 horas (supongamos que el banco abre durante 1 semana), el conjunto temporal en donde nos interesa examinar el sistema ahora es contable y finito, pues podemos identificarlo como

$$N = \{0, 1, 2, \dots, 168\}$$

$n \in N$: La n -ésima hora de operación del banco;

Por ende, este sistema será modelado como una CMTD.

Bibliografía

- [1] V. Kulkarni, *Introduction to Modeling and Analysis of Stochastic Systems*, Second Edition, New York: Springer, 2011.
- [2] S. Ross, *Introduction to Probability Models*, Ninth Edition, Academic Press, Elsevier, 2010.
- [3] Libro del curso, disponible en: <https://modelos-inst.github.io/BookLecturas/intro.html>.
- [4] B. Thomson, J. Bruckner, y A. Bruckner, *Elementary Real Analysis*, Prentice Hall, 2007.